

Tema 2: Introducción al Procesamiento del Lenguaje Natural (PLN)



Lingüística Computacional
Ferran Pla

Índice

1. Conceptos básicos
2. Recursos lingüísticos
3. Introducción a los problemas de desambiguación del Lenguaje Natural (LN)
 - Desambiguación morfosintáctica (POS-tagging)
 - Análisis Sintáctico (Parsing): shallow parsing, clause detection, semantic role labeling, PP attachment, ... Full Parsing.
 - Reconocimiento de Entidades Nombradas (Name Entity Recognition)
 - Desambiguación semántica (Word Sense Disambiguation)
4. Métodos de resolución
 - Métodos basados en corpus (aprendizaje automático)

1. Conceptos básicos

Procesamiento de Lenguaje Natural

- El objetivo general de los sistemas de Procesamiento del Lenguaje Natural (PLN) es el tratamiento de la lengua a fin de ser **interpretada** y/o **producida** a la manera en la que lo hacemos los seres humanos (**COMPRENSIÓN**)
- Tarea de gran complejidad.
- Se distinguen distintos aspectos interrelacionados: fonética, léxico, morfología, sintaxis, semántica y pragmática.

Procesamiento de Lenguaje Natural

- La disciplina que hace uso de sistemas de computación para la comprensión y la generación de lenguas naturales es la
Lingüística Computacional
Ingeniería Lingüística
- Algunas aplicaciones del PLN son:
 - Reconocimiento Automático del Habla, Traducción Automática, Sistemas de Diálogo, Extracción/Recuperación de Información, Interfaces en LN, Herramientas para discapacitados, ayuda a la redacción, ...

PLN desde diferentes perspectivas

- **Fonética y fonología**: el estudio del análisis de las señales acústicas que emitimos y generamos.
- **Morfología**: El estudio de la información contenida en una palabra considerada ésta en el contexto en el que se utiliza.
- **Sintaxis**: Estudio de las relaciones estructurales entre las palabras en una frase. Estudio de cómo ordenar y agrupar las palabras en la frase.
- **Semántica**: Estudio de los significados de las palabras y su forma de combinarse para formar significados más complejos.
- **Pragmática, Discurso**: Estudia cómo el contexto afecta a la interpretación de las oraciones.


El problema de la ambigüedad en PLN

- La ambigüedad inherente al LN es uno de los problemas presentes en todas fases del procesamiento de la lengua.

Ejemplos:

- *Vino de la Rioja.*
- *Compré unos zapatos de piel de señora.*
- *La policía observó al sospechoso con unos prismáticos.*
- *El pescado está listo para comer.*
- *El cura recibió una cura en la sala de curas.*
- *Juan vio a Pedro enfurecido.*
- *Antonio no nada nada.*
- *No puedo ir a la fiesta porque no traje traje.*
- *Estaré de vacaciones solo unos días.*
- *El Villareal le ganó al Valencia en su campo.*
- *Me quedé esperándote en el banco.*

Ejemplo de ambigüedad en PLN



2. Recursos Lingüísticos

Recursos Léxicos

- **Información de los léxicos:**

- **Ortografía:** grafía de los componentes de la entrada, unidades estándar y variantes dialectales. Abreviaturas, acrónimos, locuciones
- **Morfología:** características morfológicas. Información sobre los fenómenos de la flexión y derivación.
- **Sintaxis:** categoría, subcategorización de verbos, selecciones de restricción.
- **Semántica:** Sentido o concepto. Características propias: animado/no-animado, persona, contable/no-contable. Relaciones de sinonimia, antonimia, ...

Recursos Léxicos

- Dictionarios

- LONGMAN DICTIONARY AND THESAURUS: LDOCE. Se compone de 2000 palabras básicas y sus definiciones. Contiene información gramatical muy rica (etiquetas semánticas, ...)
- LLOCE: Longman Lexicon Of Contemporary English. Utilizan el concepto de similitud semántica.
- The Webster' s Seventh New Collegiate Dictionary (W7)
- Oxford Advanced Learner' s Dictionary of Current English (OALDCE).
- CAMBRIDGE INTERNATIONAL DICTIONARY OF ENGLISH.
<http://www.cup.cam.ac.uk/elt/reference/data.htm>.
- Collins COBUILD English Language Dictionary (CED)

- Dictionarios bilingües

- Bilingual Oxford Hachette French dictionary
- Collins-Robert English-French dictionary. 70.000 pares de co-ocurrencias.
- ...

Recursos Léxicos

Redes semánticas

- Relaciones entre conceptos
 - Sinonimia: diferente forma, mismo significados
instrumento, aparato
 - Hiponimia e hiperonimia: un concepto denota una subclase del otro
vehículo > coche
 - Meronimia y holonimia: parte, sustancia o miembro de otro
coche > rueda, libro > papel
- Ontologías
 - WordNet: taxonomía semántica del inglés, formada por conceptos agrupados en conjuntos de sinónimos

Recursos Léxicos

WordNet

- Ejemplos de relaciones entre sustantivos
 - **Hiperonimia**: del concepto al supertipo
desayuno --> comida
 - **Hiponimia**: del concepto al subtipo
comida --> picnic
 - **Has-Member**: de los grupos a los miembros
claustro --> profesor
 - **Member-Of**: de los miembros a los grupos
copiloto --> tripulación
 - **Has-Part**: del todo a la parte
auto --> ventanilla
 - **Part-Of**: de la parte al todo
amortiguador --> suspensión
 - **Antonimia**: opuestos
líder --> seguidor

Recursos Lingüísticos: corpora

Corpora

- Colección de textos no anotados o anotados con información lingüística
- **Características:**
 - Volumen
 - Propósito
 - Balanceado/no balanceado
 - Lenguaje de anotación, ...
 - Método anotación: manual, automática, semiautomática, supervisado, ...
 - Tipo información: POS, sintaxis, semántica, ...

Ejemplos de corpus

Corpus	Idioma	Volumen	Información	Temática
Brown	Inglés	1 millón	POS	Periodístico, Literario
Penn Tree Bank	Inglés	> 1 millón	POS, Sintaxis	Periodístico
Suzanne	Inglés	130.000	POS, Sintaxis	Periodístico, Literario
LexEsp	Castellano	100.000	POS, Sintaxis, Sentidos	Literario
GENIA	Inglés	500.000	POS, Sintaxis, Entidades	Biomedicina
NEGRA	Alemán	350.000	POS, Sintaxis	Periodístico

La WEB, Wikipedia, Corpus paralelos, ...

Penn Treebank

Ejemplo de anotación

```
( (S
  (NP-SBJ
    (NP (NNP Pierre) (NNP Vinken) )
    ( , , )
    (ADJP
      (NP (CD 61) (NNS years) )
      (JJ old) )
    ( , , ) )
  (VP (MD will)
    (VP (VB join)
      (NP (DT the) (NN board) )
      (PP-CLR (IN as)
        (NP (DT a) (JJ nonexecutive) (NN director) ))
      (NP-TMP (NNP Nov.) (CD 29) )))
    ( . . ) ) )
```

3. Introducción a los problemas de desambiguación del PLN

POS tagging

- **POS Tagging** (etiquetado morfológico, etiquetado léxico, desambiguación morfosintáctica, ...) es el proceso de asignar, a cada una de las palabras de un texto, la categoría gramatical (**POS: part-of-speech**), sin tener en cuenta sus relaciones sintácticas.
 - Las palabras, tomadas en forma aislada, en general, son ambiguas respecto a su categoría.
 - La categoría de la mayoría de las palabras se puede desambiguar dentro de un contexto.
- **Ejemplo**
 - “Mételo en ese **sobre**” -> **nombre**
 - “Déjalo **sobre** la mesa” -> **preposición**
 - “Dame lo que te **sobre**” -> **verbo**

Categorías Gramaticales (POS)

- La elección del conjunto de etiquetas afecta a la dificultad del problema. Hay que llegar a un equilibrio entre:
 - Obtener la mayor información posible (etiquetas más específicas),
 - Simplificar el trabajo de desambiguación (etiq. más generales).
- Tipos categorías
 - Abiertas o Cerradas
- Principales Categorías
 - Nombres (comunes y propios)
 - Pronombres (posesivos, interrogativos, ...)
 - Determinantes (artículos, demostrativos, ...)
 - Adjetivos
 - Verbos
 - Adverbios
 - Preposiciones
 - Conjunciones ...
- Ejemplos de Etiquetas (POS)
 - Penn Treebank: 45
 - Brown Corpus: 87
 - Susanne: 350
 - LexEsp (PAROLE): 250

Conjunto de etiquetas Penn Tree Bank

Tag	Description	Example	Tag	Description	Example
CC	Coordin. Conjunction	<i>and, but, or</i>	SYM	Symbol	<i>+, %, &</i>
CD	Cardinal number	<i>one, two, three</i>	TO	“to”	<i>to</i>
DT	Determiner	<i>a, the</i>	UH	Interjection	<i>ah, oops</i>
EX	Existential ‘there’	<i>there</i>	VB	Verb, base form	<i>eat</i>
FW	Foreign word	<i>mea culpa</i>	VBD	Verb, past tense	<i>ate</i>
IN	Preposition/sub-conj	<i>of, in, by</i>	VBG	Verb, gerund	<i>eating</i>
JJ	Adjective	<i>yellow</i>	VCN	Verb, past participle	<i>eaten</i>
JJR	Adj., comparative	<i>bigger</i>	VBP	Verb, non-3sg pres	<i>eat</i>
JJS	Adj., superlative	<i>wildest</i>	VBZ	Verb, 3sg pres	<i>eats</i>
LS	List item marker	<i>1, 2, One</i>	WDT	Wh-determiner	<i>which, that</i>
MD	Modal	<i>can, should</i>	WP	Wh-pronoun	<i>what, who</i>
NN	Noun, sing. or mass	<i>llama</i>	WP\$	Possessive wh-	<i>whose</i>
NNS	Noun, plural	<i>llamas</i>	WRB	Wh-adverb	<i>how, where</i>
NNP	Proper noun, singular	<i>IBM</i>	\$	Dollar sign	<i>\$</i>
NNPS	Proper noun, plural	<i>Carolinas</i>	#	Pound sign	<i>#</i>
PDT	Predeterminer	<i>all, both</i>	“	Left quote	<i>(‘ or “)</i>
POS	Possessive ending	<i>’s</i>	”	Right quote	<i>(’ or ”)</i>
PP	Personal pronoun	<i>I, you, he</i>	(	Left parenthesis	<i>([, { , <)</i>
PP\$	Possessive pronoun	<i>your, one’s</i>	)	Right parenthesis	<i>(],), }, >)</i>
RB	Adverb	<i>quickly, never</i>	,	Comma	<i>,</i>
RBR	Adverb, comparative	<i>faster</i>	.	Sentence-final punc	<i>(. ! ?)</i>
RBS	Adverb, superlative	<i>fastest</i>	:	Mid-sentence punc	<i>(: ; ... - -)</i>
RP	Particle	<i>up, off</i>			

Conjunto reducido de etiquetas Parole

AQ Adjetivos
C0 Conjunción sin clasificar
CC Conjunción Coordinada
CS Conjunción Subordinada
D0 Determinante sin clasificar
DD Determinante Demostrativo
DE Determinante Exclamativo
DI Determinantes Indefinidos
DP Determinante Posesivo
DT Determinante Interrogativo
E0 Términos Extranjeros
I Interjecciones
MC Numeral Cardinal
MO Numeral Ordinal
NC Nombre Común
NP Nombre Propio
P0 Pronombre sin clasificar
PD Pronombre Demostrativo
PI Pronombre Indefinido
PP Pronombre personal
PR Pronombre Relativo
PT Pronombre Interrogativo
PX Pronombre Posesivo
RG Adverbios y Fases Adverbiales
SP Preposiciones
TD Artículos
TI Determinante Indefinido

VAC
V Verbo A Auxiliar C Condicional
VAG G Gerundio
VAI I Otros tiempos de indicativo
VAM M Imperativo
VAN N Infinitivo
VAP P Participio
VAS S Subjuntivo
VMC M Principal
VMG
VMI
VMM
VMN
VMP
VMS
W Fecha
X Residuales
Y Abreviaturas
Z Cifras
SIGNOS DE PUNTUACIÓN
Faa ; Fah [Faiç
Fal { Fap (Fc ,
Fca ! Fcd " Fch]
Fci ? Fcl } Fcp)
Fcs ' Fdp : Fg -
Fgd – Fp . Fpc ; Fps ...
Fs / Ftp % Fac « Fcc »

Morfología

- La **morfología** estudia cómo se construyen las palabras a partir de unidades más pequeñas que son los monemas (morfemas y lexemas).
- Formas de componer palabras:
 - **Inflexión**: se combina la raíz o lexema de una palabra con morfemas gramaticales. La palabra resultante es de la misma categoría sintáctica.
 - Derivaciones verbales (canté, cantabas, cantaba, ...)
 - Variaciones de género y número en nombres y adjetivos.
 - **Derivación**: se combina un lexema con morfemas gramaticales resultando una palabra de categoría sintáctica diferente o de significado diferente.
 - Ej. Cantar (V) → Cant + ante (N)
 - Ej. Torpe (Adj) → En + torp + ecedor (Adj)
 - **Composición**: se combinan varios lexemas resultando una palabra de la misma categoría gramatical.
 - Ej. Moto + Sierra → Motosierra

Ej: Categorías Gramaticales (POS)

Ejemplo Análisis Morfológico

Etiquetas PAROLE

Este	este	<u>DD</u> 3MS00	este	<u>NC</u> MS000	este	<u>PD</u> 3MS000
río	reír	<u>VM</u> IP1S0	río	<u>NC</u> MS000		
está	estar	<u>VM</u> MP2S0	estar	<u>VM</u> IP3S0		
seco	secar	<u>VM</u> IP1S0	seco	<u>NC</u> MS000	seco	<u>AQ</u> 0MS00
.	.	Fp				

**Error del analizador
morfológico**

POS tagging

¿Cómo se determinan las posibles POS de una palabra?

- Dicionarios
- Corpus anotados
- ...

Problemas previos:

- Formatos de textos (txt, doc, pdf, html, xml, ...)
- Segmentación de oraciones
- Tokenización
- Análisis Morfológico

Ej: Análisis Morfológico

ENTRADA: Roberto González Cepeda que nació el 12 de enero de 1900, era un gran hombre de letras que por lo menos publicó 100 libros.

Roberto_González_Cepeda roberto_gonzález_cepeda 5 NP00000
que que CS00 que PR3CN000
nació nacer VMIS3S0
el el TDMS0
12_de_enero_de_1900 12/1/1900 F W
, , E2 Fc
era era NCFS000 erar VMMP2S0 erar VMIP3S0 ser VAI1S0 ser VAI3S0
un un TIMS0 un MCMS00
gran gran AQ0CS00
hombre hombre NCMS000
de de SPS00 de NCFS000
letras letra NCFP000
que que CS00 que PR3CN000
por_lo_menos por_lo_menos RG000
publicó publicar VMIS3S0
100 100 Z
libros libro NCMP000
.. E1 Fp

Segmentación (oraciones)

+

Tokenización

+

Análisis Morfológico

Ej: Desambiguación morfosintáctica (POS tagging)

ENTRADA: Roberto González Cepeda que nació el 12 de enero de 1900, era un gran hombre de letras que por lo menos publicó 100 libros.

Roberto_González_Cepeda roberto_gonzález_cepeda 5 NP00000
que que CS00 que PR3CN000
nació nacer VMIS3S0
el el TDMS0
12_de_enero_de_1900 12/1/1900 F W
, , E2 Fc
era era NCFS000 erar VMMP2S0 erar VMIP3S0 ser VAI1S0 ser VAI3S0
un un TIMS0 un MCMS00
gran gran AQ0CS00
hombre hombre NCMS000
de de SPS00 de NCFS000
letras letra NCFP000
que que CS00 que PR3CN000
por_lo_menos por_lo_menos RG000
publicó publicar VMIS3S0
100 100 Z
libros libro NCMP000
.. E1 Fp

Consiste en elegir la categoría correcta,
teniendo en cuenta el **contexto**

Ej: Desambiguación Morfosintáctica (POS tagging)

Ejemplo Análisis Morfológico

Etiquetas PAROLE

Este este (DD3MS00) este NCMS000 este PD3MS000
río reír VMIP1S0 río (NCMS000)
está estar VMMP2S0 estar (VMIP3S0)
seco secar VMIP1S0 seco NCMS000 seco (AQ0MS00)
. . (Fp)

Análisis Sintáctico

El Análisis Sintáctico (Parsing) de textos consiste en recuperar la estructura sintáctica (árbol sintáctico) asociada a la oración.

–SINTAGMAS

- Un grupo de palabras que determina en la frase una determinada función. Dentro del sintagma las palabras se organizan entorno al **núcleo**.
 - SNominal: “El castillo medieval ...” (SPreposicional)
 - SVerbal: “ ... no cantes ...”
 - Sadj: “ ... más estudioso ...”
 - Sadv: “ ... muy lejos ...”
- En torno al núcleo pueden aparecer otras palabras o sintagmas que realizan la función de **determinante** , **modificador** o **complemento**
 - **SN(Esa(det) chica(N) tan alta (comp)) SV(no(mod) tiene(N)) ...**

Análisis Sintáctico

– **FUNCIONES SINTÁCTICAS**


- Tiene por objeto determinar la función que desempeñan en la oración los distintos sintagmas.

- **Sujeto**

- **Predicado**

- » Objeto Directo
- » Objeto Indirecto
- » Complemento circunstancial
- » Atributo
- » Complemento preposicional
- » ...



Ejemplo de Análisis Sintáctico



Análisis Sintáctico

- PROBLEMAS:
 - Dificultad en la definición de gramáticas de alta cobertura.
 - Sobregeneralización
 - Subgeneración
 - Robustez
 - Ambigüedad estructural.
 - Eficiencia
 - ...

Ej: Posibles análisis de “Luís ve al hombre con el telescopio”



Alternativas al A. Sintáctico Completo

- Análisis Parcial (Shallow Parsing)
 - Sacrificar la completitud del análisis total, para determinar ciertos constituyentes sintácticos más simples, pero con mayor precisión
- INFO:
 - <http://www.cnts.ua.ac.be/conll/>
 - http://jmlr.csail.mit.edu/papers/special/shallow_parsing02.html

Detección de Entidades

- Las Entidades son segmentos de la oración que contienen nombres de persona, organizaciones, lugares, fechas, cantidades, etc.
- **Problema:** detección y clasificación.
- **Ejemplo:**
[PER Wolff] , currently a journalist in [LOC Argentina] , played with [PER Del Bosque] in the final years of the seventies in [ORG Real Madrid]

INFO:

<http://www.cnts.ua.ac.be/conll/>

Entidades biomédicas

DNA, RNA, protein, cell_line, cell_type, ...

PROBLEMAS:

- No existe un diccionario completo para muchos tipos de entidades biológicas nombradas, por lo que un simple algoritmo de ‘matching’ no es suficiente.
- La misma palabra o frase se puede referir a diferentes entidades dependiendo del contexto (sinónimos), un término varios significados (homónimos), variantes tipográficas o léxicas,
- Rápida evolución de la terminología
- Muchas entidades están compuestas por palabras compuestas (‘multiwords’)
- Detección de acrónimos

- [BioNLP/NLPBA 2004](#)
- <http://biocreative.sourceforge.net/>

Word Sense Disambiguation

- Determinación del sentido correcto de una palabra en una frase (texto).
- Generalmente el contexto de la palabra ambigua ayuda a desambiguar:

Ejemplo:

Lavó la ropa en la **pila**.

La **pila** del juguete se ha gastado

- Pero no siempre es así

Ejemplo:

Te esperé en el **banco**.

- ¿Qué se entiende por **sentido** actualmente?

WordNet

<http://www.cogsci.princeton.edu/~wn/>

EuroWordNet

<http://nipadio.lsi.upc.edu/cgi-bin/wei4/public/wei.consult.perl>

Métodos de resolución

- Se presentarán las aproximaciones más relevantes del estado del arte para los problemas planteados:
 - POS tagging
 - Shallow Parsing
 - NER
 - WSD
- Se profundizará en las aproximaciones basadas en **Aprendizaje Automático (Estadístico)**
 - Son aproximaciones que hacen uso de corporas anotados con información lingüística de interés para el problema a resolver.
 - Principales paradigmas:
 - Modelos Ocultos de Markov (HMM)
 - Modelos de Máxima Entropía (ME)
 - Memory based Learning (MBL)
 - Transformaton based Learning (TBL)
 - Métodos combinados
 - ...

Bibliografía

- Daniel Jurafsky and James H. Martin, *SPEECH and LANGUAGE PROCESSING: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, Prentice-Hall, 2009 (Second Edition)
<http://www.cs.colorado.edu/~martin/slp.html>
- Chris Manning and Hinrich Schütze, *Foundations of Statistical Natural Language Processing*, MIT Press. Cambridge, 1999.
<http://nlp.stanford.edu/fsnlp/>
- Recursos:
<http://www-nlp.stanford.edu/links/statnlp.html>
<http://cran.es.r-project.org/web/views/NaturalLanguageProcessing.html>
- Curso online:
<https://class.coursera.org/nlp/lecture/preview/index#close>