

Tema 3-1. HMM y POS tagging



Lingüística Computacional
Ferran Pla

Cadenas de Markov


Es un caso particular de autómatas de estados finitos probabilísticos

- Conjunto de estados: $Q = q_1 q_2 \dots q_N$
- Matriz de probabilidad de transición entre estados: $\sum_{j=1}^n a_{ij} = 1 \quad \forall i$
- Probabilidad estado inicial: $\sum_{i=1}^n \pi_i = 1$
(alternativamente se puede definir un estado inicial)
(también se puede definir un estado final)

Asunción de Markov

Cadena de Markov 1er orden (bigramas): $P(q_i | q_1 \dots q_{i-1}) = P(q_i | q_{i-1})$

Ejemplo



$$A = \{a_{ij}\} = \begin{bmatrix} 0,4 & 0,3 & 0,3 \\ 0,2 & 0,6 & 0,2 \\ 0,1 & 0,1 & 0,8 \end{bmatrix}$$

$$\pi_i = \frac{1}{3} \quad 1 \leq i \leq 3.$$

¿Probabilidad de la secuencia: “nublado, soleado, nublado, lluvia” ?

$$P(2, 3, 2, 1) = P(2)P(3|2)P(2|3)P(1|2) = \pi_2 \times a_{23} \times a_{32} \times a_{21} = \frac{1}{3} \times 0,2 \times 0,1 \times 0,2 = 0,00133333$$

Modelo de Markov Oculto (HMM)

SECUENCIA DE SALIDA OBSERVABLE

$O = \{\text{GREEN, GREEN, BLUE, RED, YELLOW, RED, , BLUE}\}$



$P(\text{RED}) = b_1(1)$
 $P(\text{BLUE}) = b_1(2)$
 $P(\text{GREEN}) = b_1(3)$
 $P(\text{YELLOW}) = b_1(4)$
 $\vdots$
 $P(\text{ORANGE}) = b_1(M)$

$P(\text{RED}) = b_2(1)$
 $P(\text{BLUE}) = b_2(2)$
 $P(\text{GREEN}) = b_2(3)$
 $P(\text{YELLOW}) = b_2(4)$
 $\vdots$
 $P(\text{ORANGE}) = b_2(M)$

$P(\text{RED}) = b_N(1)$
 $P(\text{BLUE}) = b_N(2)$
 $P(\text{GREEN}) = b_N(3)$
 $P(\text{YELLOW}) = b_N(4)$
 $\vdots$
 $P(\text{ORANGE}) = b_N(M)$

Modelo de Markov Oculto (HMM)

- Conjunto de estados: $Q = q_1 q_2 \dots q_N$
- Matriz de probabilidad de transición entre estados: $\sum_{j=1}^n a_{ij} = 1 \quad \forall i$
- Probabilidad estado inicial: $\sum_{i=1}^n \pi_i = 1$
(alternativamente se puede definir un estado inicial)
(también se puede definir un estado final)
- Una secuencia de observación, O , de longitud T , que pertenecen a un vocabulario V $O = o_1 o_2 \dots o_T \quad V = v_1, v_2, \dots, v_V$
- Probabilidad de emisión: $B = b_i(o_t)$


Asunción de Markov 1er orden: $P(q_i | q_1 \dots q_{i-1}) = P(q_i | q_{i-1})$

Emisión dep. solo estado: $P(o_i | q_1 \dots q_i \dots q_n, o_1 \dots o_i \dots, o_n) = P(o_i | q_i)$

Modelo de Markov Oculto (HMM)

Los 3 problemas a resolver

- 1 Dada una secuencia de observaciones, $O = o_1 o_2 \dots o_T$, y un MM $\lambda = (A, B, \Pi)$, ¿cómo se calcula de forma eficiente la probabilidad con que el modelo genera esa secuencia de observaciones, $P(O|\lambda)$?
- 2 Dada una secuencia de observaciones, $O = o_1 o_2 \dots o_T$, y un MM $\lambda = (A, B, \Pi)$, ¿cómo se obtiene la secuencia de estados, $Q = q_1, q_2, \dots, q_T$, que maximiza la probabilidad de esa observación?
- 3 Dada una secuencia de observaciones, $O = o_1 o_2 \dots o_T$, ¿cómo se ajustan los parámetros de un modelo $\lambda = (A, B, \Pi)$ para maximizar la probabilidad con que se genera esa observación, $P(O|\lambda)$?



¿Cuántas secuencias de estados pueden generar la observación, $O=3 \ 1 \ 3$?

N : número de estados

T : longitud de la cadena


N^T secuencias de estados (2^3)

$$P(O) = \sum_Q P(O, Q) = \sum_Q P(O|Q)P(Q) = \sum_Q \prod_{i=1}^n P(o_i|q_i) \times \prod_{i=1}^n P(q_i|q_{i-1})$$

$$P(3 \ 1 \ 3, \text{hot hot cold}) = P(\text{hot}|\text{start}) \times P(\text{hot}|\text{hot}) \times P(\text{cold}|\text{hot}) \\ \times P(3|\text{hot}) \times P(1|\text{hot}) \times P(3|\text{cold})$$


$$P(3 \ 1 \ 3) = P(3 \ 1 \ 3, \text{cold cold cold}) + P(3 \ 1 \ 3, \text{cold cold hot}) + P(3 \ 1 \ 3, \text{hot hot cold}) + \dots$$

¿Cómo hacer estos cálculos más eficientemente, sin utilizar la fuerza bruta?



Utilizaremos Programación Dinámica

- Algoritmo Forward
- Coste ($T \cdot N^2$)



Probabilidad Forward $\alpha_t(j) = P(o_1, o_2 \dots o_t, q_t = j | \lambda) = \sum_{i=1}^N \alpha_{t-1}(i) a_{ij} b_j(o_t)$

Inicialización:


$$\alpha_1(j) = a_{0j} b_j(o_1) \quad 1 \leq j \leq N$$

Recursión:

$$\alpha_t(j) = \sum_{i=1}^N \alpha_{t-1}(i) a_{ij} b_j(o_t); \quad 1 \leq j \leq N, 1 < t \leq T$$

Fin:

$$P(O | \lambda) = \alpha_T(q_F) = \sum_{i=1}^N \alpha_T(i) a_{iF}$$



function FORWARD(*observations* of len T , *state-graph* of len N) **returns** *forward-prob*

create a probability matrix $forward[N+2, T]$

for each state s **from** 1 **to** N **do** ;initialization step

$forward[s, 1] \leftarrow a_{0,s} * b_s(o_1)$


for each time step t **from** 2 **to** T **do** ;recursion step

for each state s **from** 1 **to** N **do**

$forward[s, t] \leftarrow \sum_{s'=1}^N forward[s', t-1] * a_{s',s} * b_s(o_t)$

$forward[q_F, T] \leftarrow \sum_{s=1}^N forward[s, T] * a_{s,q_F}$; termination step

return $forward[q_F, T]$



Algoritmo Backward

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T | q_t = i, \mu)$$

1. Inicialización:


$$\beta_T(i) = 1, \quad 1 \leq i \leq N.$$

2. Recurrencia:

$$\beta_t(i) = \sum_{j=1}^N a_{ij} \beta_{t+1}(j) b_j(o_{t+1}), \quad t = T-1, T-2, \dots, 1, \quad 1 \leq i \leq N.$$

3. Terminación:

$$P(O|\mu) = \sum_{i=1}^N \beta_1(i) \pi_i b_i(o_1).$$



2 Secuencia de estados más probable dada un secuencia O: $P(Q|O, \lambda)$

Algoritmo de Viterbi

$$\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1 q_2 \dots q_t = i, o_1 o_2 \dots o_t | \lambda)$$

1. Inicialización

$$\delta_1(i) = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$

$$\psi_1(i) = 0$$

2. Inducción

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(o_t), \quad 2 \leq t \leq T, \quad 1 \leq j \leq N$$

$$\psi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}], \quad 2 \leq t \leq T, \quad 1 \leq j \leq N$$


3. Terminación

$$P(\hat{Q}) = \max_{1 \leq i \leq N} [\delta_T(i)]$$

$$\hat{q}_T = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$$

4. Recuperación de la secuencia de estados más probable

$$\hat{q}_t = \psi_{t+1}(\hat{q}_{t+1}), \quad t = T-1, T-2, \dots, 1$$



2 Secuencia de estados más probable dada una secuencia O : $P(Q|O, \lambda)$

Algoritmo de Viterbi

$viterbi[N+1, T], back-pointer[N+1, T]$

for each time step t **from** 1 **to** T **do**

for each state s **from** 1 **to** $num-states$ **do**


$viterbi[s, t] \leftarrow \max_{1 \leq s' \leq num-states} [viterbi[s', t-1] * a_{s', s}] * b_s(o_t)$

$back-pointer[s, t] \leftarrow \operatorname{argmax}_{1 \leq s' \leq num-states} [viterbi[s', t-1] * a_{s', s}]$

Algoritmo de Viterbi (ejemplo)

$$Q = \{1, 2, 3\}, \quad V = \{v_1, v_2\}, \quad \pi = \begin{bmatrix} 0,25 \\ 0,50 \\ 0,25 \end{bmatrix},$$

$$A = \begin{bmatrix} 0,25 & 0,25 & 0,50 \\ 0 & 0,25 & 0,75 \\ 0,50 & 0,50 & 0 \end{bmatrix} \quad y \quad B = \begin{bmatrix} 0,50 & 0,50 \\ 0,25 & 0,75 \\ 0,75 & 0,25 \end{bmatrix}.$$



$$O = (v_1, v_1, v_1, v_1, v_2, v_2, v_1, v_2)$$

$$Q = \{1, 2, 3\}, \quad V = \{v_1, v_2\}, \quad \pi = \begin{bmatrix} 0, 25 \\ 0, 50 \\ 0, 25 \end{bmatrix},$$

$$A = \begin{bmatrix} 0, 25 & 0, 25 & 0, 50 \\ 0 & 0, 25 & 0, 75 \\ 0, 50 & 0, 50 & 0 \end{bmatrix} \quad y \quad B = \begin{bmatrix} 0, 50 & 0, 50 \\ 0, 25 & 0, 75 \\ 0, 75 & 0, 25 \end{bmatrix}.$$

$$\begin{aligned} \delta_1(1) &= \pi_1 b_1(v_1) = (0, 25)(0, 50) \\ \delta_1(2) &= \pi_2 b_2(v_1) = (0, 50)(0, 25) \\ \delta_1(3) &= \pi_3 b_3(v_1) = (0, 25)(0, 75) \end{aligned}$$

$$\delta_2(1) = \max [\delta_1(1) a_{11}, \delta_1(2) a_{21}, \delta_1(3) a_{31}] b_1(v_1) = (0, 25)(0, 50)^2(0, 75) \quad \psi_2(1) = 3$$

$$\delta_2(2) = \max [\delta_1(1) a_{12}, \delta_1(2) a_{22}, \delta_1(3) a_{32}] b_2(v_1) = (0, 25)^2(0, 50)(0, 75) \quad \psi_2(2) = 3$$

$$\delta_2(3) = \max [\delta_1(1) a_{13}, \delta_1(2) a_{23}, \delta_1(3) a_{33}] b_3(v_1) = (0, 25)(0, 50)(0, 75)^2 \quad \psi_2(3) = 2$$

$$\delta_3(1) = \max [\delta_2(1) a_{11}, \delta_2(2) a_{21}, \delta_2(3) a_{31}] b_1(v_1) = (0, 25)(0, 50)^3(0, 75)^2 \quad \psi_3(1) = 3$$

$$\delta_3(2) = \max [\delta_2(1) a_{12}, \delta_2(2) a_{22}, \delta_2(3) a_{32}] b_2(v_1) = (0, 25)^2(0, 50)^2(0, 75)^2 \quad \psi_3(2) = 3$$

$$\delta_3(3) = \max [\delta_2(1) a_{13}, \delta_2(2) a_{23}, \delta_2(3) a_{33}] b_3(v_1) = (0, 25)(0, 50)^3(0, 75)^2 \quad \psi_3(3) = 1$$

$$\delta_4(1) = \max [\delta_3(1) a_{11}, \delta_3(2) a_{21}, \delta_3(3) a_{31}] b_1(v_1) = (0, 25)(0, 50)^5(0, 75)^2 \quad \psi_4(1) = 3$$

$$\delta_4(2) = \max [\delta_3(1) a_{12}, \delta_3(2) a_{22}, \delta_3(3) a_{32}] b_2(v_1) = (0, 25)^2(0, 50)^4(0, 75)^2 \quad \psi_4(2) = 3$$

$$\delta_4(3) = \max [\delta_3(1) a_{13}, \delta_3(2) a_{23}, \delta_3(3) a_{33}] b_3(v_1) = (0, 25)(0, 50)^4(0, 75)^3 \quad \psi_4(3) = 1$$

$$\delta_5(1) = \max [\delta_4(1) a_{11}, \delta_4(2) a_{21}, \delta_4(3) a_{31}] b_1(v_2) = (0, 25)(0, 50)^6(0, 75)^3 \quad \psi_5(1) = 3$$

$$\delta_5(2) = \max [\delta_4(1) a_{12}, \delta_4(2) a_{22}, \delta_4(3) a_{32}] b_2(v_2) = (0, 25)(0, 50)^5(0, 75)^4 \quad \psi_5(2) = 3$$

$$\delta_5(3) = \max [\delta_4(1) a_{13}, \delta_4(2) a_{23}, \delta_4(3) a_{33}] b_3(v_2) = (0, 25)^2(0, 50)^6(0, 75)^2 \quad \psi_5(3) = 1$$

$$\delta_6(1) = \max [\delta_5(1) a_{11}, \delta_5(2) a_{21}, \delta_5(3) a_{31}] b_1(v_2) = (0, 25)^2(0, 50)^7(0, 75)^3 \quad \psi_6(1) = 1$$

$$\delta_6(2) = \max [\delta_5(1) a_{12}, \delta_5(2) a_{22}, \delta_5(3) a_{32}] b_2(v_2) = (0, 25)^2(0, 50)^5(0, 75)^5 \quad \psi_6(2) = 2$$

$$\delta_6(3) = \max [\delta_5(1) a_{13}, \delta_5(2) a_{23}, \delta_5(3) a_{33}] b_3(v_2) = (0, 25)^2(0, 50)^5(0, 75)^5 \quad \psi_6(3) = 2$$

$$\delta_7(1) = \max [\delta_6(1) a_{11}, \delta_6(2) a_{21}, \delta_6(3) a_{31}] b_1(v_1) = (0, 25)^2(0, 50)^7(0, 75)^5 \quad \psi_7(1) = 3$$


$$\delta_7(2) = \max [\delta_6(1) a_{12}, \delta_6(2) a_{22}, \delta_6(3) a_{32}] b_2(v_1) = (0, 25)^3(0, 50)^6(0, 75)^5 \quad \psi_7(2) = 3$$


$$\delta_7(3) = \max [\delta_6(1) a_{13}, \delta_6(2) a_{23}, \delta_6(3) a_{33}] b_3(v_1) = (0, 25)^2(0, 50)^5(0, 75)^7 \quad \psi_7(3) = 2$$

$$\delta_8(1) = \max [\delta_7(1) a_{11}, \delta_7(2) a_{21}, \delta_7(3) a_{31}] b_1(v_2) = (0, 25)^2(0, 50)^7(0, 75)^7 \quad \psi_8(1) = 3$$

$$\delta_8(2) = \max [\delta_7(1) a_{12}, \delta_7(2) a_{22}, \delta_7(3) a_{32}] b_2(v_2) = (0, 25)^2(0, 50)^6(0, 75)^8 \quad \psi_8(2) = 3$$

$$\delta_8(3) = \max [\delta_7(1) a_{13}, \delta_7(2) a_{23}, \delta_7(3) a_{33}] b_3(v_2) = (0, 25)^3(0, 50)^8(0, 75)^5 \quad \psi_8(3) = 1$$





$$\varepsilon_t(i, j) = P(q_t = s_i, q_{t+1} = s_j | O, \lambda)$$

$$\begin{aligned} \varepsilon_t(i, j) &= P(q_t = s_i, q_{t+1} = s_j | O, \lambda) = \frac{P(q_t = s_i, q_{t+1} = s_j, O | \lambda)}{P(O | \lambda)} \\ &= \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{P(O | \lambda)} = \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)} \end{aligned}$$

$$\gamma_t(i) = \sum_{j=1}^N \xi_t(i, j)$$

$\bar{\pi}_i$ = frecuencia esperada de estar en el estado i en el primer instante $= \gamma_1(i)$,

$$\bar{a}_{ij} = \frac{\text{número esperado de transiciones desde el estado } i \text{ al estado } j}{\text{número esperado de transiciones desde el estado } i} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)},$$

$$P(O | \hat{\lambda}) > P(O | \lambda)$$

$$\bar{b}_j(v_k) = \frac{\text{número esperado de veces en el estado } j \text{ observando el símbolo } v_k}{\text{número esperado de veces en el estado } j} = \frac{\sum_{t=1}^T \gamma_t(j) \text{ tal que } o_t = v_k}{\sum_{t=1}^T \gamma_t(j)}$$

POS Tagging

POS Tagging (Etiquetado morfosintáctico):


dada una secuencia de palabras ¿cuál es la secuencia de categorías gramaticales más probable?

POS TAGGING

ENTRADA

Este río está seco

D	V	V	V
P	N		A
N			



SALIDA

Este río está seco

D N V A

HMM y POS tagging

- POS Tagging (Etiquetado morfosintáctico):
 - dada una secuencia de palabras ¿cuál es la secuencia de categorías gramaticales más probable?
- Problema de maximización:

$$\begin{aligned} C &= \{c_1, c_2, \dots, c_N\}, \quad w_i \in V \\ \hat{C} &= \arg \max_{C^T} P(c_1, c_2, \dots, c_T \mid w_1, w_2, \dots, w_T) = \\ &= \arg \max_{C^T} \frac{P(c_1, c_2, \dots, c_T) \cdot P(w_1, w_2, \dots, w_T \mid c_1, c_2, \dots, c_T)}{P(w_1, w_2, \dots, w_T)} \\ &= \arg \max_{C^T} P(c_1, c_2, \dots, c_T) \cdot P(w_1, w_2, \dots, w_T \mid c_1, c_2, \dots, c_T) \end{aligned}$$

HMM y POS tagging (bigramas)


**Probabilidades
léxicas** (emisión)

$$P(w_1, w_2, \dots, w_T \mid c_1, c_2, \dots, c_T) \approx \prod_{i=1..T} P(w_i \mid c_i)$$

**Probabilidades de
contexto** (transición)

$$P(c_1, c_2, \dots, c_T) \approx \prod_{i=1..T} P(c_i \mid c_{i-1})$$

$$\hat{C} = \arg \max_C \prod_{i=1..T} P(c_i \mid c_{i-1}) \cdot P(w_i \mid c_i)$$



Aprendizaje de un Modelo de Markov

- Estimación de los parámetros
 - Métodos no supervisados:
 - Algoritmo de Baum-Welch
 - Métodos supervisados (máxima verosimilitud):
 - Probabilidades de Contexto:

$$P(c_i | c_{i-1}) = \frac{f(c_{i-1}, c_i)}{f(c_{i-1})}$$

- Probabilidades Léxicas:

$$P(w_i | c_i) = \frac{f(w_i, c_i)}{f(c_i)}$$

Necesidad de Métodos de Suavizado.

Se estudiará en Modelos de Lenguaje (n-gramas)

Métodos de Suavizado

PROBABILIDADES CONTEXTO

- Interpolación lineal

$$P^{Int}(c_i|c_j) = \lambda_{i1} \cdot P(c_i|c_j) + \lambda_{i2} \cdot P(c_i); \quad \lambda_{i1} + \lambda_{i2} = 1 \quad (1)$$

- Back-off

$$P^{Suavizada}(c_i|c_j) = \begin{cases} P(c_i|c_j) & r > 0, r > k \\ d_r \cdot P(c_i|c_j) & 0 < r \leq k \\ \alpha \cdot P(c_i) & r = 0 \end{cases} \quad (2)$$

Diferentes funciones de descuento: lineal, absoluto, Good Turing,...

Métodos de Suavizado

PROBABILIDADES LÉXICAS

$$\begin{aligned} P(w^{desconocida}|c_i) &= \frac{P(c_i|w^{desconocida}) \cdot P(w^{desconocida})}{P(c_i)} \\ &\approx \frac{P(c_i|w^{menos_probable}) \cdot P(w^{desconocida})}{P(c_i)} \end{aligned} \quad (3)$$

$$P^{uniforme}(w_j|c_i) = \frac{1}{T(c_i)} \quad (4)$$

$$P^{Int}(w_j|c_i) = \lambda \cdot P(w_j|c_i) + (1 - \lambda) \cdot P^{uniforme}(w_j|c_i) \quad (5)$$

$$P(w^{UNK}|c_i) = P(W_{unknown}|c_i) \cdot P(W_{Capital}|c_i) \cdot P(W_{ending}|c_i)$$


Ejemplo de valores estimados de probabilidades

		P(Este DD)			
		↓			
P(DD Este)	Este	0.99302	0.170038 -este-	esteDD	DD_NC_PD
		0.00611	0.000034 -este-	esteNC	DD_NC_PD
		0.00087	0.000438 -este-	estePD	DD_NC_PD
río		0.00862	0.000081 -río-	reírVMI	NC_VMI
		0.99138	0.003023 -río-	río NC	NC_VMI
está		0.01125	0.010678 -está-	estar	VMM VMI_VMM
		0.98875	0.012705 -está-	estar	VMI VMI_VMM
seco		0.03333	0.000023 -seco-	secar	VMI AQ_NC_VMI
		0.03333	0.000007 -seco-	secoNC	AQ_NC_VMI
		0.93333	0.000566 -seco-	secoAQ	AQ_NC_VMI
.					
1		1.000000	.	Fp	

		Logaritmo de la P(NC DD)	
-6.106067	P(DD <s>)	-4.872681	P(NC DD)
-6.196267	P(NC <s>)	-7.446781	P(VMI DD)
-5.805067	P(PP <s>)	-6.486866	P(NC NC)
		-5.678267	P(VMI NC)
		-7.519969	P(NC PP)
		-4.751669	P(VMI PP)

Etiquetado

- Proceso de etiquetado:



- Estructura de datos: trellis
- Algoritmo Viterbi, coste temporal: $O(TN^2)$

Algoritmo de Viterbi

ENTRADAS:

frase : $W_1, \dots, W_T$

categorías : $C_1, \dots, C_N$

prob. léxicas : $P(W_i | C_i)$

prob. contexto : $P(C_i | C_j)$

INICIALIZACIÓN:

$\forall i = 1$ hasta N hacer

$SEQSCORE[i, 1] = P(W_1 | C_i) \cdot P(C_i | \Phi)$

$BACKPTR[i, 1] = 0$

fi $\forall$

ITERACIÓN:

$\forall t = 2$ hasta T hacer

$\forall i = 1$ hasta N hacer

$SEQSCORE[i, t] = \max_{j=1 \dots N} (SEQSCORE[j, t-1] \cdot P(C_i | C_j)) \cdot P(W_t | C_i)$

$BACKPTR[i, t] = \text{índice de } j \text{ del máximo}$

fi $\forall$

fi $\forall$

IDENTIFICACIÓN DE LA MEJOR SECUENCIA:

$S[T] = i$ que maximice $SEQSCORE(i, T)$


$\forall i = T - 1$ hasta 1 hacer

$S[i] = BACKPTR[S[i+1], i+1]$

fi $\forall$


Optimizaciones

- Considerar sólo las secuencias lingüísticamente correctas



- Estructuras de datos
- Técnicas de Beam search
- Problemas de precisión:
 - Trabajar con logaritmos de probabilidad y además es más eficiente al sustituir productos por sumas
- ...

Esquema de un POS tagger basado en HMM



TnT tagger basado en HMM [Brants,2000]

PROBABILIDADES DE CONTEXTO

- Modelo de Trigramas, suavizado con interpolación lineal

$$P(c_3|c_1, c_2) = \lambda_1 \hat{P}(c_3) + \lambda_2 \hat{P}(c_3|c_2) + \lambda_3 \hat{P}(c_3|c_1, c_2)$$

$\lambda_1 + \lambda_2 + \lambda_3 = 1$; Estimados por "deleted interpolation".

PROBABILIDADES LÉXICAS

- Palabras desconocidas

Recursión que calcula la probabilidad de una etiqueta C_j dadas las últimas m letras l_i de una palabra de n letras, para $i = m \dots 0$

$$P(C_j|l_{n-i+1}, \dots, l_n) = \frac{\hat{P}(C_j|l_{n-i+1}, \dots, l_n) + \theta_i P(C_j|l_{n-i}, \dots, l_n)}{1 + \theta_i}$$

$$\text{donde } \hat{P}(C_j|l_{n-i+1}, \dots, l_n) = \frac{f(C_j, l_{n-i+1}, \dots, l_n)}{f(l_{n-i+1}, \dots, l_n)}$$

$$\text{y } \theta_i = \frac{1}{s-1} \sum_{j=1}^s [\hat{P}(C_j) - \frac{1}{s} \sum_{j=1}^s \hat{P}(C_j)]^2 ; i = 0 \dots m; s \text{ número de etiquetas.}$$

ALGORITMO DE ETIQUETADO

- Viterbi + Beam Search. (30,000–60,000 pal/seg, Pentium 500, Linux)

Ejercicio

Dado el siguiente conjunto de entrenamiento, donde el conjunto de categorías morfosintácticas (Ci) está compuesto sólo por 4 (Determinante, Nombre, Adjetivo, Verbo) y donde <s> representa el símbolo inicial.

<s> La/D niña/N lleva/V trenzas/N

<s> La/D rubia/A niña/N canta/V

<s> Corre/V Andrés/N

<s> Come/V peras/N

<s> El/D coche/N azul/A echa/V humo/N negro/A

<s> El/D gris/A coche/N está/V cerrado/A

- a) Calcular por máxima verosimilitud, los parámetros de un modelo de Markov de primer orden.
- b) Estimar por máxima verosimilitud, sin aplicar ningún suavizado, las probabilidades de emisión para el estado N.
- c) Utilizar el suavizado “añadir 1” para calcular las probabilidades de transición del estado D a cualquier estado.

Referencias

- (Jurafsky,2000) Jurafsky, D., Martin, J.H. Speech and Language Processing. Pearson International Edition. 2009.
- (Pla, 2000) F. Pla. *Etiquetado Léxico y Análisis Sintáctico Superficial basado en Modelos Estadísticos*. Phd. Thesis. Dep. de Sistemes Informàtics i Computació. Universitat Politècnica de València. 2000.
- (Brants, 2000) T. Brants. TnT - a statistical part-of-speech tagger. In *Proceedings of the Sixth Applied Natural Language Processing (ANLP-2000)*, Seattle, WA. 2000.
- (Pla F. and Molina A, 2004). Improving part-of-speech tagging using Lexicalized HMMs. *Natural Language Engineering* 10(2). Cambridge University Press. UK.