

Tema 3-2. POS tagging: aproximaciones y evaluación



Lingüística Computacional
Ferran Pla

Índice

APROXIMACIONES

- Máxima Entropía (ME)
- MEMM
- Conditional Random Fields
- Reglas de Transformación
- Memory Based Learning
- Lexicalized HMMs
- Combinados

EVALUACIÓN

- Metodología
- Resultados

Referencias

Formalismo	POS Tagging
HMM	[Church, 1988] [Cutting et al., 1992], [Pla, 2000] [Merialdo, 1994], [Brants, 2000]
ME	[Ratnaparkhi, 1996]
TBL	[Brill, 1992, Brill, 1995]
MBL	[Daelemans et al., 1996]
Comb.	[Van Halteren et al., 1998], [Brill and Wu, 1998]
...	

Modelos de Máxima Entropía (MaxEnt)

- Clasificador exponencial o log-linear

$$p(c|x) = \frac{1}{Z} \exp(\sum_i w_i f_i)$$

- Dada una entrada (x), el objetivo es asignarle una clase (c), donde $\mathbf{f}_i$ son un conjunto de características, $\mathbf{w}_i$ un conjunto de pesos y $\mathbf{Z}$ un factor de normalización
- Asumimos que las características sólo pueden tomar los valores **0** o **1**, y que tanto estas como sus pesos dependen de cada clase.

$$p(c|x) = \frac{\exp\left(\sum_{i=0}^N w_{ci} f_i(c, x)\right)}{\sum_{c' \in \mathcal{C}} \exp\left(\sum_{i=0}^N w_{c'i} f_i(c', x)\right)}$$

donde $\mathcal{C}$ es el conjunto de clases en las que se puede clasificar $\mathbf{x}$

CLASIFICACIÓN:

$$\hat{c} = \operatorname{argmax}_{c \in \mathcal{C}} P(c|x)$$

MaxEnt: un ejemplo

Secretariat/NNP is/BEZ expected/VBN to/TO race/?? tomorrow/

Problema: clasificar/etiquetar la palabra "race"

Conjunto de características

$$f_1(c, x) = \begin{cases} 1 & \text{if } word_i = \text{"race"} \ \& \ c = \text{NN} \\ 0 & \text{otherwise} \end{cases}$$

$$f_2(c, x) = \begin{cases} 1 & \text{if } t_{i-1} = \text{TO} \ \& \ c = \text{VB} \\ 0 & \text{otherwise} \end{cases}$$

$$f_3(c, x) = \begin{cases} 1 & \text{if } \text{suffix}(word_i) = \text{"ing"} \ \& \ c = \text{VBG} \\ 0 & \text{otherwise} \end{cases}$$

$$f_4(c, x) = \begin{cases} 1 & \text{if } \text{is_lower_case}(word_i) \ \& \ c = \text{VB} \\ 0 & \text{otherwise} \end{cases}$$

$$f_5(c, x) = \begin{cases} 1 & \text{if } word_i = \text{"race"} \ \& \ c = \text{VB} \\ 0 & \text{otherwise} \end{cases}$$

$$f_6(c, x) = \begin{cases} 1 & \text{if } t_{i-1} = \text{TO} \ \& \ c = \text{NN} \\ 0 & \text{otherwise} \end{cases}$$

Pesos de las características

		f1	f2	f3	f4	f5	f6
VB	f	0	1	0	1	1	0
VB	w		.8		.01	.1	
NN	f	1	0	0	0	0	1
NN	w	.8					-1.3

$$p(c|x) = \frac{\exp\left(\sum_{i=0}^N w_{ci} f_i(c, x)\right)}{\sum_{c' \in C} \exp\left(\sum_{i=0}^N w_{c'i} f_i(c', x)\right)}$$

$$P(NN|x) = \frac{e^{.8} e^{-1.3}}{e^{.8} e^{-1.3} + e^{.8} e^{.01} e^{-1}} = .20$$

$$P(VB|x) = \frac{e^{.8} e^{.01} e^{-1}}{e^{.8} e^{-1.3} + e^{.8} e^{.01} e^{-1}} = .80$$

$$\hat{c} = \underset{c \in C}{\operatorname{argmax}} P(c|x)$$

¿MaxEnt?

¿Por qué llamamos modelos de máxima entropía (MaxEnt o multinomial logit regression) ?

EJEMPLO: Queremos etiquetar la palabra “zzfish”

La distribución de probabilidad que impone menos restricciones (máxima entropía) sería una distribución equiprobable entre todas las POS ($H(x) = -\sum_x P(x) \log_2 P(x)$)

NN	JJ	NNS	VB	NNP	IN	MD	UH	SYM	VBG	POS	PRP	CC	CD	...
$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	$\frac{1}{45}$	...

➡ Supongamos , que disponemos de un conj. de entrenamiento en el que se observa que las posibles etiquetas para “zzfish” son NN, JJ, NNS y VB, entonces la distribución de máx. entropía que cumple con estas restricciones sería:

NN	JJ	NNS	VB	NNP	IN	MD	UH	SYM	VBG	POS	PRP	CC	CD	...
$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	0	0	0	0	0	0	0	0	0	0	...

$$P(NN) + P(JJ) + P(NNS) + P(VB) = 1$$

➡ Supongamos:

$$\begin{cases} P(NN) + P(JJ) + P(NNS) + P(VB) = 1 \\ P(\text{word is zzfish and } t_i = NN \text{ or } t_i = NNS) = \frac{8}{10} \end{cases}$$



NN	JJ	NNS	VB	NNP	...
$\frac{4}{10}$	$\frac{1}{10}$	$\frac{4}{10}$	$\frac{1}{10}$	0	...

➡ Supongamos:

$$\begin{cases} P(NN) + P(JJ) + P(NNS) + P(VB) = 1 \\ P(\text{word is zzfish and } t_i = NN \text{ or } t_i = NNS) = \frac{8}{10} \\ P(VB) = \frac{1}{20} \end{cases}$$



NN	JJ	NNS	VB
$\frac{4}{10}$	$\frac{3}{20}$	$\frac{4}{10}$	$\frac{1}{20}$


$$p^* = \underset{p \in \mathcal{C}}{\operatorname{argmax}} H(p)$$

Dist. de probabilidad que se modifica cuando añadimos restricciones (características) y que se adapta al conjunto de entrenamiento.

MaxEnt Markov Models (MEMM)

$$\begin{aligned}\hat{T} &= \operatorname{argmax}_T P(T|W) \\ &= \operatorname{argmax}_T P(W|T)P(T) = \operatorname{argmax}_T \prod_i P(\text{word}_i | \text{tag}_i) \prod_i P(\text{tag}_i | \text{tag}_{i-1})\end{aligned}$$


$$\begin{aligned}\hat{T} &= \operatorname{argmax}_T P(T|W) \\ &= \operatorname{argmax}_T \prod_i P(\text{tag}_i | \text{word}_i, \text{tag}_{i-1})\end{aligned}$$



Modelos Generativos vs. Discriminativos

$$P(Q|O) = \prod_{i=1}^n P(o_i | q_i) \times \prod_{i=1}^n P(q_i | q_{i-1})$$

$$P(Q|O) = \prod_{i=1}^n P(q_i | q_{i-1}, o_i) \quad P(q|q', o) = \frac{1}{Z(o, q')} \exp \left(\sum_i w_i f_i(o, q) \right)$$




Conditional Random Fields (CRF): (Lafferty, 2001) modelos condicionales o discriminativos.

Función de distribución de probabilidad similar a ME.

HMM-MEMM-CRF

MODELOS GENERATIVOS: maximización de la probabilidad conjunta.




$$p(y_t|y_{t-1})$$


$$p(x_t|y_t)$$

HMM:
$$p(\mathbf{X}, \mathbf{Y}) = \prod_{t=1}^T p(y_t|y_{t-1})p(x_t|y_t)$$

MODELOS DISCRIMINATIVOS: maximización de la probabilidad condicionada.



$$\text{MEMM: } p(\mathbf{Y}|\mathbf{X}) = \prod_{t=1}^T \frac{1}{Z(\mathbf{X}, t, y_{t-1})} \exp \left(\sum_a \lambda_a f_a(y_t, y_{t-1}, \mathbf{X}, t) \right)$$



$$\text{CRF: } p(\mathbf{Y}|\mathbf{X}) = \frac{1}{Z(\mathbf{X})} \prod_{t=1}^T \exp \left(\sum_a \lambda_a f_a(y_t, y_{t-1}, \mathbf{X}, t) \right)$$

Aprendizaje MEMM, CRF

- Definición de las **características relevantes** f_a para el problema.
- Estimación de parámetros λ_a : consiste maximizar la función de probabilidad sobre el conjunto de entrenamiento.
- Existen varios métodos:
 - Iterative Scaling
 - Gradient Descent
 - Newton's method
 - Quasi-Newton methods
 - ...


$$\text{MEMM: } p(\mathbf{Y}|\mathbf{X}) = \prod_{t=1}^T \frac{1}{Z(\mathbf{X}, t, y_{t-1})} \exp \left(\sum_a \lambda_a f_a(y_t, y_{t-1}, \mathbf{X}, t) \right)$$

MEMMs: Decodificación (Viterbi)

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) P(s_j | s_i) P(o_t | s_j) \quad 1 \leq j \leq N, 1 < t \leq T$$



$$v_t(j) = \max_{i=1}^N v_{t-1}(i) P(s_j | s_i, o_t) \quad 1 \leq j \leq N, 1 < t \leq T$$



Reglas de Transformación (Brill, 1992)

- Método supervisado (necesita corpus anotado)
- Aprende reglas contextuales correctoras a partir de plantillas predefinidas
- **Aprendizaje:**
 - Paso 1: Asignar a cada palabra su etiqueta POS más probable.
 - Paso 2: Se compara el corpus etiquetado con el corpus de referencia y se instancian las reglas que mejoran el etiquetado inicial.
 - Paso 3: Reetiquetar el corpus aplicando la mejor transformación.
 - Paso 4: Repetir pasos 1, 2 y 3 hasta que no se observen mejoras.
 - Resultado: lista ordenada de transformaciones
- **Etiquetado:**
 - Paso 1: Asignar a cada palabra su etiqueta POS más probable.
 - Paso 2: Reetiquetar el corpus aplicando la lista ordenada de transformaciones obtenida en el aprendizaje.

Reglas de Transformación (Brill, 1992)

- Ejemplo:
 - They are expected to **race** tomorrow.
 - The **race** for outer space.
- Plantilla:
 - T1 por T2, si la palabra precedente está etiquetada con T3
- Regla de transformación:
 - NN por VB, si la palabra precedente está etiquetada con TO
- Algoritmo de etiquetado:
 1. Asignar la etiqueta más probable. En el corpus Brown la etiqueta más probable para "race" es NN.
 - They are expected to **race/NN** tomorrow
 - The **race/NN** for outer space
 2. Aplicar la regla de transformación instanciada:
 - They are expected to **race/VB** tomorrow
 - The **race/NN** for outer space

Reglas de Transformación (Brill, 1992)

- Ejemplos de plantillas:

The preceding (following) word is tagged **z**.

The word two before (after) is tagged **z**.

One of the two preceding (following) words is tagged **z**.

One of the three preceding (following) words is tagged **z**.

The preceding word is tagged **z** and the following word is tagged **w**.

The preceding (following) word is tagged **z** and the word
two before (after) is tagged **w**.

Reglas de Transformación (Brill, 1992)

- Ejemplos de reglas aprendidas:

#	Change tags		Condition	Example
	From	To		
1	NN	VB	Previous tag is TO	to/TO race/NN → VB
2	VBP	VB	One of the previous 3 tags is MD	might/MD vanish/VBP → VB
3	NN	VB	One of the previous 2 tags is MD	might/MD not reply/NN → VB
4	VB	NN	One of the previous 2 tags is DT	
5	VBD	VBN	One of the previous 3 tags is VBZ	

Reglas de Transformación (Brill, 1992)

- Reglas contextuales aprendidas (20 primeras):

Change Tag			
#	From	To	Condition
1	NN	VB	Previous tag is <i>TO</i>
2	VBP	VB	One of the previous three tags is <i>MD</i>
3	NN	VB	One of the previous two tags is <i>MD</i>
4	VB	NN	One of the previous two tags is <i>DT</i>
5	VBD	VBN	One of the previous three tags is <i>VBZ</i>
6	VBN	VBD	Previous tag is <i>PRP</i>
7	VBN	VBD	Previous tag is <i>NNP</i>
8	VBD	VBN	Previous tag is <i>VBD</i>
9	VBP	VB	Previous tag is <i>TO</i>
10	POS	VBZ	Previous tag is <i>PRP</i>
11	VB	VBP	Previous tag is <i>NNS</i>
12	VBD	VBN	One of previous three tags is <i>VBP</i>
13	IN	WDT	One of next two tags is <i>VB</i>
14	VBD	VBN	One of previous two tags is <i>VB</i>
15	VB	VBP	Previous tag is <i>PRP</i>
16	IN	WDT	Next tag is <i>VBZ</i>
17	IN	DT	Next tag is <i>NN</i>
18	JJ	NNP	Next tag is <i>NNP</i>
19	IN	WDT	Next tag is <i>VBD</i>
20	JJR	RBR	Next tag is <i>JJ</i>

Reglas de Transformación (Brill, 1992)

- Reglas léxicas aprendidas (20 primeras).
- Tratamiento de palabras desconocidas.

Change Tag			
#	From	To	Condition
1	NN	NNS	Has suffix -s
2	NN	CD	Has character .
3	NN	JJ	Has character -
4	NN	VDN	Has suffix -ed
5	NN	VBG	Has suffix -ing
6	??	RB	Has suffix -ly
7	??	JJ	Adding suffix -ly results in a word.
8	NN	CD	The word \$ can appear to the left.
9	NN	JJ	Has suffix -al
10	NN	VB	The word would can appear to the left.
11	NN	CD	Has character 0
12	NN	JJ	The word be can appear to the left.
13	NNS	JJ	Has suffix -us
14	NNS	VBZ	The word it can appear to the left.
15	NN	JJ	Has suffix -ble
16	NN	JJ	Has suffix -ic
17	NN	CD	Has character 1
18	NNS	NN	Has suffix -ss
19	??	JJ	Deleting the prefix un- results in a word
20	NN	JJ	Has suffix -ive

Memory-Based Learning (MBL) (Daelemans 1996)

Se almacena en memoria el conjunto de entrenamiento estructurado como vectores de características y la categoría asociada al vector.

IB1-IG: “Overlap Metric” + “Gain Ratio”

$$D(X, Y) = \sum_{i=1}^n \omega_i \sigma(x_i, y_i)$$

$$\sigma(x_i, y_i) = \begin{cases} 0 & \text{si } x_i = y_i \\ 1 & \text{otro caso} \end{cases}$$

Para asignar pesos a las características




Etiquetado: problema de clasificación, una muestra se clasifica en términos de su similitud con los ejemplos almacenados

Lexicalized HMM (Pla, 2000)

Objetivo: incluir el léxico en el modelo contextual (ML) de manera selectiva

El/TD profesor/NC **que/PR** vino/VMI dijo/VMI al/SP alumno/NC **que/CS** callase/VMS ./Fp
 La/TD casa/NC donde/PR vivo/VMI es/VMI de/SP madera/NC ./Fp
 Llevo/VMI paraguas/NC cuando/CS llueve/VMI ./Fp

$$\mathcal{W}_e = \{\text{que}\} \Rightarrow \langle \text{que} / (\text{que}, \text{PR}) \rangle, \langle \text{que} / (\text{que}, \text{CS}) \rangle$$



Lexicalized HMM

$\Sigma = \{C_1, \dots, C_N\}$: conjunto de categorías léxicas.

$V = \{w_1, \dots, w_M\}$: conjunto de palabras o vocabulario de la aplicación.

$E \subset (V \times \Sigma)^*$: conjunto de aprendizaje.

$\mathcal{W}_e$: conjunto de palabras a especializar $\implies \hat{\Sigma} \subset ((\mathcal{W}_e \cup \lambda) \times \Sigma)$

■ **Función Especialización** $f_e : E \subset (V \times \Sigma)^* \rightarrow \hat{E} \subset (V \times \hat{\Sigma})^*$

$$f_e(< w_i, C_i >) = \begin{cases} < w_i, (w_i, C_i) > & \text{si } w_i \in \mathcal{W}_e \\ < w_i, (\lambda, C_i) > & \text{si } w_i \notin \mathcal{W}_e \end{cases}$$

■ **Función Inversa** $f_d : \hat{\Sigma} \rightarrow \Sigma$

$$f_d((w_i, C_i)) = C_i \text{ donde } w_i \in (\mathcal{W}_e \cup \lambda)$$

Criterio Lexicación $\mathcal{W}_e$: palabras más frecuentes, de difícil desambigüación, pertenecientes a categorías cerradas, etc.

Metodología de Evaluación

- **Paso 1**, Dividir el corpus en 3 partes:
 - Entrenamiento (*training*).
 - Desarrollo o ajuste (*development*).
 - Prueba (*test*).
- **Paso 2**, Ajustar los parámetros del modelo:
 - aprendiendo en el conjunto de entrenamiento y evaluándolo sobre el de desarrollo.
- **Paso 3**, Evaluar el modelo:
 - El mejor modelo obtenido en el paso 2 se evalúa sobre el conjunto de prueba para determinar las prestaciones reales.

Precisión (P) (*accuracy*):

$P = \text{Palabras Acertadas} / \text{Total de Palabras de Test}$

Metodología de Evaluación

Validación cruzada: para aumentar la fiabilidad de la evaluación del sistema

- **Paso 1**, Dividir aleatoriamente el corpus en n partes:
 - Usualmente $n=10$.
- **Paso 2**, Hacer n ejecuciones:
 - $n-1$ partes como entrenamiento.
 - 1 parte como prueba.
 - La parte de prueba es diferente en cada ejecución.
- **Paso 3**, Evaluar el modelo:
 - Calcular la precisión media de las distintas ejecuciones

Metodología de Evaluación

INTERVALO DE CONFIANZA: para validar el nivel de confianza de los resultados obtenidos.

- Intervalo de confianza (IC al 95%) para **un solo experimento**

$$IC = P \pm 1,96 \sqrt{\frac{P(1-P)}{N}}$$

donde P es la precisión y N el número de muestras del test

Ex: $P=0.97$, $N=100.000$; $IC=0.970 \pm 0.001$ ($97.0\% \pm 0.1$)

- Para un **Ten-fold cross-validation**

$$\overline{P} \pm 1,96 \sqrt{\frac{s^2}{10}}$$

donde $\overline{P}$ es la precisión media y s^2 es la varianza ($s_n^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \overline{y})^2$)

Evaluación

CORPORA UTILIZADOS

- **WSJ**

- *Penn Treebank* (1,170,000 palabras).
- Diccionario de 49,000 entradas.
- 34 % palabras ambiguas, 1.47 et/pal total, 2.40 et/pal sobre ambiguas.

- **LexEsp**

- 5,500,000 palabras etiquetadas con categorías PAROLE.
- 100,000 palabras supervisadas (vocabulario de 16,000).
- 39.8 % palabras ambiguas, 1.6 et/pal total, 2.6 et/pal sobre ambiguas.
- APRENDIZAJE: 65,000 palabras; PRUEBA: 25,000 palabras.

Evaluación

Corpus WSJ: MODELOS ESPECIALIZADOS [Pla, 2000] Tesis

Prueba: 100,000 palabras

Especialización: Palabras más frecuentes

Entrenamiento	% Precisión de Etiquetado	
#Palabras $\times 10^3$	BIG	BIG _{esp}
50	96.32	96.49
100	96.57	96.82
150	96.72	96.99
200	96.77	97.08
300	96.84	97.18
400	96.87	97.23
500	96.88	97.24
600	96.91	97.25
700	96.91	97.30

Evaluación

Corpus LexEsp: MODELOS ESPECIALIZADOS

Aprendizaje: 65,000 palabras, Prueba: 25,000 palabras

Especialización: Palabras más frecuentes (94 palabras)

BIG	96.97 % (762 errores)
BIG _{esp}	97.42 % (648 errores)

Palabra	Frecuencia		Nº Errores		Mejora
	Train	Test	BIG	BIG _{esp}	
<i>que</i>	1680	709	109	83	26 (23.9 %)
<i>los</i>	1188	371	17	11	6 (35.3 %)
<i>lo</i>	268	140	53	13	40 (28.6 %)
<i>la</i>	2530	869	12	7	7 (41.6 %)
<i>las</i>	743	270	4	3	1 (25.0 %)

Evaluación

COMPARACIÓN CON OTRAS APROXIMACIONES
(mismas condiciones experimentales [Pla et al., 2001])

Sobre el Corpus LexEsp

Método	Precisión (%)
TT [Màrquez, 1999]	97.00 %
RB	97.30 %
RT [Padró, 1998]	97.20 %
RBT	97.40 %
BIG	96.97 %
BIGesp	97.42 %

Sobre el Corpus WSJ

TT [Màrquez, 1999]	97.29 %
BIGesp	97.30 %

Evaluación (Pla and Molina, 2004)

Corpus: WSJ


Training set: secciones de 00 a 19

Test set: secciones 23 y 24

Tagger: TnT con opciones por defecto

Uso de criterios de lexicalización

[We] 200 286 200 31	Model	Precision
	BIG	96.28 %
	BIG-SCC	96.52 %
	BIG-SWF	96.71 %
	TRI	96.58 %
	TRI-SCC	96.77 %
	TRI-SWF	96.80 %




Evaluación (Pla and Molina, 2004)

COMPARACIÓN CON OTRAS APROXIMACIONES

Ordenador: Pentium 266Mhz, 256MB RAM

Tagger	Precision	Training	Testing
TRI-SFW (Brants,00)+ Lex	96.80 %	20 sec.	18,000 w/s
ME (Ratnaparkhi,96)	96.92 %	1 day	70 w/s
TBL(Brill,95)	96.47 %	9 days	750 w/s
MBL(Zavrel & Daelemans,99)	96.45 %	4.5 min.	11,200 w/s



10-fold cross-validation: TRI-SFW(96.58%) ME(96.63%)

Referencias

- (Jurafsky,2000) Jurafsky, D., Martin, J.H. Speech and Language Processing. Pearson International Edition. 2009.
- (Pla, 2000) F. Pla. *Etiquetado Léxico y Análisis Sintáctico Superficial basado en Modelos Estadísticos*. Phd. Thesis. Dep. de Sistemes Informàtics i Computació. Universitat Politècnica de València. 2000.
- (Brants, 2000) T. Brants. TnT - a statistical part-of-speech tagger. In *Proceedings of the Sixth Applied Natural Language Processing (ANLP-2000)*, Seattle, WA. 2000.
- (Pla F. and Molina A, 2004). Improving part-of-speech tagging using Lexicalized HMMs. *Natural Language Engineering* 10(2). Cambridge University Press. UK.
- (Lafferty, 2001) J. Lafferty, A. McCallum, and F. Pereira. Conditional random fields: Probabilistic models for segmenting and labeling sequence data. In *Proceedings of 18th International Conference on Machine Learning*, pages 282–289, 2001.
- (Ratnaparkhi, 1996) Ratnaparkhi, A. (1996). A Maximum Entropy Part-of-speech Tagger. In *Proceedings of the 1st Conference on Empirical Methods in Natural Language Processing, EMNLP*.
- (Daelemans et al., 1996) Daelemans, W., Zavrel, J., Berck, P., and Gillis, S. (1996). MBT: A Memory-Based Part-of-speech Tagger Generator. In *Proceedings of the 4th Workshop on Very Large Corpora*, pages 14–27, Copenhagen, Denmark.
- (Brill, 1995) E. Brill. Transformation-based Error-driven Learning and Natural Language Processing: A Case Study in Part-of-speech Tagging. *Computational Linguistics*, 21(4). 1995

Métodos Combinados

- **Mayoría simple** es la más sencilla y consiste en asignar un peso uniforme (1) a cada etiqueta.
- **Precisión total:** la idea es dar más peso al etiquetador de mayor calidad. Para ello se asigna como peso la precisión total del etiquetador. Esta precisión se debe calcular previamente sobre un conjunto de desarrollo.
- **Precisión por etiqueta:** en este caso se da más peso al etiquetador de mayor calidad en la identificación de un tipo determinado de etiqueta. Para ello se pondera con la precisión del etiquetador para esa etiqueta.
- **Precisión-Cobertura por etiqueta:** se tiene en cuenta también cuánto falla el etiquetador al reconocer la etiqueta correcta. El peso se calcula sumando a la precisión del etiquetador para una etiqueta determinada, la probabilidad de que los otros etiquetadores fallen al detectar esa etiqueta, es decir, el peso es $\text{precisión} + (1 - \text{cobertura})$.
- **Pairwise:** en lugar de considerar la información de cada etiquetador de forma individual, se examina ésta por parejas. Sobre un conjunto de desarrollo se calcula la probabilidad de que la etiqueta correcta sea t cuando dos etiquetadores proponen t_1 y t_2 , respectivamente. La votación se realiza por parejas ponderando con esa probabilidad.