

Tema 5. Word Sense Disambiguation



Lingüística Computacional
Ferran Pla

Introducción

- WSD es el problema de determinar computacionalmente cuál es el sentido correcto de una palabra en un **contexto**.
- Es un problema de **clasificación** (o etiquetado).
 - Asignar a una palabra un sentido (clase).
 - Cada palabra tiene un núm. finito de sentidos (recogidos en un diccionario)
- Gran **complejidad** ¿Por qué?
 - P.e. Las 120 palabras inglesas más frecuentes → 7,8 sentidos de media en WordNet
 - Sentido?, Contexto? Recursos? Evaluación? ...
- WSD es un **problema abierto** en PLN
- WSD explícita: módulo genérico de desambiguación.
- WSD implícita: particular de cada aplicación.
- **¡ Pero, no se ha demostrado suficientemente su utilidad en aplicaciones reales !**
 - Escasez de recursos adaptados a dominios (diccionarios o corpora) y de desarrollo de técnicas que faciliten esa adaptación.
 - WSD explícita no ofrece tasas de acierto suficientemente altas.

Información útil para WSD (Aguirre and Stevenson, 2006)

- Sintaxis
 - Etiqueta POS
 - Bajo/NC bajo/ADJ bajo/PREP bajo/VB
 - Morfología
 - tin en plural sólo puede tener el sentido de caja de metal
 - Colocaciones
 - mesa electoral, river bank
 - Subcategorización
 - to grow:
 - intransitivo: John grew quickly
 - transitivo: John grew the plants
- Semántica
 - Frecuencia de sentidos
 - Asociaciones semánticas
 - El gato maúlla
 - Cherry is a type of tree common in Japan (hiperonimia)
 - Restricciones seleccionales
 - Juan toca el bajo en la banda
- Pragmática
 - Dominios, Conocimiento del mundo
 - Dominio financiero: banco tiene el sentido de entidad financiera

Recursos Lingüísticos

- Corpora
 - Semcor (corpus supervisado)
- Dicionarios
- WordNet (English) y EWN


- WordNet: BD léxica (ontología) N, V, Adj, Adv
- Las palabras sinónimas se agrupan para formar conjuntos de sinónimos o SYNSETS
- Cada synset tiene asociado una definición o glosa
- Los synsets están conectados entre sí a través de relaciones semánticas explícitas que están definidas en WordNet
- Estas relaciones conectan principalmente sentidos de palabras que pertenecen a la misma categoría gramatical (POS tag), aunque existen algunas relaciones entre distintas categorías N-Adj, V-Adj

Overview of noun tree


The noun tree has 2 senses (first 1 from tagged texts)

1. {09396070} <noun.plant> tree --
{a tall perennial woody plant having a main trunk and branches forming a distinct elevated crown; includes both gymnosperms and angiosperms}
2. {10025462} <noun.shape> tree, tree diagram --
{a figure that branches from a single root; "genealogical tree"}

WORDNET



WORDNET relaciones



Recursos Semánticos

- WordNet EWN

<http://adimen.si.ehu.es/cgi-bin/wei/public/wei.consult.perl>

- BabelNet

<https://babelnet.org/>

- ConceptNet

<http://conceptnet.io/>

- Dbpedia

<https://wiki.dbpedia.org/>

- Word Embeddings

<https://projector.tensorflow.org/>

Aproximaciones

- **Basadas en conocimiento** (tesauros, diccionarios, reglas):
 - Solapamiento del contexto de una palabra con glosas.
 - Medidas de similitud semánticas.
 - Heurísticas.
 - Preferencias seleccionales adquiridas (semi) automáticamente.
- **Basadas en corpus, NO supervisadas:**
 - Agrupamiento de palabras en diferentes contextos.
 - Corpus paralelos alineados (traducción automática).
- **Basadas en corpus, Supervisadas:**
 - Aprendizaje automático o estadístico sobre corpus anotados.
 - Técnicas de bootstrapping o semisupervisadas.
- **Otras:**
 - Métodos combinados
 - Conocimiento del dominio

Aproximaciones WSD (Knowledge-based)

- Se usa información de léxicos o bases de conocimiento
 - Machine-readable dictionary (Longman Dictionary of Contemporary English)
 - Thesaurus (Rodget's Thesaurus)
 - Bases de datos de conocimiento léxico (WordNet)
 - ...
- Ejemplos:
 - (Lesk 1986) (Yarowsky 1992) (Voorhee 1993) (Resnik 1995) (Agirre & Rigau 1996) (Stevenson & Wilks 2001) ...

Aproximaciones WSD (Knowledge-based)

Ejemplo (Lesk) :

BANCO:


- Asiento, con respaldo o sin él, en que pueden **sentarse** varias personas.
- Madero grueso escuadrado que se coloca horizontalmente sobre cuatro pies y sirve como de mesa para muchas labores de los carpinteros, cerrajeros, herradores y otros artesanos.
- Conjunto de **peces** que van juntos en gran número.
- Establecimiento público de crédito, constituido en sociedad por acciones.

Contextos:

- a) El pescador está **sentado** en un banco sobre cubierta.
Solapamiento(1)=1
Solapamiento(2)=Solapamiento(3)=Solapamiento(4)=0
- b) El pescador dividió un banco de **peces**.
Solapamiento(3)=1
Solapamiento(1)=Solapamiento(2)=Solapamiento(4)=0

Basadas en WordNet

Densidad Conceptual (Agirre & Rigau 96)



1. Se identifican todos los nodos que corresponden a los distintos sentidos de la palabra a desambiguar W y de las palabras del contexto.
2. Se mide la densidad conceptual alrededor de cada sentido de W
3. Se elige el sentido con la mayor densidad

Machine Learning Supervised Approaches

- Definir un vector de **características** ($\vec{f}$) para predecir el correcto sentido de una palabra
- Usualmente se usan 2 clases de características
 - **Collocations**: importa la posición de la característica respecto a la palabra a desambiguar
 - Ej: $W_{i-2}, P_{i-2}, W_{i-1}, P_{i-1}, w_i, W_{i+1}, P_{i+1}, W_{i+2}, P_{i+2}$
 - **Bag-of_Words**: no importa la posición
 - Ej: $(w_1, w_2, w_3, w_4, \dots, w_{n-1}, w_N) \rightarrow (0, 1, 1, 0, \dots, 1, 0)$

Clasificador Naïve Bayes

La aproximación de Naïve Bayes para WSD consiste en encontrar el mejor sentido $\hat{s}$ del conjunto de sentidos S para un vector de características $\vec{f}$

$$\hat{s} = \operatorname{argmax}_{s \in S} P(s|\vec{f})$$

Para estimar el vector $\vec{f}$ hay que hacer simplificaciones.

Ejemplo: Si definimos un vector de 20 palabras, tendríamos 2^{20} posibles vectores de características, considerando características binarias

$$\hat{s} = \operatorname{argmax}_{s \in S} \frac{P(\vec{f}|s)P(s)}{P(\vec{f})}$$

Simplificación: Las características son independientes unas de otras

$$P(\vec{f}|s) \approx \prod_{j=1}^n P(f_j|s)$$

$$\hat{s} = \operatorname{argmax}_{s \in S} P(s) \prod_{j=1}^n P(f_j|s)$$

$$P(s_i) = \frac{\text{count}(s_i, w_j)}{\text{count}(w_j)}$$

$$P(f_j|s) = \frac{\text{count}(f_j, s)}{\text{count}(s)}$$

WSD -- HMM

Planteamiento general del problema

$$\begin{aligned}\hat{S} &= \arg \max_S P(S|W) \\ &= \arg \max_S \left(\frac{P(S) \cdot P(W|S)}{P(W)} \right); S \in \mathcal{S}^T\end{aligned}$$

$$\arg \max_S \left(\prod_{i:1 \dots T} P(s_i | s_{i-1}) \cdot P(w_i | s_i) \right)$$

WSD -- HMM

A. Molina, F. Pla, E. Segarra. A Hidden Markov Model Approach to Word Sense Disambiguation. IBERAMIA 2002. Sevilla.

- Principales características
 - Método supervisado
 - Criterios de selección y especialización
 - HMM especializado

WSD – HMM Selección categorías (sentidos)

Overview of noun tree

The noun tree has 2 senses (first 1 from tagged texts)

1. {09396070} <noun.plant> tree --
(a tall perennial woody plant having a main trunk
and branches forming a distinct elevated crown;
includes both gymnosperms and angiosperms)
2. {10025462} <noun.shape> tree, tree diagram --
(a figure that branches from a single root;
"genealogical tree")

Overview of verb tree

The verb tree has 1 sense (no senses from tagged texts)

1. {00777894} <verb.competition> tree --
(chase a bear up a tree with dogs and kill it)

POS(1,2,3,4) **lex_sense**

lema

sense_key	synset	n.rel.	frec
tree%1:20:00::	09396070	1	107
tree%1:25:00::	10025462	2	0
tree%2:33:00::	00777894	1	0

Categoría	sense_key	synsets	lex_senses
Nombres	116,317	66,025	155
Verbos	22,066	12,127	217
Adjetivos	8,950	7,003	20
Adverbios	5,677	3,575	16
Adj. Satélites	20,931	10,912	3,355
Total	173,941	99,330	3,763

WSD – HMM especializados

Selección de rasgos relevantes

Se aprende un modelo de BIGRAMAS.

- Suavizado por interpolación lineal con unigramas.
- Uso de WORDNET.
- Selección Entrada:
 - * lema.POS (palabras con sentido en WordNet)
 - * lema (palabras sin sentido en WordNet)
- Especialización:
 - * lema.lex-sense (para lemas frecuentes)
 - * lex-sense (en general)
 - * lema.notag (palabras que no estan en WordNet)

WSD – HMM especializados

Selección de rasgos

$\mathcal{T}$				$\xrightarrow{f}$	$\tilde{\mathcal{T}}$	
$\mathcal{R}_1$ (Palabras)	$\mathcal{R}_2$ (Lemas)	$\mathcal{R}_3$ (POS)	$\mathcal{O}$ (Sentidos)		$\tilde{\mathcal{I}}$	$\tilde{\mathcal{O}}$
There	there	EX	notag		there·EX	notag
is	be	VB	2:42:00::		be·VB	2:42:00::
a	a	DT	notag		a·DT	notag
lack	lack	NN	1:26:00::		lack·NN	1:26:00::
of	of	IN	notag		of·IN	notag
interest	interest	NN	1:09:00::		interest·NN	interest·1:09:00::
on	on	IN	notag		on·IN	notag
the	the	DT	notag		the·DT	notag
part	part	NN	1:09:02::		part·NN	1:09:02::
of	of	IN	notag		of·IN	notag
the	the	DT	notag		the·DT	notag
community	community	NN	1:14:00::		community·NN	1:14:00::

WSD – HMM especializados Evaluación

Molina, A, Pla, F., Segarra, E. 2002. *Word Sense Disambiguation using Statistical Models and WordNet*. LREC2002

- Corpus: SEMCOR (186 ficheros contenidos en Brown1 y Brown2)
- 413.506 palabras (220.867 con etiqueta semántica)
- Desambigua todas las palabras (nombres, verbos, adjetivos y adverbios)

Model	Precision
UNI	43.03%
UNIpos	54.06%
UNIesp	62.86%
BIG	65.49%
BIGpos	70.04%
BIGesp	70.36%
Baseline	70.79%

Resultados (Ten-fold cross validation)
para palabras polisémicas en Semcor

WSD – HMM especializados Evaluación

- TAREA: Desambiguación de 16 palabras(lexical-sample) sobre *SemCor*

Palabras = {account, age, art, car, child, church, cost, duty, head, interest, line, member, people, term, test, work}

Modelo	Precision	Recall	Cobertura
Marcas de Especificidad*	40.4%	39.5%	97.8%
Densidad Conceptual*	39.3%	35.3%	93.6%
Máxima Entropía*	63.8%	61.4%	96.3%
Bigrama	53.6%	53.6%	100.0%
Bigrama Lexicalizado + Wordnet	60.0%	60.0%	100.0%

Lexical-sample ten-fold cross validation

Modelo	Precision	Recall	Cobertura
Máxima Entropía*	58.6%	47.3%	80.5%
Bigrama	57.5%	57.5%	100.0%
Bigrama Lexicalizado + Wordnet	58.3%	58.3%	100.0%

*Resultados extraídos de Montoyo, A. Suárez. A y Palomar, M. Combining Supervised-Unsupervised Methods for WSD. CICLING 2002.

WSD – HMM especializados Evaluación


- Evaluación sobre *Senseval-2*

Model	Precision
UNI	40.00%
UNIpos	52.30%
UNIesp	58.80%
BIG	50.10%
BIGpos	58.20%
BIGesp	60.20%


Tabla 2: Precision results for the *English all-words* task in *Senseval-2*. 100% of the words were tagged.

- *Senseval-2* Results:
 - 1 HYBRID –heuristics– (Rada Mihalcea): 69.0%
 - 2 VOTING –MBL, rule induction, ...–(Veronique Hoste): 63.6%
 - 3 HMM+classification trees (Crestan, Beze, Loupy): 61.8%
 - 4 UNSUPERVISED (Amorós): 56.9%


Senseval2 (English All Words)



Senseval2 (English Lexical Sample)



Senseval2 (Spanish)



Evaluación sistemas WSD

- Senseval3 (2004) www.senseval.org:

Language	Task ^a	Systems	Lemmas	Instances	ITA ^b	Baseline ^c	Best score
English	AW	26	–	2,081	62%	62%/– ^d	65%/58%
Basque	LS	8	40	7,362	78	59	70
Catalan	LS	7	27	6,721	93	66	85
English	LS	47	57	–	67	55/–	73/66
Italian	LS	6	45	7,584	89	18	53
Romanian	LS	7	39	11,532	–	58	73
Spanish	LS	9	46	12,625	83–90	67	84
Hindi	TM	8	41	11,984	–	56	67
English	GL	10	–	42,491	–	–	68

Copyright © 2004, Association for Computational Linguistics. Reproduced with permission of the Association for Computational Linguistics and Mihalcea and Edmonds.

^aAW all-words, LS lexical sample, TM translation memory, GL gloss task.

^bITA is inter-tagger agreement.

^cThe baseline is most-frequent sense.

^dScores separated by a slash are supervised/unsupervised methods; supervised when there is no slash.

WSD – HMM especializados Evaluación

Senseval3 (2004)

System	Precision	Recall
GAMBL-AW-S	.651	.651
SenseLearner-S	.651	.642
Koc University-S	.648	.639
R2D2: English-all-words	.626	.626
Meaning-allwords-S	.625	.623
Meaning-simple-S	.611	.610
LCCaw	.614	.606
upv-shmm-eaw-S	.616	.605
UJAEN-S	.601	.588
IRST-DDD-00-U	.583	.582
University of Sussex-Prob5	.585	.568
University of Sussex-Prob4	.575	.550
University of Sussex-Prob3	.573	.547
DFA-Unsup-AW-U	.557	.546
KUNLP-Eng-All-U	.510	.496
IRST-DDD-LSI-U	.661	.496
upv-unige-CIAOSENSE-eaw-U	.581	.480
merl.system3	.467	.456
upv-unige-CIAOSENSE2-eaw-U	.608	.451
merl.system1	.459	.447
IRST-DDD-09-U	.729	.441
autoPS-U	.490	.433
chr04-aw	.506	.431
autoPSNVs-U	.563	.354
merl.system2	.480	.352
DLSI-UA-all-Nosu	.343	.275

Referencias

- (Aguirre & Edmonds 2006) E. Aguirre and P. Edmonds. *Word Sense Disambiguation: Algorithms and Applications*. Springer Verlag. 2006.
- (Aguirre & Rigau 1996) Agirre, E., Rigau, G. Word Sense Disambiguation Using Conceptual Density. In *Proceedings of the 16th International Conference on Computational Linguistics, COLING*, Copenhagen, Denmark.
- (Aguirre & Stevenson 2006) E. Aguirre and M. Stevenson. *Knowledge Sources for WSD*. Word Sense Disambiguation: Algorithms and Applications. Springer Verlag. 2006.
- (Cowie, Guthrie & Guthrie, 1992) Lexical disambiguation using simulated annealing. *Proceedings of COLING*. Nantes, France, pp 157-161. 1992.
- (Escudero, Marquez & Rigau 2000) Escudero, G., Marquez, L., Rigau, G. A comparison between supervised learning algorithms for Word Sense Disambiguation. In *Proceedings of CoNLL-2000 and LLL-2000*, Lisbon, Portugal (2000)
- (Ide & Veronis 1998) N. Ide and J. Véronis. 1998. *Word Sense Disambiguation: The State of the Art*. *Computational Linguistics*. 24(1). pp 1-40
- (Lesk 1986) Lesk, M. *Automated Sense Disambiguation using Machine-readable Dictionaries: How to tell a pine cone from an ice cream cone*. In *Proceedings of the 1986 SIGDOC Conference*, Toronto, Canada. (1986) pp 24-26
- (Loupy 1998) Loupy, C., El-Beze, M., Marteau, P.F. *Word Sense Disambiguation using HMM Tagger*. In: *Proceedings of the 1st International Conference on Language Resources and Evaluation, LREC*, Granada, Spain (1998) pp 1255-1258
- (Molina, Pla, Segarra 2002) A. Molina, F. Pla, E. Segarra. *A Hidden Markov Model Approach to Word Sense Disambiguation*. IBERAMIA 2002. Sevilla.
- (Ng 1997) Ng, H.T. *Exemplar-Base Word Sense Disambiguation: Some Recent Improvements*. In *Proceedings of the 2nd Conference on Empirical Methods in Natural Language Processing, EMNLP*.
- (Resnik 1995) Resnik, P.S. *Using Information Content to Evaluate Semantic Similarity in a Taxonomy*. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence, IJCAI*, Montreal, Canada (1995) pp 448—453.

Refererencias

- (Resnik & Yarowski 2000) P. S. Resnik and D. Yarowsky. 2000. *Distinguishing systems and distinguishing senses: new evaluation methods for Word Sense Disambiguation*. Natural Language Engineering. 6(3): pp 113-133.
- (Sanderson 1994) Sanderson, M. *Word Sense disambiguation and information retrieval*. Proceedings of the 17th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, Dublin, Ireland, pp 142-151. 1994.
- (Segond et. al. 1997) Segond, F., Schiller, A., Grefenstette, G., Chanod, J.P.: *An Experiment in Semantic Tagging using Hidden Markov Model Tagging*. In Proceedings of the Joint ACL/EACL Workshop on Automatic Information Extraction and Building of Lexical Semantic Resources, Madrid, Spain(1997) pp. 78--81
- SENSEVAL <http://www.senseval.org/>
- (Stevenson & Wilks 2001) Stevenson, M., Wilks, Y. *The Interaction of Knowledge Sources in Word Sense Disambiguation*. Computational Linguistics, 27 (2001) pp. 21-349
- (Vasilescu, Langlais & Lapalme, 2004). Vasilescu, F., Langlais, P., Lapalme, G. Evaluating variants of the Lesk approach for disambiguating words. Proceedings of LREC, Lisbon, Portugal, pp 663-636. 2004
- (Voorhee 1993) Voorhees, E. *Using WordNet to Disambiguate Word Senses for Text Retrieval*. In Proceedings of the 16th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, Pittsburgh. (1993) pp. 171--180
- (Yarowsky 1992) Yarowsky, D. *Word-sense Disambiguations Using Statistical Models of Roget's Categories Trained on Large Corpora*. In Proceedings of the 14th International Conference on Computational Linguistics, COLING, Nantes, France (1992) pp 454--460
- (Yarowsky 1994) Yarowsky, D. *Decision Lists for Lexical Ambiguity Resolution: Application to Accent Restoration in Spanish and French*. In: Proceedings of the 32nd Annual Meeting of the Association for Computational Linguistics, Las Cruces, NM, ACL (1994) pp 88-95
- (Yarowsky 1995) Yarowsky, D. *Unsupervised word sense disambiguation rivaling supervised methods*. ACL. pp 189-196