



LINGÜÍSTICA COMPUTACIONAL

Lingüística Computacional

- Se ocupa de la formulación e investigación de mecanismos computacionales para la comunicación entre personas y ordenadores, haciendo uso de lenguajes naturales.
- La asignatura presenta una introducción al procesamiento del lenguaje natural y al modelado del lenguaje.
- Se estudian los problemas de ambigüedad y las principales soluciones desde el punto de vista lingüístico y estadístico.

OBJETIVOS:

- Explicar y manejar las técnicas básicas del procesamiento y modelado del lenguaje natural. Entender sus aplicaciones.

OTROS TÉRMINOS:

- Procesamiento del Lenguaje Natural
- Tecnologías del Lenguaje
- Ingeniería lingüística

Lingüística Computacional

DISCIPLINAS:

- **Informática** para implementar modelos computables
- **Lingüística** para proporcionar modelos del lenguaje humano
- **Teoría de la Información** para proporcionar modelos de la comunicación
- **Matemáticas y Estadística** para proporcionar herramientas para analizar y adquirir tales modelos
- **Teoría de la señal** para el procesamiento de la señal vocal cuando interviene en el proceso comunicativo

Módulo 1: Fundamentos (Obligatorio)

Materia: Técnicas Fundamentales
12c.

GRÁFICOS POR
COMPUTADOR

LINGÜÍSTICA
COMPUTACIONAL

TECNICAS DE INTELIGENCIA
ARTIFICIAL

RECONOCIMIENTO DE
FORMAS Y APRENDIZAJE
COMPUTACIONAL

Módulo 2: Especialización (3 materias de 4)

Materia: Tecnologías del
Lenguaje (9 cr)

APLICACIONES DE LA
LINGÜÍSTICA
COMPUTACIONAL

RECONOCIMIENTO
AUTOMÁTICO DEL HABLA

TRADUCCIÓN AUTOMÁTICA

Lingüística Computacional

APLICACIONES:

- Interfaces inteligentes y multimodales: sistemas de diálogo hablado, control oral de dispositivos, dictado automático.
- Reconocimiento de escritura manuscrita y de documentos antiguos.
- Gestión documental: recuperación y extracción de información, búsqueda de respuestas, clasificación de documentos, análisis de sentimientos, detección de ironía en opiniones, detección de plagio, etc.

Lingüística Computacional

❑ Modelos de lenguaje

- Modelos de lenguaje y evaluación
- Modelos estadísticos y técnicas de suavizado
- Modelos gramaticales y otros
- Herramientas de modelización del lenguaje

❑ Problemas de ambigüedad en procesamiento del lenguaje natural

- Etiquetado Morfosintáctico
- Análisis sintáctico
- Desambiguación semántica

❑ Recursos lingüísticos

❑ Manipulación de documentos con **python** y **nltk** (laboratorio)

Lingüística Computacional

❑ BIBLIOGRAFÍA Y CONGRESOS

- [bibliografía](#)
- [recursos](#)

Lingüística Computacional

□ EVALUACIÓN

• Trabajo práctico 50%

- El alumno deberá realizar el trabajo que se propondrá a lo largo del curso.
- Alternativamente, se podrá realizar un trabajo diferente, dentro del área de la asignatura, previo acuerdo con alguno de los profesores.
- Este trabajo se realizará en grupos de uno o dos alumnos.
- Se realizará una presentación breve (5 minutos aprox.) presencial (27 de octubre, por la tarde), y se entregará una memoria escrita del trabajo.


• Examen escrito de conceptos básicos 30%


- El examen se realizará el día 17 de octubre 2022 y constará de preguntas de carácter general sobre los contenidos impartidos.

• Seguimiento del laboratorio 20%

- Se realizará un seguimiento en las prácticas de laboratorio consistente en al menos dos entregas de los ejercicios prácticos propuestos

Sistema de Reconocimiento Automático del Habla





Modelos de lenguaje causales (RNNLM)






Figure 9.6 Training RNNs as language models.

Representaciones vectoriales de las palabras


Propiedad de los embeddings: capturan relaciones semánticas

$\text{vector}('king') - \text{vector}('man') + \text{vector}('woman') \approx \text{vector}('queen')$

$\text{vector}('Paris') - \text{vector}('France') + \text{vector}('Italy') \approx \text{vector}('Rome')$



Ejemplo de ambigüedad en PLN




HMM: representación

POS TAGGING

ENTRADA

Este río está seco

D	V	V	V
P	N		A
N			



SALIDA

Este río está seco


D N V A

CHUNKING

ENTRADA

Este río está seco

D N V A



SALIDA

Este río está seco

B_SN I_SN B_SV O

HMM: proceso de etiquetado





Figura 1: Representación de las secuencias de categorías léxicas posibles para la frase "Este río está seco".

Ejemplo de derivación

Un árbol de derivación para la oración: *I prefer a morning flight*



En notación parentizada este árbol de derivación es:



[S [NP [Pro I]] [VP [Verb prefer] [NP [Det a] [Nom [Nom [Noun morning]] [Noun flight]]]]]

Ejemplo de gramática estocástica ambigua

$S \rightarrow NP VP$	[.80]
$S \rightarrow Aux NP VP$	[.15]
$S \rightarrow VP$	[.05]
$NP \rightarrow Pronoun$	[.35]
$NP \rightarrow Proper-Noun$	[.30]
$NP \rightarrow Det Nominal$	[.20]
$NP \rightarrow Nominal$	[.15]
$Nominal \rightarrow Noun$	[.75]
$Nominal \rightarrow Nominal Noun$	[.20]
$Nominal \rightarrow Nominal PP$	[.05]
$VP \rightarrow Verb$	[.35]
$VP \rightarrow Verb NP$	[.20]
$VP \rightarrow Verb NP PP$	[.10]
$VP \rightarrow Verb PP$	[.15]
$VP \rightarrow Verb NP NP$	[.05]
$VP \rightarrow VP PP$	[.15]
$PP \rightarrow Preposition NP$	[1.0]

$Det \rightarrow that$	[.10]		a	[.30]		the	[.60]
$Noun \rightarrow book$	[.10]		$flight$	[.30]			
			$meal$	[.15]		$money$	[.05]
			$flights$	[.40]		$dinner$	[.10]
$Verb \rightarrow book$	[.30]		$include$	[.30]			
			$prefer$	[.40]			
$Pronoun \rightarrow I$	[.40]		she	[.05]			
			me	[.15]		you	[.40]
$Proper-Noun \rightarrow Houston$	[.60]						
			TWA	[.40]			
$Aux \rightarrow does$	[.60]		can	[.40]			
$Preposition \rightarrow from$	[.30]		to	[.30]			
			on	[.20]		$near$	[.15]
			$through$	[.05]			

Ejemplo de gramática ambigua: “Book the dinner flight”



Rules			P	Rules			P
S	→	VP	.05	S	→	VP	.05
VP	→	Verb NP	.20	VP	→	Verb NP NP	.10
NP	→	Det Nominal	.20	NP	→	Det Nominal	.20
Nominal	→	Nominal Noun	.20	NP	→	Nominal	.15
Nominal	→	Noun	.75	Nominal	→	Noun	.75
Verb	→	book	.30	Nominal	→	Noun	.75
Det	→	the	.60	Verb	→	book	.30
Noun	→	dinner	.10	Det	→	the	.60
Noun	→	flights	.40	Noun	→	dinner	.10
				Noun	→	flights	.40

Recursos lingüísticos

```
\data\  
ngram 1=1447  
ngram 2=9420  
ngram 3=5201  
  
\1-grams:  
-0.8679678 </s>  
-99 <s> -1.068532  
-4.743076 chow-fun -0.1943932  
-4.266155 fries -0.5432462  
-3.175167 thursday -0.7510199  
-1.776296 want -1.04292  
...  
  
\2-grams:  
-0.6077676 <s> i -0.6257131  
-0.4861297 i want 0.0425899  
-2.832415 to drink -0.06423882  
-0.5469525 to eat -0.008193135  
-0.09403705 today </s>  
...  
  
\3-grams:  
-2.579416 <s> i prefer  
-1.148009 <s> about fifteen  
-0.4120701 to go to  
-0.3735807 me a list  
-0.260361 at jupiter </s>  
-0.260361 a malaysian restaurant  
...  
\end\
```

Figure 4.10 ARPA format for N -grams, showing some sample N -grams. Each is represented by a *logprob*, the word sequence, $w_1 \dots w_n$, followed by the log backoff weight α . Note that no α is computed for the highest-order N -gram or for N -grams ending in $\langle s \rangle$.

Recursos lingüísticos

En el Penn Treebank se proporciona un corpus en el cual cada oración está anotada sintácticamente con su árbol de derivación. En particular se anotan los siguientes corpus del inglés: Brown, Switchboard, ATIS, and Wall Street Journal.

<pre>((S (NP-SBJ (DT That) (JJ cold) (, ,) (JJ empty) (NN sky)) (VP (VBD was) (ADJP-PRD (JJ full) (PP (IN of) (NP (NN fire) (CC and) (NN light))))) (. .)))</pre>	<pre>((S (NP-SBJ The/DT flight/NN) (VP should/MD (VP arrive/VB (PP-TMP at/IN (NP eleven/CD a.m/RB)) (NP-TMP tomorrow/NN)))))</pre>
(a)	(b)

Figure 12.7 Parsed sentences from the LDC Treebank3 version of the Brown (a) and ATIS (b) corpora.

El Proyecto Penn Treebank

```
( (S (`` ``)
  (S-TPC-2
    (NP-SBJ-1 (PRP We) )
    (VP (MD would)
      (VP (VB have)
        (S
          (NP-SBJ (-NONE- *-1) )
          (VP (TO to)
            (VP (VB wait)
              (SBAR-TMP (IN until)
                (S
                  (NP-SBJ (PRP we) )
                  (VP (VBP have)
                    (VP (VBN collected)
                      (PP-CLR (IN on)
                        (NP (DT those) (NNS assets) ))))))))))))
    (, ,) (`` ``)
    (NP-SBJ (PRP he) )
    (VP (VBD said)
      (S (-NONE- *T*-2) ))
    (. .) ))
```

Figure 12.9 A sentence from the Wall Street Journal portion of the LDC Penn Treebank. Note the use of the empty -NONE- nodes.