



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Introducción (actividades)

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

1.1 ¿Qué es aprendizaje automático?	1
1.2 Aprendizaje supervisado	4
1.2.1 Clasificación	4
1.2.1.1 Ejemplo: clasificación de flores iris	4
1.2.1.2 Análisis exploratorio de datos	6
1.2.1.3 Aprendizaje de un clasificador	8
1.2.1.4 Minimización del riesgo empírico	9
1.2.1.5 Incertidumbre	10
1.2.1.6 Estimación por máxima verosimilitud	11
1.2.2 Regresión	12
1.2.2.1 Regresión lineal	13
1.2.2.2 Regresión polinómica	15
1.2.2.3 Redes neuronales profundas	17
1.2.3 Sobreentrenamiento y generalización	18
1.2.4 El teorema <i>no free lunch</i>	20
1.3 Aprendizaje no supervisado	21
1.3.1 Clustering	22

1.3.2	Descubriendo “factores de variación” latentes	24
1.3.3	Aprendizaje auto-supervisado	25
1.3.4	Evaluación del aprendizaje no supervisado	26
1.4	Aprendizaje por refuerzo	27
1.5	Tareas típicas y preproceso de datos	28
1.5.1	Algunos conjuntos de imágenes comunes	28
1.5.2	Algunos conjuntos de texto comunes	29
1.5.3	Preproceso de datos de entrada discretos	30
1.5.4	Preproceso de texto	31
1.5.5	Datos perdidos	32
1.6	El aprendizaje automático y otras áreas	33
A	Material suplementario	34

1.1. ¿Qué es aprendizaje automático (ML)?

- ▶ Kevin Murphy enmarca la aproximación probabilística al ML en la definición de ML dada por Tom Mitchell en 1997; ¿cuál?
 1. El ML es un campo de estudio que da a los ordenadores la habilidad de aprender sin ser explícitamente programados
 2. Un sistema (de ML) aprende de la experiencia E respecto a una clase de tareas T y una medida de rendimiento R, si su rendimiento en T, medido por R, mejora con E
 3. El ML estudia cómo construir sistemas que mejoran automáticamente mediante la experiencia
 4. Ninguna de las anteriores

La 2. La 1 es de Arthur Samuel, quien en 1959 acuñó el término *machine learning* para describir un programa de damas capaz de aprender solo. La 3 es de Michael Jordan, investigador actual muy influyente; su breve definición enfatiza la importancia de la experiencia (entendida como datos).

Recursos principales

► *Web de la serie de libros sobre ML de Kevin Murphy*

`http://probml.ai`

`https://probml.github.io/pml-book`

► *Libro 1: “Probabilistic Machine Learning: An Introduction”*

`https://probml.github.io/pml-book/book1.html`

`https://github.com/probml/pml-book/releases/latest/download/book1.pdf`

► *Material suplementario*

`https://github.com/probml`

▷ *Código python 3 para reproducir figuras y más cosas*

`https://github.com/probml/pyprobml`

↳ *Cuadernos del libro 1*

`https://github.com/probml/pyprobml/tree/master/notebooks/book1`

Primeros pasos en Colab

- ▶ Entra en Colab con (Chrome y) una cuenta Google:

`https://colab.research.google.com`

- ▶ Lee los siguientes cuadernos introductorios:
 - ▷ [Welcome to Colab!](#)
 - ▷ [Overview of Colaboratory](#)
 - ▷ [Guide to Markdown](#)
 - ▷ [Importing libraries and installing dependencies](#)
 - ▷ [Saving and loading notebooks in GitHub](#)
 - ▷ [Loading data: Drive, Sheets, and Google Cloud Storage](#)
- ▶ Lee y ejecuta el cuaderno introductorio de Kevin Murphy:
 - ▷ [Introduction to colab \(Kevin Murphy\)](#)

1.2. Aprendizaje supervisado

1.2.1. Clasificación

1.2.1.1. Ejemplo: clasificación de flores iris

- El corpus iris es una colección de $N = 150$ muestras etiquetadas, 50 por clase, descritas con:

1. Imágenes a color
2. Imágenes de grises
3. Vectores de características
4. Ninguna de las anteriores

La 3; el corpus iris es un ejemplo bien conocido de datos tabulados. Los vectores son de $D = 4$ características: longitud y amplitud de sépalos y pétalos.

► *Primer script ejecutado en una terminal de PC o PoliLabs:*

- ▷ Abre una terminal en tu PC o PoliLabs DSIC-LINUX
- ▷ Ejecuta el script

```
1.2.1.1.iris.py  
1 from sklearn.datasets import load_iris  
2 iris = load_iris()  
3 print(dir(iris))  
4 print(iris.feature_names)  
5 print(iris.target_names)  
6 print(iris.data[0:2])  
7 print(iris.target[0:2])
```

- ▷ Comprueba la salida


```
1.2.1.1.iris.out  
1 ['DESCR', 'data', 'data_module', 'feature_names', 'filename',  
  ↪ 'frame', 'target', 'target_names']  
2 ['sepal length (cm)', 'sepal width (cm)', 'petal length  
  ↪ (cm)', 'petal width (cm)']  
3 ['setosa' 'versicolor' 'virginica']  
4 [[5.1 3.5 1.4 0.2]  
5  [4.9 3.  1.4 0.2]]  
6 [0 0]
```

1.2.1.2. Análisis exploratorio de datos

- ▶ Antes de abordar un problema de ML, estudiamos los datos (informalmente) para ver si hay patrones o problemas obvios; con pocas características, hacemos un gráfico matricial donde:
 1. El panel (i, j) , $i \neq j$, mostrará el gráfico de dispersión de las variables i y j
 2. El panel de la diagonal (i, i) mostrará la densidad marginal de la variable i
 3. Asignaremos un color y símbolo distintos a cada clase
 4. Las tres opciones anteriores son correctas (no solo una)



La 4.

► Reproduce el cuaderno asociado a la [Figura 1.3](#)



1.2.1.3. Aprendizaje de un clasificador

- Reproduce el cuaderno asociado a la [Figura 1.4](#)



- Observa que el cuaderno también muestra un árbol de decisión de profundidad 3 y otro de profundidad no restringida

1.2.1.4. Minimización del riesgo empírico

- Sea $f(\mathbf{x}; \boldsymbol{\theta})$ un clasificador para iris entrenado con $N = 5$ muestras de clases verdaderas y estimadas (set=0, ver=1, vir=2):

	$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\mathbf{x}_4$	$\mathbf{x}_5$
y_n	0	1	1	2	2
$\hat{y}_n$	0	1	2	1	2

Halla su riesgo empírico con ℓ_{01} y la pérdida ℓ_{virkk} , de costes:

		Estimada		
		setosa	versicolor	virginica
Verdadera	setosa	0	1	1
	versicolor	1	0	1
	virginica	10	10	0

$$\mathcal{L}_{01}(\boldsymbol{\theta}) = \frac{1}{N} \sum_n \ell_{01}(y_n, f(\mathbf{x}_n; \boldsymbol{\theta})) = \frac{2}{5}$$

$$\mathcal{L}_{\text{virkk}}(\boldsymbol{\theta}) = \frac{1}{N} \sum_n \ell_{\text{virkk}}(y_n, f(\mathbf{x}_n; \boldsymbol{\theta})) = \frac{11}{5}$$

1.2.1.5. Incertidumbre

- ▶ En general no es posible aprender clasificadores libres de error:
 1. Por la *incertidumbre epistémica o de modelo*, o falta de conocimiento sobre la transformación entrada-salida
 2. Por la *incertidumbre aleatoria o de los datos*, o estocasticidad intrínseca e irreducible en la transformación
 3. Por la incertidumbre de modelo y de los datos; esto es, no solo por una, sino por ambas
 4. Falso; en general sí es posible aprender clasificadores libres de error

La 3. La 1 es obvia ya que, en general, no conocemos el modelo real subyacente a los datos y hacemos asunciones poco realistas como, por ejemplo, que sea lineal. La 2 también es obvia puesto que, en muchos casos, ni siquiera las personas somos capaces de predecir correctamente la clase de una entrada.

1.2.1.6. Estimación por máxima verosimilitud

- Los modelos de clasificación suelen ajustarse por máxima verosimilitud, minimizando el riesgo empírico con:

1. Pérdida 0-1:

$$\ell_{01}(y, \hat{y}) = \mathbb{1}(y \neq \hat{y})$$

2. Log-pérdida:

$$\ell(y, \hat{y}) = -\log p(y \mid \hat{y})$$

3. Pérdida cuadrática:

$$\ell_2(y, \hat{y}) = (y - \hat{y})^2$$

4. Ninguna de las anteriores

La 2.

1.2.2. Regresión

- Los modelos de regresión suelen ajustarse minimizando el riesgo empírico con:

1. Pérdida 0-1:

$$\ell_{01}(y, \hat{y}) = \mathbb{1}(y \neq \hat{y})$$

2. Log-pérdida:

$$\ell(y, \hat{y}) = -\log p(y \mid \hat{y})$$

3. Pérdida cuadrática:


$$\ell_2(y, \hat{y}) = (y - \hat{y})^2$$

4. Ninguna de las anteriores

La 3.

1.2.2.1. Regresión lineal

- Reproduce el cuaderno asociado a la [Figura 1.5](#)





- Los datos se han generado con el modelo no lineal (cuadrático) de regresión simple (1d):



$$f(x; \boldsymbol{\theta}) = b + w_0 x + w_1 x^2 + \xi \mathcal{N}(0, 1)$$

con $b = 0$, $w_0 = -1.5$, $w_1 = 1/9$ y $\xi = 2$

▷ Prueba $b = 0$, $w_0 = 1$, $w_1 = 0$ y $\xi = 0.1$




▷ Prueba $b = 0$, $w_0 = 1$, $w_1 = 0$ y $\xi = 1$




1.2.2.2. Regresión polinómica

- Reproduce el cuaderno de la [Figura 1.7](#) con `chosen_degs=[2]`



► Reproduce el cuaderno de la [Figura 1.6](#)



- Modelizamos la temperatura en una sala con datos reales 2d
- El problema no es de regresión simple (1d) sino múltiple (2d)
- Modelos lineal (izquierda) y cuadrático (derecha):

$$f(\mathbf{x}; \mathbf{w}) = w_0 + w_1x_1 + w_2x_2$$

$$f(\mathbf{x}; \mathbf{w}) = w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_2^2$$

1.2.2.3. Redes neuronales profundas

- Las redes generalizan regresión polinómica múltiple mediante extractores de características con sus propios parámetros:

$$f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^t \phi(\mathbf{x}) \quad \rightarrow \quad f(\mathbf{x}; \mathbf{w}, \mathbf{V}) = \mathbf{w}^t \phi(\mathbf{x}; \mathbf{V})$$

Decimos que la red consta de $L \geq 2$ funciones o capas anidadas

$$f(\mathbf{x}; \boldsymbol{\theta}) = f_L(f_{L-1}(\cdots f_1(\mathbf{x}) \cdots))$$


tal que:

1. La función de la capa ℓ -ésima se define en términos de un subconjunto de parámetros $\boldsymbol{\theta}_\ell$, $f_\ell(\mathbf{x}) = f_\ell(\mathbf{x}; \boldsymbol{\theta}_\ell)$
2. La composición de todas las capas salvo la última, $f_{1:L-1}(\mathbf{x})$, constituye el extractor de características de la red
3. La capa final es lineal, $f_L(\mathbf{x}) = \mathbf{w}^t f_{1:L-1}(\mathbf{x})$
4. Las tres opciones son correctas


La 4, claro.

1.2.3. Sobreentrenamiento y generalización

- Reproduce el cuaderno de la [Figura 1.7](#) con `chosen_degs=[20]`



- ▷ Un regresor polinómico de grado $D = 20$ entrenado con $N = 21$ datos reduce la pérdida en entrenamiento a cero (MSE = 0) y predice la salida de los mismos sin error; sin embargo, la pérdida con nuevos datos será grande y no predecirá bien sus salidas
- ▷ En general, calculamos el riesgo (sobre un conjunto) de test para descartar modelos *subajustados* (demasiado sencillos) o *sobreajustados* (demasiado complejos); $D = 2$ en este caso:



1.2.4. El teorema *no free lunch*

- El teorema *no free lunch* establece que no existe un único mejor modelo que responda óptimamente en todo tipo de problemas. Por tanto, la selección de modelos se suele hacer con base en el conocimiento del dominio, así como la prueba y error mediante técnicas tales como:

1. Redes neuronales y validación cruzada
2. Redes neuronales y métodos Bayesianos
3. Validación cruzada y métodos Bayesianos
4. Ninguna de las anteriores

La 3. Las redes no son técnicas de selección de modelos, sino modelos propiamente dichos. De hecho, la selección de modelos podría limitarse a decidir si usamos una red de 2 o 3 capas.

1.3. Aprendizaje no supervisado



► Dado un conjunto de N pares entrada-salida, $\mathcal{D} = \{(\mathbf{x}_n, \mathbf{y}_n)\}_{n=1}^N$, aprendizaje supervisado suele reducirse a ajustar un modelo condicional $p(\mathbf{y} \mid \mathbf{x})$. En comparación, aprendizaje no supervisado:

1. Ajusta un modelo conjunto $p(\mathbf{x}, \mathbf{y})$
2. Ajusta un modelo incondicional $p(\mathbf{x})$ cuando solo tenemos entradas sin sus correspondientes salidas, $\mathcal{D} = \{\mathbf{x}_n\}_{n=1}^N$
3. Ajusta un modelo incondicional $p(\mathbf{y})$ cuando solo tenemos salidas sin sus correspondientes entradas, $\mathcal{D} = \{\mathbf{y}_n\}_{n=1}^N$
4. Ninguna de las anteriores

La 2. La 1 también es un planteamiento usual del aprendizaje supervisado. La 3 solo tendría en cuenta la supervisión, justo lo contrario de lo que aprendizaje no supervisado sugiere.

1.3.1. Clustering

► Reproduce el cuaderno de la [Figura 1.8](#)




▷ Modifica el cuaderno para que halle cuatro clústers

→ **K=4**

→ `mapping = np.array([2, 0, 1, 3])`

▷ Comprueba el resultado:



1.3.2. Descubriendo “factores de variación” latentes

- El descubrimiento de “factores de variación” latentes consiste en asumir que cada dato $\mathbf{x}_n \in \mathbb{R}^D$ se genera por K factores latentes ocultos (no observados), $\mathbf{z}_n \in \mathbb{R}^K$, siendo $K \ll D$. Entre los modelos más conocidos podemos encontrar:

1. Análisis factorial
2. PCA probabilístico
3. Autoencoders variacionales
4. No uno solo de los anteriores, sino todos

La 4. Análisis factorial asume un modelo lineal

$$p(\mathbf{x}_n \mid \mathbf{z}_n; \boldsymbol{\theta}) = \mathcal{N}(\mathbf{x}_n \mid \mathbf{W}\mathbf{z}_n + \boldsymbol{\mu}, \boldsymbol{\Sigma})$$

PCA probabilístico lo particulariza (con $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}$) y los autoencoders variacionales lo generalizan.

1.3.3. Aprendizaje auto-supervisado

- ▶ El aprendizaje auto-supervisado es un área emergente del aprendizaje no supervisado que propone:
 1. La inferencia de “factores latentes” con la creación de tareas supervisadas indirectas (proxy) a partir de datos no supervisados
 2. Que el modelo aprenda la estructura de alto nivel de la distribución de los datos con datos no supervisados y usar los supervisados solo para aprender detalles finos de una tarea dada
 3. Predecir salidas de datos no supervisados con un modelo dado y usarlas para re-entrenar el modelo supervisadamente
 4. Ninguna de las anteriores

La 1, aunque la 3 también vale. La 2 es aprendizaje semi-supervisado. La 3 una aproximación primitiva y directa al semi-supervisado que originalmente se denominó auto-aprendizaje, aunque ahora tiende a denominarse pseudo-etiquetado para distinguirla de la 1.

1.3.4. Evaluación del aprendizaje no supervisado

- ▶ El aprendizaje no supervisado se evalúa:
 1. Como problema de estimación de densidad
 2. En una tarea de aprendizaje supervisado marco (downstream)
 3. Como herramienta de análisis para comprender mejor la estructura subyacente a los datos
 4. De las tres maneras anteriores (no solo una)

La 4.

1.4. Aprendizaje por refuerzo

- ▶ La forma más común de ML es el aprendizaje supervisado; junto al mismo, las otras dos formas usuales de ML son:
 1. El aprendizaje no supervisado y el aprendizaje activo
 2. El aprendizaje no supervisado y el aprendizaje por refuerzo
 3. El aprendizaje auto-supervisado y el aprendizaje activo
 4. El aprendizaje auto-supervisado y el aprendizaje por refuerzo

La 2. El aprendizaje auto-supervisado es un área emergente del no supervisado. El activo no lo hemos visto pero también existe; asume que el sistema puede pedir supervisión para los datos no supervisados que le convenga.

1.5. Tareas típicas y preproceso de datos

1.5.1. Algunos conjuntos de imágenes comunes

► MNIST es un corpus clásico en aprendizaje supervisado de clasificadores de imágenes que consta de:

1. 60K+10K imágenes 28×28 de los 10 dígitos
2. 698K+116K imágenes 28×28 de 62 caracteres
3. 60K+10K imágenes 28×28 de 10 prendas de ropa
4. 50K+10K imágenes $32 \times 32 \times 3$ (RGB) de 10 tipos de objeto

La 1. La 2 es EMNIST, la 3 Fashion-MNIST y la 4 CIFAR.

1.5.2. Algunos conjuntos de texto comunes

- El procesamiento del lenguaje natural (NLP) incluye las siguientes tareas sobre texto:

1. Clasificación de texto
2. Modelado del lenguaje
3. Traducción automática
4. Todas las anteriores (no solo una)

La 4.

1.5.3. Preproceso de datos de entrada discretos

► La técnica de codificación one-hot de una variable x :

1. Asume que x es categórica o nominal, por lo que toma un valor de un conjunto discreto de valores posibles entre los cuales no existe necesariamente ninguna relación
2. Asume que x es ordinal, esto es, categórica y asumiendo que el conjunto discreto de valores posibles es ordenado
3. Asume que x es continua
4. Ninguna de las anteriores

La 1.

1.5.4. Preproceso de texto

- Entre las técnicas más populares de preproceso de (documentos de) texto para su codificación vectorial tenemos:

1. La bolsa de palabras

2. La TF-IDF

3. La bolsa de embeddings de palabras

4. Todas las anteriores (no solo una)

La 4.

1.5.5. Datos perdidos

- ▶ Los datos perdidos pueden producirse en una matriz de datos por mecanismos más o menos aleatorios:
 1. *Missing completely at random (MCAR)*: completamente al azar
 2. *Missing at random (MAR)*: condicionados por los observados
 3. *Missing not at random (MNAR)*: no aleatorios; dependientes tanto de observados como perdidos
 4. Todas los anteriores (no solo uno)

La 4.

1.6. El aprendizaje automático y otras áreas

► Las bases del ML incluyen:

1. Probabilidad, estadística y teoría de la decisión
2. Teoría de la información
3. Álgebra lineal y optimización
4. Todas las anteriores (no solo una)

La 4.

A. Material suplementario

- ▶ Aprende Python
- ▶ Pandas
- ▶ JAX
- ▶ Preproceso de texto
- ▶ Scikit-learn
- ▶ Dive into deep learning