



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Introducción

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

1.1 ¿Qué es aprendizaje automático?	1
1.2 Aprendizaje supervisado	3
1.2.1 Clasificación	5
1.2.1.1 Ejemplo: clasificación de flores iris	6
1.2.1.2 Análisis exploratorio de datos	11
1.2.1.3 Aprendizaje de un clasificador	14
1.2.1.4 Minimización del riesgo empírico	17
1.2.1.5 Incertidumbre	21
1.2.1.6 Estimación por máxima verosimilitud	25
1.2.2 Regresión	26
1.2.2.1 Regresión lineal	28
1.2.2.2 Regresión polinómica	33
1.2.2.3 Redes neuronales profundas	40
1.2.3 Sobreentrenamiento y generalización	42
1.2.4 El teorema <i>no free lunch</i>	46
1.3 Aprendizaje no supervisado	47
1.3.1 Clustering	48

1.3.2	Descubriendo “factores de variación” latentes	51
1.3.3	Aprendizaje auto-supervisado	53
1.3.4	Evaluación del aprendizaje no supervisado	54
1.4	Aprendizaje por refuerzo	56
1.5	Tareas típicas y preproceso de datos	60
1.5.1	Algunos conjuntos de imágenes comunes	60
1.5.1.1	Conjuntos de imágenes pequeños	60
1.5.1.2	ImageNet	65
1.5.2	Algunos conjuntos de texto comunes	67
1.5.2.1	Clasificación de texto	67
1.5.2.2	Traducción automática	68
1.5.2.3	Otras tareas seq2seq	69
1.5.2.4	Modelado del lenguaje	71
1.5.3	Preproceso de datos de entrada discretos	72
1.5.3.1	Codificación <i>one-hot</i>	72
1.5.3.2	Cruce de variables	73
1.5.4	Preproceso de texto	75
1.5.4.1	El modelo bolsa de palabras	76
1.5.4.2	TF-IDF	79

1.5.4.3	Word embeddings	80
1.5.4.4	Palabras fuera de vocabulario	82
1.5.5	Datos perdidos	83
1.6	El aprendizaje automático y otras áreas	84

1.1. ¿Qué es aprendizaje automático (ML)?

- ▶ Arthur Samuel [1]: campo de estudio que da a los ordenadores la habilidad de aprender sin ser explícitamente programados
- ▶ Tom Mitchell [2]: un sistema aprende de la experiencia E respecto a una clase de tareas T y una medida de rendimiento R , si su rendimiento en T , medido por R , mejora con E
- ▶ Nils Nilsson [3]: la mayoría de métodos de aprendizaje automático construyen hipótesis a partir de datos ... a partir de los años 80, el ML se ha convertido en una de las principales ramas de la IA
- ▶ Michael Jordan [4]: estudia cómo construir sistemas que mejoran automáticamente mediante la experiencia

► *Kevin Murphy [5]:*

- ▷ Tomando como referencia la definición de Mitchel, hay muchos tipos de ML, dependiendo de la naturaleza de T (areas), (medida de) R (endimiento) y E (experiencia)
- ▷ Los tipos usuales de ML pueden tratarse convenientemente desde una perspectiva probabilística (estadística)
- ▷ La aproximación probabilística es óptima para la toma de decisiones bajo incertidumbre y enmarca formalmente el ML junto con muchas otras áreas científicas e ingenieriles

1.2. Aprendizaje supervisado

- ▶ El aprendizaje supervisado es la forma de ML más común
- ▶ **Tarea T:** consiste en aprender una transformación

$$f : \mathcal{X} \rightarrow \mathcal{Y} \quad (1)$$

- ▷ Las entradas $x \in \mathcal{X}$, **características**, *covariables* o *predictores* suelen ser un vector numérico de dimensión fija; por ejemplo, $\mathcal{X} = \mathbb{R}^D$, donde D es la dimensión del vector
- ▷ Las salidas $y \in \mathcal{Y}$, **etiquetas**, *objetivos* o *respuestas* suelen ser etiquetas de clase o **reales**

- **Experiencia E :** viene dada por un **conjunto de entrenamiento**, esto es, un conjunto de N pares entrada-salida

$$\mathcal{D} = \{(\mathbf{x}_n, \mathbf{y}_n)\}_{n=1}^N \quad (2)$$

- ▷ N es el **tamaño de la muestra**
- ▷ También es usual referirnos a cada par $(\mathbf{x}_n, \mathbf{y}_n)$ como **muestra (de entrenamiento)**
- **Medida de rendimiento:** P depende del tipo de salida

1.2.1. Clasificación

- ▶ En los problemas de *clasificación*, el espacio de salida es un conjunto de C etiquetas mutuamente exclusivas y desordenadas que llamamos *clases*,

$$\mathcal{Y} = \{1, 2, \dots, C\} \quad (3)$$

- ▶ La predicción de la etiqueta de clase de una entrada dada se conoce como *reconocimiento de formas (pattern recognition)*
- ▶ *Clasificación binaria*: caso particular de gran interés académico y práctico en el que solo tenemos dos clases, las cuales se suelen denotar como

$$y \in \{0, 1\} \quad \text{o} \quad y \in \{-1, +1\} \quad (4)$$

1.2.1.1. Ejemplo: clasificación de flores iris

- ▶ La clasificación de flores iris de las especies setosa, versicolor y virgínica es un ejemplo clásico en clasificación estadística
- ▶ *Ejemplo:* un ejemplo de cada clase

setosa



versicolor



virginica




► *Clasificación de imágenes:*

- ▷ El espacio de entrada $\mathcal{X}$ es el conjunto de imágenes
- ▷ $\mathcal{X}$ es de muy alta dimensión; para una imagen a color con $C = 3$ canales y $D_1 \times D_2$ píxeles, tenemos

$$\mathcal{X} = \mathbb{R}^D \quad \text{con} \quad D = C \times D_1 \times D_2 \quad (5)$$

- ▷ El aprendizaje de $f : \mathcal{X} \rightarrow \mathcal{Y}$ es muy difícil
- ▷ ***Redes neuronales convolucionales (CNNs):*** consiguen aprender f en algunas tareas
- ▷ En iris no trataremos las imágenes directamente

- *Ejemplo:* dificultad del aprendizaje de $f : \mathcal{X} \rightarrow \mathcal{Y}$



- ▶ **Corpus iris:** ejemplo de *datos tabulados (tabular data)*
- ▷ **Conocimiento a priori:** en muchas ocasiones disponemos de conocimiento sobre la tarea en forma de características numéricas altamente informativas (discriminativas)
- ▷ En iris, se sabe que la longitud y amplitud de sépalos y pétalos es altamente discriminativa, por lo que no trabajamos con las imágenes directamente, sino con un espacio de entrada de dimensión mucho más reducida, $\mathcal{X} = \mathbb{R}^4$
- ▷ **Corpus iris:** colección de $N = 150$ muestras etiquetadas, 50 por clase, descritas con $D = 4$ características
 - ⇒ **Matriz de datos (design matrix):** matriz $N \times D$ que representa N muestras con vectores de D características
 - ⇒ El corpus iris es un ejemplo de *datos tabulados*


▷ *Ejemplo:* extracto de la tabla (matriz) de datos iris

índice	sl	sw	pl	pw	etiqueta
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
	...				
50	7.0	3.2	4.7	1.4	versicolor
	...				
149	5.9	3.0	5.1	1.8	virginica

1.2.1.2. Análisis exploratorio de datos

- ▶ **Análisis exploratorio de datos:** antes de abordar un problema de ML, estudiamos los datos (informalmente) para ver si hay:
 - ▷ patrones obvios que den una idea de la dificultad del problema y, en definitiva, qué métodos escoger (p.e. lineales o no)
 - ▷ cualquier problema obvio con los datos, tal como:
 - ↳ **label noise**, esto es, etiquetas ruidosas (dudosas)
 - ↳ **outliers**, esto es, datos erróneos por sus características (perdidas, no en $\mathcal{X}$ o claramente incorrectas) o etiquetas (perdidas, no en $\mathcal{Y}$ o claramente incorrectas)

- ▶ **Inspección visual:** representamos gráficamente los datos para comprobar si algunas clases se separan fácilmente
- ▷ **Pocas características:** hacemos un **gráfico matricial de dispersión (pair plot)**
 - ↳ El panel (i, j) , $i \neq j$, muestra el gráfico de dispersión de las variables i y j
 - ↳ El panel de la diagonal (i, i) muestra la densidad marginal de la variable i
 - ↳ Asignamos un color y símbolo distintos a cada clase
 - ↳ *Ejemplo (en transpa siguiente):* pair plot de iris
- ▷ **Muchas características:** aplicamos una técnica de **reducción de la dimensión** y luego los visualizamos en 2D o 3D



1.2.1.3. Aprendizaje de un clasificador

► **Regla de decisión** para clasificar setosa y no-setosa:

$$f(x; \theta) = \begin{cases} \text{setosa si longitud pétalo} \leq 2.45 \\ \text{versicolor o virgínica si no} \end{cases} \quad (6)$$

► θ : parámetros (2.45)

► **Frontera de decisión:**


$$x = 2.45$$

► **Regiones de decisión:**


$$\mathcal{R}_{\text{setosa}} = \{x \leq 2.45\}$$

$$\mathcal{R}_{\text{no-setosa}} = \{x > 2.45\}$$


► Separa bien setosa, pero no versicolor y virgínica



► *Regla de decisión* con sub-regla para versicolor y virgínica:



► Frontera y regiones de decisión (2d):



► **Árbol de decisión:** anidamiento jerárquico de reglas

► Objetivo: aprender automáticamente los **parámetros** θ del árbol

1.2.1.4. Minimización del riesgo empírico

- **Tasa de error (en entrenamiento):** medida de rendimiento obvia para aprender el θ de un clasificador

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{n=1}^N \mathbb{1}(y_n \neq f(\mathbf{x}_n; \theta)) \quad (7)$$

donde $\mathbb{1}$ es la **función indicadora**:

$$\mathbb{1}(z) = \begin{cases} 1 & \text{si } z \text{ es cierto} \\ 0 & \text{si } z \text{ es falso} \end{cases} \quad (8)$$

- **Riesgo empírico:** generaliza la tasa de error mediante la introducción de una *función de pérdida*,

$$\ell(y, \hat{y}) \quad (9)$$

para medir la pérdida (coste) producida al clasificar una muestra de la clase y en la clase $\hat{y}$,

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N \ell(y_n, f(\mathbf{x}_n; \boldsymbol{\theta})) \quad (10)$$

- **Pérdida cero-uno:** cero si no hay error; uno si lo hay

$$\ell_{01}(y, \hat{y}) = \mathbb{1}(y \neq \hat{y}) \quad (11)$$

por lo que el riesgo empírico coincide con la tasa de error (7)

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N \mathbb{1}(y_n \neq f(\mathbf{x}_n; \boldsymbol{\theta})) \quad (12)$$

- ▷ *Ejemplo de pérdida con diferentes costes:* suponemos que setosa y versicolor son comestibles, pero virginica no

		Estimada		
		setosa	versicolor	virginica
Verdadera	setosa	0	1	1
	versicolor	1	0	1
	virginica	10	10	0

- **Minimización del riesgo empírico:** aproximación básica al **entrenamiento** o **ajuste del modelo**

$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}) \quad (13)$$

$$= \arg \min_{\boldsymbol{\theta}} \frac{1}{N} \sum_{n=1}^N \ell(y_n, f(\mathbf{x}_n; \boldsymbol{\theta})) \quad (14)$$

- El verdadero objetivo consiste en minimizar la pérdida esperada sobre datos futuros todavía no vistos
- Queremos que el modelo **generalice** bien, no que simplemente funcione bien con los datos de entrenamiento

1.2.1.5. Incertidumbre

► *Imposibilidad de aprender clasificadores libres de error:*

- ▷ Por la *incertidumbre epistémica o de modelo*, o falta de conocimiento sobre la transformación entrada-salida
- ▷ Por la *incertidumbre aleatoria o de los datos*, o estocasticidad intrínseca e irreducible en la transformación
 - ↳ *Ejemplo:* datos de clases distintas e idéntico x

- ***Distribución de probabilidad condicional (a posteriori)***: la empleamos para capturar la incertidumbre subyacente

$$p(y = c \mid \mathbf{x}; \boldsymbol{\theta}) = f_c(\mathbf{x}; \boldsymbol{\theta}) \quad (15)$$

donde

- ▷ $f : \mathcal{X} \rightarrow [0, 1]^C$ transforma entradas en una distribución de probabilidad sobre las C etiquetas de salida posibles
- ▷ Las restricciones de probabilidad que deben cumplirse son:

$$0 \leq f_c \leq 1 \text{ para todo } c \quad (16)$$

$$\sum_c f_c = 1 \quad (17)$$

- ▶ **La (función) softmax:** convierte log-probabilidades no normalizadas en probabilidades

$$S(\mathbf{a}) \triangleq \left[\frac{e^{a_1}}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}}, \dots, \frac{e^{a_C}}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}} \right] \quad (18)$$

- ▷ Transforma $\mathbb{R}^C$ en $[0, 1]^C$ tal que $0 \leq S_c(\mathbf{a}) \leq 1$ y $\sum_c S_c(\mathbf{a}) = 1$
- ▷ **Logits:** nombre que suele darse a sus entradas, $\mathbf{a} = f(\mathbf{x}; \boldsymbol{\theta})$
- ▷ Facilita el uso de modelos $f(\mathbf{x}; \boldsymbol{\theta})$ no restringidos por las restricciones de probabilidad; con ella, la posterior queda como:

$$p(y = c \mid \mathbf{x}; \boldsymbol{\theta}) = S_c(f(\mathbf{x}; \boldsymbol{\theta})) \quad (19)$$

► **Regresión logística:** f es una **transformación afín**

$$f(\mathbf{x}; \boldsymbol{\theta}) = b + \mathbf{w}^t \mathbf{x} = b + w_1 x_1 + \cdots + w_D x_D \quad (20)$$

donde $\boldsymbol{\theta} = (b, \mathbf{w})$ son los parámetros del modelo

▷ $\mathbf{w}$ son los **pesos** o **coeficientes de regresión** (β)

▷ b es el **sesgo** u **ordenada en el origen (intercept)**

▷ Notación homogénea: f queda como una **función lineal**

$$f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^t \mathbf{x} \quad (21)$$

con

$$\mathbf{w} = [b, w_1, \dots, w_D] \quad (22)$$

$$\mathbf{x} = [1, x_1, \dots, x_D] \quad (23)$$

1.2.1.6. Estimación por máxima verosimilitud

- **Log-pérdida (log-loss):** los modelos suelen ajustarse tomando el negativo de la log-probabilidad como función de pérdida

$$\ell(y, f(\mathbf{x}; \boldsymbol{\theta})) = -\log p(y \mid f(\mathbf{x}; \boldsymbol{\theta})) \quad (24)$$

- **Log-verosimilitud negativa (NLL, negative log-likelihood):** riesgo empírico con log-pérdida

$$\text{NLL}(\boldsymbol{\theta}) = -\frac{1}{N} \sum_n \log p(y_n \mid f(\mathbf{x}_n; \boldsymbol{\theta})) \quad (25)$$

- **Estimador máximo-verosímil (MLE):** minimiza el riesgo empírico con log-pérdida

$$\hat{\boldsymbol{\theta}}_{\text{mle}} = \arg \min_{\boldsymbol{\theta}} \text{NLL}(\boldsymbol{\theta}) \quad (26)$$

1.2.2. Regresión

- ▶ **Regresión:** la salida es un real $y \in \mathbb{R}$, en lugar de una etiqueta de clase $y \in \{1, \dots, C\}$ (clasificación)
- ▶ **Pérdida cuadrática o ℓ_2 :** función de pérdida usual en regresión

$$\ell_2(y, \hat{y}) = (y - \hat{y})^2 \quad (27)$$

- ▷ **Residuo:** diferencia entre observación y predicción, $y - \hat{y}$
- ▶ **Error cuadrático medio (MSE, mean squared error):** riesgo empírico con pérdida cuadrática

$$\text{MSE}(\boldsymbol{\theta}) = \frac{1}{N} \sum_n (y_n - f(\mathbf{x}_n; \boldsymbol{\theta}))^2 \quad (28)$$

- **Distribución a posteriori normal:** para capturar la incertidumbre subyacente, se suele asumir que la distribución de salida es **normal** o **Gaussiana**

$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \mathcal{N}(y \mid f(\mathbf{x}; \boldsymbol{\theta}), \sigma^2) \quad (29)$$

$$= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - f(\mathbf{x}; \boldsymbol{\theta}))^2}{2\sigma^2} \right] \quad (30)$$

donde hemos asumido que la media depende de las entradas, $\mu = f(\mathbf{x}; \boldsymbol{\theta})$, y que la varianza σ^2 es fija (por simplicidad)

► En este supuesto, la NLL es proporcional al MSE:

$$\text{NLL}(\boldsymbol{\theta}) = -\frac{1}{N} \sum_n \log \left[\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp \left(-\frac{1}{2\sigma^2} (y_n - f(\mathbf{x}_n; \boldsymbol{\theta}))^2 \right) \right] \quad (31)$$

$$= \frac{1}{2\sigma^2} \text{MSE}(\boldsymbol{\theta}) + \text{const} \quad (32)$$

1.2.2.1. Regresión lineal

► *Regresión lineal simple (1d):*

$$f(x; \boldsymbol{\theta}) = b + wx \quad (33)$$

donde

↳ w es la *pendiente*

↳ b el *desplazamiento (ordenada en el origen)*


↳ $\boldsymbol{\theta} = (w, b)$

▷ *Mínimos cuadrados (least squares):*


$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta}} \text{MSE}(\boldsymbol{\theta}) \quad (34)$$

$$= \arg \min_{\boldsymbol{\theta}} \frac{1}{N} \sum_n (y_n - f(x_n; \boldsymbol{\theta}))^2 \quad (35)$$

▷ *Ejemplo:* regresión lineal simple con datos 1d



▷ *Ejemplo (cont.):* residuos entre observaciones y predicciones



► *Regresión lineal multiple:*

$$f(\mathbf{x}; \boldsymbol{\theta}) = b + w_1x_1 + \cdots + w_Dx_D \quad (36)$$

$$= b + \mathbf{w}^t \mathbf{x} \quad (37)$$

con $\boldsymbol{\theta} = (\mathbf{w}, b)$

► *Ejemplo:* predicción de temperatura como una función de la localización 2d en una sala

$$f(\mathbf{x}; \boldsymbol{\theta}) = b + w_1x_1 + w_2x_2 \quad (38)$$

1.2.2.2. Regresión polinómica

► *Regresión polinómica simple de grado D :*


$$f(x; \mathbf{w}) = \mathbf{w}^t \phi(x) \quad (39)$$

con $\phi(x) = (1, x, x^2, \dots, x^D)$

▷ ϕ hace *extracción o ingeniería de características*


▷ *Ejemplo con datos 1d (cont.): $D = 1$*

degree 1




▷ *Ejemplo con datos 1d (cont.): $D = 2$*


degree 2



▷ *Ejemplo con datos 1d (cont.): $D = 10$*
degree 10



▷ *Ejemplo con datos 1d (cont.):* $D = 20$, $D = N - 1$, $\text{MSE} = 0$
degree 20




► *Regresión polinómica múltiple (de grado D):*

$$f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^t \phi(\mathbf{x}) \quad (40)$$

con $\phi(\mathbf{x}) = (1, \dots)$

▷ *Ejemplo con datos 2d (cont.):*

$$f(\mathbf{x}; \mathbf{w}) = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_1^2 + w_4 x_2^2 \quad (41)$$



1.2.2.3. Redes neuronales profundas

- La función de extracción de características puede tener su propio conjunto de parámetros, V , para incluir modelos más generales:

$$f(\mathbf{x}; \mathbf{w}, \mathbf{V}) = \mathbf{w}^t \phi(\mathbf{x}; \mathbf{V}) \quad (42)$$

- **Redes neuronales profundas (DNNs, deep neural networks):** descomponen recursivamente la extracción de características, dando lugar a una pila de L funciones o **capas** anidadas

$$f(\mathbf{x}; \boldsymbol{\theta}) = f_L(f_{L-1}(\cdots f_1(\mathbf{x}) \cdots)) \quad (43)$$

donde la función de la capa ℓ -ésima se define en términos de un subconjunto de parámetros $\boldsymbol{\theta}_\ell$,

$$f_\ell(\mathbf{x}) = f_\ell(\mathbf{x}; \boldsymbol{\theta}_\ell) \quad (44)$$

y la capa final es lineal, de la forma

$$f_L(\mathbf{x}) = \mathbf{w}^t f_{1:L-1}(\mathbf{x}) \quad (45)$$

siendo $f_{1:L-1}(\mathbf{x})$ el extractor de características

- Uso: **redes neuronales convolucionales (CNNs)** para imágenes y **redes neuronales recurrentes (RNNs)** para secuencias


1.2.3. Sobreentrenamiento y generalización

- Reescribimos el riesgo empírico (10) con referencia explícita al conjunto de entrenamiento, $\mathcal{D}_{\text{train}}$:

$$\mathcal{L}(\boldsymbol{\theta}; \mathcal{D}_{\text{train}}) = \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x, y) \in \mathcal{D}_{\text{train}}} \ell(y, f(x; \boldsymbol{\theta})) \quad (46)$$

- ***Sobreentrenamiento:*** un modelo suficientemente flexible (complejo) puede reducir la pérdida en entrenamiento a cero, pero no predecirá bien la salida para nuevos datos

▷ *Ejemplo con datos 1d (cont.):* $D = 20$, $D = N - 1$, $\text{MSE} = 0$



- **Riesgo teórico (poblacional):** si conociéramos la distribución conjunta real de x e y , $p^*(x, y)$, sería

$$\mathcal{L}(\theta; p^*) = \mathbb{E}_{p^*(x, y)}[\ell(y, f(x; \theta))] \quad (47)$$

- **Gap de generalización:** la diferencia entre el riesgo teórico y el empírico permitiría saber si un modelo está sobreentrenado o no


$$\mathcal{L}(\theta; p^*) - \mathcal{L}(\theta; \mathcal{D}_{\text{train}}) \quad (48)$$

- **Conjunto y riesgo de test:** para aproximar el riesgo teórico, apartamos una fracción (p.e. un 10 %) de $\mathcal{D}_{\text{train}}$, $\mathcal{D}_{\text{test}}$

$$\mathcal{L}(\theta; \mathcal{D}_{\text{test}}) = \frac{1}{|\mathcal{D}_{\text{test}}|} \sum_{(x, y) \in \mathcal{D}_{\text{test}}} \ell(y, f(x; \theta)) \quad (49)$$

- ▷ El riesgo de test permite descartar modelos **subajustados** (demasiado sencillos) o **sobreajustados** (demasiado complejos)

▷ *Ejemplo con datos 1d (cont.):* MSE en función de D



- ▷ En la práctica, la selección de un modelo adecuado no se hace con el test, sino con una fracción distinta del training (p.e. otro 10 %) que llamamos *conjunto de validación*

1.2.4. El teorema *no free lunch*

- ▶ **Teorema no free lunch (nadie da un duro a cuatro pesetas):** no existe un único mejor modelo que responda óptimamente en todo tipo de problemas
- ▶ **Selección de modelos:** se suele hacer con base en el conocimiento del dominio, así como la prueba y error mediante técnicas tales como **validación cruzada** o **métodos Bayesianos**
- ▶ **AutoML:** área reciente que estudia la automatización del aprendizaje automático, desde la preparación de datos a la selección de modelos y optimización de hiperparámetros


1.3. Aprendizaje no supervisado

- ▶ **Aprendizaje no supervisado:** trata de “explicar” los datos cuando solo tenemos un conjunto de “entradas”, $\mathcal{D} = \{\mathbf{x}_n\}_{n=1}^N$, sin sus correspondientes “salidas” $\{\mathbf{y}_n\}$
- ▶ **Aproximación probabilística:** ajusta un modelo incondicional $p(\mathbf{x})$, en lugar de uno condicional $p(\mathbf{y} | \mathbf{x})$ como en supervisado
- ▶ **Mayor aplicabilidad que el aprendizaje supervisado:** pues los datos no supervisados son fáciles de conseguir; no la supervisión
- ▶ **Aplicable a tareas mal definidas:** en principio no requiere disponer de un conjunto de categorías dado, ni siquiera asumir que los datos se agrupan en un cierto número de categorías dado


1.3.1. Clustering

- ▶ **Clustering:** área clásica del análisis exploratorio de datos cuyo objetivo es encontrar “agrupamientos naturales” de los datos en grupos homogéneos o **clústers**
- ▶ El interés por el clustering arranca en las ciencias sociales durante los años 60 y pronto abarca muchas otras áreas científicas
- ▶ Las técnicas clásicas suelen agruparse en función del tipo de agrupamiento que encuentran:
 - ▷ **Clustering particional:** el resultado es una partición de los datos en un cierto número de clústers por lo general dado
 - ▷ **Clustering jerárquico:** el resultado es una secuencia de particiones anidadas para formar un árbol

► *Ejemplo:* datos iris según longitud y amplitud de pétalos



► *Ejemplo (cont.):* clustering con $K = 3$ clústers



1.3.2. Descubriendo “factores de variación” latentes

- ▶ *Reducción de la dimensión:* si la dimensión de los datos es elevada, la reducimos mediante una proyección a un subespacio de menor dimensión que capture la “esencia” de los datos
- ▶ *Factores latentes:*
 - ▷ Asumimos que cada observación $\mathbf{x}_n \in \mathbb{R}^D$ se genera por K , $K \ll D$, factores latentes ocultos (no observados), $\mathbf{z}_n \in \mathbb{R}^K$
 - ▷ Como los factores latentes $\mathbf{z}_n$ no se conocen, asumimos un modelo probabilístico sencillo para $p(\mathbf{z}_n)$ tal como una Gaussiana

- **Análisis factorial:** asume un modelo lineal

$$p(\mathbf{x}_n \mid \mathbf{z}_n; \boldsymbol{\theta}) = \mathcal{N}(\mathbf{x}_n \mid \mathbf{W}\mathbf{z}_n + \boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad (50)$$

- ▷ Similar a regresión lineal, excepto que solo observamos las salidas $\mathbf{x}_n$, y no las entradas $\mathbf{z}_n$

- **Análisis de componentes principales (PCA, principal component analysis) probabilístico:** caso particular de análisis factorial tal que

$$\boldsymbol{\Sigma} = \sigma^2 \mathbf{I} \quad (51)$$

- **Autoencoder variacional:** extiende análisis factorial con

$$p(\mathbf{x}_n \mid \mathbf{z}_n; \boldsymbol{\theta}) = \mathcal{N}(\mathbf{x}_n \mid f(\mathbf{z}_n; \boldsymbol{\theta}), \sigma^2 \mathbf{I}) \quad (52)$$

donde $f(\mathbf{z}_n; \boldsymbol{\theta})$ es un modelo no lineal, por ejemplo una DNN

1.3.3. Aprendizaje auto-supervisado

- ▶ *Aprendizaje auto-supervisado o auto-supervisión:* área emergente del aprendizaje no supervisado que propone la inferencia de “factores latentes” mediante la creación de tareas supervisadas indirectas (proxy) a partir de datos no supervisados
- ▶ *Ejemplos:* la predicción de una imagen a color a partir de grises, o el ocultamiento de palabras en un texto con el fin de predecirlas a partir de su contexto

1.3.4. Evaluación del aprendizaje no supervisado

► *Como problema de estimación de densidad:*

- La bondad de un modelo $p(\mathbf{x} \mid \boldsymbol{\theta})$ puede evaluarse mediante la probabilidad asignada a un conjunto de test (datos no vistos) $\mathcal{D}$
- Formalmente, podemos calcular la log-verosimilitud negativa (incondicional) del test

$$\mathcal{L}(\boldsymbol{\theta}; \mathcal{D}) = -\frac{1}{\mathcal{D}} \sum_{\mathbf{x} \in \mathcal{D}} \log p(\mathbf{x} \mid \boldsymbol{\theta}) \quad (53)$$

- Un buen modelo no se “sorprenderá” con datos reales no vistos; esto es, les asignará alta probabilidad y, por tanto, baja $\mathcal{L}$

- ▶ **En una tarea de aprendizaje supervisado marco (downstream):**
 - ▷ La representación no supervisada aprendida puede usarse como entrada para un método de aprendizaje supervisado marco
 - ▷ **Eficiencia muestral:** si la representación no supervisada aprendida es útil, el método supervisado aprenderá con menos datos supervisados de los que requeriría sin ella
 - ↳ *Ejemplo:* iris con 4 características (en lugar de fotos); reconocimiento del habla con modelos de lenguaje externos
- ▶ **Interpretabilidad:** en línea con el objetivo clásico del clustering, el uso de modelos no supervisados fácilmente interpretables puede ayudarnos a comprender la estructura subyacente a los datos

1.4. Aprendizaje por refuerzo

- ▶ *Aprendizaje por refuerzo (RL, reinforcement learning)*: el sistema o *agente* interactúa con su entorno mediante una *política* $a = \pi(x)$ que especifica qué acción tomar en respuesta a cada entrada posible x (derivada del estado del entorno)
- ▶ *Comparación con aprendizaje supervisado*:
 - ▷ *Aprendizaje supervisado o learning with a teacher*: al sistema se le enseña con la acción óptima que debe tomar en cada paso
 - ▷ *Aprendizaje por refuerzo o learning with a critic*: el sistema recibe una *recompensa (o castigo)* ocasional en respuesta a las acciones que toma

- *Ejemplos:* mover la nave en Space Invaders o controlar los motores de un robot que debe realizar cierta tarea



► *Gran aplicabilidad y dificultad:*

- ▷ Aunque es muy popular por su gran aplicabilidad, es muy difícil pues la recompensa solo se obtiene ocasionalmente y el agente puede no conocer cuáles de sus múltiples acciones la originaron
- ▷ Para compensar la poca información aportada por la recompensa, se suelen explotar otras fuentes de información como
 - ↳ demostraciones expertas usadas de manera supervisada
 - ↳ datos no supervisados usados mediante un sistema no supervisado para descubrir la estructura subyacente del entorno



► Los tres tipos de ML vistos como una tarta de chocolate:

■ “Pure” Reinforcement Learning (cherry)

- The machine predicts a scalar reward given once in a while.
- **A few bits for some samples**

■ Supervised Learning (icing)

- The machine predicts a category or a few numbers for each input
- Predicting human-supplied data
- **10→10,000 bits per sample**

■ Unsupervised/Predictive Learning (cake)

- The machine predicts any part of its input for any observed part.
- Predicts future frames in videos
- **Millions of bits per sample**




1.5. Tareas típicas y preproceso de datos

1.5.1. Algunos conjuntos de imágenes comunes


1.5.1.1. Conjuntos de imágenes pequeños

- ▶ ***MNIST***: 60K+10K imágenes 28×28 de los 10 dígitos
- ▶ ***EMNIST***: 698K+116K imágenes 28×28 de 62 caracteres
- ▶ ***Fashion-MNIST***: 60K+10K imágenes 28×28 de 10 clases
- ▶ ***CIFAR***: 50K+10K imágenes $32 \times 32 \times 3$ (RGB) de 10 clases

► **MNIST:** 60K+10K imágenes 28×28 de los 10 dígitos




► **EMNIST:** 698K+116K imàgenes 28×28 de 62 caracteres



► **Fashion-MNIST:** 60K+10K imágenes 28×28 de 10 prendas de ropa



► **CIFAR:** 50K+10K imágenes $32 \times 32 \times 3$ (RGB) de 10 tipos de objeto




1.5.1.2. ImageNet

► **ImageNet:** 14M imágenes $256 \times 256 \times 3$ de objetos de 20K clases



- **ImageNet Large Scale Visual Recognition Challenge:** competición desarrollada de 2010 a 2018 sobre 1.3M imágenes de 1K clases, en la que se obtuvieron tasas de error super-humanas ($< 5\%$)



1.5.2. Algunos conjuntos de texto comunes

- ▶ *Procesamiento del lenguaje natural (NLP, natural language processing)*: incluye gran variedad de tareas sobre texto en las que el aprendizaje automático obtiene grandes resultados

1.5.2.1. Clasificación de texto

- ▶ *Clasificación de texto*: tarea sencilla para aplicaciones como
 - ▷ *Filtrado de correo spam*
 - ▷ *Análisis de sentimientos: polaridad* positiva o negativa de la opinión expresada en un texto
 - ⇒ *IMDB movie review dataset* contiene 50K revisiones (+ o -) de películas; mitad para entrenamiento y mitad de test:
 - *this film was just brilliant casting location...* (+)
 - *big hair big boobs bad music and a giant safety...* (-)

1.5.2.2. Traducción automática

- ▶ **Traducción automática (MT, machine translation):** estudia la automatización de la traducción de textos (o habla) entre idiomas
- ▶ **Textos paralelos:** colecciones de ejemplos de traducción para entrenar redes neuronales en los sistemas actuales
- ▶ **Europarl v10:** corpus con ejemplos EsPt, DeEn, FrEn, etc.

Ratificación y ampliación de los convenios actualizados de la OIT (votación)

Ratifizierung und Umsetzung der aktualisierten IAO-Übereinkommen (Abstimmung)

Ratification et mise en œuvre des conventions de l'OIT mises à jour (vote)

Ratificação e aplicação das convenções que a OIT considerou actualizadas (votação)

The ratification and implementation of the updated ILO conventions (vote)

The ratification and implementation of the updated ILO conventions (vote)

1.5.2.3. Otras tareas seq2seq

- ▶ **seq2seq:** generalización de MT que estudia el aprendizaje de una transformación desde una secuencia (de entrada) x a cualquier otra secuencia (de salida) y
- ▶ seq2seq incluye tareas como:
 - ▷ *Resumen (automático) de documentos*
 - ▷ *Búsqueda de respuestas (question answering)*

► **Stanford Question Answering Dataset (SQuAD):** 100K preguntas sobre pasajes (texto) de Wikipedia

▷ *T: In meteorology, precipitation is any product of the condensation of atmospheric water vapor that falls under **gravity**. The main forms of precipitation include drizzle, rain, sleet, snow, **graupel** and hail... Precipitation forms as smaller droplets coalesce via collision with other rain drops or ice crystals **within a cloud**. Short, intense periods of rain in scattered locations are called “showers”.*

▷ *Q1: What causes precipitation to fall?*

↳ *A1: **gravity***

▷ *Q2: What is another main form of precipitation besides drizzle, rain, snow, sleet and hail?*

↳ *A2: **graupel***

▷ *Q3: Where do water droplets collide with ice crystals to form precipitation?*

↳ *A3: **within a cloud***

1.5.2.4. Modelado del lenguaje

- ▶ **Language modeling:** estudia cómo aprender un modelo incondicional, $p(x)$, siendo x un texto de entrada sin salida correspondiente (aprendizaje no supervisado)
- ▶ **Textos monolingües:** grandes colecciones para entrenar
- ▶ **n -gramas:** tablas de cuentas de secuencias de n palabras
- ▶ **Modelos de lenguaje neuronales:** redes del mayor tamaño posible y entrenadas con el mayor número posible de ejemplos
- ▶ **Modelos pre-entrenados:** redes pre-entrenadas con muchísimos ejemplos y luego aplicadas a tareas diversas de **natural language understanding (NLU)** mediante **fine-tuning** discriminativo propio de la tarea específica

1.5.3. Preproceso de datos de entrada discretos

1.5.3.1. Codificación *one-hot*

- **Codificación *one-hot* o *dummy* (ficticia)**: dada una variable categórica x que puede tomar K valores, su codificación one-hot es

$$\text{one-hot}(x) = [\mathbb{1}(x = 1), \dots, \mathbb{1}(x = K)] \quad (54)$$

- **Ejemplo**: si x puede valer R, G o B

$$\text{one-hot}(R) = [1, 0, 0] \quad (55)$$

$$\text{one-hot}(G) = [0, 1, 0] \quad (56)$$

$$\text{one-hot}(B) = [0, 0, 1] \quad (57)$$

1.5.3.2. Cruce de variables

- **Efectos principales y de interacción:** un modelo lineal con codificación one-hot para cada variable categórica captura los efectos principales de cada variable, pero no los de interacción entre ellas
- *Ejemplo:* queremos predecir la eficiencia (en consumo de combustible) de un vehículo a partir de dos variables categóricas

$x_1 \in \{S, T, F\}$: tipo; SUV, Truck o Family car

$x_2 \in \{U, J\}$: origen; USA o Japón

- ▷ Concatenación de sus codificaciones one-hot:

$$\phi(\mathbf{x}) = [1, \mathbb{1}(x_1 = S), \mathbb{1}(x_1 = T), \mathbb{1}(x_1 = F), \mathbb{1}(x_2 = U), \mathbb{1}(x_2 = J)]$$

- ▷ Un modelo lineal tiene en cuenta x_1 y x_2 por separado, pero no conjuntamente, por lo que no puede modelizar adecuadamente la eficiencia de, por ejemplo, camiones USA

- ***Cruces de variables (feature crosses)***: introducimos nuevas variables mediante la composición de otras
- ***Ejemplo (cont.)***: introducimos una nueva característica compuesta, con 3×2 valores posibles, cruzando las dos originales

$$f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^t \phi(\mathbf{x}) \quad (58)$$

$$\begin{aligned} &= w_0 + w_1 \mathbb{1}(x_1 = S) + w_2 \mathbb{1}(x_1 = T) + w_3 \mathbb{1}(x_1 = F) \\ &+ w_4 \mathbb{1}(x_2 = U) + w_5 \mathbb{1}(x_2 = J) \\ &+ w_6 \mathbb{1}(x_1 = S, x_2 = U) \\ &+ w_7 \mathbb{1}(x_1 = T, x_2 = U) \\ &+ w_8 \mathbb{1}(x_1 = F, x_2 = U) \\ &+ w_9 \mathbb{1}(x_1 = S, x_2 = J) \\ &+ w_{10} \mathbb{1}(x_1 = T, x_2 = J) \\ &+ w_{11} \mathbb{1}(x_1 = F, x_2 = J) \end{aligned} \quad (59)$$

1.5.4. Preproceso de texto

- ▶ Aspectos a considerar para trabajar con (documentos de) texto:
 - ▷ Los documentos puede ser de diferentes longitudes, por lo que no podemos tratarlos directamente como vectores de características de dimensión fija
 - ▷ Las palabras son variables categóricas con muchos valores posibles (la talla del vocabulario), por lo que sus codificaciones one-hot son de muy alta dimensión y sin noción de **similitud natural**
 - ▷ *Out-of-vocabulary (OOV) words*: podemos encontrar palabras en test que no hayan sido vistas en entrenamiento


1.5.4.1. El modelo bolsa de palabras

- ▶ **Bag of words:** ignoramos el orden de las palabras en el documento, reduciéndolo a un vector de cuentas (de ocurrencias) de cada **palabra, término** o **token** en un vocabulario dado
- ▶ Para reducir el número de tokens, los documentos se preprocesan con técnicas diversas como:
 - ▷ Eliminación de signos de puntuación
 - ▷ **Lowercasing:** conversión a minúsculas
 - ▷ **Stop word removal:** supresión de palabras funcionales
 - ▷ **Word stemming:** lematización

- ▶ **Vector space model:** modelo de representación de documentos en un espacio vectorial
 - ▷ Sea D el número de tokens del vocabulario
 - ▷ Sea T_n la longitud del documento n
 - ▷ Sea x_{nt} el token en la posición t del documento n
 - ▷ El documento n se representa con un vector D -dimensional $\tilde{x}_n$ en el que $\tilde{x}_{nv}$ es el número de ocurrencias de la palabra v

$$\tilde{x}_{nv} = \sum_{t=1}^{T_n} \mathbb{1}(x_{nt} = v) \quad (60)$$

- **Term frequency matrix:** matriz $D \times N$ donde TF_{ij} es la frecuencia del término i en el documento j (mayor cuanto más oscura bajo)



1.5.4.2. TF-IDF

- **TF log-escalada:** resta importancia a la TF ya que muchos de los términos más frecuentes tienen poca carga semántica

$$\log(\text{TF}_{ij} + 1) \quad (61)$$

- **Inverse document frequency (IDF):** estima la importancia de un término i en proporción inversa al número de documentos que lo incluyen, DF_i , log-escalada

$$\text{IDF}_i = \log \frac{N}{1 + \text{DF}_i} \quad (62)$$

- **TF-IDF:** combina la TF log-escalada con la IDF

$$\text{TFIDF}_{ij} = \log(\text{TF}_{ij} + 1) \cdot \text{IDF}_i \quad (63)$$

1.5.4.3. Word embeddings

- **Word embedding (encaje o inmersión de palabras):** transforma cada vector disperso one-hot, $\mathbf{x}_{nt} \in \{0, 1\}^V$, en uno denso de baja dimensión, $\mathbf{e}_{nt} \in \mathbb{R}^K$, usando

$$\mathbf{e}_{nt} = \mathbf{E}\mathbf{x}_{nt} \quad (64)$$

donde $\mathbf{E} \in \mathbb{R}^{K \times V}$ se aprende para que la proximidad entre vectores indique similitud semántica entre las palabras que representan

- **Bag of word embeddings:** extiende la bag of words sustituyendo codificaciones one-hot por sus embeddings

$$\bar{\mathbf{e}}_n = \sum_{t=1}^{T_n} \mathbf{e}_{nt} = \mathbf{E}\tilde{\mathbf{x}}_n \quad (65)$$

donde $\tilde{\mathbf{x}}_n$ es la bag of words del documento n

- ▶ Clasificación de documentos mediante regresión logística aplicada a bag of words embeddings:

$$p(y = c \mid \mathbf{x}; \boldsymbol{\theta}) = S_c(f(\mathbf{x}; \boldsymbol{\theta})) \quad (66)$$

- ▷ ***Pre-trained word embeddings***: se suelen usar matrices de embedding pre-entrenadas, por lo que se obtiene un modelo lineal

1.5.4.4. Palabras fuera de vocabulario

- ▶ **Out-of-vocabulary (OOV) words:** podemos encontrar palabras en test que no hayan sido vistas en entrenamiento
 - ▷ *Ejemplo:* nombres propios de personas y lugares
- ▶ **UNK:** un heurístico convencional consiste en reemplazar las palabra desconocidas por un símbolo especial, UNK, si bien supone renunciar a adivinar parte del significado al menos
 - ▷ *Ejemplo:* de athazagoraphobia (miedo a ser ignorado) podríamos adivinar que significa miedo a algo gracias al sufijo
- ▶ **Subword units** o **wordpieces:** alternativa consistente en emplear vocabularios de sub-palabras obtenidos con técnicas de codificación como **byte-pair encoding (BPE)**

1.5.5. Datos perdidos

- ▶ ***Datos perdidos:*** pueden producirse en una matriz de datos por mecanismos más o menos aleatorios
 - ▷ ***Missing completely at random (MCAR):*** completamente al azar
 - ▷ ***Missing at random (MAR):*** condicionados por los observados
 - ▷ ***Missing not at random (MNAR):*** no aleatorios; dependientes tanto de observados como perdidos
- ▶ En MAR (y MCAR) podemos ignorar el mecanismo que origina los datos perdidos, pero no en MNAR (caso que no estudiamos)
- ▶ ***Imputación del valor medio:*** técnica usual
- ▶ ***Algoritmo expectation minimization (EM):*** técnica más general

1.6. El aprendizaje automático y otras áreas

- ▶ **Análisis predictivo (*predictive analytics*)**: similar al ML, se centra en aplicaciones de negocios como la administración de relaciones con el cliente, análisis de cobros y predicción de cartera
- ▶ **Minería de datos**: cubre tanto aprendizaje supervisado como no supervisado, pero se orienta a bases de datos (estructuradas)
- ▶ **Ciencia de datos**: emplea técnicas de ML y estadística, pero desde una óptica más estadística, haciendo énfasis en la integración y visualización de datos, así como en el papel del analista de datos y el análisis experto del dominio
- ▶ **IA simbólica**: basada en la lógica, el procesamiento de listas simbólicas y el conocimiento experto; decayó en los 90, la **IA moderna** es sinónimo de ML y redes neuronales
- ▶ **Bases del ML**: *probabilidad, estadística, teorías de la decisión e información, álgebra lineal y optimización*

Referencias

- [1] Arthur Samuel. Some studies in machine learning using the game of checkers. *IBM Journal of Research and Development*, 1959.
- [2] Tom Mitchell. *Machine Learning*. McGraw Hill, 1997.
- [3] Nils J. Nilsson. *The Quest for Artificial Intelligence*. Cambridge University Press, 2009.
- [4] M. I. Jordan and T. M. Mitchell. Machine learning: Trends, perspectives, and prospects. *Science*, 349(6245):255–260, 2015.
- [5] Kevin P. Murphy. *Probabilistic Machine Learning: An introduction*. MIT Press, 2021.