



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Probabilidad: modelos univariados

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

2.1	Introducción	1
2.1.1	Qué es probabilidad?	1
2.1.2	Tipos de incertidumbre	1
2.1.3	Probabilidad como extensión de la lógica	2
2.1.3.1	Probabilidad de un evento	2
2.1.3.2	Probabilidad de una conjunción de dos eventos	3
2.1.3.3	Probabilidad de una unión de dos eventos	4
2.1.3.4	Probabilidad condicional de un evento dado otro	5
2.1.3.5	Independencia de eventos	6
2.1.3.6	Independencia condicional de eventos	7
2.2	Variables aleatorias	8
2.2.1	Variables aleatorias discretas	9
2.2.2	Variables aleatorias continuas	11
2.2.2.1	Función de distribución acumulada (cdf)	12
2.2.2.2	Función de densidad de probabilidad (pdf)	14
2.2.2.3	Cuantiles	16
2.2.3	Conjuntos de variables aleatorias relacionadas	17
2.2.4	Independencia e independencia condicional	20

2.2.5	Momentos de una distribución	21
2.2.5.1	Media de una distribución	21
2.2.5.2	Varianza de una distribución	23
2.2.5.3	Moda de una distribución	25
2.2.5.4	Momentos condicionales	26
2.2.6	Limitaciones de la estadística descriptiva	30
2.3	Regla de Bayes	31
2.3.1	Ejemplo: Test de COVID-19	34
2.3.2	Ejemplo: El problema de Monty Hall	35
2.3.3	Problemas inversos	36
2.4	Distribuciones Bernoulli y binomial	37
2.4.1	Definición	37
2.4.2	Función logística o sigmoide	41
2.4.3	Regresión logística binaria	47
2.5	Distribuciones categórica y multinomial	49
2.5.1	Definición	49
2.5.2	La función softmax	54
2.5.3	Regresión logística multiclase	57
2.5.4	El truco log-sum-exp	60

2.6	Distribución (normal) Gaussiana univariada	63
2.6.1	Función de distribución acumulada	63
2.6.2	Función de densidad de probabilidad	67
2.6.3	Regresión	70
2.6.4	¿Por qué se emplea tanto?	72
2.6.5	La función delta de Dirac como caso límite	73

2.1. Introducció

2.1.1. Qué es probabilidad?

- ▶ *Frecuentista*: frecuencia (asintótica) de eventos repetitivos
- ▶ *Bayesiana*: modelo de *incertidumbre* sobre eventos

2.1.2. Tipos de incertidumbre

- ▶ *Epistémica*: incertidumbre sobre el modelo
- ▶ *Aleatória*: incertidumbre de los datos

2.1.3. Probabilidad como extensión de la lógica

2.1.3.1. Probabilidad de un evento

- ▶ **Evento:** variable binaria A
- ▶ Probabilidad de que el evento A sea cierto: $\Pr(A)$
- ▶ Requerimos: $0 \leq \Pr(A) \leq 1$
- ▶ $\Pr(A) = 0$ significa que es **imposible** que A ocurra (falso)
- ▶ $\Pr(A) = 1$ significa que es **seguro** que A ocurra (cierto)
- ▶ $\Pr(\bar{A}) = 1 - \Pr(A)$ es la probabilidad de que A no ocurra

2.1.3.2. Probabilidad de una conjunción de dos eventos

- *Probabilidad conjunta* de que A y B ocurran

$$\Pr(A \wedge B) = \Pr(A, B) \quad (1)$$

- Si A y B son eventos independientes, tenemos

$$\Pr(A, B) = \Pr(A) \Pr(B) \quad (2)$$

- *Ejemplo:*

- ▷ X e Y se escogen uniformemente al azar de $\mathcal{X} = \{1, 2, 3, 4\}$
- ▷ A es el evento $X \in \{1, 2\}$
- ▷ B es el evento $Y \in \{3\}$
- ▷ A y B son independientes (pues X e Y se escogen indep.)
- ▷ $\Pr(A, B) = \Pr(A) \Pr(B) = \frac{1}{2} \cdot \frac{1}{4}$

2.1.3.3. Probabilidad de una unión de dos eventos

- Probabilidad de que el evento A o B ocurran (uno solo o los dos)

$$\Pr(A \vee B) = \Pr(A) + \Pr(B) - \Pr(A \wedge B) \quad (3)$$

- Si A y B son eventos mutuamente excluyentes, esto es, no pueden darse a la vez; tenemos

$$\Pr(A \vee B) = \Pr(A) + \Pr(B) \quad (4)$$

- *Ejemplo:*

- ▷ X se escoge uniformemente al azar de $\mathcal{X} = \{1, 2, 3, 4\}$

- ▷ A es el evento $X \in \{1, 2\}$

- ▷ B es el evento $X \in \{3\}$

- ▷ $\Pr(A \vee B) = \frac{2}{4} + \frac{1}{4}$

2.1.3.4. Probabilidad condicional de un evento dado otro

- **Probabilidad condicional** de que un evento B ocurra sabiendo que otro evento dado, A , ha ocurrido, es:

$$\Pr(B \mid A) \triangleq \frac{\Pr(A, B)}{\Pr(A)} \quad (5)$$

- No está definida si $\Pr(A) = 0$ pues no tiene sentido condicionar sobre la base de un evento imposible

2.1.3.5. Independencia de eventos

- Dos eventos A y B son *independientes* sii

$$\Pr(A, B) = \Pr(A) \Pr(B) \quad (6)$$

- Se suele escribir como $A \perp B$ o $A \perp\!\!\!\perp B$

2.1.3.6. Independencia condicional de eventos

- Dos eventos A y B son *condicionalmente independientes* dado un evento C sii

$$\Pr(A, B \mid C) = \Pr(A \mid C) \Pr(B \mid C) \quad (7)$$

- Se suele escribir como $A \perp B \mid C$ o $A \perp\!\!\!\perp B \mid C$

2.2. Variables aleatorias

- ▶ **Variable aleatoria:** valor desconocido de interés X
- ▶ **Espacio muestral:** conjunto de valores posibles $\mathcal{X}$
- ▶ **Evento:** subconjunto de valores en $\mathcal{X}$
- ▶ **Ejemplo:**
 - ▷ X = "valor obtenido al lanzar un dado"
 - ▷ $\mathcal{X} = \{1, \dots, 6\}$
 - ▷ $X = 1 \rightarrow$ "sale 1"
 - ▷ $X \in \{1, 3, 5\} \rightarrow$ "sale valor impar"
 - ▷ $1 \leq X \leq 3 \rightarrow$ "sale entre 1 y 3"

2.2.1. Variables aleatorias discretas

► *Variable aleatoria discreta:* $\mathcal{X}$ discreto, finito o infinito contable

► $\Pr(X = x)$ es la probabilidad del evento “ X toma el valor x ”

► *Función de masa de probabilidad (pmf):*


$$p(x) \triangleq \Pr(X = x) \quad (8)$$

► Se cumple:

$$0 \leq p(x) \leq 1 \quad (9)$$


$$\sum_{x \in \mathcal{X}} p(x) = 1 \quad (10)$$

► *Ejemplo:* dos pmfs definidas en $\mathcal{X} = \{1, 2, 3, 4\}$



$$p(x) = \frac{1}{4}$$

uniforme



$$p(x) = \mathbb{1}(x = 1)$$

indicadora

2.2.2. Variables aleatorias continuas

- ▶ *Variable aleatoria continua:* $\mathcal{X}$ es $\mathbb{R}$
- ▶ No podemos asociar X a un número discreto de valores distintos
- ▶ Sí podemos asociar X a un número discreto de *intervalos* que particionen $\mathcal{X}$
- ▶ Asociando eventos con que X pertenezca a cada uno de los intervalos, podemos razonar con los mismos al igual que con los valores individuales del caso discreto
- ▶ Permitiendo que la talla de los intervalos se reduzca a un infinitesimal, podemos representar la probabilidad de que X tome un valor específico (aproximadamente)

2.2.2.1. Función de distribución acumulada (cdf)

- ▶ Sean $A = (X \leq a)$, $B = (X \leq b)$ y $C = (a < X \leq b)$, con $a < b$
- ▶ Dado que $B = A \vee C$ y que A y C son mutuamente excluyentes

$$\Pr(B) = \Pr(A) + \Pr(C) \quad (11)$$

por lo que

$$\Pr(C) = \Pr(B) - \Pr(A) \quad (12)$$

- ▶ **Función de distribución acumulada (cdf)** de una v.a. X :

$$P(x) \triangleq \Pr(X \leq x) \quad (13)$$


- ▶ Probabilidad de que X se encuentre en intervalo dado:

$$\Pr(a < X \leq b) = \Pr(X \leq b) - \Pr(X \leq a) = P(b) - P(a) \quad (14)$$

- ▶ Las cdfs son funciones monótonas no-decrecientes

► Cdf de la normal estándar:

Gaussian cdf



2.2.2.2. Función de densidad de probabilidad (pdf)

- *Función de densidad de probabilidad (pdf)*: derivada de la cdf

$$p(x) \triangleq \frac{d}{dx}P(x) \quad (15)$$

- La pdf solo está definida donde existe derivada
- Probabilidad de que X se encuentre en intervalo dado:


$$\Pr(a < X \leq b) = \int_a^b p(x) dx = P(b) - P(a) \quad (16)$$

- Cuando la talla del intervalo es muy pequeña, podemos escribir:

$$\Pr(x \leq X \leq x + dx) \approx p(x) dx \quad (17)$$

La probabilidad de que X “caiga” en un pequeño intervalo alrededor de x es igual a la densidad en x por la amplitud del intervalo

- Pdf de la normal estándar: cada región sombreada contiene $\alpha/2$ de la masa de probabilidad ($\alpha = 0.05$)



2.2.2.3. Cuantiles

- **Cdf inversa** o **función cuantil** de una cdf P monótona estricta:

$$P^{-1}(q) \triangleq \{x : P(x) = q\} \quad (0 < q < 1) \quad (18)$$

- Si P no es monótona estricta (con saltos o llanos):

$$P^{-1}(q) \triangleq \inf\{x : P(x) \geq q\} \quad (19)$$

- **Cuantil** q de P : el $x_q \triangleq P^{-1}(q)$ tal que $\Pr(X \leq x_q) = q$

- **Mediana** de P : $P^{-1}(0.5)$

- **Cuartiles** inferior y superior de P : $P^{-1}(0.25)$ y $P^{-1}(0.75)$

- **Ejemplo:** si Φ es la cdf de la normal estándar y Φ^{-1} su inversa, el intervalo centrado en el origen con un 95 % de probabilidad es

$$(\Phi^{-1}(0.025), \Phi^{-1}(0.975)) = (-1.96, 1.96) \quad (20)$$

2.2.3. Conjuntos de variables aleatorias relacionadas

- *Distribución conjunta* de dos variables aleatorias X e Y :

$$p(x, y) = p(X = x, Y = y) \quad (21)$$

- Si X e Y son finitas, su distribución conjunta puede representarse en una tabla 2d cuyas entradas suman uno en total
- *Ejemplo:*

$p(X, Y)$	$Y = 0$	$Y = 1$
$X = 0$	0.2	0.3
$X = 1$	0.3	0.2

- **Distribución marginal** de una variable aleatoria X :

$$p(X = x) = \sum_y p(X = x, Y = y) \quad (22)$$

- La marginal de Y se define análogamente

$$p(Y = y) = \sum_x p(X = x, Y = y) \quad (23)$$

- *Ejemplo:* marginales en los **márgenes** de la tabla

$p(X, Y)$	$Y = 0$	$Y = 1$	$p(X)$
$X = 0$	0.2	0.3	0.5
$X = 1$	0.3	0.2	0.5
$p(Y)$	0.5	0.5	

- También llamada **regla suma** o **de la probabilidad total**

► **Distribución condicional** de Y dada X :

$$p(Y = y \mid X = x) = \frac{p(X = x, Y = y)}{p(X = x)} \quad (24)$$

► **Ejemplo:**

$p(X, Y)$	$Y = 0$	$Y = 1$	$p(X = x)$		$p(Y X)$	$Y = 0$	$Y = 1$
$X = 0$	0.2	0.3	0.5	→	$X = 0$	0.4	0.6
$X = 1$	0.3	0.2	0.5		$X = 1$	0.6	0.4

► **Regla producto:** reordenando factores

$$p(X = x, Y = y) = p(X = x)p(Y = y|X = x) \quad (25)$$

► **Regla de la cadena:** extiende la regla producto a D variables

$$p(\mathbf{x}_{1:D}) = p(x_1) p(x_2|x_1) p(x_3|x_1, x_2) \cdots p(x_D|\mathbf{x}_{1:D-1}) \quad (26)$$

2.2.4. Independencia e independencia condicional

- ▶ X e Y *incondicional* o *marginamente independientes*:

$$X \perp Y \quad \Leftrightarrow \quad p(X, Y) = p(X)p(Y) \quad (27)$$

- ▶ El conjunto de variables $X_1, \dots, X_n$ es *independiente* si:

$$p(X_1, \dots, X_n) = \prod_{i=1}^n p(X_i) \quad (28)$$

- ▶ X e Y *condicionalmente independientes* dada Z :

$$X \perp Y \mid Z \quad \Leftrightarrow \quad p(X, Y \mid Z) = p(X \mid Z) p(Y \mid Z) \quad (29)$$

- ▷ Representación: $X - Z - Y$ o con *modelos gráficos*

2.2.5. Momentos de una distribución

2.2.5.1. Media de una distribución

► *Media o valor esperado:* denotada mediante μ

► Para variables continuas:

$$\mathbb{E}[X] \triangleq \int_{\mathcal{X}} x p(x) dx \quad (30)$$

► Para variables discretas:

$$\mathbb{E}[X] \triangleq \sum_{x \in \mathcal{X}} x p(x) \quad (31)$$

► El caso discreto solo es útil si los valores de x están ordenados de alguna manera; por ejemplo, si representan cuentas enteras

► *Linealidad de la esperanza:*

$$\mathbb{E}[aX + b] = a \mathbb{E}[X] + b \quad (32)$$

► Esperanza de la suma de n variables aleatorias:

$$\mathbb{E} \left[\sum_{i=1}^n X_i \right] = \sum_{i=1}^n \mathbb{E}[X_i] \quad (33)$$

► Esperanza del producto de n v.a. independientes:

$$\mathbb{E} \left[\prod_{i=1}^n X_i \right] = \prod_{i=1}^n \mathbb{E}[X_i] \quad (34)$$

2.2.5.2. Varianza de una distribución

- **Varianza:** denotada mediante σ^2

$$\mathbb{V}[X] \triangleq \mathbb{E}[(X - \mu)^2] \quad (35)$$

- Para variables continuas:

$$\mathbb{V}[X] = \int (x - \mu)^2 p(x) dx \quad (36)$$

- Para variables discretas:

$$\mathbb{V}[X] = \sum_x (x - \mu)^2 p(x) \quad (37)$$

- Propiedad: "media del cuadrado menos cuadrado de la media"

$$\mathbb{V}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] \quad (38)$$

$$= \mathbb{E}[X^2 - 2X \mathbb{E}[X] + \mathbb{E}[X]^2] \quad (39)$$

$$= \mathbb{E}[X^2] - 2 \mathbb{E}[X] \mathbb{E}[X] + \mathbb{E}[X]^2 \quad (40)$$

$$= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \quad (41)$$

- **Desviación típica:** denotada mediante σ

$$\text{std}[X] \triangleq \sqrt{\mathbb{V}[X]} \quad (42)$$

- Varianza de una variable aleatoria escalada y desplazada:

$$\mathbb{V}[aX + b] = a^2 \mathbb{V}[X] \quad (43)$$

- Varianza de la suma de n v.a. independientes:

$$\mathbb{V} \left[\sum_{i=1}^n X_i \right] = \sum_{i=1}^n \mathbb{V}[X_i] \quad (44)$$

- Varianza del producto de n v.a. independientes:


$$\mathbb{V} \left[\prod_{i=1}^n X_i \right] = \prod_{i=1}^n (\sigma_i^2 + \mu_i^2) - \prod_{i=1}^n \mu_i^2 \quad (45)$$

2.2.5.3. Moda de una distribución

- **Moda:** valor de máxima (densidad de) probabilidad

$$\mathbf{x}^* = \arg \max_{\mathbf{x}} p(\mathbf{x}) \quad (46)$$

- Si la distribución es **multimodal**, puede no ser única



2.2.5.4. Momentos condicionales

► *Ley de la esperanza total* o *esperanzas iteradas*:

$$\mathbb{E}[X] = \mathbb{E}_Y[\mathbb{E}[X|Y]] \quad (47)$$

► Demostración en el caso discreto:

$$\begin{aligned} \mathbb{E}_Y[\mathbb{E}[X|Y]] &= \mathbb{E}_Y \left[\sum_x x p(X = x|Y) \right] \\ &= \sum_y \left[\sum_x x p(X = x|Y = y) \right] p(Y = y) \\ &= \sum_{x,y} x p(X = x, Y = y) \\ &= \sum_x x \sum_y p(X = x, Y = y) \\ &= \mathbb{E}[X] \end{aligned}$$

► *Ejemplo:* esperanza de vida de una bombilla

- ▷ X es la esperanza de vida de una bombilla en horas
- ▷ Y identifica la fábrica que la produce de dos posibles
- ▷ $\mathbb{E}[X|Y = 1] = 5000$ (las de la fábrica 1 duran 5000 horas)
- ▷ $\mathbb{E}[X|Y = 2] = 4000$ (las de la 2 duran 4000)
- ▷ $p(Y = 1) = 0.6$ (la fábrica 1 produce el 60 % de las bombillas)
- ▷ $p(Y = 2) = 0.4$ (las restantes se producen en la 2)
- ▷ La duración esperada de una bombilla escogida al azar es:

$$\begin{aligned}\mathbb{E}[X] &= \mathbb{E}[X|Y = 1] p(Y = 1) + \mathbb{E}[X|Y = 2] p(Y = 2) \\ &= 5000 \cdot 0.6 + 4000 \cdot 0.4 \\ &= 4600 \text{ horas}\end{aligned}$$

► *Ley de la varianza total* o *fórmula de la varianza condicional*:

$$\mathbb{V}[X] = \mathbb{E}_Y[\mathbb{V}[X|Y]] + \mathbb{V}_Y[\mathbb{E}[X|Y]] \quad (48)$$

► Demo: dados los momentos condicionales (funciones de Y)

$$\mu_{X|Y} = \mathbb{E}[X|Y] \quad (49)$$

$$s_{X|Y} = \mathbb{E}[X^2|Y] \quad (50)$$

$$\sigma_{X|Y}^2 = \mathbb{V}[X|Y] = s_{X|Y} - \mu_{X|Y}^2 \quad (51)$$

tenemos:

$$\mathbb{V}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \quad (52)$$

$$= \mathbb{E}_Y[s_{X|Y}] - (\mathbb{E}_Y[\mu_{X|Y}])^2 \quad (53)$$

$$= \mathbb{E}_Y[\sigma_{X|Y}^2] + \mathbb{E}_Y[\mu_{X|Y}^2] - (\mathbb{E}_Y[\mu_{X|Y}])^2 \quad (54)$$

$$= \mathbb{E}_Y[\mathbb{V}[X|Y]] + \mathbb{V}_Y[\mu_{X|Y}] \quad (55)$$

► *Ejemplo:* mixtura de K Gaussianas univariadas

▷ Y es una variable oculta que indica la componente

$$\triangleright X = \sum_{y=1}^K \pi_y \mathcal{N}(X | \mu_y, \sigma_y)$$

▷ $\pi_1 = \pi_2 = 0.5$, $\mu_1 = 0$, $\mu_2 = 2$, $\sigma_1 = \sigma_2 = 0.5$ (Sec. 2.2.5.3)

▷ **Tenemos:** $\mathbb{V}[X] = \mathbb{E}_Y[\mathbb{V}[X|Y]] + \mathbb{V}_Y[\mathbb{E}[X|Y]]$

$$\mathbb{E}[\mathbb{V}[X|Y]] = \pi_1 \sigma_1^2 + \pi_2 \sigma_2^2 = 0.25 \quad (56)$$

$$\mathbb{V}[\mathbb{E}[X|Y]] = \pi_1 (\mu_1 - \bar{\mu})^2 + \pi_2 (\mu_2 - \bar{\mu})^2 \quad (57)$$



$$= 0.5(0 - 1)^2 + 0.5(2 - 1)^2 \quad (58)$$

$$= 0.5 + 0.5 = 1 \quad (59)$$

por lo que la varianza de X depende más del centroide generador que de la varianza local alrededor de cada centroide

2.2.6. Limitaciones de la estadística descriptiva

- ▶ Aunque es usual resumir una distribución con estadísticos simples (media y varianza), ello supone gran pérdida de información
- ▶ *Ejemplo:* conjuntos de datos con mismas medias y varianzas



2.3. Regla de Bayes

► *Inferencia Bayesiana:*

- ▷ *Inferencia:* "acto de pasar del muestreo de datos a generalizaciones, usualmente con grados de certidumbre calculados"
 - ▷ *Bayesiana:* métodos que representan los grados de certidumbre con teoría de la probabilidad y que aprovechan la *regla de Bayes* para actualizarlos con datos
- *Regla de Bayes:* fórmula para calcular la distribución de probabilidad sobre los posibles valores de una cantidad oculta (hidden) o desconocida, H , a partir de datos observados $Y = y$

$$p(H = h \mid Y = y) = p(H = h) \frac{p(Y = y \mid H = h)}{p(Y = y)} \quad (60)$$

Se sigue de la regla producto $p(y)p(h|y) = p(h, y) = p(h)p(y|h)$

- ▶ **Distribución a priori:** $p(H)$ es lo que sabemos sobre los posibles valores de H antes de observar datos
 - ▷ *Ejemplo:* si H tiene K valores posibles, entonces $p(H)$ es un vector de K probabilidades que suman 1
- ▶ **Distribución de observaciones:** $p(Y \mid H = h)$ es la distribución sobre los posibles valores de Y que esperamos ver si $H = h$
- ▶ **Verosimilitud:** $p(Y = y \mid H = h)$ es la evaluación de $p(Y \mid H = h)$ con las observaciones reales y
 - ▷ Se interpreta como función de h ya que y es fija, por lo que no es una distribución de probabilidad
- ▶ **Distribución conjunta no normalizada:**

$$p(H = h, Y = y) = p(H = h) p(Y = y \mid H = h) \quad (61)$$

- **Verosimilitud marginal:** $p(Y = y)$, distribución normalizada obtenida mediante marginalización sobre la H desconocida

$$p(Y = y) = \sum_{h' \in \mathcal{H}} p(H = h') p(Y = y | H = h') \quad (62)$$

$$= \sum_{h' \in \mathcal{H}} p(H = h', Y = y) \quad (63)$$

- **Distribución a posteriori:** $p(H = h | Y = y)$, se obtiene normalizando la distribución conjunta por la verosimilitud marginal

$$p(H = h | Y = y) = \frac{p(H = h, Y = y)}{p(Y = y)} = p(H = h) \frac{p(Y = y | H = h)}{p(Y = y)} \quad (64)$$

- ▷ Representa nuestro (nuevo) **estado de creencia** sobre los posibles valores de H tras observar y
- **Resumen:** dado que $p(Y = y)$ no depende de H , puede tratarse como una constante de proporcionalidad que podemos ignorar

$$\text{posterior} \propto \text{prior} \times \text{likelihood}$$

2.3.1. Ejemplo: Test de COVID-19

- ▶ $H = 1$ infección positiva; $H = 0$ infección negativa
- ▶ $Y = 1$ test positivo; $Y = 0$ test negativo
- ▶ Verosimilitud: $p(Y | H)$

	$Y = 0$	$Y = 1$
$H = 0$	0.975	0.025
$H = 1$	0.125	0.875


	$Y = 0$	$Y = 1$
$H = 0$	TNR	FPR
$H = 1$	FNR	TPR

- ▷ TNR: (tasa de) **verdaderos negativos** o **especificidad**
- ▷ TPR: (tasa de) **verdaderos positivos** o **sensibilidad**
- ▷ FPR=1-TNR: (tasa de) **falsos positivos**
- ▷ FNR=1-TPR: (tasa de) **falsos negativos**
- ▶ Prevalencia de la infección: $p(H = 1) = 1\%$
- ▶ Probabilidad de estar infectado si el test es positivo:

$$p(H = 1 | Y = 1) = p(H = 1) \frac{p(Y = 1 | H = 1)}{p(Y = 1)} = 0.01 \frac{0.875}{0.0335} = 26\%$$

2.3.2. Ejemplo: El problema de Monty Hall

- ▶ El *problema de Monty Hall* se basa en el concurso televisivo *Let's Make a Deal* (1963–) presentado por Monty Hall durante 30 años.
- ▶ El concursante elige una puerta de tres; el presentador abre otra y aparece una cabra. En las dos que siguen cerradas hay un coche y otra cabra. El concursante puede cambiar de puerta. ¿Cambia?



- ▶ $H = i$ indica que el coche está en la puerta i ; $P(H = i) = \frac{1}{3}$
- ▶ Escogemos la 1 y el presentador abre la $Y = j$, 2 o 3, escogiendo al azar si el coche está en la 1. Sea k la que deja cerrada.

$$P(Y = j) = \sum_{i=1,j,k} P(H = i) P(Y = j \mid H = i) = \frac{1}{3} \left(\frac{1}{2} + 0 + 1 \right) = \frac{1}{2}$$

$$P(H = k \mid Y = j) = P(H = k) \frac{P(Y = j \mid H = k)}{P(Y = j)} = \frac{1}{3} \frac{1}{\frac{1}{2}} = \frac{2}{3}$$

2.3.3. Problemas inversos

- ▶ La teoría de la probabilidad se ocupa de la predicción de una distribución sobre salidas y dado conocimiento (o asunciones) sobre el estado de la naturaleza, h
- ▶ **Probabilidad inversa:** se ocupa de inferir el estado de la naturaleza a partir de observaciones sobre salidas, esto es, invierte la transformación $h \rightarrow y$
- ▶ *Ejemplos:* inferir una forma 3d a partir de una imagen 2d en **comprensión de escenas visuales**, o la intención h de un locutor a partir de lo que dice en **comprensión del lenguaje natural**
- ▶ **Problemas inversos:** usamos la regla de Bayes para calcular la posterior, $p(h|y)$, mediante un **modelo hacia adelante** $p(y|h)$ y un prior $p(h)$ que descarte estados de la naturaleza no plausibles

2.4. Distribuciones Bernoulli y binomial

2.4.1. Definición

- **Distribución de Bernoulli:** una variable aleatoria binaria Y sigue una distribución de Bernoulli de parámetro θ ,

$$Y \sim \text{Ber}(\theta) \quad (0 \leq \theta \leq 1) \quad (65)$$

si su **pmf** es (convenimos que $0^0 \triangleq 1$ y $0 \log 0 \triangleq 0$)

$$p(y \mid \theta) \triangleq \begin{cases} 1 - \theta & \text{si } y = 0 \\ \theta & \text{si } y = 1 \end{cases} \quad (66)$$

$$= \theta^y + (1 - \theta)(1 - y) \quad (67)$$

$$= \theta^y (1 - \theta)^{1-y} \quad (68)$$

- Y es el resultado de un **experimento** o **ensayo** con probabilidad de **éxito** ($Y = 1$) θ y probabilidad de **fracaso** ($Y = 0$) $1 - \theta$

- Media de una Bernoulli: $Y \sim \text{Ber}(\theta)$

$$\mathbb{E}[Y] = 0 p(0 \mid \theta) + 1 p(1 \mid \theta) \quad (69)$$

$$= 0 (1 - \theta) + 1 \theta = \theta \quad (70)$$

- Media del cuadrado de una Bernoulli:

$$\mathbb{E}[Y^2] = 0^2 p(0 \mid \theta) + 1^2 p(1 \mid \theta) \quad (71)$$

$$= \theta \quad (72)$$

- Varianza de una Bernoulli:

$$\mathbb{V}[Y] = \mathbb{E}[Y^2] - \mathbb{E}[Y]^2 \quad (73)$$

$$= \theta - \theta^2 \quad (74)$$

$$= \theta(1 - \theta) \quad (75)$$

- **Distribución binomial:** una variable aleatoria S sigue una distribución binomial de parámetros $N \in \mathbb{N}$ y θ ,

$$S \sim \text{Bin}(N, \theta) \quad (0 \leq \theta \leq 1) \quad (76)$$

si su pmf es

$$p(s \mid N, \theta) \triangleq \binom{N}{s} \theta^s (1 - \theta)^{N-s} \quad (s = 0, 1, \dots, N) \quad (77)$$


donde $\binom{N}{s}$ es el **coeficiente binomial** N sobre s :

$$\binom{N}{s} \triangleq \frac{N!}{(N-s)!s!} \quad (78)$$

- s es la suma (número) de éxitos en una secuencia de N experimentos de Bernoulli independientes con probabilidad de éxito θ
- (77) se debe a que hay $\binom{N}{s}$ secuencias distintas con s éxitos y cada secuencia ocurre con probabilidad $\theta^s (1 - \theta)^{N-s}$

► *Ejemplo:* distribución binomial con $N = 10$ y $\theta = 0.25$

$\theta=0.25$



2.4.2. Función logística o sigmoide

- **Distribución de probabilidad condicional:** para predecir una variable binaria $y \in \{0, 1\}$ dada una entrada $x \in \mathcal{X}$ necesitamos una distribución de probabilidad condicional de la forma

$$p(y \mid x, \theta) = \text{Ber}(y \mid f(x; \theta)) \quad (79)$$

donde $f(x; \theta)$ es una función para predecir la media de la Bernoulli

- Para evitar la restricción $0 \leq f(x; \theta) \leq 1$, podemos dejar que f sea una función no restringida y emplear el modelo


$$p(y \mid x, \theta) = \text{Ber}(y \mid \sigma(f(x; \theta))) \quad (80)$$

donde $\sigma(\cdot)$ es la **función logística o sigmoide** (en forma de S)


$$\sigma(a) \triangleq \frac{1}{1 + e^{-a}} \quad (81)$$

con $a = f(x; \theta)$

- La sigmoide transforma la recta real en $[0, 1]$:



- Suaviza la *función escalón de Heaviside* $H(a) \triangleq \mathbb{1}(a > 0)$



- Insertando la sigmoide en el modelo tenemos:

$$p(y = 1 \mid \mathbf{x}, \boldsymbol{\theta}) = \frac{1}{1 + e^{-a}} = \frac{e^a}{1 + e^a} = \sigma(a) \quad (82)$$

$$p(y = 0 \mid \mathbf{x}, \boldsymbol{\theta}) = 1 - \frac{1}{1 + e^{-a}} = \frac{e^{-a}}{1 + e^{-a}} = \frac{1}{1 + e^a} = \sigma(-a) \quad (83)$$

- **Log odds (log-posibilidades):** si $p = p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta})$

$$\log \left(\frac{p}{1 - p} \right) = \log \left(\frac{e^a}{1 + e^a} \frac{1 + e^a}{1} \right) = \log(e^a) = a \quad (84)$$

- Así, la logística o sigmoide transforma **log-odds a en p**

$$\sigma(a) = \frac{1}{1 + e^{-a}} = \frac{e^a}{1 + e^a} = p \quad (85)$$

- **Función logit:** la inversa de $\sigma(\cdot)$ transforma **p en log-odds a**


$$\text{logit}(p) = \sigma^{-1}(p) \triangleq \log \left(\frac{p}{1 - p} \right) = a \quad (86)$$

sigmoide



$$\sigma(a) \triangleq \frac{1}{1 + e^{-a}} = \frac{e^a}{1 + e^a} = p$$


$$H(a) \triangleq \mathbb{1}(a > 0)$$



logit

$$\text{logit}(p) \triangleq \log \left(\frac{p}{1 - p} \right) = a$$

$$(0 < p < 1)$$



► Propiedades de la sigmoide y otras funciones relacionadas:

$$\sigma(x) \triangleq \frac{1}{1 + e^{-x}} = \frac{e^x}{1 + e^x} \quad (87)$$

$$\frac{d}{dx} \sigma(x) = \sigma(x)(1 - \sigma(x)) \quad (88)$$

$$1 - \sigma(x) = \sigma(-x) \quad (89)$$

$$\sigma^{-1}(p) = \log \left(\frac{p}{1 - p} \right) \triangleq \text{logit}(p) \quad (90)$$

$$\sigma_+(x) \triangleq \log(1 + e^x) \triangleq \text{softplus}(x) \quad (91)$$

$$\frac{d}{dx} \sigma_+(x) = \sigma(x) \quad (92)$$

2.4.3. Regresión logística binaria

► *Regresión logística binaria*: modelo Bernoulli condicional

$$p(y \mid \mathbf{x}, \boldsymbol{\theta}) = \text{Ber}(y \mid \sigma(f(\mathbf{x}; \boldsymbol{\theta}))) \quad (93)$$

con función predictora de log-odds lineal


$$f(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{w}^t \mathbf{x} + b \quad (94)$$

Esto es,

$$p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = \sigma(\mathbf{w}^t \mathbf{x} + b) \quad (95)$$

$$= \frac{1}{1 + \exp(-(\mathbf{w}^t \mathbf{x} + b))} \quad (96)$$

- *Ejemplo:* modelo ajustado para discriminar entre virgínica y no-virgínica a partir de la amplitud de pétalos



2.5. Distribuciones categórica y multinomial

2.5.1. Definición

- ▶ Queremos generalizar la Bernoulli a $C > 2$ clases, esto es, una distribución sobre un conjunto finito de etiquetas, $y \in \{1, \dots, C\}$
- ▶ **Distribución categórica:** una v.a. Y sigue una distribución categórica de parámetros $\boldsymbol{\theta} = (\theta_1, \dots, \theta_C) \in [0, 1]^C, \sum_c \theta_c = 1$,

$$Y \sim \text{Cat}(\boldsymbol{\theta}) \quad (97)$$

si su pmf es

$$p(y \mid \boldsymbol{\theta}) \triangleq \prod_{c=1}^C \theta_c^{\mathbb{1}(y=c)} \quad (98)$$

- ▶ θ_c es la probabilidad de que y valga c , $p(y = c \mid \boldsymbol{\theta}) = \theta_c$
- ▶ Solo tenemos $C-1$ parámetros libres por las restricciones sobre $\boldsymbol{\theta}$

- **Vector one-hot:** codificación de y como vector binario a cero salvo un uno en la posición de la clase indicada

$$C = 3, y = 2 \rightarrow \mathbf{y} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad (99)$$

- El término one-hot viene de la ingeniería eléctrica, donde los vectores binarios se codifican mediante corrientes eléctricas en un conjunto de cables que pueden estar activos (hot) o no (cold)
- Distribución categórica usando encodings one-hot:

$$p(\mathbf{y} \mid \boldsymbol{\theta}) \triangleq \prod_{c=1}^C \theta_c^{y_c} \quad (100)$$

- ▶ Al igual que de la Bernoulli pasamos a la binomial como suma de N Bernoullis, de la categórica pasaremos a la **multinomial** como suma de N categóricas
- ▶ Consideremos la suma s de resultados en una secuencia de N experimentos categóricos independientes, $\mathbf{y}_n \sim \text{Cat}(\boldsymbol{\theta})$

$$\mathbf{s} = \sum_{n=1}^N \mathbf{y}_n \quad (101)$$

- ▶ *Ejemplo:* tiramos un dado de $C = 3$ caras $N = 2$ veces

$$\mathbf{y}_1 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \mathbf{y}_2 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \rightarrow \mathbf{s} = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} \quad (102)$$

- ▶ En general, s es un vector de contadores que indica el número de veces que se ha observado cada categoría en los N experimentos

- **Coeficiente multinomial:** número de formas de dividir un conjunto de talla $N = \sum_{c=1}^C s_c$ en subconjuntos de tallas $s = (s_1, \dots, s_C)^t$

$$\binom{N}{s} = \binom{N}{s_1, \dots, s_C} \triangleq \frac{N!}{s_1! s_2! \cdots s_C!} \quad (103)$$

- *Ejemplo:* con $C = 3, N = 2, s_1 = 0$ y $s_2 = s_3 = 1$

$$\binom{2}{0, 1, 1} = \frac{2!}{0!1!1!} = 2 \quad (\{y_1 = 2, y_2 = 3\} \text{ o } \{y_1 = 3, y_2 = 2\}) \quad (104)$$

- Se reduce al coeficiente binomial con $C = 2$:

$$\binom{N}{s_1, s_2} = \frac{N!}{s_1! s_2!} = \frac{N!}{s_1! (N - s_1)!} = \binom{N}{s_1} \quad (105)$$

- Igual a 1 con $N = 1$:

$$\binom{1}{s_1, \dots, s_C} = \frac{1!}{1! \prod_{c: s_c=0} 0!} = 1 \quad (106)$$

- **Distribución multinomial:** una v.a. S sigue una distribución multinomial de parámetros $N \in \mathbb{N}$ y $\boldsymbol{\theta} \in [0, 1]^C$, $\sum_c \theta_c = 1$,

$$S \sim \mathcal{M}(N, \boldsymbol{\theta}) \quad (107)$$

si su pmf es:

$$p(\mathbf{s} \mid N, \boldsymbol{\theta}) \triangleq \binom{N}{\mathbf{s}} \prod_{c=1}^C \theta_c^{s_c} \quad (108)$$

para todo

$$\mathbf{s} = (s_1, \dots, s_C)^t \in \{0, N\}^C \quad \text{tal que} \quad \sum_c s_c = N \quad (109)$$

- s es la suma de resultados (éxitos por categoría) en una secuencia de N experimentos categóricos independientes (con mismo $\boldsymbol{\theta}$)
- (108) se debe a que hay $\binom{N}{\mathbf{s}}$ secuencias distintas con s éxitos por categoría y cada secuencia ocurre con probabilidad $\prod_{c=1}^C \theta_c^{s_c}$
- Se reduce a la categórica con $N = 1$

2.5.2. La función softmax

- ▶ Al igual que en el caso de la Bernoulli, para predecir una variable categórica $y \in \{1, \dots, C\}$ dada una entrada $x \in \mathcal{X}$ necesitamos una distribución de probabilidad condicional de la forma



$$p(\mathbf{y} \mid \mathbf{x}, \boldsymbol{\theta}) = \text{Cat}(\mathbf{y} \mid f(\mathbf{x}; \boldsymbol{\theta})) = \mathcal{M}(\mathbf{y} \mid \mathbf{1}, f(\mathbf{x}; \boldsymbol{\theta})) \quad (110)$$

donde $f(\mathbf{x}; \boldsymbol{\theta})$ es una función para predecir un vector de probabilidades de las C clases tal que

$$0 \leq f_c(\mathbf{x}; \boldsymbol{\theta}) \leq 1 \quad (111)$$

y

$$\sum_{c=1}^C f_c(\mathbf{x}; \boldsymbol{\theta}) = 1 \quad (112)$$

- De nuevo como en el caso de la Bernoulli, podemos evitar las restricciones de probabilidad dejando que f sea no restringida y empleando el modelo

$$p(\mathbf{y} \mid \mathbf{x}, \theta) = \text{Cat}(\mathbf{y} \mid \mathcal{S}(f(\mathbf{x}; \theta))) \quad (113)$$

donde $\mathcal{S}(\cdot)$ es la **función softmax** o **multinomial logit**

$$\mathcal{S}(\mathbf{a}) \triangleq \left[\frac{e^{a_1}}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}}, \dots, \frac{e^{a_C}}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}} \right] \quad (114)$$

con **logits** $\mathbf{a} = f(\mathbf{x}; \theta)$

- La softmax transforma logits $\mathbf{a} \in \mathbb{R}^C$ en un vector de probabilidades $\mathcal{S}(\mathbf{a}) \in [0, 1]^C$, esto es, cumple


$$0 \leq \mathcal{S}(\mathbf{a})_c \leq 1 \quad \text{y} \quad \sum_{c=1}^C \mathcal{S}(\mathbf{a})_c = 1 \quad (115)$$

- ▶ La softmax puede verse como una versión suavizada de la argmax
- ▶ Si dividimos cada a_c por una constante de *temperatura* T ,

$$\lim_{T \rightarrow 0} \mathcal{S}(a/T)_c = \begin{cases} 1.0 & \text{si } c = \arg \max_{c'} a_{c'} \\ 0.0 & \text{en otro caso} \end{cases} \quad (116)$$

mientras que, a altas temperaturas, se aproxima a la uniforme

- ▶ *Ejemplo:* $\mathcal{S}(a/T)$ para $a = (3, 0, 1)$ con $T = 0.5$, $T = 1$ y $T = 10$



2.5.3. Regresión logística multiclase

► *Regresión logística multinomial*: modelo categórico condicional

$$p(y \mid \mathbf{x}, \boldsymbol{\theta}) = \text{Cat}(y \mid \mathcal{S}(f(\mathbf{x}; \boldsymbol{\theta}))) \quad (117)$$

con función predictora de logits lineal

$$f(\mathbf{x}; \boldsymbol{\theta}) \triangleq \mathbf{a} \triangleq \mathbf{W}\mathbf{x} + \mathbf{b} \quad (118)$$

Esto es,

$$p(y = c \mid \mathbf{x}; \boldsymbol{\theta}) = \mathcal{S}(\mathbf{W}\mathbf{x} + \mathbf{b})_c \quad (119)$$

$$= \frac{e^{a_c}}{\sum_{c'=1}^C e^{a_{c'}}} \quad (120)$$

- Se reduce a regresión logística binaria con dos clases (0 y 1):


$$S(\mathbf{a})_0 = \frac{e^{a_0}}{e^{a_0} + e^{a_1}} \quad (121)$$

$$= \frac{1}{1 + e^{a_1 - a_0}} = \sigma(a) \quad (122)$$

con $a \triangleq a_0 - a_1$

- En el caso binario, regresión logística multinomial emplea un vector de pesos por clase, w_0 y w_1 , mientras que regresión logística binaria solo emplea uno, w
- En el caso binario, decimos que regresión logística multinomial es un modelo **sobre-parametrizado**, de mayor dificultad interpretativa que regresión logística binaria (e idénticas predicciones)

- *Ejemplo:* aplicación a iris con 3 clases y 2 características



2.5.4. El truco log-sum-exp

- Dados los logits $\mathbf{a} = f(\mathbf{x}; \boldsymbol{\theta})$, queremos calcular


$$p(y = c \mid \mathbf{x}) = p_c = \frac{e^{a_c}}{Z(\mathbf{a})} \quad (123)$$

donde tenemos la *función partición* $Z(\mathbf{a}) = \sum_{c'=1}^C e^{a_{c'}}$

- El cálculo de Z suele plantear problemas numéricos
 - ▷ Si $\mathbf{a} = (0, 1, 0)$, entonces $Z = e^0 + e^1 + e^0 = 4.71$
 - ▷ Si $\mathbf{a} = (1000, 1001, 1000)$, entonces $Z = \infty$ en la máquina ya que **`np.exp(1000)=inf`**
 - ▷ Si $\mathbf{a} = (-1000, -999, -1000)$, entonces $Z = 0$ en la máquina ya que **`np.exp(-1000)=0`**

- Consideremos la identidad, válida para todo m ,

$$\log \sum_{c=1}^C \exp(a_c) = \log \sum_{c=1}^C \exp(a_c - m) \exp(m) \quad (124)$$

$$= m + \log \sum_{c=1}^C \exp(a_c - m) \quad (125)$$

- **Truco log-sum-exp**: tomando $m = \max_{c'} a_{c'}$, tenemos

$$\log \sum_{c=1}^C \exp(a_c) = \max_{c'} a_{c'} + \log \sum_{c=1}^C \exp(a_c - \max_{c'} a_{c'}) \quad (126)$$

- No se da overflow porque el mayor valor a exponenciar es cero
- Sí se puede dar underflow con algunos términos del sumatorio, pero el resultado será aproximadamente correcto ya que el sumatorio completo no será menor que 1, por lo que su logaritmo no planteará problemas numéricos

- **Función log-sum-exp (lse)**: usa el truco lse para implementar

$$\text{lse}(\mathbf{a}) \triangleq \log \sum_{c=1}^C \exp(a_c) \quad (127)$$

- Cálculo de probabilidades a partir de logits $\mathbf{a}$ con la lse:

$$p(y = c \mid \mathbf{x}) = \frac{\exp(a_c)}{Z(\mathbf{a})} \quad (128)$$

$$= \exp(\log(\exp(a_c)) - \log(Z(\mathbf{a}))) \quad (129)$$

$$= \exp(a_c - \text{lse}(\mathbf{a})) \quad (130)$$

2.6. Distribución (normal) Gaussiana univariada

2.6.1. Función de distribución acumulada

- *Cumulative distribution function (cdf)* de una v.a. Y :

$$P(y) \triangleq P(Y \leq y) \quad (131)$$

- Probabilidad de que Y se halle en un intervalo:

$$\Pr(a < Y \leq b) = P(b) - P(a) \quad (132)$$

- Las cdfs son funciones monótonas no decrecientes


- *Cdf Gaussiana:*

$$\Phi(y; \mu, \sigma^2) \triangleq \int_{-\infty}^y \mathcal{N}(z \mid \mu, \sigma^2) dz \quad (133)$$

donde $z = (y - \mu)/\sigma$

► *Cdf Gaussiana:*

Gaussian cdf



► **Función error:**

$$\operatorname{erf}(u) \triangleq \frac{2}{\sqrt{\pi}} \int_0^u e^{-t^2} dt \quad (134)$$

► Cdf Gaussiana implementada con la función error:

$$\Phi(y; \mu, \sigma^2) = \frac{1}{2} \left[1 + \operatorname{erf}(z/\sqrt{2}) \right] \quad (135)$$

► **Media y moda:** el parámetro μ codifica la media de la distribución, que coincide con la moda ya que la distribución es unimodal

► **Varianza y precisión:** el parámetro σ^2 codifica la varianza; llamamos precisión a la inversa de la varianza, $\lambda = 1/\sigma^2$

► **Distribución normal estándar:** $\mu = 0$ y $\sigma = 1$

► **Cuantil** q de P : el $y_q \triangleq P^{-1}(q)$ tal que $\Pr(Y \leq y_q) = q$

► **Mediana** de P : $P^{-1}(0.5)$

► **Cuartiles** inferior y superior de P : $P^{-1}(0.25)$ y $P^{-1}(0.75)$

- **Función probit:** cdf inversa o función cuantil de la cdf Gaussiana

$$\Phi^{-1}(q) = \{y_q : \Phi(y_q) = q\} \quad (0 < q < 1) \quad (136)$$

- Dado α tal que $0 < \alpha < 0.5$:

- ▷ La izquierda de $\Phi^{-1}(\alpha/2)$ contiene $\alpha/2$ de masa de probabilidad
- ▷ La derecha de $\Phi^{-1}(1 - \alpha/2)$ también contiene $\alpha/2$ de masa
- ▷ El intervalo central $(\Phi^{-1}(\alpha/2), \Phi^{-1}(1-\alpha/2))$ contiene $1-\alpha$ de masa
- ▷ Con $\alpha = 0.05$, el intervalo central con el 95 % de masa es

$$(\Phi^{-1}(0.025), \Phi^{-1}(0.975)) = (-1.96, 1.96) \quad (137)$$

- ▷ Si la distribución es $\mathcal{N}(\mu, \sigma^2)$, el intervalo 95 % es

$$(\mu - 1.96\sigma, \mu + 1.96\sigma) \quad (138)$$

lo que suele aproximarse como $\mu \pm 2\sigma$

2.6.2. Función de densidad de probabilidad

► *Probability density function (pdf)*: derivada de la cdf


$$p(y) \triangleq \frac{d}{dy} P(y) \quad (139)$$

► *Pdf Gaussiana*:

$$\mathcal{N}(y \mid \mu, \sigma^2) \triangleq \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2\sigma^2} (y - \mu)^2 \right) \quad (140)$$

► $\sqrt{2\pi\sigma^2}$ es una constante de normalización necesaria para que la densidad integre a 1

► *Pdf Gaussiana:*



- Probabilidad de que una variable continua se halle en un intervalo:

$$\Pr(a < Y \leq b) = \int_a^b p(y) dy = P(b) - P(a) \quad (141)$$

- Cuando el intervalo es muy pequeño, tenemos:

$$\Pr(y \leq Y \leq y + dy) \approx p(y) dy \quad (142)$$

por lo que la **densidad** en y , $p(y)$, puede valer más de uno

- **Media o valor esperado:**

$$\mathbb{E}[Y] \triangleq \int_{\mathcal{Y}} y p(y) dy \quad \mathbb{E}[\mathcal{N}(\cdot \mid \mu, \sigma^2)] = \mu \quad (143)$$

- **Varianza y esperanza del cuadrado:**

$$\mathbb{V}[Y] \triangleq \mathbb{E}[(Y - \mu)^2] = \mathbb{E}[Y^2] - \mu^2 \rightarrow \mathbb{E}[Y^2] = \sigma^2 + \mu^2 \quad (144)$$

- **Desviación típica:**

$$\text{std}[Y] \triangleq \sqrt{\mathbb{V}[Y]} = \sigma \quad (145)$$

2.6.3. Regresión

- Modelo condicional de media $f_\mu(\mathbf{x}; \boldsymbol{\theta})$ y varianza $f_\sigma(\mathbf{x}; \boldsymbol{\theta})^2$:

$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \mathcal{N}(y \mid f_\mu(\mathbf{x}; \boldsymbol{\theta}), f_\sigma(\mathbf{x}; \boldsymbol{\theta})^2) \quad (146)$$

- **Regresión homocedástica:** asume $f_\sigma(\mathbf{x}; \boldsymbol{\theta})^2 = \sigma^2$ fija
- **Regresión lineal:** homocedástica con $f_\mu(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{w}^t \mathbf{x} + b$:


$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \mathcal{N}(y \mid \mathbf{w}^t \mathbf{x} + b, \sigma^2) \quad (\boldsymbol{\theta} = (\mathbf{w}, b, \sigma^2)) \quad (147)$$

- **Regresión heterocedástica:** σ^2 depende de la entrada

$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \mathcal{N}(y \mid \mathbf{w}_\mu^t \mathbf{x} + b, \sigma_+(\mathbf{w}_\sigma^t \mathbf{x})) \quad (148)$$

donde $\boldsymbol{\theta} = (\mathbf{w}_\mu, b, \mathbf{w}_\sigma)$ y la **softplus** es $\sigma_+(a) = \log(1 + e^a)$

► *Ejemplos:* regresión lineal homocedástica y heterocedástica



▷ Recta roja: $\mu(x) = wx + b$

▷ Curvas verdes: $[\mu(x) - 2\sigma(x), \mu(x) + 2\sigma(x)]$

2.6.4. ¿Por qué se emplea tanto la Gaussiana?

- ▶ Por la facilidad interpretativa de sus parámetros
- ▶ Por el teorema central del límite, según el cual la suma de variables aleatorias independientes sigue una distribución aproximadamente Gaussiana, por lo que resulta una buena elección para modelizar errores residuales o “ruido”
- ▶ Porque es la distribución que menos asunciones hace, sujeto a la restricción de tener una media y varianza especificadas
- ▶ Por su sencilla forma matemática, lo que resulta en métodos fáciles de implementar y, a la vez, frecuentemente muy efectivos

2.6.5. La función delta de Dirac como caso límite

- Cuando la varianza se acerca a cero, la Gaussiana se aproxima a un “pico” en la media, infinitamente estrecho y alto:

$$\lim_{\sigma \rightarrow 0} \mathcal{N}(y \mid \mu, \sigma^2) \rightarrow \delta(y - \mu) \quad (149)$$

donde δ es la **función delta de Dirac**:

$$\delta(\theta) \triangleq \begin{cases} +\infty & \text{si } \theta = 0 \\ 0 & \text{si } \theta \neq 0 \end{cases} \quad (150)$$

cumpliéndose

$$\int_{-\infty}^{\infty} \delta(\theta) d\theta = 1 \quad (151)$$

- La delta de Dirac cumple la **propiedad del cribado (sifting)**:

$$\int_{-\infty}^{\infty} f(y) \delta(x - y) dy = f(x) \quad (152)$$