



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Probabilidad: modelos multivariados

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

3.1	Distribuciones conjuntas para v.a. múltiples	1
3.1.1	Covarianza	1
3.1.2	Correlación	4
3.1.3	Correlación nula no implica independencia	6
3.1.4	Correlación no implica causalidad	7
3.1.5	La paradoja de Simpson	8
3.2	La Gaussiana (normal) multivariada	9
3.2.1	Definición	9
3.2.2	Distancia de Mahalanobis	18
3.5	Modelos de mixtura	21
3.5.1	Mixturas de Gaussianas	23
3.5.2	Mixturas de Bernoullis	29

3.1. Distribuciones conjuntas para v.a. múltiples

3.1.1. Covarianza

- La **covarianza** entre dos variables aleatorias X e Y mide hasta qué grado están (linealmente) relacionadas:

$$\text{Cov}[X, Y] \triangleq \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \quad (1)$$

$$= \mathbb{E}[XY] - \mathbb{E}[X] \mathbb{E}[Y] \quad (2)$$

- Si $\mathbf{x}$ es un vector aleatorio D -dimensional, su **matriz de covarianzas** es la matriz semi-definida positiva y simétrica:

$$\text{Cov}[\mathbf{x}] \triangleq \mathbb{E} [(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^t] \triangleq \mathbf{\Sigma} \quad (3)$$

$$= \begin{pmatrix} \mathbb{V}[X_1] & \text{Cov}[X_1, X_2] & \cdots & \text{Cov}[X_1, X_D] \\ \text{Cov}[X_2, X_1] & \mathbb{V}[X_2] & \cdots & \text{Cov}[X_2, X_D] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[X_D, X_1] & \text{Cov}[X_D, X_2] & \cdots & \mathbb{V}[X_D] \end{pmatrix} \quad (4)$$

de donde se obtiene el importante resultado

$$\mathbb{E}[\mathbf{x}\mathbf{x}^t] = \mathbf{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^t \quad (5)$$

- La covarianza de una transformación lineal es:

$$\text{Cov}[\mathbf{A}\mathbf{x} + \mathbf{b}] = \mathbf{A} \text{Cov}[\mathbf{x}] \mathbf{A}^t \quad (6)$$

- La *covarianza cruzada* entre dos vectores aleatorios es:

$$\text{Cov}[\mathbf{x}, \mathbf{y}] = \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^t] \quad (7)$$

3.1.2. Correlación

- El *coeficiente de correlación (de Pearson)* entre X e Y es:

$$\rho \triangleq \text{corr}[X, Y] \triangleq \frac{\text{Cov}[X, Y]}{\sqrt{\mathbb{V}[X] \mathbb{V}[Y]}} \quad (8)$$

- El coeficiente de correlación se halla en $[-1, 1]$:

$$-1 \leq \rho \leq 1 \quad (9)$$

- Para algunos parámetros $a > 0$ y b :

$$\text{corr}[X, Y] = 1 \quad \text{sii} \quad Y = aX + b \quad (10)$$

- **Grado de linealidad:** ρ indica el grado de linealidad en la relación entre X e Y ; si es próximo 0, no existe una relación lineal entre ambas, pero puede existir (o no) una relación no lineal fuerte

► La *matriz de correlación* de un vector aleatorio $\mathbf{x}$ es:

$$\text{corr}(\mathbf{x}) = \begin{bmatrix} 1 & \frac{\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]}{\sigma_1 \sigma_2} & \dots & \frac{\mathbb{E}[(X_1 - \mu_1)(X_D - \mu_D)]}{\sigma_1 \sigma_D} \\ \frac{\mathbb{E}[(X_2 - \mu_2)(X_1 - \mu_1)]}{\sigma_2 \sigma_1} & 1 & \dots & \frac{\mathbb{E}[(X_2 - \mu_2)(X_D - \mu_D)]}{\sigma_2 \sigma_D} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\mathbb{E}[(X_D - \mu_D)(X_1 - \mu_1)]}{\sigma_D \sigma_1} & \frac{\mathbb{E}[(X_D - \mu_D)(X_2 - \mu_2)]}{\sigma_D \sigma_2} & \dots & 1 \end{bmatrix} \quad (11)$$

► De forma más compacta:

$$\text{corr}(\mathbf{x}) = (\text{diag}(\mathbf{K}_{xx}))^{-\frac{1}{2}} \mathbf{K}_{xx} (\text{diag}(\mathbf{K}_{xx}))^{-\frac{1}{2}} \quad (12)$$


donde $\mathbf{K}_{xx}$ es la *matriz de (auto-)covarianzas*

$$\mathbf{K}_{xx} = \Sigma = \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^t] = \mathbf{R}_{xx} - \boldsymbol{\mu}\boldsymbol{\mu}^t \quad (13)$$

y $\mathbf{R}_{xx} = \mathbb{E}[\mathbf{x}\mathbf{x}^t]$ es la *matriz de autocorrelación*


3.1.3. Correlación nula no implica independencia

- ▶ Si X e Y son independientes, $\text{corr}[X, Y] = \text{Cov}[X, Y] = 0$
- ▶ Si $\text{corr}[X, Y] = 0$, X e Y pueden no ser independientes; por ejemplo, si $X \sim U(-1, 1)$ y $Y = X^2$
- ▶ Coeficientes de correlación para varios conjuntos de datos:





3.1.4. Correlación no implica causalidad

- ▶ Si X e Y están correladas, no puede inferirse que una de ellas es causa de la otra; puede que se trate de una **correlación espuria** o que exista una **causa común oculta** que explique la correlación
- ▶ *Ejemplo:* ventas de helados y crímenes violentos (oculta: tiempo)



3.1.5. La paradoja de Simpson

- ▶ Se da cuando una tendencia que aparece en varios grupos de datos desaparece cuando estos grupos se combinan y en su lugar aparece la tendencia contraria para los datos agregados
- ▶ *Ejemplo:* y crece con x en cada grupo, pero decrece globalmente



3.2. La Gaussiana (normal) multivariada

- *Multivariate Gaussian* o *multivariate normal (MVN)*: es la distribución de probabilidad conjunta más utilizada, sobre todo por conveniencia matemática, pero también porque la asunción Gaussiana es razonable en muchos casos

3.2.1. Definición

- *Densidad Gaussiana multivariada*:

$$p(\mathbf{y} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) \triangleq \frac{1}{(2\pi)^{D/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{y} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) \right] \quad (14)$$

donde $\boldsymbol{\mu} = \mathbb{E}[\mathbf{y}]$ es la *media* y $\boldsymbol{\Sigma} = \text{Cov}[\mathbf{y}]$ la *matriz de covarianzas*

- $Z = (2\pi)^{D/2} |\boldsymbol{\Sigma}|^{1/2}$ es una constante para que integre a 1

► **Matriz de covarianzas:**

$$\Sigma = \text{Cov}[\mathbf{y}] \triangleq \mathbb{E}[(\mathbf{y} - \mathbb{E}[\mathbf{y}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^t] \quad (15)$$

$$= \begin{pmatrix} \mathbb{V}[Y_1] & \text{Cov}[Y_1, Y_2] & \cdots & \text{Cov}[Y_1, Y_D] \\ \text{Cov}[Y_2, Y_1] & \mathbb{V}[Y_2] & \cdots & \text{Cov}[Y_2, Y_D] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[Y_D, Y_1] & \text{Cov}[Y_D, Y_2] & \cdots & \mathbb{V}[Y_D] \end{pmatrix} \quad (16)$$

donde

$$\mathbb{V}[Y_i] = \text{Cov}[Y_i, Y_i] \quad (17)$$

$$\text{Cov}[Y_i, Y_j] \triangleq \mathbb{E}[(Y_i - \mathbb{E}[Y_i])(Y_j - \mathbb{E}[Y_j])] = \mathbb{E}[Y_i Y_j] - \mathbb{E}[Y_i] \mathbb{E}[Y_j] \quad (18)$$

► De (15) se sigue un resultado importante:

$$\mathbb{E}[\mathbf{y}\mathbf{y}^t] = \Sigma + \boldsymbol{\mu}\boldsymbol{\mu}^t \quad (19)$$

► **Gaussiana bivariada:** $\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ con $\mathbf{y} \in \mathbb{R}^2$, $\boldsymbol{\mu} \in \mathbb{R}^2$ y

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1^2 & \sigma_{12}^2 \\ \sigma_{21}^2 & \sigma_2^2 \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \quad (20)$$


donde ρ es el **coeficiente de correlación**

$$\text{corr}[X, Y] \triangleq \frac{\text{Cov}[X, Y]}{\sqrt{\mathbb{V}[X] \mathbb{V}[Y]}} = \frac{\sigma_{12}^2}{\sigma_1\sigma_2} \quad (21)$$

► La pdf de la Gaussiana 2D puede escribirse como:


$$p(y_1, y_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \times \exp\left(-\frac{1}{2(1-\rho^2)} \left[\frac{(y_1 - \mu_1)^2}{\sigma_1^2} + \frac{(y_2 - \mu_2)^2}{\sigma_2^2} - 2\rho \frac{(y_1 - \mu_1)(y_2 - \mu_2)}{\sigma_1\sigma_2} \right] \right) \quad (22)$$

► Σ *esférica*: $\Sigma = \sigma^2 \mathbf{I}$, $\sigma^2 = 1$




► Σ *esférica*: $\Sigma = \sigma^2 \mathbf{I}$, $\sigma^2 = 1$


Spherical




► Σ *diagonal*: D parámetros, $\sigma_1^2 = 1$, $\sigma_2^2 = 3$, $\sigma_{12}^2 = 0$




► Σ *diagonal*: D parámetros, $\sigma_1^2 = 1$, $\sigma_2^2 = 3$, $\sigma_{12}^2 = 0$



► Σ completa: $D(D + 1)/2$ parámetros, $\sigma_1^2 = \sigma_2^2 = 2$, $\sigma_{12}^2 = 1.8$



► Σ *completa*: $D(D + 1)/2$ parámetros, $\sigma_1^2 = \sigma_2^2 = 2$, $\sigma_{12}^2 = 1.8$



3.2.2. Distancia de Mahalanobis

- **Conjuntos de nivel (level sets)** de la pdf Gaussiana: conjunto de puntos de (log) densidad (de probabilidad) constante (p.e. curvas de nivel elípticas en 2D) que caracterizan su forma geométrica
- La log-densidad Gaussiana en un punto dado $\mathbf{y}$ es:

$$\log p(\mathbf{y} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu}) + \text{const} \quad (23)$$

- La dependencia de $\mathbf{y}$ puede expresarse en términos de la **distancia de Mahalanobis** Δ entre $\mathbf{y}$ y $\boldsymbol{\mu}$, cuyo cuadrado es:

$$\Delta^2 \triangleq (\mathbf{y} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu}) \quad (24)$$

- Los contornos de (log) densidad constante son, por tanto, equivalentes a los contornos de distancia de Mahalanobis constante

- ▶ Para determinar los contornos de isodistancia, asumimos que Σ es definida positiva, por lo que $\Lambda = \Sigma^{-1}$ también lo es
- ▶ Descomposición en valores propios de Σ y Σ^{-1} :

$$\Sigma = \sum_{d=1}^D \lambda_d \mathbf{u}_d \mathbf{u}_d^t \rightarrow \Sigma^{-1} = \sum_{d=1}^D \frac{1}{\lambda_d} \mathbf{u}_d \mathbf{u}_d^t \quad (25)$$

- ▶ Definiendo $\mathbf{z} \triangleq \mathbf{U}(\mathbf{y} - \boldsymbol{\mu})$, esto es, $z_d \triangleq \mathbf{u}_d^t(\mathbf{y} - \boldsymbol{\mu})$ para todo d :

$$(\mathbf{y} - \boldsymbol{\mu})^t \Sigma^{-1} (\mathbf{y} - \boldsymbol{\mu}) = (\mathbf{y} - \boldsymbol{\mu})^t \left(\sum_{d=1}^D \frac{1}{\lambda_d} \mathbf{u}_d \mathbf{u}_d^t \right) (\mathbf{y} - \boldsymbol{\mu}) \quad (26)$$


$$= \sum_{d=1}^D \frac{1}{\lambda_d} (\mathbf{y} - \boldsymbol{\mu})^t \mathbf{u}_d \mathbf{u}_d^t (\mathbf{y} - \boldsymbol{\mu}) = \sum_{d=1}^D \frac{z_d^2}{\lambda_d} \quad (27)$$

- ▶ Mahalanobis puede verse como la Euclídea en un sistema de coordenadas escalado con Λ y rotado con $\mathbf{U}$

- En 2d, consideremos el conjunto de puntos (z_1, z_2) que satisface:

$$\frac{z_1^2}{\lambda_1} + \frac{z_2^2}{\lambda_2} = r \quad (28)$$

- Como los puntos están a idéntica distancia de Mahalanobis, corresponden a puntos de igual probabilidad, por lo que las curvas de nivel de una Gaussiana 2d son elipses
- Los vectores propios determinan la orientación de la elipse y los valores propios su excentricidad (elongación):



3.5. Modelos de mixtura

- Una manera de crear modelos probabilísticos complejos consiste en establecer una combinación convexa de distribuciones simples
- *Modelo de mixtura:* combinación lineal ponderada de modelos

$$p(\mathbf{y} \mid \boldsymbol{\theta}) = \sum_{k=1}^K \pi_k p_k(\mathbf{y}) \quad (29)$$

donde los *coeficientes* de la mixtura, π_k , satisfacen

$$0 \leq \pi_k \leq 1 \quad \text{y} \quad \sum_k \pi_k = 1 \quad (30)$$

y ponderan las K *componentes* de la mixtura, $p_k(\mathbf{y})$

► Interpretación como modelo jerárquico

- Una variable latente $z \in \{1:K\}$ indica qué componente genera y
- El prior sobre la variable latente es $p(z = k) = \pi_k$, por lo que se trata de una variable categórica gobernada por π

$$p(z \mid \boldsymbol{\theta}) = \text{Cat}(z \mid \boldsymbol{\pi}) \quad (31)$$

- La condicional es

$$p(\mathbf{y} \mid z = k) = p_k(\mathbf{y}) = p(\mathbf{y} \mid \boldsymbol{\theta}_k) \quad (32)$$

- $\boldsymbol{\theta}$ incluye coeficientes y parámetros de cada componente

$$\boldsymbol{\theta} = (\pi_1, \dots, \pi_K, \boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_K) \quad (33)$$

- Interpretación generativa: primero se genera z y luego y
- Marginalizando z recuperamos el modelo original:

$$p(\mathbf{y} \mid \boldsymbol{\theta}) = \sum_{k=1}^K p(z = k \mid \boldsymbol{\theta}) p(\mathbf{y} \mid z = k, \boldsymbol{\theta}) = \sum_{k=1}^K \pi_k p_k(\mathbf{y} \mid \boldsymbol{\theta}_k) \quad (34)$$

3.5.1. Mixturas de Gaussianas

► *Gaussian mixture model (GMM), mixture of Gaussians (MoG):*

$$p(\mathbf{y} \mid \boldsymbol{\theta}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{y} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (35)$$

► *Ejemplo:*

▷ Coeficientes:

$$\pi_1 = 0.5, \quad \pi_2 = 0.4 \quad \pi_3 = 0.2 \quad (36)$$


▷ Componentes:


$$\boldsymbol{\mu}_1 = \begin{pmatrix} 0.22 \\ 0.45 \end{pmatrix} \quad \boldsymbol{\Sigma}_1 = \begin{pmatrix} 0.011 & -0.01 \\ -0.01 & 0.018 \end{pmatrix} \quad (37)$$

$$\boldsymbol{\mu}_2 = \begin{pmatrix} 0.50 \\ 0.50 \end{pmatrix} \quad \boldsymbol{\Sigma}_2 = \begin{pmatrix} 0.018 & 0.01 \\ 0.01 & 0.011 \end{pmatrix} \quad (38)$$

$$\boldsymbol{\mu}_3 = \begin{pmatrix} 0.77 \\ 0.55 \end{pmatrix} \quad \boldsymbol{\Sigma}_3 = \boldsymbol{\Sigma}_1 \quad (39)$$

► Medias y curvas de nivel:





► *Aplicación en clustering:*

- Las mixturas de Gaussianas se emplean en *clustering* de un conjunto de datos $\mathcal{D} = \{\mathbf{y}_1, \dots, \mathbf{y}_N\}$ hallando primero el MLE,

$$\hat{\boldsymbol{\theta}} = \arg \max \log p(\mathcal{D} \mid \boldsymbol{\theta}) \quad (40)$$

y asociando cada dato $\mathbf{y}_n$ con una variable $z_n \in \{1, \dots, K\}$ que identifica la componente o clúster del que procede


- *Responsabilidad* del clúster k para el dato $\mathbf{y}_n$:

$$r_{nk} \triangleq p(z_n = k \mid \mathbf{y}_n, \boldsymbol{\theta}) \quad (41)$$


- *Hard clustering:* asocia cada dato al clúster más responsable

$$\hat{z}_n = \arg \max_k r_{nk} \quad (42)$$

► *Ejemplo:* datos en 2d



► *Ejemplo (cont.):* clustering con $K = 5$ clústers usando un GMM



3.5.2. Mixturas de Bernoullis

- *Bernoulli mixture model (BMM)* o *mixture of Bernoullis*: cada componente es de la forma

$$p(\mathbf{y} \mid z = k, \boldsymbol{\theta}) = \prod_{d=1}^D \text{Ber}(y_d \mid \mu_{dk}) \quad (43)$$

$$= \prod_{d=1}^D \mu_{dk}^{y_d} (1 - \mu_{dk})^{1-y_d} \quad (44)$$

- μ_{dk} es la probabilidad de que el bit d sea 1 en la componente k

► *Ejemplo:* BMM de $K = 20$ componentes para MNIST (π_k y μ_k)

