



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico (actividades)

Estadística

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

4.2	Estimación máximo-verosímil	1
4.2.1	Definición	1
4.2.2	Justificación del MLE	2
4.2.3	Ejemplo: MLE para la Bernoulli	3
4.2.4	Ejemplo: MLE para la categórica	4
4.2.5	Ejemplo: MLE para la Gaussiana univariada	5
4.2.6	Ejemplo: MLE para la Gaussiana multivariada	6
4.2.7	Ejemplo: MLE para regresión lineal	8
4.3	Minimización del riesgo empírico	11
4.5	Regularización	13
4.5.1	Ejemplo: estimación MAP para la Bernoulli	16
4.5.3	Ejemplo: regularización ℓ_2	17
4.5.4	Elección del regularizador mediante validación	18
4.5.5	Validación cruzada	19
4.5.6	Terminación temprana	20
4.5.7	Uso de más datos	22

4.2. Estimación máximo-verosímil

4.2.1. Definición

► En aprendizaje supervisado, MLE suele plantearse como:

1. $\hat{\theta}_{\text{mle}} = \arg \min_{\theta} \sum_{n=1}^N \log p(\mathbf{y}_n \mid \mathbf{x}_n, \theta)$
2. $\hat{\theta}_{\text{mle}} = \arg \min_{\theta} - \sum_{n=1}^N \log p(\mathbf{y}_n \mid \mathbf{x}_n, \theta)$
3. $\hat{\theta}_{\text{mle}} = \arg \min_{\theta} \sum_{n=1}^N \log p(\mathbf{x}_n \mid \mathbf{y}_n, \theta)$
4. $\hat{\theta}_{\text{mle}} = \arg \min_{\theta} - \sum_{n=1}^N \log p(\mathbf{x}_n \mid \mathbf{y}_n, \theta)$

4.2.2. Justificación del MLE

- ▶ El método MLE suele justificarse como:
 1. Aproximación puntual a la posterior Bayesiana
 2. Aproximación a la distribución empírica
 - 3.** Las dos anteriores (no solo una)
 4. Ninguna de las anteriores

4.2.3. Ejemplo: MLE para la Bernoulli

- Sea Y una variable aleatoria que representa el resultado de clasificar un objeto mediante un clasificador dado; $Y = 1$ denota que el resultado es incorrecto, mientras que $Y = 0$ indica que no ha habido error de clasificación. Sea $\theta = p(Y = 1)$ la probabilidad de error del clasificador. Supón que se han clasificado N muestras de test independientes, N_1 erróneamente y $N_0 = N - N_1$ sin error. Estima la probabilidad de error del clasificador por máxima verosimilitud.

4.2.4. Ejemplo: MLE para la categórica

- Sea Y una variable aleatoria que representa el resultado de clasificar un objeto en una clase de C posibles, $\{1, \dots, C\}$, mediante un clasificador dado. Sea $\theta_c = p(Y = c)$ la probabilidad (a priori) de que el resultado sea la clase c . Supón que se han clasificado N muestras de test independientes, siendo N_c el número de ellas clasificadas en la clase c . Estima θ_c por máxima verosimilitud.


4.2.5. Ejemplo: MLE para la Gaussiana univariada

- Sea $Y \sim \mathcal{N}(\mu, \sigma^2)$ y sea $\mathcal{D} = \{y_1, \dots, y_N\}$ una muestra aleatoria simple de tamaño N . Supón que la varianza σ^2 es conocida, pero no la media μ . Deriva el MLE de μ .


4.2.6. Ejemplo: MLE para la Gaussiana multivariada

► Reproduce el cuaderno de la [Figura 4.1](#)

▷ Matriz de covarianzas en iris:



▷ Matriz de correlación en iris:



4.2.7. Ejemplo: MLE para regresión lineal

- Sea $p(y \mid x; \theta) = \mathcal{N}(c + m \cdot x, \sigma^2)$, $\theta = (m, c)$, σ^2 fija, un modelo de regresión lineal simple (1d). Determina el MLE de θ con respecto a $\mathcal{D} = \{(x_n, y_n)\} = \{(0, 0), (1, 0.5), (1, 1.5), (2, 2)\}$, así como la suma de residuos correspondiente.


► Problema anterior resuelto con `np.linalg.lstsq`

4.2.7.linreg.py

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 x = np.array([0.0, 1.0, 1.0, 2.0])
5 A = np.vstack([x, np.ones(len(x))]).T
6 y = np.array([0.0, 0.5, 1.5, 2.0])
7 [m, c], [r], _, _ = np.linalg.lstsq(A, y, rcond=None)
8
9 print(np.around(m, 2), np.around(c, 2), np.around(r, 2))
10
11 plt.plot(x, y, 'o', markersize=10)
12 plt.plot(x, m*x + c, 'r')
13 plt.grid(True)
14 plt.show()
```

4.2.7.linreg.out

```
1 1.0 0.0 0.5
```



4.3. Minimización del riesgo empírico

- Minimización del riesgo empírico (ERM) generaliza MLE sustituyendo la log-pérdida por cualquier otra función de pérdida ℓ para estimar θ mediante la esperanza de ℓ con respecto a la empírica

$$\hat{\theta} = \arg \min_{\theta} \mathcal{L}(\theta) \triangleq \frac{1}{N} \sum_{n=1}^N \ell(\mathbf{y}_n, \theta; \mathbf{x}_n)$$

Una opción obvia en clasificación es la pérdida 0-1, definida como:


1. $\ell_{01}(\mathbf{y}_n, f(\mathbf{x}_n; \theta)) = \mathbb{1}(\mathbf{y}_n = f(\mathbf{x}_n; \theta))$

2. $\ell_{01}(\mathbf{y}_n, f(\mathbf{x}_n; \theta)) = \mathbb{1}(\mathbf{y}_n \neq f(\mathbf{x}_n; \theta))$

3. Se puede definir de las dos maneras (no solo una)

4. Ninguna de las anteriores

► Reproduce el cuaderno de la [Figura 4.2](#)



4.5. Regularización

- Supón que la probabilidad de error de un clasificador dado, θ , se ha estimado a partir de N muestras de test como la proporción de éstas mal clasificadas, $\hat{\theta} = N_1/N$ (sec. 4.2.3). Si N es pequeño, digamos 3, y $N_1 = N$, entonces $\hat{\theta} = 100\%$ y el clasificador dado:

1. Se equivocará siempre ya que $\hat{\theta}$ es el MLE de θ
2. Acertará siempre ya que $\hat{\theta}$ es el MLE de θ
3. No siempre se equivocará (ni acertará) ya que $\hat{\theta}$ se ha sobre-entrenado
4. Ninguna de las anteriores

- Regularización consiste en añadir un término al riesgo empírico:

$$\mathcal{L}(\boldsymbol{\theta}; \lambda) = \left[\frac{1}{N} \sum_n \ell(\mathbf{y}_n, \boldsymbol{\theta}; \mathbf{x}_n) \right] + \lambda C(\boldsymbol{\theta})$$

donde $\lambda \geq 0$ es el parámetro de regularización y $C(\boldsymbol{\theta})$ es alguna forma de penalización de complejidad, usualmente basada en un prior $p(\boldsymbol{\theta})$ y de la forma:

1. $C(\boldsymbol{\theta}) = -\log p(\boldsymbol{\theta})$
2. $C(\boldsymbol{\theta}) = \log p(\boldsymbol{\theta})$
3. Cualquiera de las anteriores (no solo una)
4. Ninguna de las anteriores

- ▶ Estimación MAP puede verse como una aproximación puntual a la posterior Bayesiana, $p(\boldsymbol{\theta} \mid \mathcal{D}) = \delta(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_{\text{map}})$, donde $\hat{\boldsymbol{\theta}}_{\text{map}}$ es la moda de la posterior,

$$\hat{\boldsymbol{\theta}}_{\text{map}} = \arg \max_{\boldsymbol{\theta}} \log p(\boldsymbol{\theta} \mid \mathcal{D})$$

Esto equivale a minimizar la log-verosimilitud negativa (NLL):





1. No regularizada
2. Regularizada con base en un prior $p(\boldsymbol{\theta})$
3. Las dos anteriores (no solo una)
4. Ninguna de las anteriores

4.5.1. Ejemplo: estimación MAP para la Bernoulli

- Sea Y una variable aleatoria que representa el resultado de clasificar un objeto mediante un clasificador dado; $Y = 1$ denota que el resultado es incorrecto, mientras que $Y = 0$ indica que no ha habido error de clasificación. Sea $\theta = p(Y = 1)$ la probabilidad de error del clasificador. Supón que se han clasificado N muestras de test independientes, N_1 erróneamente y $N_0 = N - N_1$ sin error. Estima θ mediante estimación MAP con prior $p(\theta) = \text{Beta}(\theta \mid a, b)$ y suavizado add-one, esto es, $a = b = 2$.

4.5.3. Ejemplo: regularización ℓ_2

► Reproduce el cuaderno de la [Figura 4.5](#)



4.5.4. Elección del regularizador mediante validación

- Supón que los datos $\mathcal{D}$ se han dividido en un conjunto de entrenamiento, $\mathcal{D}_{\text{train}}$, y otro separado, $\mathcal{D}_{\text{valid}}$, de validación o desarrollo. Validación escoge la fuerza del regularizador λ mediante:

$$\lambda^* = \arg \min_{\lambda \in \mathcal{S}} R_{\lambda}^{\text{val}}$$

donde $\mathcal{S}$ es un conjunto de valores de interés de λ y R_{λ}^{val} es una estimación del riesgo poblacional basada en $\mathcal{D}_{\text{valid}}$. Tras escoger λ^* , el modelo final minimizará el riesgo $R_{\lambda^*}(\theta)$ con respecto a:

1. Los datos de entrenamiento, $\mathcal{D}_{\text{train}}$
2. Los de validación, $\mathcal{D}_{\text{valid}}$
- 3.** Todos los datos, $\mathcal{D}$
4. Ninguno de los anteriores

4.5.5. Validación cruzada

- Supón que los datos $\mathcal{D}$ se han dividido en K bloques. Validación cruzada escoge la fuerza del regularizador λ mediante:


$$\lambda^* = \arg \min_{\lambda \in \mathcal{S}} R_{\lambda}^{\text{CV}}$$

donde $\mathcal{S}$ recoge valores de interés de λ y R_{λ}^{CV} es una estimación del riesgo poblacional basada en la división anterior. Tras escoger λ^* , el modelo final minimizará el riesgo $R_{\lambda^*}(\theta)$ con respecto a:


1. Un bloque de datos arbitrario
2. Todos los datos menos un bloque arbitrario
- 3.** Todos los datos
4. Ninguno de los anteriores

4.5.6. Terminación temprana

- Reproduce el cuaderno de la [Figura 4.8](#)



Training and validation accuracy



4.5.7. Uso de más datos

► Reproduce el cuaderno de la [Figura 4.9](#)

