



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Estadística

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

4.1	Introducción	1
4.2	Estimación máximo-verosímil	2
4.2.1	Definición	3
4.2.2	Justificación del MLE	5
4.2.3	Ejemplo: MLE para la Bernoulli	9
4.2.4	Ejemplo: MLE para la categórica	11
4.2.5	Ejemplo: MLE para la Gaussiana univariada	12
4.2.6	Ejemplo: MLE para la Gaussiana multivariada	14
4.2.7	Ejemplo: MLE para regresión lineal	15
4.3	Minimización del riesgo empírico	16
4.3.1	Ejemplo: minimizar el error de clasificación	17
4.3.2	Pérdida subrogada	18
4.5	Regularización	20
4.5.1	Ejemplo: estimación MAP para la Bernoulli	23
4.5.3	Ejemplo: regularización ℓ_2	25
4.5.4	Elección del regularizador mediante validación	30
4.5.5	Validación cruzada	32

4.5.5.1	La regla “un error estándar”	34
4.5.5.2	Ejemplo: regresión de cresta	36
4.5.6	Terminación temprana	38
4.5.7	Uso de más datos	41

4.1. Introducción

- ▶ La estimación de parámetros θ a partir de un conjunto de datos $\mathcal{D}$ se denomina *ajuste del modelo*, o *entrenamiento*, y constituye un problema central del aprendizaje automático

- ▶ El entrenamiento suele reducirse a un problema de optimización:

$$\hat{\theta} = \arg \min_{\theta} \mathcal{L}(\theta) \quad (1)$$

donde $\mathcal{L}(\theta)$ es alguna función de pérdida u objetivo.

- ▶ Además de calcular un *estimador puntual* θ , se suele estudiar la incertidumbre o confianza en el mismo, cosa que en estadística se conoce como *inferencia*

4.2. Estimación máximo-verosímil

- ▶ *Maximum likelihood estimation (MLE)*: es la aproximación convencional a la estimación de parámetros
- ▶ MLE consiste en escoger los parámetros que asignan máxima probabilidad a los datos de entrenamiento

4.2.1. Definición

- **Estimador máximo-verosímil (MLE)** de θ con respecto a $\mathcal{D}$:

$$\hat{\theta}_{\text{mle}} \triangleq \arg \max_{\theta} p(\mathcal{D} \mid \theta) \quad (2)$$

- Bajo la **asunción iid**, los datos son muestras independientes que siguen una distribución idéntica:

$$p(\mathcal{D} \mid \theta) = \prod_{n=1}^N p(\mathbf{y}_n \mid \mathbf{x}_n, \theta) \quad (3)$$

- Se suele emplear la **log-verosimilitud**:

$$\text{LL}(\theta) \triangleq \log p(\mathcal{D} \mid \theta) = \sum_{n=1}^N \log p(\mathbf{y}_n \mid \mathbf{x}_n, \theta) \quad (4)$$

- Basándonos en la log-verosimilitud, el MLE viene dado por:

$$\hat{\theta}_{\text{mle}} = \arg \max_{\theta} \sum_{n=1}^N \log p(\mathbf{y}_n \mid \mathbf{x}_n, \theta) \quad (5)$$

► *Log-verosimilitud negativa (NLL):*

$$\text{NLL}(\boldsymbol{\theta}) \triangleq -\log p(\mathcal{D} \mid \boldsymbol{\theta}) \quad (6)$$

$$= -\sum_{n=1}^N \log p(\mathbf{y}_n \mid \mathbf{x}_n, \boldsymbol{\theta}) \quad (7)$$

► Así, el cálculo del MLE es un problema de minimización:

$$\hat{\boldsymbol{\theta}}_{\text{mle}} = \arg \min_{\boldsymbol{\theta}} -\sum_{n=1}^N \log p(\mathbf{y}_n \mid \mathbf{x}_n, \boldsymbol{\theta}) \quad (8)$$

► Alternativamente, podemos maximizar la *verosimilitud conjunta* de entradas y salidas, en cuyo caso el MLE es:

$$\hat{\boldsymbol{\theta}}_{\text{mle}} = \arg \min_{\boldsymbol{\theta}} -\sum_{n=1}^N \log p(\mathbf{x}_n, \mathbf{y}_n \mid \boldsymbol{\theta}) \quad (9)$$

4.2.2. Justificación del MLE

Aproximación puntual a la posterior Bayesiana

- Si aproximamos la posterior mediante una función delta,

$$p(\boldsymbol{\theta} \mid \mathcal{D}) = \delta(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_{\text{map}}) \quad (10)$$

donde $\hat{\boldsymbol{\theta}}_{\text{map}}$ es la moda de la posterior,

$$\hat{\boldsymbol{\theta}}_{\text{map}} = \arg \max_{\boldsymbol{\theta}} \log p(\boldsymbol{\theta} \mid \mathcal{D}) \quad (11)$$

$$= \arg \max_{\boldsymbol{\theta}} \log p(\mathcal{D} \mid \boldsymbol{\theta}) + \log p(\boldsymbol{\theta}) \quad (12)$$

y usamos un prior uniforme,

$$p(\boldsymbol{\theta}) \propto 1 \quad (13)$$

el estimador MAP coincide con el MLE,

$$\hat{\boldsymbol{\theta}}_{\text{map}} = \hat{\boldsymbol{\theta}}_{\text{mle}} \quad (14)$$

Aproximación a la empírica: divergencia KL

- **Divergencia de Kullback Leibler (KL):** criterio usual de proximidad entre distribuciones

$$\mathbb{KL}(p||q) = \sum_{\mathbf{y}} p(\mathbf{y}) \log \frac{p(\mathbf{y})}{q(\mathbf{y})} \quad (15)$$

$$= \underbrace{\sum_{\mathbf{y}} p(\mathbf{y}) \log p(\mathbf{y})}_{-\mathbb{H}(p)} - \underbrace{\sum_{\mathbf{y}} p(\mathbf{y}) \log q(\mathbf{y})}_{\mathbb{H}(p,q)} \quad (16)$$

donde

- ▷ $\mathbb{H}(p)$ es la entropía de p
- ▷ $\mathbb{H}(p, q)$ es la entropía cruzada de p y q

- Se cumple que:

$$\mathbb{KL}(p||q) \geq 0 \quad \mathbb{KL}(p||q) = 0 \text{ si } p = q \quad (17)$$

Aproximación a la empírica: caso no supervisado

- Empírica en el caso no supervisado (incondicional):

$$p_{\mathcal{D}}(\mathbf{y}) \triangleq \frac{1}{N} \sum_{n=1}^N \delta(\mathbf{y} - \mathbf{y}_n) \quad (18)$$

la cual forma una serie de “picos” en los puntos de datos que queremos aproximar mediante una distribución $q(\mathbf{y}) = p(\mathbf{y} \mid \boldsymbol{\theta})$

- Cálculo de $q(\mathbf{y}) \triangleq p(\mathbf{y} \mid \boldsymbol{\theta})$ próxima a $p(\mathbf{y}) \triangleq p_{\mathcal{D}}(\mathbf{y})$

$$\text{KL}(p \parallel q) = \sum_{\mathbf{y}} p_{\mathcal{D}}(\mathbf{y}) \log p_{\mathcal{D}}(\mathbf{y}) - p_{\mathcal{D}}(\mathbf{y}) \log q(\mathbf{y}) \quad (19)$$

$$= -\mathbb{H}(p_{\mathcal{D}}) - \frac{1}{N} \sum_{n=1}^N \log p(\mathbf{y}_n \mid \boldsymbol{\theta}) \quad (20)$$

$$= \text{const} + \text{NLL}(\boldsymbol{\theta}) \quad (21)$$

- Por tanto, minimizar la KL equivale a minimizar la **NLL**

Aproximación a la empírica: caso supervisado

- Empírica en el caso supervisado (condicional):

$$p_{\mathcal{D}}(\mathbf{x}, \mathbf{y}) = p_{\mathcal{D}}(\mathbf{y} \mid \mathbf{x}) p_{\mathcal{D}}(\mathbf{x}) \quad (22)$$

$$= \frac{1}{N} \sum_{n=1}^N \delta(\mathbf{x} - \mathbf{x}_n) \delta(\mathbf{y} - \mathbf{y}_n) \quad (23)$$

- Cálculo de $q(\mathbf{y} \mid \mathbf{x}) \triangleq p(\mathbf{y} \mid \mathbf{x}, \boldsymbol{\theta})$ próxima a $p(\mathbf{y} \mid \mathbf{x}) \triangleq p_{\mathcal{D}}(\mathbf{y} \mid \mathbf{x})$

$$\mathbb{E}_{p_{\mathcal{D}}(\mathbf{x})}[\text{KL}(p_{\mathcal{D}}(Y \mid \mathbf{x}) \parallel q(Y \mid \mathbf{x}))] \quad (24)$$

$$= \sum_{\mathbf{x}} p_{\mathcal{D}}(\mathbf{x}) \left[\sum_{\mathbf{y}} p_{\mathcal{D}}(\mathbf{y} \mid \mathbf{x}) \log \frac{p_{\mathcal{D}}(\mathbf{y} \mid \mathbf{x})}{q_{\mathcal{D}}(\mathbf{y} \mid \mathbf{x})} \right] \quad (25)$$

$$= \text{const} - \sum_{\mathbf{x}, \mathbf{y}} p_{\mathcal{D}}(\mathbf{x}, \mathbf{y}) \log q(\mathbf{y} \mid \mathbf{x}) \quad (26)$$

$$= \text{const} - \frac{1}{N} \sum_{n=1}^N \log p(\mathbf{y}_n \mid \mathbf{x}_n, \boldsymbol{\theta}) \quad (27)$$

4.2.3. Ejemplo: MLE para la Bernoulli

► La NLL para la Bernoulli es:

$$\text{NLL}(\theta) = -\log \prod_{n=1}^N p(y_n \mid \theta) \quad (28)$$

$$= -\log \prod_{n=1}^N \theta^{\mathbb{1}(y_n=1)} (1 - \theta)^{\mathbb{1}(y_n=0)} \quad (29)$$

$$= -\sum_{n=1}^N \mathbb{1}(y_n = 1) \log \theta + \mathbb{1}(y_n = 0) \log(1 - \theta) \quad (30)$$

$$= -[N_1 \log \theta + N_0 \log(1 - \theta)] \quad (31)$$

donde

$$N_1 \triangleq \sum_n \mathbb{1}(y_n = 1) \quad (32)$$

$$N_0 \triangleq \sum_n \mathbb{1}(y_n = 0) \quad (33)$$

► N_1 y N_0 son *estadísticos suficientes* de los datos ya que resumen todo lo que necesitamos saber sobre $\mathcal{D}$

► La derivada de la NLL es:

$$\frac{d}{d\theta} \text{NLL}(\theta) = \frac{-N_1}{\theta} + \frac{N_0}{1 - \theta} \quad (34)$$

► El MLE se obtiene igualando la derivada a cero:

$$\hat{\theta}_{\text{mle}} = \frac{N_1}{N_0 + N_1} \quad (35)$$

4.2.4. Ejemplo: MLE para la categórica

- La NLL para la categórica es:

$$\text{NLL}(\boldsymbol{\theta}) = - \sum_k N_k \log \theta_k \quad (36)$$

donde N_k es el número de veces que se observa el evento $Y = k$

- Debemos minimizar NLL sujeta a la restricción $\sum_k \theta_k = 1$
- Función lagrangiana:

$$\mathcal{L}(\boldsymbol{\theta}, \lambda) \triangleq - \sum_k N_k \log \theta_k - \lambda \left(1 - \sum_k \theta_k \right) \quad (37)$$

- El MLE se obtiene derivando respecto a $\boldsymbol{\theta}$ y λ , e igualando a cero:

$$\hat{\theta}_k = \frac{N_k}{N} \quad (38)$$

4.2.5. Ejemplo: MLE para la Gaussiana univariada

► Sea $Y \sim \mathcal{N}(\mu, \sigma^2)$ y sea $\mathcal{D} = \{y_1, \dots, y_N\}$ una muestra aleatoria simple de tamaño N

► La NLL es:

$$\text{NLL}(\mu, \sigma^2) = - \sum_n \log \left[\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp \left(-\frac{1}{2\sigma^2} (y_n - \mu)^2 \right) \right] \quad (39)$$

$$= \frac{1}{2\sigma^2} \sum_n (y_n - \mu)^2 + \frac{N}{2} \log(2\pi\sigma^2) \quad (40)$$

► Un mínimo de la NLL debe satisfacer:

$$\frac{\partial}{\partial \mu} \text{NLL}(\mu, \sigma^2) = 0 \quad (41)$$

$$\frac{\partial}{\partial \sigma^2} \text{NLL}(\mu, \sigma^2) = 0 \quad (42)$$

- Se puede comprobar que:

$$\hat{\mu}_{\text{mle}} = \frac{1}{N} \sum_n y_n = \bar{y} \quad (43)$$

$$\hat{\sigma}_{\text{mle}}^2 = \frac{1}{N} \sum_n (y_n - \hat{\mu}_{\text{mle}})^2 \quad (44)$$

$$= \frac{1}{N} \left[\sum_n y_n^2 + \hat{\mu}_{\text{mle}}^2 - 2y_n \hat{\mu}_{\text{mle}} \right] \quad (45)$$

$$= s^2 - \bar{y}^2 \quad (46)$$

$$s^2 = \frac{1}{N} \sum_n y_n^2 \quad (47)$$

- $\bar{y}$ y s^2 son **estadísticos suficientes** de los datos ya que son suficientes para calcular el MLE

4.2.6. Ejemplo: MLE para la Gaussiana multivariada

- La LL sin constantes irrelevantes:

$$LL(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \log p(\mathcal{D} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad (48)$$

$$= \frac{N}{2} \log |\boldsymbol{\Lambda}| - \frac{1}{2} \sum_n (\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Lambda} (\mathbf{y}_n - \boldsymbol{\mu}) \quad (49)$$

donde $\boldsymbol{\Lambda} = \boldsymbol{\Sigma}^{-1}$ es la *matriz de precisión*

- MLE para la media:

$$\hat{\boldsymbol{\mu}} = \frac{1}{N} \sum_n \mathbf{y}_n = \bar{\mathbf{y}} \quad (50)$$

- MLE para la matriz de covarianzas:

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{N} \sum_n (\mathbf{y}_n - \bar{\mathbf{y}})(\mathbf{y}_n - \bar{\mathbf{y}})^t \quad (51)$$

4.2.7. Ejemplo: MLE para regresión lineal

- Modelo de regresión lineal con $\theta = (\mathbf{w}, \sigma^2)$, σ^2 fija:

$$p(y \mid \mathbf{x}; \Theta) = \mathcal{N}(y \mid \mathbf{w}^t \mathbf{x}, \sigma^2) \quad (52)$$

- MLE:

$$\hat{\mathbf{w}} \triangleq \arg \min_{\mathbf{w}} \text{NLL}(\mathbf{w}) \triangleq -\sum_n \log \left[\left[\frac{1}{2\pi\sigma^2} \right]^{\frac{1}{2}} \exp \left[\frac{-1}{2\sigma^2} (y_n - \mathbf{w}^t \mathbf{x}_n)^2 \right] \right] \quad (53)$$

$$= \arg \min_{\mathbf{w}} \text{RSS}(\mathbf{w}) \triangleq \sum_n (y_n - \mathbf{w}^t \mathbf{x}_n)^2 \triangleq \sum_n r_n^2 \quad \textit{residual sum} \quad (54)$$

$$= \arg \min_{\mathbf{w}} \text{MSE}(\mathbf{w}) \triangleq \frac{1}{N} \text{RSS}(\mathbf{w}) \quad \textit{mean squared error} \quad (55)$$

$$= \arg \min_{\mathbf{w}} \text{RMSE}(\mathbf{w}) \triangleq \sqrt{\text{MSE}(\mathbf{w})} \quad \textit{root MSE} \quad (56)$$

$$= (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{y} \quad \textit{ordinary least squares (OLS)} \quad (57)$$

4.3. Minimización del riesgo empírico

- *Empirical risk minimization (ERM)*: generaliza MLE sustituyendo la log-pérdida

$$\ell(\mathbf{y}_n, \boldsymbol{\theta}; \mathbf{x}_n) = -\log p(\mathbf{y}_n \mid \mathbf{x}_n, \boldsymbol{\theta}) \quad (58)$$

por cualquier otra *función de pérdida* ℓ para estimar $\boldsymbol{\theta}$ mediante la esperanza de ℓ con respecto a la empírica

$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}) \triangleq \frac{1}{N} \sum_{n=1}^N \ell(\mathbf{y}_n, \boldsymbol{\theta}; \mathbf{x}_n) \quad (59)$$

4.3.1. Ejemplo: minimizar el error de clasificación

► **Pérdida 0-1** de un clasificador $f(\mathbf{x}_n; \boldsymbol{\theta})$:

$$\ell_{01}(\mathbf{y}_n, \boldsymbol{\theta}; \mathbf{x}_n) = \begin{cases} 0 & \text{si } \mathbf{y}_n = f(\mathbf{x}_n; \boldsymbol{\theta}) \\ 1 & \text{si } \mathbf{y}_n \neq f(\mathbf{x}_n; \boldsymbol{\theta}) \end{cases} \quad (60)$$

► **Error de clasificación** en entrenamiento:

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{N} \sum_n \ell_{01}(\mathbf{y}_n, \boldsymbol{\theta}; \mathbf{x}_n) \quad (61)$$

► **Problemas binarios:**

▷ Etiquetas correcta y predicha: $\tilde{y}, \hat{y} = f(\mathbf{x}_n; \boldsymbol{\theta}) \in \{-1, +1\}$

▷ Pérdida 0-1:

$$\ell_{01}(\tilde{y}, \hat{y}) = \mathbb{1}(\tilde{y} \neq \hat{y}) = \mathbb{1}(\tilde{y} \hat{y} < 0) \quad (62)$$

▷ Riesgo empírico:

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{N} \sum_n \ell_{01}(y_n, \hat{y}_n) = \frac{1}{N} \sum_n \mathbb{1}(\tilde{y}_n \hat{y}_n < 0) \quad (63)$$

4.3.2. Pérdida subrogada

► **Surrogate loss function:** cota superior de la pérdida 0-1, más fácil de optimizar (convexa) y ajustada

► *Ejemplo:*

▷ Etiquetas $\tilde{y} \in \{-1, +1\}$

▷ Clasificador binario: con log-odds $\eta = f(\mathbf{x}; \boldsymbol{\theta})$

$$p(\tilde{y} \mid \mathbf{x}, \boldsymbol{\theta}) = \sigma(\tilde{y}\eta) = \frac{1}{1 + e^{-\tilde{y}\eta}} \quad (64)$$

▷ **Margen** $\tilde{y}\eta$: “margen de seguridad” alejado del valor umbral 0


▷ **Log-pérdida:** pérdida subrogada de MLE

$$\ell_l(\tilde{y}, \eta) = -\log p(\tilde{y} \mid \eta) = \log(1 + e^{-\tilde{y}\eta}) \quad (65)$$

▷ **Pérdida bisagra (hinge):** (bisagra de puerta abierta)

$$\ell_{\text{hinge}}(\tilde{y}, \eta) = \max(0, 1 - \tilde{y}\eta) \triangleq (1 - \tilde{y}\eta)_+ \quad (66)$$

► Pérdidas 0-1, log y bisagra en función del margen $\tilde{y}\eta$



4.5. Regularización

- ▶ **Sobre-entrenamiento (overfitting):** problema fundamental de MLE y, en general, **ERM**, asociado a la minimización de la pérdida sobre los datos de entrenamiento, ya que conduce a modelos **sobre-entrenados** que **no generalizan** (bien)
- ▶ *Ejemplo:* probabilidad de obtener cara al lanzar una moneda
 - ▷ Lanzamos la moneda $N = 3$ veces y obtenemos 3 caras
 - ▷ El MLE es $\hat{\theta}_{\text{mle}} = N_1 / (N_0 + N_1) = 3 / (0 + 3) = 1$
 - ▷ Si usamos $\text{Ber}(y \mid \hat{\theta}_{\text{mle}})$ para predecir, predeciremos cara en todos los lanzamientos futuros, cosa bastante inverosímil
- ▶ **Muchos parámetros y no generalización:** el modelo tiene suficientes parámetros para explicar los datos, por lo que acaba pareciéndose mucho a la empírica y no es capaz de generalizar

- **Regularización:** es la principal solución al sobre-entrenamiento; consiste en añadir un término de **penalización (penalty)** a la NLL (o el riesgo empírico):

$$\mathcal{L}(\boldsymbol{\theta}; \lambda) = \left[\frac{1}{N} \sum_n \ell(\mathbf{y}_n, \boldsymbol{\theta}; \mathbf{x}_n) \right] + \lambda C(\boldsymbol{\theta}) \quad (67)$$

donde

- ▷ $\lambda \geq 0$ es el **parámetro de regularización** y
 - ▷ $C(\boldsymbol{\theta})$ es alguna forma de **penalización de complejidad**
- **Penalización de complejidad usual:** introduce un **prior** $p(\boldsymbol{\theta})$

$$C(\boldsymbol{\theta}) = -\log p(\boldsymbol{\theta}) \quad (68)$$

► Estimación maximum a posteriori (MAP):

► Si ℓ es la log-pérdida, el objetivo regularizado es:

$$\mathcal{L}(\boldsymbol{\theta}; \lambda) = -\frac{1}{N} \sum_n \log p(\mathbf{y}_n \mid \mathbf{x}_n, \boldsymbol{\theta}) - \lambda \log p(\boldsymbol{\theta}) \quad (69)$$

► Tomando $\lambda = 1$ y reescalando $p(\boldsymbol{\theta})$ apropiadamente:

$$\mathcal{L}(\boldsymbol{\theta}; \lambda) = - \left[\sum_n \log p(\mathbf{y}_n \mid \mathbf{x}_n, \boldsymbol{\theta}) + \log p(\boldsymbol{\theta}) \right] \quad (70)$$

$$= -[\log p(\mathcal{D} \mid \boldsymbol{\theta}) + \log p(\boldsymbol{\theta})] \quad (71)$$


► Minimizar $\mathcal{L}$ equivale a maximizar la (log-)posterior (MAP):

$$\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta}} \log p(\boldsymbol{\theta} \mid \mathcal{D}) \quad (72)$$

$$= \arg \max_{\boldsymbol{\theta}} [\log p(\mathcal{D} \mid \boldsymbol{\theta}) + \log p(\boldsymbol{\theta}) - \text{const}] \quad (73)$$

4.5.1. Ejemplo: estimación MAP para la Bernoulli

- ▶ *Ejemplo de la moneda (cont.):* $\hat{\theta}_{\text{mle}} = 1$ si solo observamos caras, por lo que necesitamos penalizar valores extremos de $\theta \in [0, 1]$
- ▶ Prior $p(\theta) = \text{Beta}(\theta \mid a, b)$: $a, b > 1$ favorece θ próximo a $a/(a+b)$



- La log-verosimilitud más log-prior es:

$$LL(\theta) = \log p(\mathcal{D} \mid \theta) + \log p(\theta) \quad (74)$$

$$\begin{aligned} &= [N_1 \log \theta + N_0 \log(1 - \theta)] \\ &\quad + [(a - 1) \log(\theta) + (b - 1) \log(1 - \theta)] \end{aligned} \quad (75)$$

- Derivando e igualando a cero:

$$\theta_{\text{map}} = \frac{N_1 + a - 1}{N_1 + N_0 + a + b - 2} \quad (76)$$

- Tomando $a = b = 2$, obtenemos el *suavizado add-one*:

$$\theta_{\text{map}} = \frac{N_1 + 1}{N_1 + N_0 + 2} \quad (77)$$

- El suavizado add-one es una técnica muy popular en estimación basada en cuentas (p.e. en modelado de lenguaje estadístico)

4.5.3. Ejemplo: regularización ℓ_2

- **Regularización ℓ_2 o penalización de pesos:** añade un prior Gaussiano de media nula sobre los pesos en regresión polinómica


$$\hat{\mathbf{w}}_{\text{map}} = \arg \min_{\mathbf{w}} \text{NLL}(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2 \quad (78)$$

- Cuanto mayor es λ , mayor es el número de parámetros penalizados por ser “grandes” (desviarse del prior Gaussiano con media nula), por lo que el modelo es menos flexible
- **Regresión de cresta (ridge):** regresión lineal ℓ_2 -regularizada
- **Ejemplo:** regresión de cresta con predictor polinómico ($D = 14$) a ajustar con $N = 21$ datos


$$f(x; \mathbf{w}) = \sum_{d=0}^D w_d x^d = \mathbf{w}^t [1, x, x^2, \dots, x^D] \quad (79)$$

► *Ejemplo (cont.):* ajuste MSE


L2 regularizer 0.00000




- *Ejemplo (cont.):* ajuste con $\lambda = 1.9 \cdot 10^{-4}$



► *Ejemplo (cont.):* ajuste con $\lambda = 1.1$



► *Ejemplo (cont.):* MSE en función de λ



4.5.4. Elección del regularizador mediante validación

- ▶ La elección de la fuerza del regularizador, λ , es clave:
 - ▷ Un valor demasiado pequeño equivale a minimizar el riesgo empírico y acabar con un modelo **sobre-ajustado**
 - ▷ Un valor demasiado grande equivale a no desviarse mucho del prior y acabar con un modelo **sub-ajustado**
- ▶ **Validación:** método más popular y sencillo para escoger λ
 - ▷ Dividimos los datos en un conjunto de entrenamiento, $\mathcal{D}_{\text{train}}$, y otro separado, $\mathcal{D}_{\text{valid}}$, de **validación** o **desarrollo** (80-20 % p.e.)
 - ▷ Por cada valor de interés de λ , el modelo se ajusta con $\mathcal{D}_{\text{train}}$ y se evalúa en validación
 - ▷ Elegimos el λ que proporciona mejor rendimiento en validación

► *Validación con más detalle:*

- ▷ Riesgo empírico regularizado con un conjunto de datos $\mathcal{D}$:

$$R_\lambda(\boldsymbol{\theta}, \mathcal{D}) = \frac{1}{|\mathcal{D}|} \sum_{(\mathbf{x}, \mathbf{y}) \in \mathcal{D}} \ell(\mathbf{y}, f(\mathbf{x}; \boldsymbol{\theta})) + \lambda C(\boldsymbol{\theta}) \quad (80)$$

- ▷ Por cada valor de interés de λ , obtenemos el estimador:

$$\hat{\boldsymbol{\theta}}_\lambda(\mathcal{D}_{\text{train}}) = \arg \min_{\boldsymbol{\theta}} R_\lambda(\boldsymbol{\theta}, \mathcal{D}_{\text{train}}) \quad (81)$$

- ▷ *Riesgo poblacional* estimado como *riesgo en validación*:

$$R_\lambda^{\text{val}} \triangleq R_0(\hat{\boldsymbol{\theta}}_\lambda(\mathcal{D}_{\text{train}}), \mathcal{D}_{\text{valid}}) \quad (82)$$

- ▷ Escogemos el regularizador óptimo en validación:

$$\lambda^* = \arg \min_{\lambda \in \mathcal{S}} R_\lambda^{\text{val}} \quad (83)$$

- ▷ Finalmente reajustamos el modelo con todo $\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{valid}}$:


$$\hat{\boldsymbol{\theta}}^* = \arg \min_{\boldsymbol{\theta}} R_{\lambda^*}(\boldsymbol{\theta}, \mathcal{D}) \quad (84)$$

4.5.5. Validación cruzada

- **Cross validation (CV):** divide los datos en K bloques y, por cada bloque $k \in \{1, \dots, K\}$, ajusta el modelo con todos los bloques menos el k -ésimo, el cual se usa como conjunto de validación:

$$R_{\lambda}^{\text{CV}} \triangleq \frac{1}{K} \sum_k R_0(\hat{\theta}_{\lambda}(\mathcal{D}_{-k}), \mathcal{D}_k) \quad (85)$$

- *Ejemplo:* validación cruzada con $K = 5$ bloques



► *Leave-one-out (LOO) cross validation:* CV con $K = N$

► En general, usamos el estimador CV para hallar un λ óptimo:

$$\hat{\lambda} = \arg \min_{\lambda} R_{\lambda}^{\text{CV}} \quad (86)$$

► Tras hallar $\hat{\lambda}$, re-estimamos θ con todos los datos:

$$\hat{\theta} = \arg \min_{\theta} R_{\hat{\lambda}}(\theta, \mathcal{D}) \quad (87)$$

4.5.5.1. La regla “un error estándar”

- ▶ CV proporciona un estimador del riesgo, $\hat{R}_\lambda$, pero no añade ninguna medida de incertidumbre
- ▶ **Error estándar de la media:** medida de incertidumbre (frecuentista) usual de un estimador
 - ▷ Por cada muestra n , estimamos su pérdida con el modelo ajustado sin ella en entrenamiento (con su bloque en validación)

$$L_n = \ell(\mathbf{y}_n, f(\mathbf{x}_n; \hat{\boldsymbol{\theta}}_\lambda(\mathcal{D}_{-n}))) \quad (88)$$

- ▷ Media y varianza empíricas: de L_n

$$\hat{\mu} = \frac{1}{N} \sum_n L_n \quad \hat{\sigma}^2 = \frac{1}{N} \sum_n (L_n - \hat{\mu})^2 \quad (89)$$


- ▷ Error estándar de la media: incertidumbre sobre $\hat{\mu}$

$$\text{se}(\hat{\mu}) = \frac{\hat{\sigma}}{\sqrt{N}} \quad (90)$$


- ▶ ***One-standard error rule:*** se emplea para la selección de un modelo entre varios candidatos
 - ▷ Primero se aplica CV a cada modelo, obteniéndose la media y error estándar (de la media) a partir de sus riesgos estimados
 - ▷ Se selecciona el modelo más simple cuyo riesgo no sea mayor que un error estándar por encima del riesgo del mejor modelo

4.5.5.2. Ejemplo: regresión de cresta

- MSE en test y train vs $\log(\lambda)$: el de test tiene forma de U; primero decrece al aumentar λ , pero luego crece a causa del subajuste




- MSE estimado con 5-bloques CV vs $\log(\lambda)$, con error estándar de la media en barras verticales: mínimo cercano al óptimo en test




4.5.6. Terminación temprana

- ▶ Por lo general, el ajuste de parámetros se realiza mediante un algoritmo de optimización iterativa
- ▶ *Early stopping:* consiste en validar el rendimiento del modelo tras cada iteración y terminar antes de convergencia si se observa sobre-entrenamiento

► *Ejemplo:* pérdida de un clasificador de texto en IMDB



► *Ejemplo (cont.):* precisión



4.5.7. Uso de más datos

- ▶ A medida que la cantidad de datos aumenta, la posibilidad de sobre-ajuste decrece (para un modelo de complejidad fija)


- ▶ *Ejemplo:*

- ▷ Regresión de cresta con predictor polinómico

$$f(x; \mathbf{w}) = \sum_{d=0}^D w_d x^d = \mathbf{w}^t [1, x, x^2, \dots, x^D] \quad (91)$$


- ▷ Estudiamos el MSE en train y test, en función del número de datos de entrenamiento N
 - ▷ Ajustamos cuatro modelos con $D = 1, 2, 10, 20$
 - ▷ **Error de Bayes:** error del modelo óptimo (de grado 2), mostrado como línea horizontal negra

- *Ejemplo (cont.):* $D = 1$; modelo demasiado simple
truth = degree 2, model = degree 1




► *Ejemplo (cont.):* $D = 2$; modelo de complejidad óptima

truth = degree 2, model = degree 2



- *Ejemplo (cont.):* $D = 10$; necesitamos más datos para ajustarlo
truth = degree 2, model = degree 10



- *Ejemplo (cont.):* $D = 20$; necesitamos todavía más datos

truth = degree 2, model = degree 20

