



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Teoría de la decisión (actividades)

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

5.1	Teoría de la decisión Bayesiana	1
5.1.1	Conceptos básicos	1
5.1.2	Problemas de clasificación	2
5.1.3	Curvas ROC	5
5.1.4	Curvas PR	7
5.1.5	Problemas de regresión	8
5.1.6	Problemas de predicción probabilística	10

5.1. Teoría de la decisión Bayesiana

5.1.1. Conceptos básicos

- Sean $\mathcal{H}$, $\mathcal{X}$ y $\mathcal{A}$ los posibles estados de la naturaleza, observaciones y acciones de un problema de decisión. Sea $\ell : \mathcal{H} \times \mathcal{A} \rightarrow \mathbb{R}$ la pérdida asociada a cada par estado-acción posible. La pérdida esperada de una acción a , a posteriori de una observación x , es:

$$1. R(a \mid \mathbf{x}) \triangleq \mathbb{E}_{p(\mathbf{x})}[\ell(h, a)]$$

$$2. R(a \mid \mathbf{x}) \triangleq \mathbb{E}_{p(h)}[\ell(h, a)]$$

$$3. R(a \mid \mathbf{x}) \triangleq \mathbb{E}_{p(h|\mathbf{x})}[\ell(h, a)]$$

$$4. R(a \mid \mathbf{x}) \triangleq \mathbb{E}_{p(\mathbf{x}|h)}[\ell(h, a)]$$

La 3.

5.1.2. Problemas de clasificación

- En un problema de clasificación en C clases, tanto los posibles estados de la naturaleza como las posibles acciones son etiquetas de clase, $\mathcal{H} = \mathcal{A} = \mathcal{Y} \triangleq \{1, \dots, C\}$. Si la pérdida asociada a cada par estado-acción es la 0-1, $\ell(y^*, \hat{y}) = \mathbb{1}(y^* \neq \hat{y})$, la pérdida esperada de una acción $\hat{y}$, a posteriori de una observación $\mathbf{x}$, es:

$$1. R(\hat{y} \mid \mathbf{x}) = p(y^* = \hat{y} \mid \mathbf{x})$$

$$2. R(\hat{y} \mid \mathbf{x}) = p(y^* \neq \hat{y} \mid \mathbf{x})$$

$$3. R(\hat{y} \mid \mathbf{x}) = 1 - p(y^* = \hat{y} \mid \mathbf{x})$$

$$4. R(\hat{y} \mid \mathbf{x}) = 1 - p(y^* \neq \hat{y} \mid \mathbf{x})$$

La 2 o la 3:

$$\begin{aligned} R(\hat{y} \mid \mathbf{x}) &= \mathbb{E}_{p(y^* \mid \mathbf{x})}[\ell(y^*, \hat{y})] = \sum_{y^*} p(y^* \mid \mathbf{x}) \mathbb{1}(y^* \neq \hat{y}) \\ &= p(y^* \neq \hat{y} \mid \mathbf{x}) = 1 - p(y^* = \hat{y} \mid \mathbf{x}) \end{aligned}$$

- En un problema de clasificación en C clases, el clasificador o regla de decisión de Bayes (a posteriori), o estimador MAP, consiste en decidirse por la clase de menor riesgo a posteriori, esto es:

$$1. \pi^*(\mathbf{x}) = \arg \min_{y \in \mathcal{Y}} p(y \mid \mathbf{x})$$

$$2. \pi^*(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} p(y \mid \mathbf{x})$$

$$3. \pi^*(\mathbf{x}) = \arg \min_{y \in \mathcal{Y}} 1 - p(y \mid \mathbf{x})$$

$$4. \pi^*(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} 1 - p(y \mid \mathbf{x})$$

La 2 o la 3; son equivalentes.

- Sea un problema de clasificación de datos $\mathbf{x} = (x_1, x_2)^t \in \{0, 1\}^2$ en tres clases, según las distribuciones de probabilidad de la tabla. Determina el clasificador de Bayes y su error (riesgo con pérdida 0-1), a posteriori para cada $\mathbf{x}$, $\varepsilon^*(\mathbf{x})$, y a priori, ε^* .

$\mathbf{x}$		$p(y \mid \mathbf{x})$			$p(\mathbf{x})$
x_1	x_2	$y=1$	$y=2$	$y=3$	
0	0	0.2	0.5	0.3	0.5
0	1	0.2	0.8	0	0.3
1	0	0	0.9	0.1	0
1	1	0.1	0.7	0.2	0.2

$\mathbf{x}$		$p(y \mid \mathbf{x})$			$p(\mathbf{x})$	$\pi^*(\mathbf{x})$	$\varepsilon^*(\mathbf{x})$
x_1	x_2	$y=1$	$y=2$	$y=3$			
0	0	0.2	0.5	0.3	0.5	2	0.5
0	1	0.2	0.8	0	0.3	2	0.2
1	0	0	0.9	0.1	0	2	0.1
1	1	0.1	0.7	0.2	0.2	2	0.3

$$\varepsilon^*(\mathbf{x}) \triangleq 1 - p(\pi^*(\mathbf{x}) \mid \mathbf{x})$$

$$\varepsilon^* \triangleq \mathbb{E}[\varepsilon^*(\mathbf{x})] = \sum_{\mathbf{x}} p(\mathbf{x}) \varepsilon^*(\mathbf{x}) = 0.5 \cdot 0.5 + 0.3 \cdot 0.2 + 0.2 \cdot 0.3 = 0.37$$


5.1.3. Curvas ROC

- Las matrices de confusión se usan tanto en problemas de clasificación binarios como no binarios. Con base en la siguiente matriz de confusiones vocálicas entre hablantes de un lenguaje silbado, estima el error de comunicación vocálico entre hablantes, ε^h .

vocal producida	vocal percibida				
	<i>i</i>	<i>e</i>	<i>a</i>	<i>o</i>	<i>u</i>
<i>i</i>	15		1		
<i>e</i>	1		1		
<i>a</i>			79	5	
<i>o</i>			4	15	3
<i>u</i>				2	2


$$\varepsilon^h = \frac{1 + 2 + 5 + 7 + 2}{16 + 2 + 84 + 22 + 4} = \frac{17}{128} = 13\%$$

- Reproduce el cuaderno de la [Figura 5.2 \(a\)](#)



5.1.4. Curvas PR

- Reproduce el cuaderno de la [Figura 5.2 \(b\)](#)



5.1.5. Problemas de regresión

- En un problema de regresión, tanto los posibles estados de la naturaleza como las posibles acciones son reales, $\mathcal{H} = \mathcal{A} = \mathbb{R}$. Si el riesgo asociado a cada par estado-acción es la pérdida L2, $\ell_2(h, a) = (h - a)^2$, la acción óptima (a posteriori), $a^* = \pi^*(\mathbf{x})$, es:

1. Media: $\pi^*(\mathbf{x}) = \mathbb{E}[h \mid \mathbf{x}] = \int h p(h \mid \mathbf{x}) dh$


2. Mediana: $\pi^*(\mathbf{x}) : p(h < \pi^*(\mathbf{x}) \mid \mathbf{x}) = p(h \geq \pi^*(\mathbf{x}) \mid \mathbf{x}) = 0.5$

3. Moda: $\pi^*(\mathbf{x}) = \max_h p(h \mid \mathbf{x})$ (cualquier pico)

4. Ninguna de las anteriores

La 1, esto es, la media a posteriori. La mediana es el estimador óptimo para la pérdida L1. La moda se suele entender como cualquier pico de la posterior, no necesariamente el más alto (si solo hay uno). Las tres coinciden si la posterior es normal.

► Reproduce el cuaderno de la [Figura 5.3](#)



5.1.6. Problemas de predicción probabilística

- En un problema de predicción probabilística, tanto los posibles estados de la naturaleza como las posibles acciones son distribuciones de probabilidad sobre alguna variable de interés, $h = p(Y|\mathbf{x})$ y $a = q(Y|\mathbf{x})$. Así, el riesgo asociado a cada par estado-acción se suele definir en términos de la divergencia $\mathbb{KL}$, $\ell_{KL}(p, q) = \mathbb{KL}(p, q) = -\mathbb{H}(p) + \mathbb{H}(p, q)$, donde, asumiendo Y discreta:

1. $\mathbb{H}(p) = -\sum_y p(y|\mathbf{x}) \log p(y|\mathbf{x})$ y $\mathbb{H}(p, q) = -\sum_y p(y|\mathbf{x}) \log q(y|\mathbf{x})$

2. $\mathbb{H}(p) = -\sum_y p(y|\mathbf{x}) \log p(y|\mathbf{x})$ y $\mathbb{H}(p, q) = \sum_y p(y|\mathbf{x}) \log q(y|\mathbf{x})$

3. $\mathbb{H}(p) = \sum_y p(y|\mathbf{x}) \log p(y|\mathbf{x})$ y $\mathbb{H}(p, q) = -\sum_y p(y|\mathbf{x}) \log q(y|\mathbf{x})$

4. $\mathbb{H}(p) = \sum_y p(y|\mathbf{x}) \log p(y|\mathbf{x})$ y $\mathbb{H}(p, q) = \sum_y p(y|\mathbf{x}) \log q(y|\mathbf{x})$

La 1. La entropía, $\mathbb{H}(p)$, se ignora en el cálculo del estimador óptimo, $q^*(Y|\mathbf{x})$. La entropía cruzada de q relativa a p , $\mathbb{H}(p, q)$, se reduce a la log-pérdida si los estados son one-hot, como en clasificación.