



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Teoría de la decisión

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

5.1 Teoría de la decisión Bayesiana	1
5.1.1 Conceptos básicos	2
5.1.2 Problemas de clasificación	6
5.1.2.1 Pérdida 0-1	6
5.1.2.2 Clasificación sensible al coste	8
5.1.2.3 Clasificación con opción de rechazo	9
5.1.3 Curvas ROC	12
5.1.3.1 Matrices de confusión de clase	12
5.1.3.2 Resumen de curvas ROC con un escalar	15
5.1.3.3 Clases desequilibradas	17
5.1.4 Curvas PR	18
5.1.4.1 Cálculo de la precisión y cobertura	19
5.1.4.2 Resumen mediante un escalar	21
5.1.4.3 <i>F-scores</i>	22
5.1.4.4 Clases desequilibradas	24
5.1.5 Problemas de regresión	26
5.1.5.1 Pérdida L2	27
5.1.5.2 Pérdida L1	28

5.1.5.3	Pérdida de Huber	29
5.1.6	Problemas de predicción probabilística	31
5.1.6.1	KL, entropía cruzada y log-pérdida	32
5.1.6.2	Reglas de puntuación propias	34

5.1. Teoría de la decisión Bayesiana

- ▶ La inferencia Bayesiana aplica la regla de Bayes para actualizar la distribución de probabilidad sobre los posibles valores de una cantidad oculta H , a partir de datos observados $\mathbf{X} = \mathbf{x}$
- ▶ La *teoría de la decisión* aprovecha los resultados de la inferencia para decidir cuál es la mejor de las posibles *acciones* a realizar

5.1.1. Conceptos básicos

- ▶ **Agente:** debe escoger un acción de un conjunto $\mathcal{A}$
- ▶ *Ejemplo:* un médico debe tratar un paciente que podría tener COVID y las posibles acciones son: no hacer nada o dar una medicina con efectos secundarios graves, pero que podría salvarle la vida
- ▶ **Estado de la naturaleza:** $h \in \mathcal{H}$, condiciona los costes y beneficios que se derivan de tomar cada acción posible
- ▶ *Ejemplo (cont.):* el estado viene dado por la edad del paciente (joven o mayor) y si tiene COVID o no; se trata de un estado **parcialmente observado** ya que podemos observar la edad del paciente directamente, pero no si tiene COVID o no, cosa que inferimos a partir de observaciones ruidosas con la regla de Bayes

- **Función de pérdida** $\ell(h, a)$: especifica el coste incurrido al tomar la acción $a \in \mathcal{A}$ cuando el estado de la naturaleza es $h \in \mathcal{H}$
- *Ejemplo (cont.)*: medimos costes y beneficios en quality-adjusted life years (QALYs); asumimos que el coste de dar una medicina es de 8 QALYs, independientemente del estado del paciente; sin embargo, el beneficio para un paciente se considera de 60 QALYs si es joven; 10 si es mayor
- *Ejemplo (cont.)*: matriz de pérdidas para un decisor, con 4 estados de la naturaleza y 2 posibles acciones

Estado	nada	med.
No COVID, joven	0	8
COVID, joven	60	8
No COVID, mayor	0	8
COVID, mayor	10	8

- **Riesgo (pérdida) esperado a posteriori:** de a tras observar $\mathbf{x}$

$$R(a \mid \mathbf{x}) \triangleq \mathbb{E}_{p(h|\mathbf{x})}[\ell(h, a)] = \sum_{h \in \mathcal{H}} \ell(h, a) p(h \mid \mathbf{x}) \quad (1)$$

- **Política óptima o estimador de Bayes:** por cada observación posible, indica qué acción tomar para minimizar el riesgo

$$\pi^*(\mathbf{x}) = \arg \min_{a \in \mathcal{A}} R(a \mid \mathbf{x}) \quad (2)$$

- *Ejemplo (cont.):* $\mathbf{x}$ incluye edad y el resultado de un test (0 o 1) para actualizar la probabilidad de COVID con Bayes; a partir de las posteriors de los estados y la matriz de pérdidas, podemos hallar la acción de menor riesgo por cada observación posible

test	edad	pr(covid)	nada	med.	acción
0	0	0.01	0.84	8.00	0
0	1	0.01	0.14	8.00	0
1	0	0.80	47.73	8.00	1
1	1	0.80	7.95	8.00	0

- **Función de utilidad:** deseabilidad de cada acción posible en cada posible estado, esto es, riesgo con signo cambiado

$$U(h, a) = -\ell(h, a) \quad (3)$$

- **Principio de utilidad esperada máxima:** estimador de Bayes expresado en términos de utilidad

$$\pi^*(\mathbf{x}) = \arg \max_{a \in \mathcal{A}} \mathbb{E}_h[U(h, a)] \quad (4)$$

- **Sensibilidad al riesgo:** asumimos que el agente es *neutral*, esto es, insensible al riesgo, pero podría no ser así
 - ▷ *Ejemplo:* nos da igual obtener 50 EUR con seguridad, o con 50 % de probabilidad de 0 o 100 EUR

5.1.2. Problemas de clasificación

5.1.2.1. Pérdida 0-1

- Estados de la naturaleza y acciones son etiquetas de clase:

$$\mathcal{H} = \mathcal{Y} = \{1, \dots, C\} \quad \text{y} \quad \mathcal{A} = \mathcal{Y} \quad (5)$$

- **Pérdida 0-1:** para $\mathcal{Y} = \{0, 1\}$ pero directamente generalizable

$$\ell_{01}(y^*, \hat{y}) = \left[\begin{array}{c|cc} & \hat{y} = 0 & \hat{y} = 1 \\ \hline y^* = 0 & 0 & 1 \\ y^* = 1 & 1 & 0 \end{array} \right] \quad (6)$$

$$= \mathbb{1}(y^* \neq \hat{y}) \quad (7)$$

► **Pérdida esperada a posteriori:**

$$R(\hat{y} \mid \mathbf{x}) = p(\hat{y} \neq y^* \mid \mathbf{x}) = 1 - p(y^* = \hat{y} \mid \mathbf{x}) \quad (8)$$

- **Estimador máximo a posteriori (MAP):** la etiqueta más probable o **moda** de la posterior minimiza la pérdida esperada

$$\pi(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} p(y \mid \mathbf{x}) \quad (9)$$

5.1.2.2. Clasificación sensible al coste

- Problema de clasificación binario con función de pérdida:

$$\ell(y^*, \hat{y}) = \begin{pmatrix} \ell_{00} & \ell_{01} \\ \ell_{10} & \ell_{11} \end{pmatrix} \quad (10)$$

- Si $p_0 \triangleq p(y^* = 0 \mid \mathbf{x})$ y $p_1 \triangleq 1 - p_0$, debemos escoger $\hat{y} = 0$ sii

$$\ell_{00} p_0 + \ell_{10} p_1 < \ell_{01} p_0 + \ell_{11} p_1 \quad (11)$$

- Si $\ell_{00} = \ell_{11} = 0$, la regla de decisión se simplifica como

$$p_1 < \frac{\ell_{01}}{\ell_{01} + \ell_{10}} \quad (12)$$

- Si un falso negativo cuesta c veces más que un falso positivo, $\ell_{10} = c \ell_{01}$, debemos escoger $\hat{y} = 0$ sii

$$p_1 < \frac{1}{1 + c} \quad (13)$$

5.1.2.3. Clasificación con opción de rechazo

- ▶ **Reject option:** en algunos casos podemos decir “no sé” en lugar de dar una respuesta en la que no confiamos del todo
- ▶ Sean $\mathcal{H} = \mathcal{Y} = \{1, \dots, C\}$ los estados de la naturaleza
- ▶ Sean $\mathcal{A} = \mathcal{Y} \cup \{0\}$ las acciones, con 0 para el rechazo
- ▶ Sean λ_r el coste del rechazo, λ_e el del error de clasificación y la función de pérdida

$$\ell(y^*, a) = \begin{cases} 0 & \text{si } y^* = a \text{ y } a \in \{1, \dots, C\} \\ \lambda_r & \text{si } a = 0 \\ \lambda_e & \text{en otro caso} \end{cases} \quad (14)$$

► La política óptima es:

$$a^* = \begin{cases} y^* & \text{si } p^* > \lambda^* \\ \text{rechazo} & \text{en otro caso} \end{cases} \quad (15)$$


donde

$$y^* = \arg \max_{y \in \{1, \dots, C\}} p(y \mid \mathbf{x}) \quad (16)$$

$$p^* = p(y^* \mid \mathbf{x}) = \max_{y \in \{1, \dots, C\}} p(y \mid \mathbf{x}) \quad (17)$$

$$\lambda^* = 1 - \frac{\lambda_r}{\lambda_e} \quad (18)$$

- *Il·lustració:* rechazamos en regiones con posteriors igualadas



5.1.3. Curvas ROC

5.1.3.1. Matrices de confusión de clase

- Sean un problema de clasificación binario y la regla de decisión:

$$\hat{y}_\tau(\mathbf{x}) = \mathbb{1}(p(y = 1 \mid \mathbf{x}) \geq 1 - \tau) \quad (\tau \text{ umbral fijo}) \quad (19)$$

- *Matriz de confusión:*

		Estimado		Suma fila
		0	1	
Verdad	0	TN_τ	FP_τ	N
	1	FN_τ	TP_τ	P
Suma col.		$\hat{N}$	$\hat{P}$	

- ▷ TN_τ es el número de *true negatives*
- ▷ FP_τ es el número de *false positives*
- ▷ FN_τ es el número de *false negatives*
- ▷ TP_τ es el número de *true positives*
- ▷ P y $\hat{P}$ son los números verdadero y predicho de positivos
- ▷ N y $\hat{N}$ son los números verdadero y predicho de negativos

► **Matriz de confusión normalizada por filas:** $p(\hat{y} | y)$

		Estimado	
		0	1
Verdad	0	TNR_{τ}	FPR_{τ}
	1	FNR_{τ}	TPR_{τ}

▷ $TNR_{\tau} = \frac{TN_{\tau}}{N}$: *true negative (rate), specificity*

▷ $FPR_{\tau} = \frac{FP_{\tau}}{N}$: *false positive, false alarm, type I error, fallout*

▷ $FNR_{\tau} = \frac{FN_{\tau}}{P}$: *false negative, miss, type II error*

▷ $TPR_{\tau} = \frac{TP_{\tau}}{P}$: *true positive, hit, recall, sensitivity*

▷ Normalización: $TNR_{\tau} + FPR_{\tau} = 1$ y $FNR_{\tau} + TPR_{\tau} = 1$

► **Matriz de confusión normalizada por columnas:** $p(y \mid \hat{y})$

		Estimado	
		0	1
Verdad	0	NPV_{τ}	FDR_{τ}
	1	FOR_{τ}	PPV_{τ}

► $NPV_{\tau} = \frac{TN_{\tau}}{\hat{N}}$: **negative predictive value**

► $FOR_{\tau} = \frac{FN_{\tau}}{\hat{N}}$: **false omission rate**


► $FDR_{\tau} = \frac{FP_{\tau}}{\hat{P}}$: **false discovery rate**

► $PPV_{\tau} = \frac{TP_{\tau}}{\hat{P}}$: **positive predictive value, precision**

► Normalización: $NPV_{\tau} + FOR_{\tau} = 1$ y $FDR_{\tau} + PPV_{\tau} = 1$

5.1.3.2. Resumen de curvas ROC con un escalár

- *Receiver Operating Characteristic (ROC) curve*: gráfica que muestra TPR_τ en función de FPR_τ para τ de 0 a 1



- ▶ **Area under curve (AUC):** es la manera en la que suele resumirse la calidad de una curva ROC con un solo número (área azul para el clasificador B)
 - ▷ *Ejemplo:* el área bajo la curva del clasificador A es mejor (mayor) que la del B (sombreada en azul)
- ▶ **Equal error rate (EER) o cross-over rate:** es otro estadístico resumido popular; se define como el valor que cumple

$$FPR_{\tau} \stackrel{!}{=} FNR_{\tau} = 1 - TPR_{\tau} \quad (20)$$

el cual puede hallarse trazando una recta de la esquina superior izquierda a la inferior derecha y viendo dónde intersecciona la curva

- ▷ *Ejemplo:* la EER del A (rojo) es mejor (menor) que la del B (azul)

5.1.3.3. Clases desequilibradas

- ▶ Algunos problemas presentan clases muy desequilibradas
- ▶ *Ejemplo:* recuperación de información
 - ▷ El conjunto de negativos (documentos irrelevantes) es mucho mayor que el de positivos (relevantes)
 - ▷ La TPR y FPR no se ven afectadas por desequilibrios de clase ya que son fracciones de positivos y negativos, respectivamente
 - ▷ Un pequeño aumento de FPR supone un gran número de falsos positivos adicionales, cosa que no tiene interés práctico
 - ▷ La curva ROC solo tiene interés para valores pequeños de FPR

5.1.4. Curvas **PR**

- ▶ La noción de “negativo” no está bien definida en todo problema
- ▶ *Ejemplo:*
 - ▷ Detección de objetos en visión con patches: el número de verdaderos negativos depende del número de patches examinados
 - ▷ Recuperación de información: el conjunto de negativos (documentos irrelevantes) depende del total de ítems recuperados
 - ▷ Tanto patches examinados como ítems recuperados son resultado del algoritmo, no parte de la definición del problema
- ▶ **Curvas precision-recall (PR):** se usan para evaluar sistemas en estos casos, prestando especial atención a positivos

5.1.4.1. Cálculo de la precisión y cobertura

- **Precision:** fracción de positivos predichos que son verdad


$$\mathcal{P}(\tau) \triangleq \frac{TP_{\tau}}{TP_{\tau} + FP_{\tau}} = PPV_{\tau} \quad (21)$$

- **Recall:** fracción de positivos de verdad que son predichos

$$\mathcal{R}(\tau) \triangleq \frac{TP_{\tau}}{TP_{\tau} + FN_{\tau}} = TPR_{\tau} \quad (22)$$

- **Curva PR:** gráfica de $\mathcal{P}(\tau)$ en función de $\mathcal{R}(\tau)$ para τ de 0 a 1
- Cuanto más cercana a la esquina superior derecha, mejor

- *Ejemplo:* sistema A mejor que el B



5.1.4.2. Resumen mediante un escalar

- ▶ ***Precisión a K*** : precisión a un nivel de cobertura dado (K ítems)
- ▶ ***Área bajo la curva PR*** y otras medidas relacionadas:
 - ▷ ***Precisión interpolada***
 - ▷ ***Precisión promedio***
 - ▷ ***Precisión promedio media***

5.1.4.3. *F*-scores

- ***F*-score** F_β : combina precisión y recall de acuerdo con un peso $\beta > 0$ de importancia relativa del recall

$$\frac{1}{F_\beta} = \frac{1}{1 + \beta^2} \frac{1}{\mathcal{P}} + \frac{\beta^2}{1 + \beta^2} \frac{1}{\mathcal{R}} \quad (23)$$

- Equivalentemente:

$$F_\beta \triangleq (1 + \beta^2) \frac{\mathcal{P} \mathcal{R}}{\beta^2 \mathcal{P} + \mathcal{R}} \quad (24)$$

$$= \frac{(1 + \beta^2) TP}{(1 + \beta^2) TP + \beta^2 FN + FP} \quad (25)$$

- Con $\beta = 1$ obtenemos la media harmónica de precisión y recall:

$$\frac{1}{F_1} = \frac{1}{2} \left(\frac{1}{\mathcal{P}} + \frac{1}{\mathcal{R}} \right) \quad (26)$$

$$F_1 = \frac{2}{\frac{1}{\mathcal{R}} + \frac{1}{\mathcal{P}}} = 2 \frac{\mathcal{P} \mathcal{R}}{\mathcal{P} + \mathcal{R}} = \frac{TP}{TP + \frac{1}{2}(FP + FN)} \quad (27)$$

- La media harmónica es más conservadora que la aritmética ya que requiere que tanto la precisión como el recall sean altos
- *Ejemplo:* si $\mathcal{P} = 10^{-4}$ y $\mathcal{R} = 1$, la media aritmética es del 50 % y

$$F_1 = \frac{2 \cdot 10^{-4} \cdot 1}{10^{-4} + 1} \approx 0.02 \% \quad (28)$$

- F_1 pondera precisión y recall por igual; podemos usar $\beta = 2$ si el recall es más importante, o $\beta = 0.5$ si lo es la precisión

5.1.4.4. Clases desequilibradas

- ▶ Las curvas PR son sensibles al desequilibrio de clases
- ▶ Sean la fracción de positivos y el ratio de positivos a negativos

$$\pi = \frac{P}{P + N} \quad \text{y} \quad r = \frac{P}{N} = \frac{\pi}{1 - \pi} \quad (29)$$

- ▶ La precisión puede reescribirse como

$$\mathcal{P} = \frac{TP}{TP + FP} = \frac{P \cdot TPR}{P \cdot TPR + N \cdot FPR} = \frac{TPR}{TPR + \frac{1}{r} FPR} \quad (30)$$

- ▶ Tenemos que

$$\mathcal{P} \rightarrow 1 \quad \text{cuando} \quad r \rightarrow \infty \quad (\text{porque} \quad \pi \rightarrow 1) \quad (31)$$

$$\mathcal{P} \rightarrow 0 \quad \text{cuando} \quad r \rightarrow 0 \quad (\text{porque} \quad \pi \rightarrow 0) \quad (32)$$

- El F-score también es sensible al desequilibrio de clases:

$$\frac{1}{F_\beta} = \frac{1}{1 + \beta^2} \frac{1}{\mathcal{P}} + \frac{\beta^2}{1 + \beta^2} \frac{1}{\mathcal{R}} \quad (33)$$

$$= \frac{1}{1 + \beta^2} \frac{TPR + \frac{N}{P} FPR}{TPR} + \frac{\beta^2}{1 + \beta^2} \frac{1}{TPR} \quad (34)$$

$$F_\beta = \frac{(1 + \beta^2) TPR}{TPR + \frac{1}{r} FPR + \beta^2} \quad (35)$$

- Al igual que la precisión, tenemos que

$$F_\beta \rightarrow 1 \text{ cuando } r \rightarrow \infty \text{ (porque } \pi \rightarrow 1) \quad (36)$$

$$F_\beta \rightarrow 0 \text{ cuando } r \rightarrow 0 \text{ (porque } \pi \rightarrow 0) \quad (37)$$

5.1.5. Problemas de regresión

- ▶ En los problemas de clasificación suponemos que tanto estados de la naturaleza $\mathcal{H}$ como acciones $\mathcal{A}$ son finitos
- ▶ En los problemas de regresión consideramos que estados y acciones son iguales a la recta real, $\mathcal{H} = \mathcal{A} = \mathbb{R}$
- ▶ Consideramos pérdidas usuales para $\mathbb{R}$ que pueden extenderse fácilmente a $\mathbb{R}^D$ con cálculo de la pérdida elemento a elemento
- ▶ Las reglas de decisión resultantes pueden usarse para calcular los parámetros óptimos que debe devolver un estimador, la acción óptima que debe realizar un robot, etc.

5.1.5.1. Pérdida L2

- ℓ_2 **loss, squared error o quadratic loss:** es la más popular

$$\ell_2(h, a) = (h - a)^2 \quad (38)$$

- Sensible a **outliers** pues penaliza desviaciones al cuadrado
- Riesgo y derivada:

$$R(a \mid \mathbf{x}) = \mathbb{E}[(h - a)^2 \mid \mathbf{x}] = \mathbb{E}[h^2 \mid \mathbf{x}] - 2a \mathbb{E}[h \mid \mathbf{x}] + a^2 \quad (39)$$

$$\frac{\partial}{\partial a} R(a \mid \mathbf{x}) = -2 \mathbb{E}[h \mid \mathbf{x}] + 2a \quad (40)$$

- **Minimum mean squared error (MMSE):** la acción óptima, a^* , debe satisfacer que la derivada del riesgo sea nula, por lo que consiste en escoger la media a posteriori

$$\pi(\mathbf{x}) = \mathbb{E}[h \mid \mathbf{x}] = \int h p(h \mid \mathbf{x}) dh \quad (41)$$

5.1.5.2. Pérdida L1

- **Pérdida ℓ_1** : alternativa a L2 más *robusta* frente a outliers

$$\ell_1(h, a) = |h - a| \quad (42)$$

- El estimador óptimo es la *mediana a posteriori*:

$$a : \Pr(h < a \mid \mathbf{x}) = \Pr(h \geq a \mid \mathbf{x}) = 0.5 \quad (43)$$


5.1.5.3. Pérdida de Huber

- **Pérdida de Huber:** es otra alternativa a L2 *robusta*

$$\ell_{\delta}(h, a) = \begin{cases} \frac{r^2}{2} & \text{si } |r| \leq \delta \\ \delta|r| - \frac{\delta^2}{2} & \text{si } |r| > \delta \end{cases} \quad (r = h - a) \quad (44)$$

- Es L2 para errores menores que δ ; L1 para errores mayores

► *Il·lustración:*



5.1.6. Problemas de predicción probabilística

- ▶ **Predicción probabilística:** en lugar de etiquetas de clase o reales, las acciones consideradas son distribuciones de probabilidad
- ▶ Suponemos que
 - ▷ el “estado de la naturaleza” es una distribución $h = p(Y \mid x)$,
 - ▷ la acción es otra distribución $a = q(Y \mid x)$, y
 - ▷ queremos escoger una q que minimice $\mathbb{E}[\ell(p, q)]$ para un x dado

5.1.6.1. KL, entropía cruzada y log-pérdida

► *Divergencia de Kullback-Leibler (KL)*: muy popular

$$\mathbb{KL}(p||q) \triangleq \sum_{y \in \mathcal{Y}} p(y) \log \frac{p(y)}{q(y)} \quad (45)$$

- ▷ Puede extenderse a variables reales
- ▷ Cumple que $\mathbb{KL}(p||q) \geq 0$ con igualdad sii $p = q$
- ▷ Es asimétrica

► La KL en términos de entropía y entropía cruzada:

$$\mathbb{KL}(p||q) = -\mathbb{H}(p) + \mathbb{H}(p, q) \quad (46)$$

$$\mathbb{H}(p) \triangleq - \sum_{y \in \mathcal{Y}} p(y) \log p(y) \quad \textit{entropía} \quad (47)$$

$$\mathbb{H}(p, q) \triangleq - \sum_{y \in \mathcal{Y}} p(y) \log q(y) \quad \textit{entropía cruzada} \quad (48)$$

- Estimador óptimo: podemos ignorar $\mathbb{H}(p)$

$$q^*(Y \mid x) = \arg \min_q \mathbb{H}(p(Y \mid x), q(Y \mid x)) \quad (49)$$

- Si el verdadero estado es una distribución **one-hot**

$$h = p(Y \mid x) = \delta(Y = c) \quad (50)$$

obtenemos la **log-pérdida**:

$$\mathbb{H}(\delta(Y = c), q) = - \sum_{y \in \mathcal{Y}} \delta(y = c) \log q(y) \quad (51)$$

$$= - \log q(c) \quad (52)$$

5.1.6.2. Reglas de puntuación propias

- **Regla de puntuación propia:** pérdida ℓ que se minimiza **sii** la distribución estimada q coincide con la verdadera p ; esto es,

$$\ell(p, p) \leq \ell(p, q) \quad \text{con igualdad sii} \quad p = q \quad (53)$$

- La entropía cruzada es una regla de puntuación propia, pero el término $\log p(y)/q(y)$ **es muy sensible a errores en eventos raros**
- Una alternativa menos sensible es la **puntuación de Brier:**

$$\ell(p, q) \triangleq \frac{1}{C} \sum_{c=1}^C (q(y = c \mid x) - p(y = c \mid x))^2 \quad (54)$$