



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Teoría de la información

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

6.1	Entropía	1
6.1.1	Entropía para variables aleatorias discretas	2
6.1.2	Entropía cruzada	6
6.1.3	Entropía conjunta	7
6.1.4	Entropía condicional	9
6.1.5	Perplejidad	11

6.1. Entropía

- ▶ **Entropy:** la *entropía* de una distribución de probabilidad es una medida de incertidumbre, o falta de predecibilidad, asociada con una variable aleatoria extraída de dicha distribución
- ▶ **Contenido de información** de una fuente de datos: puede definirse en términos de entropía; por ejemplo
 - ▷ Observamos una secuencia de símbolos $X_n \sim p$ generados por una distribución p
 - ▷ Si p tiene alta entropía, es difícil predecir el valor de cada X_n y decimos que $\mathcal{D} = \{X_1, \dots, X_n\}$ tiene alto contenido informativo
 - ▷ Si p es una distribución degenerada con entropía mínima (nula), todos los X_n son idénticos y $\mathcal{D}$ no contiene mucha información

6.1.1. Entropía para variables aleatorias discretas

- *Entropía de una variable aleatoria discreta* X con distribución p sobre K estados:

$$\mathbb{H}(X) \triangleq - \sum_k p(X = k) \log_2 p(X = k) \quad (1)$$

$$= - \mathbb{E}_X[\log p(X)] \quad (2)$$

- *bits*: unidades si usamos logaritmos binarios
- *nats*: unidades si usamos logaritmos naturales

- *Ejemplo*: si $X \in \{1, \dots, 5\}$ con $p = [0.25, 0.25, 0.2, 0.15, 0.15]$

$$\mathbb{H}(X) = -2\frac{1}{4} \log_2 \frac{1}{4} - \frac{1}{5} \log_2 \frac{1}{5} - 2\frac{3}{20} \log_2 \frac{3}{20} \quad (3)$$

$$= -\frac{1}{2}(-2) + \frac{1}{5} \log_2 5 - \frac{3}{10}(\log_2 3 - \log_2 20) \quad (4)$$

$$= 1 + 0.2 \cdot 2.3219 - 0.3(1.5850 - 4.3219) \quad (5)$$

$$= 2.29 \text{ bits} \quad (6)$$

- **Distribución de máxima entropía:** es la uniforme

$$p(X = k) = \frac{1}{K} \quad \text{para } X \text{ } K\text{-aria} \quad (7)$$

con entropía

$$\mathbb{H}(X) = - \sum_{k=1}^K \frac{1}{K} \log \frac{1}{K} = - \log \frac{1}{K} = \log K \quad (8)$$

- **Distribución de mínima entropía:** es cualquier función delta que asigne toda la masa en un estado k^*

$$p(X = k) = \delta(X = x^*) \quad (9)$$

con entropía

$$\mathbb{H}(X) = -1 \log 1 - \sum_{k \neq k^*} 0 \log 0 = 0 \quad (10)$$

► **Función entropía binaria:** en el caso de **variables aleatorias binarias**, $X \in \{0, 1\}$,

$$p(X = x) = \begin{cases} \theta & \text{si } x = 1 \\ 1 - \theta & \text{si } x = 0 \end{cases} \quad (11)$$

la entropía es


$$\mathbb{H}(\theta) \triangleq \mathbb{H}(X) \quad (12)$$

$$= -[p(X = 1) \log_2 p(X = 1) + p(X = 0) \log_2 p(X = 0)] \quad (13)$$

$$= -[\theta \log_2 \theta + (1 - \theta) \log_2 (1 - \theta)] \quad (14)$$

► $\mathbb{H}(\theta)$ alcanza su máximo de 1 bit con $\theta = 0.5$

► $H(\theta) = -[\theta \log_2 \theta + (1 - \theta) \log_2(1 - \theta)]$ en función de $p(X = 1) = \theta$



6.1.2. Entropía cruzada

- *Entropía cruzada* entre una distribución p y otra q :

$$\mathbb{H}(p, q) \triangleq - \sum_k p_k \log q_k \quad (15)$$

- Alcanza su mínimo con $q = p$, cumpliéndose $\mathbb{H}(p, p) = \mathbb{H}(p)$

6.1.3. Entropía conjunta

- **Entropía conjunta** de dos variables aleatorias X e Y :

$$\mathbb{H}(X, Y) = - \sum_{x,y} p(x, y) \log_2 p(x, y) \quad (16)$$

- *Ejemplo:* $X(n) = 1$ si n es par, $Y(n) = 1$ si n es primo, n de 1 a 8

n	1	2	3	4	5	6	7	8
X	0	1	0	1	0	1	0	1
Y	0	1	1	0	1	0	1	0

$p(X, Y)$	$Y = 0$	$Y = 1$
$X = 0$	$1/8$	$3/8$
$X = 1$	$3/8$	$1/8$

$$\mathbb{H}(X, Y) = -2\frac{1}{8} \log_2 \frac{1}{8} - 2\frac{3}{8} \log_2 \frac{3}{8} \quad (17)$$

$$= -0.25(-3) - 0.75(-1.4150) = 1.81 \text{ bits} \quad (18)$$

► **Cota superior:**

$$\mathbb{H}(X, Y) \leq \mathbb{H}(X) + \mathbb{H}(Y) \quad (19)$$

▷ *Ejemplo (cont.):* $\mathbb{H}(X) = \mathbb{H}(Y) = 1$ (marginales uniformes)

$$1.81 = \mathbb{H}(X, Y) \leq \mathbb{H}(X) + \mathbb{H}(Y) = 2 \quad (20)$$

▷ Si X e Y son independientes, $\mathbb{H}(X, Y) = \mathbb{H}(X) + \mathbb{H}(Y)$

► **Cota inferior:** si X determina Y , $\mathbb{H}(X, Y) = \mathbb{H}(X)$; luego

$$\mathbb{H}(X, Y) \geq \max(\mathbb{H}(X), \mathbb{H}(Y)) \geq 0 \quad (21)$$

▷ La combinación de variables no reduce la entropía, esto es, no podemos reducir la incertidumbre añadiendo más variables al problema; debemos observar más datos

► **Extensión a n variables:** inmediata

6.1.4. Entropía condicional

- **Entropía condicional** de Y dado X : incertidumbre sobre Y tras observar X , promediado sobre todos los valores de X

$$\mathbb{H}(Y \mid X) \triangleq \mathbb{E}_{p(X)}[\mathbb{H}(p(Y \mid X))] \quad (22)$$

$$= \sum_x p(x) \mathbb{H}(p(Y \mid X = x)) \quad (23)$$

$$= - \sum_x p(x) \sum_y p(y \mid x) \log p(y \mid x) \quad (24)$$

$$= - \sum_{x,y} p(x, y) \log p(y \mid x) \quad (25)$$

$$= - \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)} \quad (26)$$

$$= - \sum_{x,y} p(x, y) \log p(x, y) - \sum_x p(x) \log \frac{1}{p(x)} \quad (27)$$

$$= \mathbb{H}(X, Y) - \mathbb{H}(X) \quad (28)$$

- ▶ Si Y es función determinista de X , $\mathbb{H}(Y | X) = 0$
- ▶ Dado que $\mathbb{H}(Y | X) + \mathbb{H}(X) = \mathbb{H}(X, Y) \leq \mathbb{H}(X) + \mathbb{H}(Y)$,

$$\mathbb{H}(Y | X) \leq \mathbb{H}(Y) \quad (29)$$

con igualdad sii X e Y son independientes

- ▶ *Regla de la cadena para la entropía:* para dos variables

$$\mathbb{H}(X_1, X_2) = \mathbb{H}(X_1) + \mathbb{H}(X_2 | X_1) \quad (30)$$

En general, para n variables,

$$\mathbb{H}(X_1, X_2, \dots, X_n) = \sum_{i=1}^n \mathbb{H}(X_i | X_1, \dots, X_{i-1}) \quad (31)$$

6.1.5. Perplejidad

- **Perplejidad** de una distribución de probabilidad discreta p :

$$\text{perplexity}(p) \triangleq 2^{\mathbb{H}(p)} \quad (32)$$

- Se suele interpretar como una medida de (neg-)predecibilidad:
 - ▷ La predecibilidad máxima se alcanza con una distribución de entropía nula, por lo que la perplejidad es uno

$$\text{perplexity}(p) = 2^0 = 1 \quad (33)$$

- ▷ La predecibilidad mínima se da cuando p es uniforme, con entropía $\log_2 K$ (sobre K estados), por lo que la perplejidad es K

$$\text{perplexity}(p) = 2^{\log_2 K} = K \quad (34)$$

► *Perplejidad conjunta con la empírica:*

- Sea la distribución empírica de los datos $\mathcal{D}$

$$p_{\mathcal{D}}(x \mid \mathcal{D}) = \frac{1}{N} \sum_{n=1}^N \delta_{x_n}(x) \quad (35)$$

- Podemos medir cómo de bien p predice $\mathcal{D}$ calculando:

$$\text{perplexity}(p_{\mathcal{D}}, p) \triangleq 2^{\mathbb{H}(p_{\mathcal{D}}, p)} \quad (36)$$

► *Aplicación a modelado del lenguaje estadístico:*

- Sean $\mathcal{D}$ un único documento x de longitud N y p una unigrama
- La entropía cruzada es

$$\mathbb{H}(p_{\mathcal{D}}, p) = -\frac{1}{N} \sum_{n=1}^N \log_2 p(x_n) \quad (37)$$

- *Entropía cruzada exponenciada:*

$$\text{perplexity}(p_{\mathcal{D}}, p) = 2^{\mathbb{H}(p_{\mathcal{D}}, p)} = 2^{-\frac{1}{N} \log_2 \prod_{n=1}^N p(x_n)} = \sqrt[N]{\prod_n \frac{1}{p(x_n)}} \quad (38)$$

- Con n -gramas puede verse como un *factor de ramificación* que indica cuántas palabras en promedio siguen a una cualquiera