



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Algebra lineal

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

7.1	Introducción	1
7.1.1	Notación	1
7.1.1.1	Vectores	1
7.1.1.2	Matrices	2
7.1.1.3	Tensores	4
7.1.2	Espacios vectoriales	6
7.1.2.1	Suma y escalado de vectores	6
7.1.2.2	Independencia lineal, span y base	7
7.1.2.3	Transformaciones lineales y matrices	10
7.1.2.4	Rango y espacio nulo de una matriz	12
7.1.2.5	Proyección lineal	14
7.1.3	Normas vectoriales y matriciales	15
7.1.3.1	Normas vectoriales	15
7.1.3.2	Normas matriciales	17
7.1.4	Propiedades de una matriz	20
7.1.4.1	Traza de una matriz cuadrada	20
7.1.4.2	Determinante de una matriz cuadrada	22
7.1.4.3	Rango de una matriz	24

7.1.4.4	Números de condición	25
7.1.5	Tipos de matrices especiales	26
7.1.5.1	Matriz diagonal	26
7.1.5.2	Matrices triangulares	29
7.1.5.3	Matrices definidas positivas	30
7.1.5.4	Matrices ortogonales	35
7.2	Multiplicación de matrices	38
7.2.1	Productos vector-vector	39
7.2.2	Productos matriz-vector	40
7.2.3	Productos matriz-matriz	42
7.2.4	Aplicación: manipulación de matrices de datos	48
7.2.4.1	Suma de trozos de la matriz	48
7.2.4.2	Escalado de filas y columnas de una matriz	50
7.2.4.3	Suma de cuadrados y matriz de dispersión	52
7.2.4.4	Matriz de Gram	54
7.2.4.5	Matriz de distancias	55
7.3	Inversión de matrices	56
7.3.1	Inversa de una matriz cuadrada	56
7.4	Descomposición en valores propios (EVD)	58

7.4.1	Conceptos básicos	58
7.4.2	Diagonalización	62
7.4.3	Valores y vectores propios de matriz simétrica	63
7.4.3.1	Comprobación de definición positiva	65
7.4.4	Geometría de las formas cuadráticas	66
7.4.5	Estandarización y blanqueado de datos	68
7.4.6	Método de las potencias	72
7.4.7	Deflación	74
7.4.8	Optimización de formas cuadráticas	75
7.5	Descomposición en valores singulares (SVD)	76
7.5.1	Conceptos básicos	76
7.5.2	Conexión entre la SVD y la EVD	78
7.5.3	Pseudoinversa	80
7.5.5	SVD truncada	83
7.8	Cáculo matricial	87
7.8.1	Derivadas	87
7.8.2	Gradientes	89
7.8.3	Derivada direccional	90
7.8.5	La Jacobiana	91

7.8.5.1	Multiplicación de Jacobianas y vectores	92
7.8.5.2	Jacobiana de una composición	93
7.8.6	Hessiana	94
7.8.7	Gradientes de funciones comunes	95
7.8.7.1	Funciones de escalar a escalar	95
7.8.7.2	Funciones de vector a escalar	96
7.8.7.3	Funciones de matriz a escalar	97

7.1. Introducció

7.1.1. Notació

7.1.1.1. Vectores

► *Vector (columna)* $x \in \mathbb{R}^n$:

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad (1)$$

► Vector de todo unos y todo ceros: $\mathbf{1} \quad \mathbf{0}$

► *Vector unitario* e_i o *one-hot*: todo 0 salvo un 1 en la entrada i

$$e_i = (0, \dots, 0, 1, 0, \dots, 0) \quad (2)$$

7.1.1.2. Matrices

► **Matriz** $\mathbf{A} \in \mathbb{R}^{m \times n}$: **cuadrada** si $m = n$

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \quad (3)$$

► A_{ij} o $A_{i,j}$: entrada de la i -ésima fila y j -ésima columna

► $\mathbf{A}_{i,:}$ y $\mathbf{A}_{:,j}$: fila i -ésima y columna j -ésima

► Matriz vista por filas:

$$\mathbf{A} = [\mathbf{A}_{1,:} \quad \mathbf{A}_{2,:} \quad \cdots \quad \mathbf{A}_{n,:}] \quad (4)$$

► Matriz vista por columnas:

$$\mathbf{A} = [\mathbf{A}_{:,1}, \mathbf{A}_{:,2}, \dots, \mathbf{A}_{:,n}] \quad (5)$$

► **Transpuesta de** $A \in \mathbb{R}^{m \times n}$: $A^t \in \mathbb{R}^{n \times m}$

$$(A^t)_{ij} = A_{ji} \quad (6)$$

▷ Propiedades:

$$(A^t)^t = A \quad (7)$$

$$(AB)^t = B^t A^t \quad (8)$$

$$(A + B)^t = A^t + B^t \quad (9)$$


► **Simétrica:** matriz cuadrada A tal que $A = A^t$

▷ S^n denota todas las matrices simétricas de talla n

7.1.1.3. Tensores


- **Tensor:** generalización de matriz a tres o más dimensiones

Vector




$$\mathbb{R}^{64}$$

Matrix



$$\mathbb{R}^{8 \times 8}$$

Tensor



$$\mathbb{R}^{4 \times 4 \times 4}$$

- **Orden o rango:** dimensiones (concepto distinto en matrices)

► *Reformato:*

- De matriz en vector (ver figura anterior)


$$\text{vec}(\mathbf{A}) = [\mathbf{A}_{:,1}; \mathbf{A}_{:,2}; \cdots; \mathbf{A}_{:,n}] \in \mathbb{R}^{mn \times 1} \quad (10)$$

- De vector en matriz, por filas o columnas:


⇒ *Row-major order:* Python, C++

⇒ *Column-major order:* Julia, Octave, R, Fortran

Row-major order




Column-major order



7.1.2. Espacios vectoriales

7.1.2.1. Suma y escalado de vectores

- **Espacio vectorial:** conjunto de **vectores**, que pueden sumarse entre ellos y escalarse (multiplicarse) por **escalares** (números)
- *Ejemplo:* $v + w$ y $v + 2w$



7.1.2.2. Independencia lineal, span y base

► *Independencia lineal:*

- Un conjunto de vectores $\{x_1, \dots, x_n\}$ es *(linealmente) independiente* si ninguno de ellos puede representarse como combinación lineal del resto
- Por el contrario, un vector que sí puede representarse como combinación lineal del resto, es *(linealmente) dependiente*
- *Ejemplo:* si

$$x_n = \sum_{i=1}^{n-1} x_i \quad (11)$$

para algunos $\{\alpha_1, \dots, \alpha_{n-1}\}$,

→ entonces x_n es dependiente de $\{x_1, \dots, x_{n-1}\}$;

→ si no, x_n es independiente de $\{x_1, \dots, x_{n-1}\}$

► *Span o espacio generado:*

- El **span** de un conjunto de vectores $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ es el conjunto de todos los vectores que puede expresarse como combinación lineal de los mismos,

$$\text{span}(\{\mathbf{x}_1, \dots, \mathbf{x}_n\}) \triangleq \left\{ \mathbf{v} : \mathbf{v} = \sum_{i=1}^n \alpha_i \mathbf{x}_i, \alpha_i \in \mathbb{R} \right\} \quad (12)$$

- Si $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ es un conjunto de n vectores linealmente independientes, donde cada $\mathbf{x}_i \in \mathbb{R}^n$, entonces

$$\text{span}(\{\mathbf{x}_1, \dots, \mathbf{x}_n\}) = \mathbb{R}^n \quad (13)$$

► **Base:**


- Una **base** $\mathcal{B}$ es un conjunto de vectores linealmente independientes que genera el espacio completo

$$\text{span}(\mathcal{B}) = \mathbb{R}^n \quad (14)$$

- **Base estándar o canónica:** usa los **vectores canónicos**

$$\mathcal{B} = \{e_1 = (1, 0, \dots, 0), \dots, e_n = (0, 0, \dots, 1)\} \quad (15)$$

- **Ejemplo:** base canónica de $\mathbb{R}^2$ (e_1 y e_2)



7.1.2.3. Transformaciones lineales y matrices

► *Transformación lineal:*

▷ Es cualquier función $f : \mathcal{V} \rightarrow \mathcal{W}$ tal que, para todo $\boldsymbol{v}, \boldsymbol{w} \in \mathcal{V}$

$$f(\boldsymbol{v} + \boldsymbol{w}) = f(\boldsymbol{v}) + f(\boldsymbol{w}) \quad (16)$$

$$f(a\boldsymbol{v}) = af(\boldsymbol{v}) \quad (17)$$

▷ Una vez hemos escogido la base de $\mathcal{V}$, una transformación lineal $f : \mathcal{V} \rightarrow \mathcal{W}$ queda totalmente determinada a partir de las imágenes de los vectores base pues cualquier vector de $\mathcal{V}$ puede expresarse únicamente como una combinación lineal de ellos

► Representación matricial:

- Sean $\mathcal{V} = \mathbb{R}^n$ y $\mathcal{W} = \mathbb{R}^m$
- Podemos calcular $f(\mathbf{v}_i) \in \mathbb{R}^m$ para cada vector base de $\mathcal{V}$ y guardarlos en las columnas de una matriz $\mathbf{A}$, $m \times n$
- Así, podemos calcular $\mathbf{y} = f(\mathbf{x}) \in \mathbb{R}^m$ para cualquier $\mathbf{x} \in \mathbb{R}^n$:

$$\mathbf{y} = \left(\sum_{j=1}^n a_{1j}x_j, \dots, \sum_{j=1}^n a_{mj}x_j \right) = \mathbf{A} \mathbf{x} \quad (18)$$

- Si la función es invertible:

$$\mathbf{x} = \mathbf{A}^{-1} \mathbf{y} \quad (19)$$

7.1.2.4. Rango y espacio nulo de una matriz


- ▶ Veamos la matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ como conjunto de m vectores en $\mathbb{R}^n$
- ▶ **Rango, espacio columna o imagen** de $\mathbf{A}$: espacio generado por las columnas de $\mathbf{A}$

$$\text{range}(\mathbf{A}) \triangleq \{\mathbf{v} \in \mathbb{R}^m : \mathbf{v} = \mathbf{A}\mathbf{x}, \mathbf{x} \in \mathbb{R}^n\} \quad (20)$$

- ▶ **Espacio nulo o núcleo** de $\mathbf{A} \in \mathbb{R}^{m \times n}$: conjunto de todos los vectores que se transforman en el vector nulo

$$\text{nullspace}(\mathbf{A}) \triangleq \{\mathbf{x} \in \mathbb{R}^n : \mathbf{A}\mathbf{x} = \mathbf{0}\} \quad (21)$$

- Ilustración del espacio nulo y rango de una matriz $A \in \mathbb{R}^{m \times n}$:



7.1.2.5. Proyección lineal

- **Proyección** de $\mathbf{y} \in \mathbb{R}^m$ en el span de $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, $\mathbf{x}_i \in \mathbb{R}^n$, es el vector $\mathbf{v} \in \text{span}(\{\mathbf{x}_1, \dots, \mathbf{x}_n\})$ más próximo a $\mathbf{y}$ en norma Euclídea

$$\text{Proj}(\mathbf{y}; \{\mathbf{x}_1, \dots, \mathbf{x}_n\}) = \arg \min_{\mathbf{v} \in \text{span}(\{\mathbf{x}_1, \dots, \mathbf{x}_n\})} \|\mathbf{y} - \mathbf{v}\|_2 \quad (22)$$

- Dada una matriz (de rango completo) $\mathbf{A} \in \mathbb{R}^{m \times n}$ con $m \geq n$, la proyección de $\mathbf{y} \in \mathbb{R}^m$ en el rango de $\mathbf{A}$ es

$$\text{Proj}(\mathbf{y}; \mathbf{A}) = \arg \min_{\mathbf{v} \in \mathcal{R}(\mathbf{A})} \|\mathbf{v} - \mathbf{y}\|_2 \quad (23)$$

$$= \mathbf{A}(\mathbf{A}^t \mathbf{A})^{-1} \mathbf{A}^t \mathbf{y} \quad (24)$$

7.1.3. Normas vectoriales y matriciales

7.1.3.1. Normas vectoriales

► **Norma** de un vector x : $\|x\|$

▷ Informalmente, mide la “longitud” de x

▷ Formalmente, es cualquier función $f \in \mathbb{R}^n \rightarrow \mathbb{R}$ tal que:

→ $f(x) \geq 0$ para todo $x \in \mathbb{R}^n$ (no negativa)

→ $f(x) = 0$ sii $x = 0$

→ $f(tx) = |t|f(x) \quad \forall x \in \mathbb{R}^n$ (homogeneidad absoluta)

→ $f(x + y) \leq f(x) + f(y) \quad \forall x, y \in \mathbb{R}^n$ (desigualdad triangular)

► ***p*-norma o L_p :** para todo número real $p \geq 1$

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p} \quad (25)$$

► ***2*-norma, Euclídea o L_2 :**

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{\mathbf{x}^t \mathbf{x}} \quad (26)$$

► ***1*-norma, taxicab, Manhattan o L_1 :**

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i| \quad (27)$$

► ***Max*-norma, infinito o L_∞ :**

$$\|\mathbf{x}\|_\infty = \max_i |x_i| \quad (28)$$

► ***0*-norma:** es una pseudo-norma ya que no es homogénea

$$\|\mathbf{x}\|_0 = \sum_{i=1}^n \mathbb{1}(|x_i| > 0) \stackrel{0^0 \triangleq 0}{=} \sum_{i=1}^n x_i^0 \quad (29)$$

7.1.3.2. Normas matriciales

- Interpretamos $\mathbf{A} \in \mathbb{R}^{m \times n}$ como una función lineal $f(\mathbf{x}) = \mathbf{A}\mathbf{x}$
- **Norma de $\mathbf{A}$ inducida (por la p -norma vectorial):** máximo alargamiento de f aplicada a un vector unitario

$$\|\mathbf{A}\|_p = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|_p}{\|\mathbf{x}\|_p} \quad (30)$$

$$= \max_{\|\mathbf{x}\|_p=1} \|\mathbf{A}\mathbf{x}\|_p \quad (31)$$

- Típicamente $p = 2$, en cuyo caso:

$$\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^t \mathbf{A})} = \sigma_{\max}(\mathbf{A}) \quad (32)$$

donde $\sigma_{\max}(\mathbf{A})$ es el máximo valor singular de $\mathbf{A}$

► **Norma nuclear o traza:**

$$\|\mathbf{A}\|_* = \text{tr}(\sqrt{\mathbf{A}^t \mathbf{A}}) = \sum_i \sigma_i = \sum_i |\sigma_i| = \|\boldsymbol{\sigma}\|_1 \quad (33)$$

▷ Usada como regularizador, favorece que muchos valores singulares sean cero y resulta en una matriz de rango reducido

► ***p*-norma de Schatten:** con $p \geq 1$, generaliza la nuclear

$$\|\mathbf{A}\|_p = \left(\sum_i \sigma_i^p(\mathbf{A}) \right)^{1/p} \quad (34)$$

► **Norma matricial definida en términos de una vectorial:**

▷ Asumimos $\|\mathbf{A}\| = \|\text{vec}(\mathbf{A})\|$

▷ **Norma de Frobenius:** a partir la 2-norma vectorial

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2} = \sqrt{\text{tr}(\mathbf{A}^t \mathbf{A})} = \|\text{vec}(\mathbf{A})\|_2 \quad (35)$$

▷ Si $\mathbf{A}$ es costosa de evaluar, pero $\mathbf{A}\mathbf{v}$ no (para un vector aleatorio $\mathbf{v}$), podemos usar una aproximación estocástica a la norma de Frobenius con el estimador traza de Hutchinson:

$$\|\mathbf{A}\|_F^2 = \text{tr}(\mathbf{A}^t \mathbf{A}) = \mathbb{E}[\mathbf{v}^t \mathbf{A}^t \mathbf{A} \mathbf{v}] = \mathbb{E}[\|\mathbf{A}\mathbf{v}\|_2^2] \quad (36)$$

donde $\mathbf{v} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

7.1.4. Propiedades de una matriz

7.1.4.1. Traza de una matriz cuadrada

► **Traza** de una matriz cuadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$

$$\text{tr}(\mathbf{A}) \triangleq \sum_{i=1}^n A_{ii} \quad (37)$$

► Propiedades: $c \in \mathbb{R} \quad \mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$

$$\text{tr}(\mathbf{A}) = \text{tr}(\mathbf{A}^t) \quad (38)$$

$$\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B}) \quad (39)$$

$$\text{tr}(c\mathbf{A}) = c \text{tr}(\mathbf{A}) \quad (40)$$

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}) \quad (41)$$

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i \quad (\text{suma de valores propios}) \quad (42)$$

► **Propiedad de la permutación cíclica:** $\mathbf{ABC}$ cuadrada

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}) \quad (43)$$

► **Truco de la traza:**

$$\mathbf{x}^t \mathbf{A} \mathbf{x} = \text{tr}(\mathbf{x}^t \mathbf{A} \mathbf{x}) = \text{tr}(\mathbf{x} \mathbf{x}^t \mathbf{A}) \quad (44)$$

► **Estimador traza de Hutchinson:**

▷ Supongamos que $\mathbf{A}$ es costosa de evaluar, pero no $\mathbf{A} \mathbf{v}$

▷ Sea $\mathbf{v}$ un vector aleatorio tal que $\mathbb{E}[\mathbf{v} \mathbf{v}^t] = \mathbf{I}$

▷ Hutchinson es una aproximación Monte Carlo a $\text{tr}(\mathbf{A})$:

$$\text{tr}(\mathbf{A}) = \text{tr}(\mathbf{A} \mathbb{E}[\mathbf{v} \mathbf{v}^t]) \quad (45)$$

$$= \mathbb{E}[\text{tr}(\mathbf{A} \mathbf{v} \mathbf{v}^t)] \quad (46)$$

$$= \mathbb{E}[\text{tr}(\mathbf{v}^t \mathbf{A} \mathbf{v})] \quad (47)$$

7.1.4.2. Determinante de una matriz cuadrada

- El determinante de una matriz cuadrada $\mathbf{A}$, $|\mathbf{A}|$, mide cuánto cambia un volumen unitario visto como una transformación lineal
- Propiedades: $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$

$$|\mathbf{A}| = |\mathbf{A}^t| \quad (48)$$

$$|c\mathbf{A}| = c^n |\mathbf{A}| \quad (49)$$

$$|\mathbf{AB}| = |\mathbf{A}||\mathbf{B}| \quad (50)$$

$$|\mathbf{A}| = 0 \text{ si } \mathbf{A} \text{ es singular} \quad (51)$$

$$|\mathbf{A}^{-1}| = \frac{1}{|\mathbf{A}|} \text{ si } \mathbf{A} \text{ es no singular} \quad (52)$$

$$|\mathbf{A}| = \prod_{i=1}^n \lambda_i \quad (\{\lambda_i\} \text{ valores propios de } \mathbf{A}) \quad (53)$$

► Cálculo mediante la descomposición de Cholesky:

▷ Si $\mathbf{A}$ es definida positiva, podemos escribir

$$\mathbf{A} = \mathbf{L}\mathbf{L}^t \quad (54)$$

donde $\mathbf{L}$ es la matriz triangular inferior de Cholesky

▷ Determinante de $\mathbf{A}$ en función de $\mathbf{L}$:

$$|\mathbf{A}| = |\mathbf{L}||\mathbf{L}^t| = |\mathbf{L}|^2 = \left(\prod_i L_{ii} \right)^2 \quad (55)$$

▷ Logaritmo del determinante de $\mathbf{A}$ en función de $\mathbf{L}$:

$$\log|\mathbf{A}| = 2 \log|\mathbf{L}| = 2 \log \prod_i L_{ii} = 2 \operatorname{tr}(\log(\operatorname{diag}(\mathbf{L}))) \quad (56)$$

7.1.4.3. Rango de una matriz

► **Rango de una matriz $\mathbf{A}$:** $\text{rank}(\mathbf{A})$, dimensión del espacio generado por las columnas o filas de $\mathbf{A}$ (pues coincide para toda $\mathbf{A}$)

► Propiedades: $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$ $\mathbf{C} \in \mathbb{R}^{n \times p}$

$$\text{rank}(\mathbf{A}) \leq \min(m, n) \quad (57)$$

$$\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{A}^t) = \text{rank}(\mathbf{A}^t \mathbf{A}) = \text{rank}(\mathbf{A} \mathbf{A}^t) \quad (58)$$

$$\text{rank}(\mathbf{A} \mathbf{C}) \leq \min(\text{rank}(\mathbf{A}), \text{rank}(\mathbf{C})) \quad (59)$$

$$\text{rank}(\mathbf{A} + \mathbf{B}) \leq \text{rank}(\mathbf{A}) + \text{rank}(\mathbf{B}) \quad (60)$$

► Si $\text{rank}(\mathbf{A}) = \min(m, n)$, $\mathbf{A}$ de **rango completo**; si no, **deficiente**

► Una matriz cuadrada es **invertible** sii es de rango completo

7.1.4.4. Números de condición

- El *número de condición* de una matriz $\mathbf{A}$ (con respecto a una norma dada) mide la estabilidad numérica de los cálculos con $\mathbf{A}$:

$$\kappa(\mathbf{A}) \triangleq \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \quad (61)$$

- Se puede comprobar que $\kappa(\mathbf{A}) \geq 1$
- $\mathbf{A}$ està *bien condicionada* si $\kappa(\mathbf{A}) \approx 1$; si no, *mal condicionada*
- Un número de condición grande indica que $\mathbf{A}$ es (casi-)singular
- Con la norma ℓ_2 : σ valor singular λ valor propio

$$\kappa(\mathbf{A}) = \frac{\sigma_{\max}}{\sigma_{\min}} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} \quad (62)$$

7.1.5. Tipos de matrices especiales

7.1.5.1. Matriz diagonal

► **Matriz diagonal:** todos los elementos fuera de la diagonal son 0

▷ Notación:

$$\mathbf{D} = \text{diag}(d_1, \dots, d_n) \quad (63)$$

con

$$\mathbf{D} = \begin{pmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{pmatrix} \quad (64)$$

- **Matriz identidad:** $\mathbf{I} \in \mathbb{R}^{n \times n}$, matriz diagonal con unos en la diagonal (y ceros fuera)

$$\mathbf{I} = \text{diag}(1, \dots, 1) \quad (65)$$

- ▷ Propiedad: para toda $\mathbf{A} \in \mathbb{R}^{n \times n}$

$$\mathbf{A}\mathbf{I} = \mathbf{A} = \mathbf{I}\mathbf{A} \quad (66)$$

- Extracción del vector diagonal de una matriz:

$$\mathbf{d} = \text{diag}(\mathbf{D}) \quad (67)$$

- Construcción de una matriz diagonal a partir de un vector:

$$\mathbf{D} = \text{diag}(\mathbf{d}) \quad (68)$$

- **Matriz diagonal por bloques:**

$$\begin{pmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \mathbf{B} \end{pmatrix} \quad (69)$$

► **Matriz banda-diagonal:** matriz con elementos no nulos en una banda de ancho k centrada en la diagonal

▷ *Ejemplo:* matriz tridiagonal 6×6 :

$$\begin{bmatrix} A_{11} & A_{12} & 0 & \dots & \dots & 0 \\ A_{21} & A_{22} & A_{23} & \ddots & \ddots & 0 \\ 0 & A_{32} & A_{33} & A_{34} & \ddots & \vdots \\ \vdots & \ddots & A_{43} & A_{44} & A_{45} & 0 \\ \vdots & \ddots & \ddots & A_{54} & A_{55} & A_{56} \\ 0 & \dots & \dots & 0 & A_{65} & A_{66} \end{bmatrix} \quad (70)$$

7.1.5.2. Matrices triangulares

- ▶ *Matriz triangular superior (inferior):* solo tiene elementos no nulos en la diagonal y por encima (debajo) de la misma
- ▶ Los valores propios de una matriz triangular estan en su diagonal
- ▶ Si A es triangular:

$$|A| = \prod_i A_{ii} \quad (71)$$

7.1.5.3. Matrices definidas positivas

► *Forma cuadrática:* $\mathbf{A} \in \mathbb{R}^{n \times n}$ $\mathbf{x} \in \mathbb{R}^n$

$$\mathbf{x}^t \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j \quad (72)$$

► Asumimos que $\mathbf{A}$ es simétrica; si no, puede simetrizarse:

$$\mathbf{x}^t \mathbf{A} \mathbf{x} = (\mathbf{x}^t \mathbf{A} \mathbf{x})^t = ((\mathbf{A} \mathbf{x})^t \mathbf{x}) = \mathbf{x}^t \mathbf{A}^t \mathbf{x} \quad (73)$$

Por tanto:

$$\mathbf{x}^t \mathbf{A} \mathbf{x} = \frac{1}{2} \mathbf{x}^t \mathbf{A} \mathbf{x} + \frac{1}{2} \mathbf{x}^t \mathbf{A}^t \mathbf{x} \quad (74)$$

$$= \mathbf{x}^t \left(\frac{1}{2} \mathbf{A} + \frac{1}{2} \mathbf{A}^t \right) \mathbf{x} \quad (75)$$

► Sea $A \in \mathbb{S}^n$ una matriz simétrica de talla n

► A es **definida positiva** ($A \succ 0$ o $A > 0$) sii

$$x^t A x > 0 \quad \text{para todo } x \text{ no nulo} \quad (76)$$

► A es **semi-definida positiva** ($A \succeq 0$ o $A \geq 0$) sii

$$x^t A x \geq 0 \quad \text{para todo } x \quad (77)$$

► A es **definida negativa** ($A \prec 0$ o $A < 0$) sii

$$x^t A x < 0 \quad \text{para todo } x \text{ no nulo} \quad (78)$$

► A es **semi-definida negativa** ($A \preceq 0$ o $A \leq 0$) sii

$$x^t A x \leq 0 \quad \text{para todo } x \quad (79)$$

► A es **indefinida** sii no es semi-definida positiva ni semi-definida negativa

► **A y $-A$:**

- ▷ Si **A** es definida positiva, $-A$ es definida negativa y viceversa
- ▷ Si **A** es semi-definida positiva, $-A$ es semi-definida negativa y viceversa
- ▷ Si **A** es indefinida, $-A$ también lo es

► **A es definida positiva sii sus valores propios son positivos**

► **En 2d:**

$$\begin{pmatrix} a & b \\ b & d \end{pmatrix} \text{ es definida positiva } \text{ sii } a > 0, d > 0 \text{ y } ad > b^2 \quad (80)$$

▷ *Ejemplo:*

$$\begin{pmatrix} 1 & -3/2 \\ -3/2 & 4 \end{pmatrix} \text{ es definida positiva} \quad (81)$$

► *Matriz diagonalmente dominante:*

- **A** es *diagonalmente dominante* si

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \text{para todo } i \quad (82)$$

- Si **A** es diagonalmente dominante y los elementos de la diagonal son positivos, entonces es definida positiva
- Si **A** es diagonalmente dominante pero no todos los elementos diagonales son positivos, puede no ser definida positiva; p.e.

$$\mathbf{A} = \begin{pmatrix} -3 & 1 \\ 1 & 2 \end{pmatrix} \quad (83)$$

- Si **A** es definida positiva, puede que no sea diagonalmente dominante; por ejemplo

$$\mathbf{A} = \begin{pmatrix} 1 & -3/2 \\ -3/2 & 4 \end{pmatrix} \quad (84)$$

- ▶ Si todos los elementos de $\mathbf{A}$ son positivos, $\mathbf{A}$ no es necesariamente definida positiva; por ejemplo

$$\mathbf{A} = \begin{pmatrix} 4 & 3 \\ 3 & 2 \end{pmatrix} \quad (85)$$

- ▶ Si $\mathbf{A}$ es definida positiva, los elementos de $\mathbf{A}$ no son necesariamente todos positivos; por ejemplo

$$\mathbf{A} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} \quad (86)$$

- ▶ **Matriz de Gram:** dada $\mathbf{A} \in \mathbb{R}^{m \times n}$, no necesariamente simétrica ni siquiera cuadrada, la matriz de Gram es

$$\mathbf{G} = \mathbf{A}^t \mathbf{A} \quad (87)$$

- ▷ En general, $\mathbf{G}$ es semi-definida positiva
- ▷ Si $m \geq n$ y $\mathbf{A}$ es de rango completo, $\mathbf{G}$ es definida positiva

7.1.5.4. Matrices ortogonales

► *Vectores:*

- Dos vectores $x, y \in \mathbb{R}^n$ son *ortogonales* si $x^t y = 0$
- Un vector $x \in \mathbb{R}^n$ está *normalizado* si $\|x\|_2 = 1$
- Un conjunto de vectores ortogonales dos a dos y normalizados se denomina *ortonormal*

► *Matriz ortogonal:* $U \in \mathbb{R}^{n \times n}$ es ortogonal si el conjunto de todas sus columnas (y el de sus filas) es ortonormal

- De la definición de ortogonalidad y normalidad se sigue que

$$U \text{ es ortogonal} \quad \text{sii} \quad U^t U = I = U U^t \quad (88)$$

- Equivalentemente:

$$U \text{ es ortogonal} \quad \text{sii} \quad U^t = U^{-1} \quad (89)$$

- *Ejemplo:* matriz de rotación 3d de α grados (en sentido antihorario) alrededor del eje z

$$\mathbf{R}(\alpha) = \begin{pmatrix} \cos(\alpha) & -\sin(\alpha) & 0 \\ \sin(\alpha) & \cos(\alpha) & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad (90)$$

► Con $\alpha = 45$:

$$\mathbf{R}(45) = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad (91)$$

► Es ortogonal ya que $\mathbf{R}(-\alpha) = \mathbf{R}(\alpha)^{-1} = \mathbf{R}(\alpha)^t$

► *Propiedades:*

- La aplicación de una matriz ortogonal a un vector no modifica su norma Euclídea

$$\|\mathbf{U}\mathbf{x}\|_2 = \|\mathbf{x}\|_2 \quad \text{para todo } \mathbf{x} \text{ no nulo y } \mathbf{U} \text{ ortogonal} \quad (92)$$

- El ángulo entre dos vectores se preserva tras transformarlos mediante una matriz ortogonal:

$$\cos(\alpha(\mathbf{U}\mathbf{x}, \mathbf{U}\mathbf{y})) = \frac{(\mathbf{U}\mathbf{x})^t(\mathbf{U}\mathbf{y})}{\|\mathbf{U}\mathbf{x}\|\|\mathbf{U}\mathbf{y}\|} = \frac{\mathbf{x}^t\mathbf{y}}{\|\mathbf{x}\|\|\mathbf{y}\|} = \cos(\alpha(\mathbf{x}, \mathbf{y})) \quad (93)$$

- En resumen, las transformaciones mediante matrices ortogonales preservan longitudes y ángulos, por lo que generalizan

→ rotaciones, si $|\mathbf{U}| = 1$, y

→ reflexiones, si $|\mathbf{U}| = -1$

7.2. Multiplicación de matrices

- El producto de $\mathbf{A} \in \mathbb{R}^{m \times n}$ y $\mathbf{B} \in \mathbb{R}^{n \times p}$ es:

$$\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{m \times p} \quad (94)$$

donde

$$C_{ij} = \sum_{k=1}^n A_{ik} B_{kj} \quad (95)$$

- Coste: $O(mnp)$, mucho menor con GPUs

- *Propiedades:*

- ▷ *Asociativa:*

$$(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC}) \quad (96)$$

- ▷ *Distributiva:*

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC} \quad (97)$$

- ▷ No conmutativa ($\mathbf{AB} \neq \mathbf{BA}$)

7.2.1. Productos vector-vector

► *Producto escalar, interno o punto:* $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$

$$\langle \mathbf{x}, \mathbf{y} \rangle \triangleq \mathbf{x}^t \mathbf{y} = \sum_{i=1}^n x_i y_i \quad (98)$$

▷ Se cumple $\mathbf{x}^t \mathbf{y} = \mathbf{y}^t \mathbf{x}$

► *Producto vectorial, externo o cruz:* $\mathbf{x} \in \mathbb{R}^m, \mathbf{y} \in \mathbb{R}^n$

$$\mathbf{x} \mathbf{y}^t = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_n \\ \vdots & \vdots & \ddots & \vdots \\ x_m y_1 & x_m y_2 & \cdots & x_m y_n \end{bmatrix} \in \mathbb{R}^{m \times n} \quad (99)$$

7.2.2. Productos matriz-vector

- Dada una matriz $A \in \mathbb{R}^{m \times n}$ y un vector $x \in \mathbb{R}^n$ su producto es

$$y = Ax \in \mathbb{R}^m \quad (100)$$

- Dos interpretaciones distintas: por filas o por columnas de A
- Interpretación basada en las filas de A :

$$y = Ax = \begin{bmatrix} a_1^t \\ a_2^t \\ \vdots \\ a_m^t \end{bmatrix} x = \begin{bmatrix} a_1^t x \\ a_2^t x \\ \vdots \\ a_m^t x \end{bmatrix} \quad (101)$$

- En otras palabras, la i -ésima entrada de y es el producto escalar de la i -ésima fila de A y x ,

$$y_i = a_i^t x \quad (102)$$

- Interpretación basada en las columnas de A :

$$\mathbf{y} = A\mathbf{x} \quad (103)$$

$$= [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad (104)$$

$$= \mathbf{a}_1x_1 + \mathbf{a}_2x_2 + \dots + \mathbf{a}_nx_n \quad (105)$$

- En otras palabras, $\mathbf{y}$ es una **combinación lineal** de las columnas de A
- Las columnas de A pueden verse como una **base** de un **subespacio lineal**

7.2.3. Productos matriz-matriz

- Dadas dos matrices, $A \in \mathbb{R}^{m \times n}$ y $B \in \mathbb{R}^{n \times p}$, existen cuatro maneras diferentes de interpretar su producto


$$C = AB \in \mathbb{R}^{m \times p} \quad (106)$$

- Interpretación primera y usual: filas por columnas

$$C = AB = \begin{bmatrix} \mathbf{a}_1^t \\ \mathbf{a}_2^t \\ \vdots \\ \mathbf{a}_m^t \end{bmatrix} [\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_p] \quad (107)$$

$$= \begin{bmatrix} \mathbf{a}_1^t \mathbf{b}_1 & \mathbf{a}_1^t \mathbf{b}_2 & \cdots & \mathbf{a}_1^t \mathbf{b}_p \\ \mathbf{a}_2^t \mathbf{b}_1 & \mathbf{a}_2^t \mathbf{b}_2 & \cdots & \mathbf{a}_2^t \mathbf{b}_p \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_m^t \mathbf{b}_1 & \mathbf{a}_m^t \mathbf{b}_2 & \cdots & \mathbf{a}_m^t \mathbf{b}_p \end{bmatrix} \quad (108)$$

- Producto matricial en términos de filas por columnas:



- Interpretación segunda: columnas por filas

$$\mathbf{C} = \mathbf{AB} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n] \begin{bmatrix} \mathbf{b}_1^t \\ \mathbf{b}_2^t \\ \vdots \\ \mathbf{b}_n^t \end{bmatrix} \quad (109)$$

$$= \sum_{i=1}^n \mathbf{a}_i \mathbf{b}_i^t \quad (110)$$

- Dicho de otra manera, $\mathbf{AB}$ es la suma, para todo i , del producto vectorial de la i -ésima columna de $\mathbf{A}$ y la i -ésima fila de $\mathbf{B}$

- Interpretación tercera: columnas de C como productos matriz-vector de la matriz A y las columnas de B

$$C = AB = A[b_1, b_2, \dots, b_p] \quad (111)$$

$$= [Ab_1, Ab_2, \dots, Ab_p] \quad (112)$$

- ▷ La i -ésima columna de C viene dada por el producto matriz-vector $c_i = Ab_i$
- ▷ Los productos matriz-vector en las columnas de C pueden interpretarse por filas o columnas de A

- Interpretación cuarta: filas de C como productos matriz-vector de las filas de A y la matriz B

$$C = AB = \begin{bmatrix} \mathbf{a}_1^t \\ \mathbf{a}_2^t \\ \vdots \\ \mathbf{a}_m^t \end{bmatrix} B \quad (113)$$

$$= \begin{bmatrix} \mathbf{a}_1^t B \\ \mathbf{a}_2^t B \\ \vdots \\ \mathbf{a}_m^t B \end{bmatrix} \quad (114)$$

- La i -ésima fila de C viene dada por el producto matriz-vector, con el vector a la izquierda, $\mathbf{c}_i^t = \mathbf{a}_i^t B$

► *Notación:*

▷ Cuadrado matricial:

$$\mathbf{A}^2 = \mathbf{A}\mathbf{A} \quad (115)$$

▷ Cuadrado elemental:

$$\mathbf{A}^{\odot 2} = [A_{ij}^2] \quad (116)$$

▷ Raíz cuadrada matricial:

$$\mathbf{A} = \sqrt{\mathbf{M}} \quad \text{si} \quad \mathbf{A}^2 = \mathbf{M} \quad (117)$$

▷ Raíz cuadrada elemental:

$$[\sqrt{M_{ij}}] \quad (118)$$

7.2.4. Aplicación: manipulación de matrices de datos

7.2.4.1. Suma de trozos de la matriz

- ▶ Sea $\mathbf{X}$ una matriz $N \times D$
- ▶ Sumamos las filas de $\mathbf{X}$ pre-multiplicando por una matriz $1 \times N$ de unos:

$$\mathbf{1}_N^t \mathbf{X} = \left(\sum_n x_{n1}, \dots, \sum_n x_{nD} \right) \quad (119)$$

- ▶ Así, la media de los vectores de datos es:

$$\bar{\mathbf{x}}^t = \frac{1}{N} \mathbf{1}_N^t \mathbf{X} \quad (120)$$

- Sumamos las columnas de $\mathbf{X}$ post-multiplicando por una matriz $D \times 1$ de unos:

$$\mathbf{X}\mathbf{1}_D = \begin{pmatrix} \sum_d x_{1d} \\ \vdots \\ \sum_d x_{Nd} \end{pmatrix} \quad (121)$$

- Sumamos todas las entradas de $\mathbf{X}$ pre y post multiplicando por unos:

$$\mathbf{1}_N^t \mathbf{X} \mathbf{1}_D = \sum_{ij} X_{ij} \quad (122)$$

- Así, la media global de los datos es:

$$\bar{x} = \frac{1}{ND} \mathbf{1}_N^t \mathbf{X} \mathbf{1}_D \quad (123)$$

7.2.4.2. Escalado de filas y columnas de una matriz

- Escalamos las filas de $\mathbf{X}$ pre-multiplicando por una matriz diagonal de escalado $\mathbf{S} = \text{diag}(\mathbf{s})$:

$$\text{diag}(\mathbf{s})\mathbf{X} = \begin{bmatrix} s_1 & \cdots & 0 \\ & \ddots & \\ 0 & \cdots & s_N \end{bmatrix} \begin{bmatrix} x_{11} & \cdots & x_{1D} \\ & \ddots & \\ x_{N1} & \cdots & x_{ND} \end{bmatrix} \quad (124)$$

$$= \begin{bmatrix} s_1 x_{11} & \cdots & s_1 x_{1D} \\ & \ddots & \\ s_N x_{N1} & \cdots & s_N x_{ND} \end{bmatrix} \quad (125)$$

- Escalamos las columnas de $\mathbf{X}$ post-multiplicando por una matriz diagonal de escalado $\mathbf{S} = \text{diag}(\mathbf{s})$:

$$\mathbf{X} \text{diag}(\mathbf{s}) = \begin{bmatrix} x_{11} & \cdots & x_{1D} \\ & \ddots & \\ x_{N1} & \cdots & x_{ND} \end{bmatrix} \begin{bmatrix} s_1 & \cdots & 0 \\ & \ddots & \\ 0 & \cdots & s_D \end{bmatrix} \quad (126)$$

$$= \begin{bmatrix} s_1 x_{11} & \cdots & s_D x_{1D} \\ & \ddots & \\ s_1 x_{N1} & \cdots & s_D x_{ND} \end{bmatrix} \quad (127)$$

- Así, podemos reescribir la operación de estandarización como:

$$\text{standardize}(\mathbf{X}) = (\mathbf{X} - \mathbf{1}_N \boldsymbol{\mu}^t) \text{diag}(\boldsymbol{\sigma})^{-1} \quad (128)$$

donde $\boldsymbol{\mu} = \bar{\mathbf{x}}$ y $\boldsymbol{\sigma}$ son la media y desviación típica empíricas

7.2.4.3. Suma de cuadrados y matriz de dispersión

► La *matriz suma de cuadrados* es la matriz $D \times D$:

$$\mathbf{S}_0 \triangleq \mathbf{X}^t \mathbf{X} \quad (129)$$

$$= [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \begin{bmatrix} \mathbf{x}_1^t \\ \mathbf{x}_2^t \\ \vdots \\ \mathbf{x}_N^t \end{bmatrix} \quad (130)$$

$$= \sum_{n=1}^N \mathbf{x}_n \mathbf{x}_n^t \quad (131)$$

$$= \sum_{n=1}^N \begin{pmatrix} x_{n1}^2 & \cdots & x_{n1}x_{nD} \\ & \ddots & \\ x_{nD}x_{n1} & \cdots & x_{nD}^2 \end{pmatrix} \quad (132)$$

► *Matriz de dispersión:*

► Se define como la matriz $D \times D$:

$$\mathbf{S}_{\bar{\mathbf{x}}} \triangleq \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^t = \left(\sum_{n=1}^N \mathbf{x}_n \mathbf{x}_n^t \right) - N \bar{\mathbf{x}} \bar{\mathbf{x}}^t \quad (133)$$

► Vemos que es la matriz suma de cuadrados aplicada a los datos centrados $\tilde{\mathbf{X}}$, esto es, $\mathbf{X}$ menos la media $\bar{\mathbf{x}} = \frac{1}{N} \mathbf{X}^t \mathbf{1}_N$

$$\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}_N \bar{\mathbf{x}}^t = \mathbf{X} - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^t \mathbf{X} = \mathbf{C}_N \mathbf{X} \quad (134)$$

donde hemos introducido la *matriz de centrado*

$$\mathbf{C}_N \triangleq \mathbf{I}_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^t \quad (135)$$

► Así, la matriz de dispersión puede hallarse como

$$\mathbf{S}_{\bar{\mathbf{x}}} = \tilde{\mathbf{X}}^t \tilde{\mathbf{X}} = \mathbf{X}^t \mathbf{C}_N^t \mathbf{C}_N \mathbf{X} = \mathbf{X}^t \mathbf{C}_N \mathbf{X} \quad (136)$$

pues $\mathbf{C}_N$ es simétrica e idempotente ($\mathbf{C}_N^k = \mathbf{C}_N$, $k = 1, 2, \dots$)

7.2.4.4. Matriz de Gram

- La *matriz de Gram* es la matriz $N \times N$ de productos escalares:

$$\mathbf{K} \triangleq \mathbf{X}\mathbf{X}^t = \begin{bmatrix} \mathbf{x}_1^t \mathbf{x}_1 & \cdots & \mathbf{x}_1^t \mathbf{x}_N \\ \vdots & & \vdots \\ \mathbf{x}_N^t \mathbf{x}_1 & \cdots & \mathbf{x}_N^t \mathbf{x}_N \end{bmatrix} \quad (137)$$

- Si tenemos $\mathbf{K}$, pero no $\mathbf{X}$, y queremos hallarla para los datos centrados, $\tilde{\mathbf{X}}$, podemos recurrir al *truco del doble centrado*

$$\tilde{\mathbf{K}} = \tilde{\mathbf{X}}\tilde{\mathbf{X}}^t = \mathbf{C}_N \mathbf{X} (\mathbf{C}_N \mathbf{X})^t = \mathbf{C}_N \mathbf{K} \mathbf{C}_N \quad (138)$$

$$= \left(\mathbf{I}_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^t \right) \mathbf{K} \left(\mathbf{I}_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^t \right) \quad (139)$$

$$= \mathbf{K} - \frac{1}{N} \mathbf{K} \mathbf{1}_N - \mathbf{K} \frac{1}{N} \mathbf{1}_N + \frac{1}{N} \mathbf{K} \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^t \quad (140)$$

donde las medias de filas y columnas de $\tilde{\mathbf{K}}$ son nulas tras restar medias de filas y columnas de $\mathbf{K}$, y sumar la media global (que previamente habíamos restado dos veces)

7.2.4.5. Matriz de distancias

- Dadas las matrices de datos $\mathbf{X} \in \mathbb{R}^{N_x \times D}$ e $\mathbf{Y} \in \mathbb{R}^{N_y \times D}$, la **matriz de distancias al cuadrado** puede calcularse con:

$$\mathbf{D}_{ij} = (\mathbf{x}_i - \mathbf{y}_j)^t (\mathbf{x}_i - \mathbf{y}_j) = \|\mathbf{x}_i\|^2 - 2\mathbf{x}_i^t \mathbf{y}_j + \|\mathbf{y}_j\|^2 \quad (141)$$

- **Matriz de distancias** expresada como matriz $N_x \times N_y$:

- ▷ Vectores de normas cuadráticas de las matrices de datos:

$$\hat{\mathbf{x}} = [\|\mathbf{x}_1\|^2; \dots; \|\mathbf{x}_{N_x}^2\|] = \text{diag}(\mathbf{X}\mathbf{X}^t) \quad (142)$$

$$\hat{\mathbf{y}} = [\|\mathbf{y}_1\|^2; \dots; \|\mathbf{y}_{N_y}^2\|] = \text{diag}(\mathbf{Y}\mathbf{Y}^t) \quad (143)$$

- ▷ Matriz de distancias:

$$\mathbf{D} = \hat{\mathbf{x}}\mathbf{1}_{N_y}^t - 2\mathbf{X}\mathbf{Y}^t + \mathbf{1}_{N_x}\hat{\mathbf{y}}^t \quad (144)$$

- ▷ En el caso $\mathbf{X} = \mathbf{Y}$:

$$\mathbf{D} = \hat{\mathbf{x}}\mathbf{1}_N^t - 2\mathbf{X}\mathbf{X}^t + \mathbf{1}_N\hat{\mathbf{x}}^t \quad (145)$$

7.3. Inversión de matrices

7.3.1. Inversa de una matriz cuadrada

► La *inversa* de $\mathbf{A} \in \mathbb{R}^{n \times n}$ es la única matriz $\mathbf{A}^{-1}$ tal que:

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{I} = \mathbf{A}\mathbf{A}^{-1} \quad (146)$$

► $\mathbf{A}^{-1}$ existe sii $|\mathbf{A}| \neq 0$; esto es, si $\mathbf{A}$ es no singular.

► Propiedades:

$$(\mathbf{A}^{-1})^{-1} = \mathbf{A} \quad (147)$$

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1} \quad (148)$$

$$(\mathbf{A}^{-1})^t = (\mathbf{A}^t)^{-1} \triangleq \mathbf{A}^{-t} \quad (149)$$

- En el caso de una matriz 2×2 ,

$$\mathbf{A} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \quad (150)$$

su inversa es

$$\mathbf{A}^{-1} = \frac{1}{|\mathbf{A}|} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} \quad (151)$$

- Inversa de una matriz diagonal por bloques:

$$\begin{pmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \mathbf{B} \end{pmatrix}^{-1} = \begin{pmatrix} \mathbf{A}^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{B}^{-1} \end{pmatrix} \quad (152)$$

7.4. Descomposición en valores propios (EVD)

7.4.1. Conceptos básicos

► *Valor y vector propio:*

- Dada una matriz $A \in \mathbb{R}^{n \times n}$, $\lambda \in \mathbb{R}$ es un *valor propio* de A y $u \in \mathbb{R}^n$ “el” correspondiente *vector propio* si:

$$Au = \lambda u, \quad u \neq 0 \quad (153)$$

- Intuitivamente, la multiplicación de A por u resulta en un vector que apunta en la misma dirección que u , pero escalado por λ
- *Ejemplo:* si A es una matriz de rotación, u es el eje de rotación y $\lambda = 1$

► “El” vector propio asociado a un valor propio:

- ▷ Dado un valor propio, no existe un único vector propio asociado
- ▷ Si u es un vector propio asociado a un valor propio λ , entonces cu , $c \in \mathbb{R}$, también es vector propio asociado a λ

$$\mathbf{A}(cu) = c\mathbf{A}u = c\lambda u = \lambda(cu) \quad (154)$$

- ▷ Asumimos que “el” vector propio asociado con λ tiene longitud 1, si bien esto es ambiguo ya que podemos tomar u o $-u$

► Ecuación característica de A :

- La ecuación que determina si (λ, x) es un par *eigenvalue-eigenvector* puede reescribirse como

$$(\lambda \mathbf{I} - \mathbf{A})\mathbf{u} = \mathbf{0} \quad (155)$$

- Esta ecuación tiene solución no nula sii $(\lambda \mathbf{I} - \mathbf{A})$ tiene un espacio nulo no vacío, lo que ocurre solo si $(\lambda \mathbf{I} - \mathbf{A})$ es singular,

$$|\lambda \mathbf{I} - \mathbf{A}| = 0 \quad (156)$$

lo que se conoce como *characteristic equation* de A

- Las n soluciones de esta ecuación son los n valores propios λ_i , y $\mathbf{u}_i$ son los correspondientes vectores propios
- Los valores propios suelen ordenarse de mayor a menor

► *Propiedades:*

- La traza de $\mathbf{A}$ es igual a la suma de sus valores propios:

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i \quad (157)$$

- El determinante de $\mathbf{A}$ es igual al producto de sus valores propios:

$$|\mathbf{A}| = \prod_{i=1}^n \lambda_i \quad (158)$$

- El rango de $\mathbf{A}$ es igual al número de sus valores propios no nulos
- Si $\mathbf{A}$ es no singular, entonces $\frac{1}{\lambda_i}$ es un valor propio de $\mathbf{A}^{-1}$ con vector propio asociado $\mathbf{u}_i$, esto es, $\mathbf{A}^{-1}\mathbf{u}_i = \frac{1}{\lambda_i}\mathbf{u}_i$
- Los valores propios de una matriz diagonal o triangular son los elementos de su diagonal

7.4.2. Diagonalización

- Podemos escribir las ecuaciones de todos los valores y vectores propios simultáneamente como:

$$\mathbf{A}\mathbf{U} = \mathbf{U}\mathbf{\Lambda} \quad (159)$$

donde las columnas de $\mathbf{U} \in \mathbb{R}^{n \times n}$ son los vectores propios de $\mathbf{A}$,

$$\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_n] \quad (160)$$

y $\mathbf{\Lambda}$ es una matriz diagonal con los valores propios de $\mathbf{A}$,

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n) \quad (161)$$

- $\mathbf{A}$ es una *matriz diagonalizable* si puede escribirse como

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^{-1} \quad (162)$$

esto es, sus vectores propios son linealmente independientes, por lo que $\mathbf{U}$ es invertible

7.4.3. Valores y vectores propios de matriz simétrica

- Si A es real y simétrica, todos sus valores propios son *reales* y sus vectores propios *ortonormales*:

$$\mathbf{u}_i^t \mathbf{u}_j = \begin{cases} 0 & \text{si } i \neq j \\ 1 & \text{si } i = j \end{cases} \quad (163)$$

- En forma matricial,

$$\mathbf{U}^t \mathbf{U} = \mathbf{U} \mathbf{U}^t = \mathbf{I} \quad (164)$$

por lo que tenemos que $\mathbf{U}$ es una *matriz ortogonal*

- Por ortogonalidad de $\mathbf{U}$, $\mathbf{A}$ puede representarse como:

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^t \quad (165)$$

$$= (\mathbf{u}_1, \dots, \mathbf{u}_n) \text{diag}(\lambda_1, \dots, \lambda_n) (\mathbf{u}_1^t; \dots; \mathbf{u}_n^t) \quad (166)$$

$$= \lambda_1 \mathbf{u}_1 \mathbf{u}_1^t + \dots + \lambda_n \mathbf{u}_n \mathbf{u}_n^t \quad (167)$$

$$= \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^t \quad (168)$$

► *Interpretación:* la multiplicación por una matriz simétrica puede verse como la multiplicación por una matriz de rotación $\mathbf{U}^t$, una matriz de escalado $\mathbf{\Lambda}$, seguido por una rotación inversa $\mathbf{U}$

- La inversa de una matriz diagonalizada se obtiene fácilmente:

$$\mathbf{A}^{-1} = \mathbf{U}\mathbf{\Lambda}^{-1}\mathbf{U}^t = \sum_{i=1}^n \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{u}_i^t \quad (169)$$

esto es, una rotación, desescalado y rotación inversa

7.4.3.1. Comprobación de definición positiva

- ▶ La diagonalización de una matriz simétrica permite probar que es definida positiva sii todos sus valores propios son positivos:

$$\mathbf{x}^t \mathbf{A} \mathbf{x} = \mathbf{x}^t \mathbf{U} \mathbf{\Lambda} \mathbf{U}^t \mathbf{x} = \mathbf{y}^t \mathbf{\Lambda} \mathbf{y} = \sum_{i=1}^n \lambda_i y_i^2 \quad (\text{con } \mathbf{y} = \mathbf{U}^t \mathbf{x}) \quad (170)$$

- ▶ Como $y_i^2 \geq 0$, el signo solo depende de los λ_i s:
 - ▷ $\mathbf{A}$ es definida positiva sii $\lambda_i > 0$ para todo i
 - ▷ $\mathbf{A}$ es semidefinida positiva sii $\lambda_i \geq 0$ para todo i
 - ▷ $\mathbf{A}$ es definida negativa sii $\lambda_i < 0$ para todo i
 - ▷ $\mathbf{A}$ es semidefinida negativa sii $\lambda_i \leq 0$ para todo i
 - ▷ $\mathbf{A}$ es indefinida sii tiene λ_i s positivos y negativos

7.4.4. Geometría de las formas cuadráticas

- Forma cuadrática de matriz $\mathbf{A}$ definida positiva ($\lambda_i > 0$):

$$f(\mathbf{x}) = \mathbf{x}^t \mathbf{A} \mathbf{x} \quad (171)$$

$$= \mathbf{x}^t \mathbf{U} \mathbf{\Lambda} \mathbf{U}^t \mathbf{x} \quad (172)$$

$$= \mathbf{y}^t \mathbf{\Lambda} \mathbf{y} \quad (\text{con } \mathbf{y} = \mathbf{U}^t \mathbf{x}) \quad (173)$$


$$= \sum_{i=1}^n \lambda_i y_i^2 \quad (174)$$

- Las curvas de nivel de $f(\mathbf{x})$ son hiper-elipsoides de semi-ejes orientados por los vectores propios en $\mathbf{U}$ y longitudes determinadas por los valores propios en $\mathbf{\Lambda}$

▷ *Ejemplo:* en 2d, tenemos una elipse


$$\lambda_1 y_1^2 + \lambda_2 y_2^2 = r \quad (175)$$

- *Ejemplo:* curva de nivel de una forma cuadrática en 2d



7.4.5. Estandarización y blanqueado de datos

- **Estandarización:** dada una matriz de datos $X \in \mathbb{R}^{N \times D}$, a cada columna se le resta su media y se divide por su desviación típica; así, las variables estandarizadas tienen media 0 y varianza 1



- *Inconveniente:* no elimina correlaciones entre variables

► *Blanqueado principal component analysis (PCA):*

- Sean la matriz de covarianzas empírica y su diagonalización,

$$\Sigma = \frac{1}{N} \mathbf{X}^t \mathbf{X} \quad \text{y} \quad \Sigma = \mathbf{E} \mathbf{D} \mathbf{E}^t \quad (176)$$

- Sea $[\mathbf{U}, \mathbf{S}, \mathbf{V}]$ la **SVD** de $\mathbf{X}$, por lo que $\mathbf{E} = \mathbf{V}$ y $\mathbf{D} = \mathbf{S}^2$

- *Matriz blanqueante PCA:*

$$\mathbf{W}_{\text{pca}} = \mathbf{D}^{-\frac{1}{2}} \mathbf{E}^t \quad (177)$$

- Así, la matriz de covarianzas de $\mathbf{y} = \mathbf{W}_{\text{pca}} \mathbf{x}$ es blanca ($\mathbf{I}$):

$$\text{Cov}[\mathbf{y}] = \mathbf{W} \mathbb{E}[\mathbf{x} \mathbf{x}^t] \mathbf{W}^t \quad (178)$$

$$= \mathbf{W} \Sigma \mathbf{W}^t \quad (179)$$

$$= (\mathbf{D}^{-\frac{1}{2}} \mathbf{E}^t) (\mathbf{E} \mathbf{D} \mathbf{E}^t) (\mathbf{E} \mathbf{D}^{-\frac{1}{2}}) = \mathbf{I} \quad (180)$$

► *Blanqueado zero-phase component analysis (ZCA):*

- La matriz blanqueante PCA no es única ya que cualquier rotación $\mathbf{R}$ aplicada a la misma,





$$\mathbf{W} = \mathbf{R}\mathbf{W}_{\text{pca}} \quad (181)$$

mantiene la propiedad blanqueante, esto es, $\mathbf{W}^t \mathbf{W} = \Sigma^{-1}$

- *Matriz blanqueante ZCA:* escoge $\mathbf{R} = \mathbf{E}$

$$\mathbf{W}_{\text{zca}} = \mathbf{E}\mathbf{W}_{\text{pca}} \quad (182)$$

- La ventaja del blanqueado ZCA sobre el PCA es que los datos transformados se hallan lo más próximos posible a los originales (en mínimos cuadrados); por ejemplo, cuando se aplica a imágenes, los datos transformados ZCA siguen pareciendo imágenes



7.4.6. Método de las potencias

- Dada una matriz diagonalizable $\mathbf{A}$, el *método de las potencias* halla el mayor valor propio de $\mathbf{A}$ iterativamente a partir de una aproximación al vector principal dominante o un vector inicial $\mathbf{b}_0$:

$$\mathbf{b}_{k+1} = \frac{\mathbf{A}\mathbf{b}_k}{\|\mathbf{A}\mathbf{b}_k\|} = \frac{\mathbf{A}^{k+1}\mathbf{b}_0}{\|\mathbf{A}^{k+1}\mathbf{b}_0\|} \quad (183)$$

- Sea $\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^t$, con valores propios $|\lambda_1| \geq \dots \geq |\lambda_m| \geq 0$ y vectores propios $\mathbf{u}_i$; si $|\lambda_1| > |\lambda_j|$ para $j > 1$, $\mathbf{b}_k$ converge a $\mathbf{u}_1$
- λ_1 se halla a partir del *cociente de Rayleigh*:

$$R(\mathbf{A}, \mathbf{x}) \triangleq \frac{\mathbf{x}^t \mathbf{A} \mathbf{x}}{\mathbf{x}^t \mathbf{x}} \Rightarrow R(\mathbf{A}, \mathbf{u}_i) = \frac{\mathbf{u}_i^t \mathbf{A} \mathbf{u}_i}{\mathbf{u}_i^t \mathbf{u}_i} = \frac{\lambda_i \mathbf{u}_i^t \mathbf{u}_i}{\mathbf{u}_i^t \mathbf{u}_i} = \lambda_i \quad (184)$$

► Prueba de convergencia:

▷ Escribimos $\mathbf{b}_0$ como combinación lineal de los $\mathbf{u}_i$:

$$\mathbf{b}_0 = c_1 \mathbf{u}_1 + c_2 \mathbf{u}_2 + \cdots + c_m \mathbf{u}_m \quad (185)$$

▷ Asumiendo que $|\lambda_1| > |\lambda_j|$ para $j > 1$:

$$\mathbf{A}^{k+1} \mathbf{b}_0 = c_1 \mathbf{A}^k \mathbf{u}_1 + c_2 \mathbf{A}^k \mathbf{u}_2 + \cdots + c_m \mathbf{A}^k \mathbf{u}_m \quad (186)$$

$$= c_1 \lambda_1^k \mathbf{u}_1 + c_2 \lambda_2^k \mathbf{u}_2 + \cdots + c_m \lambda_m^k \mathbf{u}_m \quad (187)$$

$$= c_1 \lambda_1^k \left(\mathbf{u}_1 + \frac{c_2}{c_1} \left(\frac{\lambda_2}{\lambda_1} \right)^k \mathbf{u}_2 + \cdots + \frac{c_m}{c_1} \left(\frac{\lambda_m}{\lambda_1} \right)^k \mathbf{u}_m \right) \quad (188)$$

$$\rightarrow c_1 \lambda_1^k \mathbf{u}_1 \quad (189)$$

por lo que $\mathbf{b}_k$ converge a $\mathbf{u}_1$

7.4.7. Deflación

- ▶ Tras hallar los mayores vector y valor propios de $\mathbf{A}^{(1)} (\triangleq \mathbf{A})$, “deflactamos” $\mathbf{A}^{(1)}$ eliminando $\lambda_1 \mathbf{u}_1 \mathbf{u}_1^t$:

$$\mathbf{A}^{(2)} = (\mathbf{I} - \mathbf{u}_1 \mathbf{u}_1^t) \mathbf{A}^{(1)} \quad (190)$$

$$= \mathbf{A}^{(1)} - \mathbf{u}_1 \mathbf{u}_1^t \mathbf{A}^{(1)} \quad (191)$$

$$= \mathbf{A}^{(1)} - \lambda_1 \mathbf{u}_1 \mathbf{u}_1^t \quad (192)$$

- ▶ Aplicando el método de las potencias a $\mathbf{A}^{(2)}$ obtendremos los mayores vector y valor propios en el subespacio ortogonal a $\mathbf{u}_1$, esto es, el segundo mayor valor propio de $\mathbf{A}$ y su vector propio
- ▶ Este proceso permite hallar los primeros K vectores propios de la matriz de covarianzas empírica de los datos, necesarios en PCA

7.4.8. Optimización de formas cuadráticas

- Optimización de una forma cuadrática con restricciones:

$$\max_{\mathbf{x} \in \mathbb{R}^n} \mathbf{x}^t \mathbf{A} \mathbf{x} \quad \text{sujeito a } \|\mathbf{x}\|_2^2 = 1 \quad (\mathbf{A} \in \mathbb{S}^n) \quad (193)$$

- Versión sin restricciones:

$$\max_{\mathbf{x} \in \mathbb{R}^n, \lambda \in \mathbb{R}} \mathbf{x}^t \mathbf{A} \mathbf{x} - \lambda(1 - \mathbf{x}^t \mathbf{x}) \quad (194)$$

- Condición necesaria de optimalidad:

$$2\mathbf{A}^t \mathbf{x} - 2\lambda \mathbf{x} = \mathbf{0} \quad \Leftrightarrow \quad \mathbf{A} \mathbf{x} = \lambda \mathbf{x} \quad (195)$$

- Las soluciones son los vectores propios de $\mathbf{A}$

7.5. Descomposición en valores singulares (SVD)

7.5.1. Conceptos básicos


- La **descomposición en valores singulares (SVD)** generaliza la de valores propios a matrices rectangulares, del tipo $\mathbf{A} \in \mathbb{R}^{m \times n}$:

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^t = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^t + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^t \quad (196)$$


- $\mathbf{U} \in \mathbb{R}^{m \times m}$ es una matriz de columnas ortonormales ($\mathbf{U}^t \mathbf{U} = \mathbf{I}$) que llamamos **vectores singulares izquierdos**
- $\mathbf{S} \in \mathbb{R}^{m \times n}$ incluye $r = \min(m, n)$ **valores singulares** $\sigma_i \geq 0$ en su diagonal; ceros en el resto
- $\mathbf{V} \in \mathbb{R}^{n \times n}$ es una matriz de filas y columnas ortonormales ($\mathbf{V}^t \mathbf{V} = \mathbf{V} \mathbf{V}^t = \mathbf{I}$); sus columnas son los **vectores singulares derechos**

► **Economy sized o thin SVD:** ignora partes sombreadas

▷ $m > n$



▷ $m < n$



7.5.2. Conexión entre la SVD y la EVD

► *A real, simétrica y definida positiva:*

- ▷ Los valores singulares son los valores propios, mientras que los vectores singulares izquierdos y derechos son los vectores propios (salvo cambios de signo):

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^t = \mathbf{U}\mathbf{S}\mathbf{U}^t = \mathbf{U}\mathbf{S}\mathbf{U}^{-1} \quad (197)$$

► *A real arbitraria:* $\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^t$

▷ Vectores y valores propios de $\mathbf{A}^t\mathbf{A}$: $\mathbf{V}$ y $\mathbf{D}_n = \mathbf{S}^t\mathbf{S}$

$$\mathbf{A}^t\mathbf{A} = \mathbf{V}\mathbf{S}^t\mathbf{U}^t\mathbf{U}\mathbf{S}\mathbf{V}^t = \mathbf{V}(\mathbf{S}^t\mathbf{S})\mathbf{V}^t \Rightarrow (\mathbf{A}^t\mathbf{A})\mathbf{V} = \mathbf{V}\mathbf{D}_n \quad (198)$$

▷ Vectores y valores propios de $\mathbf{A}\mathbf{A}^t$: $\mathbf{U}$ y $\mathbf{D}_m = \mathbf{S}\mathbf{S}^t$

$$\mathbf{A}\mathbf{A}^t = \mathbf{U}\mathbf{S}\mathbf{V}^t\mathbf{V}\mathbf{S}^t\mathbf{U}^t = \mathbf{U}(\mathbf{S}\mathbf{S}^t)\mathbf{U}^t \Rightarrow (\mathbf{A}\mathbf{A}^t)\mathbf{U} = \mathbf{U}\mathbf{D}_m \quad (199)$$

▷ En resumen:

$$\mathbf{V} = \text{evec}(\mathbf{A}^t\mathbf{A}) \quad \mathbf{D}_n = \text{eval}(\mathbf{A}^t\mathbf{A}) \quad (200)$$

$$\mathbf{U} = \text{evec}(\mathbf{A}\mathbf{A}^t) \quad \mathbf{D}_m = \text{eval}(\mathbf{A}\mathbf{A}^t) \quad (201)$$

▷ Si solo se calculan las partes (no nulas) de *thin SVD*:

$$\mathbf{D} = \mathbf{S}^2 = \mathbf{S}^t\mathbf{S} = \mathbf{S}\mathbf{S}^t \quad (202)$$

▷ La EVD no siempre existe, pero la SVD sí

7.5.3. Pseudoinversa

► Dada $A \in \mathbb{R}^{m \times n}$, su *pseudoinversa*, *inversa generalizada* o *inversa de Moore–Penrose* es una matriz $A^\dagger \in \mathbb{R}^{n \times m}$ tal que:

1. $AA^\dagger A = A$ ($AA^\dagger$ preserva las columnas de A)

2. $A^\dagger AA^\dagger = A^\dagger$ ($A^\dagger$ actúa como una inversa débil)

3. $(AA^\dagger)^t = AA^\dagger$ ($AA^\dagger$ es simétrica)

4. $(A^\dagger A)^t = A^\dagger A$ ($A^\dagger A$ también es simétrica)

► La pseudoinversa es única

► Si A es cuadrada y no-singular,

$$A^\dagger = A^{-1} \quad (203)$$

- Si $m > n$ y las columnas de $\mathbf{A}$ son linealmente independientes:

$$\mathbf{A}^\dagger = (\mathbf{A}^t \mathbf{A})^{-1} \mathbf{A}^t \quad (204)$$

- ▷ $\mathbf{A}^\dagger$ es una inversa izquierda de $\mathbf{A}$:

$$\mathbf{A}^\dagger \mathbf{A} = (\mathbf{A}^t \mathbf{A})^{-1} \mathbf{A}^t \mathbf{A} = \mathbf{I} \quad (205)$$

- ▷ $\mathbf{A}^\dagger$ no es una inversa derecha de $\mathbf{A}$ porque

$$\mathbf{A} \mathbf{A}^\dagger = \mathbf{A} (\mathbf{A}^t \mathbf{A})^{-1} \mathbf{A}^t \neq \mathbf{I} \quad (206)$$

tiene rango n y no puede ser una matriz identidad $m \times m$

- Si $m < n$ y las filas de $\mathbf{A}$ son linealmente independientes:

$$\mathbf{A}^\dagger = \mathbf{A}^t (\mathbf{A} \mathbf{A}^t)^{-1} \quad (207)$$

- ▷ $\mathbf{A}^\dagger$ es una inversa derecha de $\mathbf{A}$

► *Cálculo mediante la SVD:*

▷ Sea $\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^t$ la SVD de $\mathbf{A}$ y r su rango

▷ $\mathbf{A}^\dagger$ se calcula como:

$$\mathbf{A}^\dagger = \mathbf{V}[\text{diag}(1/\sigma_1, \dots, 1/\sigma_r, 0, \dots, 0)]\mathbf{U}^t \quad (208)$$

▷ $\mathbf{A}^\dagger$ actúa como una inversa para matrices no cuadradas:

$$\mathbf{A}^\dagger = \mathbf{A}^{-1} = (\mathbf{U}\mathbf{S}\mathbf{V}^t)^{-1} = \mathbf{V}\mathbf{S}^{-1}\mathbf{U}^t \quad (209)$$

donde $\mathbf{S}^{-1} \triangleq \text{diag}(\sigma_1^{-1}, \dots, \sigma_r^{-1}, 0, \dots, 0)$

7.5.5. SVD truncada


- ▶ Sea $\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^t$ la SVD de $\mathbf{A}$
- ▶ La **SVD truncada** de $\mathbf{A}$ se define a partir de las primeras K columnas de $\mathbf{U}$, $\mathbf{S}$ y $\mathbf{V}$:

$$\hat{\mathbf{A}}_K = \mathbf{U}_K \mathbf{S}_K \mathbf{V}_K^t \quad (210)$$


- ▶ $\hat{\mathbf{A}}_K$ es la matriz de rango K más próxima a $\mathbf{A}$ según $\|\mathbf{A} - \hat{\mathbf{A}}_K\|_F^2$
- ▶ Si $K = r = \text{rank}(\mathbf{A})$, la SVD truncada no introduce error
- ▶ Si $K < r$, sí introduce error, por lo general pequeño con datos reales (pues los valores singulares que decrecen rápidamente)
- ▶ Parámetros necesarios para representar una matriz $N \times D$:

$$NK + K + KD = K(N + 1 + D) \quad (211)$$

- *Ejemplo:* imagen 200×320 (rango 200), 64000 parámetros
rank 200




- *Ejemplo (cont.):* rango 20, $(200+320+1) \cdot 20 = 10420$ parámetros
rank 20



- Error de una aproximación: σ_k k -ésimo valor singular de $\mathbf{A}$

$$\|\mathbf{A} - \hat{\mathbf{A}}\|_F = \sum_{k=K+1}^r \sigma_k \quad (212)$$

► *Ejemplo (cont.):*



7.8. Cálculo matricial

7.8.1. Derivadas

► *Derivada* de una función $f : \mathbb{R} \rightarrow \mathbb{R}$ en un punto:

$$f'(x) \triangleq \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \quad (213)$$

► $f'(x)$ puede verse como la pendiente de la línea tangente en $f(x)$:

$$f(x+h) \approx f(x) + f'(x)h \quad (214)$$

► Aproximaciones de *diferencia finita* a la derivada:

$$f'(x) \approx \frac{f(x+h) - f(x)}{h} \quad (\text{diferencia forward}) \quad (215)$$

$$f'(x) \approx \frac{f(x+h/2) - f(x-h/2)}{h} \quad (\text{diferencia central}) \quad (216)$$

$$f'(x) \approx \frac{f(x) - f(x-h)}{h} \quad (\text{diferencia backward}) \quad (217)$$

► La diferenciación es un operador funcional, $D(f) = f'$

► **Notación de Lagrange:**

▷ f' denota la derivada

▷ f'' denota la segunda derivada

▷ $f^{(n)}$ denota la n -ésima derivada

► **Notación de Leibniz:**

▷ $y = f(x)$ denota la función

▷ Derivada:

$$\frac{dy}{dx} \quad \text{o} \quad \frac{d}{dx}f(x) \quad (218)$$

▷ Derivada en un punto a :

$$\left. \frac{df}{dx} \right|_{x=a} \quad (219)$$

7.8.2. Gradientes

► **Derivada parcial** de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ respecto a x_i :

$$\frac{\partial f}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(\mathbf{x} + \mathbf{e}_i) - f(\mathbf{x})}{h} \quad (\mathbf{e}_i \text{ i-ésimo vector unitario}) \quad (220)$$

► **Gradiente** de f en un punto $\mathbf{x}$:

$$\mathbf{g} = \frac{\partial f}{\partial \mathbf{x}} = \nabla f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix} \quad (221)$$

► Para enfatizar el punto $\mathbf{x}^*$ en el que se evalúa:

$$\mathbf{g}(\mathbf{x}^*) \triangleq \left. \frac{\partial f}{\partial \mathbf{x}} \right|_{\mathbf{x}^*} \quad (222)$$

7.8.3. Derivada direccional

- *Derivada direccional* de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en la dirección $\mathbf{v}$:

$$D_{\mathbf{v}}f(\mathbf{x}) = \lim_{h \rightarrow 0} \frac{f(\mathbf{x} + h\mathbf{v}) - f(\mathbf{x})}{h} \quad (223)$$

- $D_{\mathbf{v}}f(\mathbf{x})$ puede aproximarse numéricamente con dos llamadas a f ; frente a las $n + 1$ llamadas que requiere la aproximación numérica del vector gradiente ($2n$ con diferencias centrales)
- $D_{\mathbf{v}}f(\mathbf{x})$ también puede calcularse a partir del gradiente:

$$D_{\mathbf{v}}f(\mathbf{x}) = \nabla f(\mathbf{x}) \mathbf{v} \quad (224)$$

7.8.5. La Jacobiana

► *Matriz Jacobiana* de $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$:

$$\mathbf{J}_f(\mathbf{x}) = \frac{\partial \mathbf{f}}{\partial \mathbf{x}^t} \quad (225)$$

$$\triangleq \begin{pmatrix} \frac{f_1}{x_1} & \dots & \frac{f_1}{x_n} \\ \vdots & \ddots & \vdots \\ \frac{f_m}{x_1} & \dots & \frac{f_m}{x_n} \end{pmatrix} \quad (226)$$

$$= \begin{pmatrix} \nabla f_1(\mathbf{x})^t \\ \vdots \\ \nabla f_m(\mathbf{x})^t \end{pmatrix} \quad (227)$$

7.8.5.1. Multiplicación de Jacobianas y vectores

► *Producto Jacobiana-vector:* $\mathbf{J} \in \mathbb{R}^{m \times n}$, $\mathbf{v} \in \mathbb{R}^n$

$$\mathbf{J}_f(\mathbf{x})\mathbf{v} = \begin{pmatrix} \nabla f_1(\mathbf{x})^t \\ \vdots \\ \nabla f_m(\mathbf{x})^t \end{pmatrix} \mathbf{v} \quad (228)$$

$$= \begin{pmatrix} \nabla f_1(\mathbf{x})^t \mathbf{v} \\ \vdots \\ \nabla f_m(\mathbf{x})^t \mathbf{v} \end{pmatrix} \quad (229)$$

► *Producto vector-Jacobiana:* $\mathbf{J} \in \mathbb{R}^{m \times n}$, $\mathbf{u} \in \mathbb{R}^m$

$$\mathbf{u}^t \mathbf{J}_f(\mathbf{x}) = \mathbf{u}^t \left(\frac{\partial \mathbf{f}}{\partial x_1}, \dots, \frac{\partial \mathbf{f}}{\partial x_n} \right) \quad (230)$$

$$= \left(\mathbf{u} \frac{\partial \mathbf{f}}{\partial x_1}, \dots, \mathbf{u} \frac{\partial \mathbf{f}}{\partial x_n} \right) \quad (231)$$

7.8.5.2. Jacobiana de una composición

► *Jacobiana de una composición:* $h(\mathbf{x}) = g(f(\mathbf{x}))$

$$\mathbf{J}_h(\mathbf{x}) = \mathbf{J}_g(f(\mathbf{x}))\mathbf{J}_f(\mathbf{x}) \quad (232)$$

► *Ejemplo:* $f : \mathbb{R} \rightarrow \mathbb{R}^2, \quad g : \mathbb{R}^2 \rightarrow \mathbb{R}^2$

$$\frac{\partial \mathbf{g}}{\partial x} = \begin{pmatrix} \frac{\partial}{\partial x} g_1(f_1(x), f_2(x)) \\ \frac{\partial}{\partial x} g_2(f_1(x), f_2(x)) \end{pmatrix} \quad (233)$$

$$= \begin{pmatrix} \frac{\partial g_1}{\partial f_1} \frac{\partial f_1}{\partial x} + \frac{\partial g_1}{\partial f_2} \frac{\partial f_2}{\partial x} \\ \frac{\partial g_2}{\partial f_1} \frac{\partial f_1}{\partial x} + \frac{\partial g_2}{\partial f_2} \frac{\partial f_2}{\partial x} \end{pmatrix} \quad (234)$$

$$= \frac{\partial \mathbf{g}}{\partial \mathbf{f}} \frac{\partial \mathbf{f}}{\partial x} = \begin{pmatrix} \frac{\partial g_1}{\partial f_1} & \frac{\partial g_1}{\partial f_2} \\ \frac{\partial g_2}{\partial f_1} & \frac{\partial g_2}{\partial f_2} \end{pmatrix} \begin{pmatrix} \frac{\partial f_1}{\partial x} \\ \frac{\partial f_2}{\partial x} \end{pmatrix} \quad (235)$$

7.8.6. Hessiana

► *Matriz Hessiana* de $f : \mathbb{R}^n \rightarrow \mathbb{R}$:

$$\mathbf{H}_f = \frac{\partial^2 f}{\partial \mathbf{x}^2} = \nabla^2 f = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix} \quad (236)$$

► La Hessiana es la Jacobiana del gradiente

7.8.7. Gradientes de funciones comunes

7.8.7.1. Funciones de escalar a escalar

$$\frac{d}{dx} cx^n = cnx^{n-1} \quad (237)$$

$$\frac{d}{dx} \log(x) = 1/x \quad (238)$$

$$\frac{d}{dx} \exp(x) = \exp(x) \quad (239)$$

$$\frac{d}{dx} [f(x) + g(x)] = \frac{df(x)}{dx} + \frac{dg(x)}{dx} \quad (240)$$

$$\frac{d}{dx} [f(x)g(x)] = f(x) \frac{dg(x)}{dx} + g(x) \frac{df(x)}{dx} \quad (241)$$

$$\frac{d}{dx} f(u(x)) = \frac{du}{dx} \frac{df(u)}{d(u)} \quad (242)$$

7.8.7.2. Funciones de vector a escalar

$$\frac{\partial(\mathbf{a}^t \mathbf{x})}{\partial \mathbf{x}} = \mathbf{a} \quad (243)$$

$$\frac{\partial(\mathbf{b}^t \mathbf{A} \mathbf{x})}{\partial \mathbf{x}} = \mathbf{A}^t \mathbf{b} \quad (244)$$

$$\frac{\partial(\mathbf{x}^t \mathbf{A} \mathbf{x})}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}^t) \mathbf{x} \quad (245)$$

7.8.7.3. Funciones de matriz a escalar

$$\frac{\partial f}{\partial \mathbf{X}} = \begin{pmatrix} \frac{\partial f}{\partial x_{11}} & \cdots & \frac{\partial f}{\partial x_{1n}} \\ \vdots & \ddots & \vdots \\ \frac{\partial f}{\partial x_{m1}} & \cdots & \frac{\partial f}{\partial x_{mn}} \end{pmatrix} \quad (246)$$

► *Identidades para formas cuadráticas:*

$$\frac{\partial}{\partial \mathbf{X}}(\mathbf{a}^t \mathbf{X} \mathbf{b}) = \mathbf{a} \mathbf{b}^t \quad (247)$$

$$\frac{\partial}{\partial \mathbf{X}}(\mathbf{a}^t \mathbf{X}^t \mathbf{b}) = \mathbf{b} \mathbf{a}^t \quad (248)$$

► *Identidades con la traza:*

$$\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{AXB}) = \mathbf{A}^t \mathbf{B}^t \quad (249)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{X}^t \mathbf{A}) = \mathbf{A} \quad (250)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{X}^{-1} \mathbf{A}) = -\mathbf{X}^{-t} \mathbf{A}^t \mathbf{X}^{-t} \quad (251)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{X}^t \mathbf{A} \mathbf{X}) = (\mathbf{A} + \mathbf{A}^t) \mathbf{X} \quad (252)$$

► *Identidades con el determinante:*

$$\frac{\partial}{\partial \mathbf{X}} |\mathbf{AXB}| = |\mathbf{AXB}| \mathbf{X}^{-t} \quad (253)$$

$$\frac{\partial}{\partial \mathbf{X}} \ln(|\mathbf{X}|) = \mathbf{X}^{-t} \quad (254)$$