



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Optimización (actividades)

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

8.1	Introducción	1
8.1.1	Optimización local vs global	1
8.1.1.1	Condiciones de optimalidad local	2
8.1.2	Optimización con o sin restricciones	3
8.1.3	Optimización convexa vs no-convexa	4
8.1.4	Optimización suave vs no-suave	5
8.2	Métodos de primer orden	6
8.2.1	Dirección de descenso	7
8.2.2	Tamaño de paso o factor de aprendizaje	8
8.2.3	Ratios de convergencia	10
8.2.4	Momentum	11
8.3	Métodos de segundo orden	12
8.3.1	Método de Newton	13
8.3.2	BFGS y otros métodos quasi-Newton	14
8.3.3	Métodos en regiones de confianza	15
8.4	Descenso por gradiente estocástico	16
8.4.1	Aplicación a problemas de sumas finitas	17

8.4.2	Ejemplo: SGD para ajustar regresión lineal	18
8.4.3	Elección del tamaño de paso	19
8.4.6	SGD preconditionado	20
8.5	Optimización con restricciones	21
8.5.1	Multiplicadores de Lagrange	21
8.5.2	Las condiciones KKT	22

8.1. Introducción

8.1.1. Optimización local vs global

► Decimos que un algoritmo es globalmente convergente si garantiza su convergencia a un punto estacionario del objetivo a partir de cualquier de cualquier punto de partida; esto es, el algoritmo termina hallando:

1. Un óptimo global
2. Un óptimo global o local
3. Un óptimo global, local o un punto de silla
4. Ninguna de las anteriores

La 3.

8.1.1.1. Condiciones de optimalidad local

- Sean $\mathcal{L}(\theta)$ un objetivo doblemente diferenciable, $g(\theta) = \nabla \mathcal{L}(\theta)$ el vector gradiente y $\mathbf{H}(\theta) = \nabla^2 \mathcal{L}(\theta)$ la matriz Hessiana. Sean $\theta^* \in \mathbb{R}^D$ un punto, $g^* = g(\theta^*)|_{\theta^*}$ el gradiente en dicho punto y $\mathbf{H}^* = \mathbf{H}(\theta)|_{\theta^*}$ la correspondiente Hessiana. Una condición suficiente para que θ^* sea un mínimo local de $\mathcal{L}(\theta)$ es que $g^* = 0$ y que $\mathbf{H}^*$ sea:

1. Indefinida
2. Semi-definida negativa
3. Semi-definida positiva
4. Ninguna de las anteriores; con $g^* = 0$ basta

La 4.

8.1.2. Optimización con o sin restricciones

► Indica la afirmación incorrecta:

1. La adición de restricciones puede cambiar el número de óptimos
2. Si añadimos muchas restricciones, el conjunto de soluciones posibles puede reducirse mucho, hasta el vacío, y complicar el problema de hallar una solución posible (sin importar su coste)
3. Una estrategia usual para resolver problemas con restricciones consiste en eliminar una o más restricciones, añadiendo un término al objetivo por cada restricción eliminada que lo penalice en función del grado de incumplimiento de la restricción
4. Otra estrategia usual para (tratar de) resolver problemas con restricciones consiste en ignorar una o más restricciones de desigualdad y ya está

La 4; sería correcta si, en lugar de decir “ya está”, dijese “comprobar si la solución hallada las cumple”

8.1.3. Optimización convexa vs no-convexa

- ▶ En optimización convexa, tanto el conjunto de soluciones posibles como el objetivo son convexos. Indica la afirmación incorrecta:
 1. Si el objetivo es fuertemente convexo, existe un único óptimo
 2. Si el objetivo es estrictamente convexo, existe un único óptimo
 3. Cada óptimo local es global
 4. Todas son correctas

La 4.

8.1.4. Optimización suave vs no-suave

► Indica la afirmación incorrecta:

1. En optimización suave, tanto el objetivo como las restricciones son funciones continuamente diferenciables
2. La constante de Lipschitz mide el grado de suavidad de una función
3. En optimización no suave, existen puntos en los que el gradiente del objetivo o las restricciones no están bien definidos
4. Todas son correctas

La 4.

8.2. Métodos de primer orden

- ▶ En relación con los métodos de optimización de primer orden, indica la afirmación incorrecta:
 1. Son métodos iterativos basados en derivadas de primer orden del objetivo
 2. Dependen en gran medida de la dirección de descenso y factor de aprendizaje aplicados en cada iteración
 3. Terminan al alcanzar un óptimo local
 4. Aprovechan que el gradiente es fácil de calcular y almacenar, pero no modelan la curvatura del espacio, por lo que convergen lentamente

La 3, ya que terminan en un punto estacionario, de gradiente nulo, que también podría ser un punto de silla o incluso un pésimo local.

8.2.1. Dirección de descenso

- ▶ Descenso por gradiente, o descenso más pronunciado, consiste en escoger la dirección de descenso:
 1. Del gradiente
 2. Del gradiente con signo cambiado
 3. Cualquier combinación lineal de las anteriores
 4. Ninguna de las anteriores

La 2. La 1 es ascenso por gradiente.

8.2.2. Tamaño de paso o factor de aprendizaje

- ▶ Los métodos de primer orden deben ajustar adecuadamente el tamaño de paso o factor de aprendizaje aplicado en cada iteración. Indica la afirmación incorrecta:
 1. La opción más simple consiste en usar un valor constante, pero el método puede no converger o hacerlo muy lentamente
 2. Búsqueda lineal consiste en hallar el tamaño de paso óptimo en la dirección escogida mediante optimización
 3. En general, búsqueda lineal puede resolverse aproximadamente mediante métodos iterativos
 4. Todas son correctas

La 4.

- Completa el script para minimizar $\mathcal{L}(\theta) = \theta^2$ con descenso por gradiente a partir de $\theta_0 = 10$, tamaño de paso 0.2 y tolerancia 0.01

8.2.2.gd.py

```
1 import numpy as np
2 grad, theta, eta, tol = lambda t: 2*t, 10.0, 0.2, 0.01
3 while True:
4     → delta = -eta * grad(theta)
5     → if np.all(np.abs(delta) <= tol):
6         → break
7     → theta += delta
8     → print(round(theta, 3))
```

8.2.2.gd.out

```
1 6.0
2 3.6
3 2.16
4 1.296
5 0.778
6 0.467
7 0.28
8 0.168
9 0.101
10 0.06
11 0.036
12 0.022
```

8.2.3. Ratios de convergencia

- ▶ En relación con el ratio de convergencia de descenso por gradiente, indica la afirmación incorrecta:
 1. Es lineal en problemas convexos con gradiente acotado por una constante de Lipschitz
 2. Si el objetivo es cuadrático de matriz A definida positiva, el ratio será mayor cuanto menor sea el número de condición de A (cuanto más se parezca el objetivo a un bol semi-esférico)
 3. Si el objetivo no es globalmente cuadrático, pero sí localmente cuadrático alrededor de un óptimo local, el ratio dependerá del número de condición de la Hessiana en el mismo
 4. Todas son correctas

La 4.

8.2.4. Momentum

- ▶ Momentum modifica descenso por gradiente con el fin de acelerar la convergencia. Indica la afirmación incorrecta:
 1. Momentum, o método heavy ball, compara descenso por gradiente con una bola pesada que desciende por una superficie de altura dada por el objetivo; en general, combina linealmente el gradiente actual con la dirección de descenso anterior
 2. En momentum estándar, la dirección de descenso viene a ser una media móvil de gradientes ponderados exponencialmente
 3. El gradiente acelerado de Nesterov, o momentum Nesterov, puede verse como una variante de momentum estándar con look-ahead basado en el momentum actual
 4. Todas son correctas

La 4.

8.3. Métodos de segundo orden

- ▶ Los métodos de optimización de segundo orden son técnicas iterativas basadas en derivadas del objetivo:
 1. De primer orden
 2. De segundo orden
 3. De primer y segundo orden
 4. Ninguna de las anteriores

La 3.

8.3.1. Método de Newton

- En cada iteración, el método de Newton escoge la dirección de descenso que minimiza la aproximación de Taylor de segundo orden del objetivo. Esta dirección es:

1. La inversa de la Hessiana
2. La inversa de la Hessiana por el gradiente
3. La inversa de la Hessiana, con signo cambiado
4. La inversa de la Hessiana por el gradiente, con signo cambiado

La 4.

8.3.2. BFGS y otros métodos quasi-Newton

- ▶ Los métodos quasi-Newton aproximan la Hessiana, o directamente su inversa, mediante técnicas eficientes en tiempo y espacio. En relación con BFGS, uno de métodos quasi-Newton más populares, indica la afirmación incorrecta:
 1. En cada iteración, BFGS aproxima la Hessiana añadiendo dos matrices simétricas de rango uno a la aproximación anterior
 2. Las sucesivas aproximaciones de la Hessiana son definidas positivas si el factor de aprendizaje se ajusta por búsqueda lineal cumpliendo las condiciones de Wolfe
 3. BFGS limitado en memoria es una variante muy popular por su escalabilidad pues no almacena aproximaciones explícitamente
 4. Todas son correctas

La 4.

8.3.3. Métodos en regiones de confianza

- ▶ Newton fija una dirección y ajusta el tamaño del paso por búsqueda lineal, asumiendo que la aproximación cuadrática es válida. Alternativamente, los métodos en regiones de confianza limitan el tamaño del paso con una bola o región de confianza de radio fijo y buscan en ella una dirección que optimice una aproximación del objetivo. Indica la afirmación incorrecta sobre estos métodos:

1. Suelen emplear una aproximación cuadrática al objetivo
2. La minimización de la aproximación cuadrática, sujeta a que ésta se limita a la bola de confianza, resulta en una versión regularizada de la dirección de descenso de Newton conocida como regularización Tikhonov
3. Tikhonov positiviza la Hesssiana añadiéndole $\lambda \mathbf{I}$, $\lambda > 0$
4. Todas son correctas

La 4.

8.4. Descenso por gradiente estocástico

- Optimización estocástica minimiza el valor esperado del objetivo con respecto a una v.a. z añadida, $\mathcal{L}(\theta) = \mathbb{E}_{q(z)}[\mathcal{L}(\theta, z)]$. Indica la afirmación incorrecta:
 1. Descenso por gradiente estocástico (SGD) es un método de optimización estocástica de segundo orden e iterativo
 2. En cada iteración, SGD observa $\mathcal{L}_t(\theta) = \mathcal{L}(\theta, z_t)$, con $z_t \sim q$
 3. SGD asume que q es independiente de θ y que podemos hallar un estimador insesgado del gradiente de $\mathcal{L}_t$
 4. SGD puede resumirse como $\theta_{t+1} = \theta_t - \eta_t g_t$, $g_t = \nabla \mathcal{L}(\theta_t, z_t)$

La 1 ya que SGD no es de segundo orden, sino de primer orden

8.4.1. Aplicación a problemas de sumas finitas

► Indica la afirmación incorrecta:

1. SGD se aplica a problemas de sumas finitas como la minimización del riesgo empírico en aprendizaje supervisado,

$$\mathcal{L}(\boldsymbol{\theta}_t) = \frac{1}{N} \sum_{n=1}^N \ell(\mathbf{y}_n, f(\mathbf{x}_n; \boldsymbol{\theta}_t))$$

2. El gradiente del riesgo empírico con N muestras puede aproximarse con un minibatch de $B \ll N$ muestras

3. El gradiente aproximado con un minibatch es un estimador insesgado del gradiente de $\mathcal{L}$


4. Todas son correctas

La 4.


8.4.2. Ejemplo: SGD para ajustar regresión lineal

- Reproduce el cuaderno de la [Figura 8.16](#)

black line = LMS trajectory towards LS soln (red cross)




RSS vs iteration



8.4.3. Elección del tamaño de paso

- Reproduce el cuaderno de la [Figura 8.17](#)



8.4.6. SGD preconditionado

► SGD preconditionado introduce una matriz de preconditionado $\mathbf{M}_t$, típicamente definida positiva y diagonal y toma $\Delta\theta_t = -\eta_t \mathbf{M}_t^{-1} \mathbf{g}_t$. En relación con algunos de los heurísticos más conocidos de SGD preconditionado, indica la afirmación incorrecta:

1. ADAGRAD hace $\Delta\theta_t = -\eta_t \frac{1}{\sqrt{s_t + \epsilon}} \mathbf{g}_t$, donde s_t denota la suma de gradientes cuadráticos pasados
2. RMSPROP es ADAGRAD sustituyendo s_t por una media móvil ponderada exponencialmente (EWMA)
3. ADDELTA es RMSPROP añadiendo una EWMA de actualizaciones, $\Delta\theta_t = -\eta_t \frac{\sqrt{\delta_{t-1} + \epsilon}}{\sqrt{s_t + \epsilon}} \mathbf{g}_t$ con $\delta_t = \beta \delta_{t-1} + (1 - \beta)(\Delta\theta_t)^2$
4. ADAM es ADDELTA con momentum, $\Delta\theta_t = -\eta_t \frac{1}{\sqrt{s_t + \epsilon}} \mathbf{m}_t$ con $\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t$

La 4; ADAM es RMSPROP con momentum, no ADDELTA.

8.5. Optimización con restricciones

8.5.1. Multiplicadores de Lagrange

► Maximiza $\mathcal{L}(\boldsymbol{\theta}) = \theta_1 + \theta_2$ sujeto a $\theta_1^2 + \theta_2^2 = 1$

$$L(\theta_1, \theta_2, \lambda) = \theta_1 + \theta_2 + \lambda(\theta_1^2 + \theta_2^2 - 1)$$

$$\nabla L = (1 + 2\lambda\theta_1, 1 + 2\lambda\theta_2, \theta_1^2 + \theta_2^2 - 1)^t$$

$$\nabla L = \mathbf{0} \rightarrow \theta_1 = \theta_2 = -\frac{1}{2\lambda}, \lambda \neq 0$$

$$\rightarrow \frac{1}{4\lambda^2} + \frac{1}{4\lambda^2} - 1 = 0 \rightarrow \lambda = \pm \frac{1}{\sqrt{2}}$$

$$\rightarrow \left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2}, -\frac{1}{\sqrt{2}} \right), \left(-\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2}, \frac{1}{\sqrt{2}} \right)$$

Evaluando $\mathcal{L}$ en ambos puntos estacionarios se comprueba que el máximo, $\sqrt{2}$, se alcanza en el primero

8.5.2. Las condiciones KKT

- Sea $\mathcal{L}(\boldsymbol{\theta})$ un objetivo a minimizar sujeto a múltiples restricciones de desigualdad, $\mathbf{g}(\boldsymbol{\theta}) \leq \mathbf{0}$, y de igualdad, $\mathbf{h}(\boldsymbol{\theta}) = \mathbf{0}$. Si $\mathcal{L}$ y $\mathbf{g}$ son convexas, los puntos críticos satisfacen las condiciones de Karush–Kuhn–Tucker. Indica cuál no está correctamente enunciada:

1. Estacionaridad:

$$\nabla \mathcal{L}(\boldsymbol{\theta}^*) + \sum_i \mu_i \nabla g_i(\boldsymbol{\theta}^*) + \sum_j \lambda_j \nabla h_j(\boldsymbol{\theta}^*) = \mathbf{0}$$

2. Factibilidad primal: $\mathbf{g}(\boldsymbol{\theta}^*) \leq \mathbf{0}$, $\mathbf{h}(\boldsymbol{\theta}^*) = \mathbf{0}$

3. Factibilidad dual: $\boldsymbol{\mu} \leq \mathbf{0}$

4. Holgura complementaria:

$$\mu_i g_i(\boldsymbol{\theta}^*) = 0 \quad \text{para toda desigualdad } g_i$$

La 3; debe ser $\boldsymbol{\mu} \geq \mathbf{0}$.