



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Análisis discriminante lineal

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

9.0 Avance	1
9.1 Introducción	3
9.2 Análisis discriminante Gaussiano	4
9.2.1 Fronteras de decisión cuadráticas	5
9.2.2 Fronteras de decisión lineales	9
9.2.3 Conexión entre LDA y regresión logística	11
9.2.4 Ajuste del modelo	15
9.2.4.1 Matriz de covarianzas común	17
9.2.4.2 Matrices de covarianzas diagonales	18
9.2.4.3 Estimación MAP	19
9.2.5 Clasificador por el centroide más próximo	20
9.3 Clasificadores naive Bayes	22
9.3.1 Modelos ejemplo	24
9.3.2 Ajuste del modelo	27
9.3.3 Naive Bayes Bayesiano	30
9.3.4 Conexión de naive Bayes y regresión logística	34

9.4	Clasificadores generativos vs discriminativos	36
9.4.1	Ventajas de los clasificadores discriminativos	37
9.4.2	Ventajas de los clasificadores generativos	38
9.4.3	Tratamiento de datos perdidos	39

9.0. Avance

- ▶ **Introducción:** clasificador generativo ... LDA reúne técnicas para construir **generativos** lineales
- ▶ **Análisis discriminante Gaussiano:** condicionales Gaussianas
 - ▷ **Fronteras de decisión cuadráticas:** caso general ... **QDA**
 - ▷ **Fronteras de decisión lineales:** caso $\Sigma_c = \Sigma$... **LDA**
 - ▷ **Conexión entre LDA y regresión logística:** mismo modelo
 - ▷ **Ajuste del modelo:** verosimilitud **conjunta** ... $\hat{\Sigma}_c$ sobreajustada
 - ↳ **LDA diagonal:** Σ común y **diagonal**
 - ↳ **Regularized discriminant analysis:** estimación MAP de Σ
 - ▷ **Clasificador por el centroide más próximo:** caso más sencillo

- ▶ **Clasificadores naive Bayes: asunción *naive* Bayes!**
 - ▷ **Modelos ejemplo:** Bernoulli, categórico y Gaussiano
 - ▷ **Ajuste del modelo:** verosimilitud *conjunta*
 - ▷ **Naive Bayes Bayesiano:** para categórico
 - ▷ **Conexión de naive Bayes y regresión logística:** naive Bayes categórico coincide con regresión logística multinomial
- ▶ **Clasificadores generativos vs discriminativos:**
 - ▷ **Ventajas de los *discriminativos*:** precisión, preproceso de características y calibrado de posteriors
 - ▷ **Ventajas de los *generativos*:** ajuste, datos perdidos, flexibles respecto a las clases, aprovechamiento de datos no etiquetados y robustez frente a características espurias
 - ▷ **Tratamiento de datos perdidos:** fácil con generativos

9.1. Introducció

- **Clasificador generativo:** modelo que expresa las *posteriors* en función de *priors y densidades condicionales*:

$$p(y = c \mid \mathbf{x}; \boldsymbol{\theta}) = \frac{p(\mathbf{x} \mid y = c; \boldsymbol{\theta})p(y = c; \boldsymbol{\theta})}{\sum_{c'} p(\mathbf{x} \mid y = c'; \boldsymbol{\theta})p(y = c'; \boldsymbol{\theta})} \quad (1)$$

- ▷ Se llama generativo porque explica cómo generar $\mathbf{x}$ por cada c
- ▷ Por el contrario, un **clasificador discriminativo** modela posteriors directamente sin explicar cómo generar $\mathbf{x}$ por cada c
- ▷ Ciertas condicionales resultan en posteriors (log-)lineales con $\mathbf{x}$:

$$\log p(y = c \mid \mathbf{x}; \boldsymbol{\theta}) = \mathbf{w}^t \mathbf{x} + \text{const} \quad (2)$$

donde $\mathbf{w}$ se deriva de $\boldsymbol{\theta}$

- **Análisis discriminante lineal (LDA):** técnicas para construir clasificadores generativos lineales

9.2. Análisis discriminante Gaussiano

- *Análisis discriminante Gaussiano (GDA)*: modelo generativo con densidades condicionales Gaussianas

$$p(\mathbf{x} \mid y = c, \boldsymbol{\theta}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c) \quad (3)$$

- Las posteriors son proporcionales a las Gaussianas:

$$p(y = c \mid \mathbf{x}, \boldsymbol{\theta}) \propto \pi_c \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c) \quad (4)$$

donde π_c es el prior de la clase c , $\pi_c = p(y = c)$

- Ignoramos la constante de normalización en el denominador de las posteriors porque es independiente de c (y, por tanto, no influye en el cálculo de la posterior máxima)


9.2.1. Fronteras de decisión cuadráticas

► **Función discriminante:** a partir de (4) obtenemos la log-posterior


$$\log p(y = c \mid \mathbf{x}, \boldsymbol{\theta}) = \log \pi_c - \frac{1}{2} \log |2\pi \boldsymbol{\Sigma}_c| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_c)^t \boldsymbol{\Sigma}_c^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) \quad (5)$$

► **Análisis discriminante cuadrático (QDA):** la frontera decisión entre cualquier par de clases, c y c' , es función cuadrática de $\mathbf{x}$


► *Ejemplo:* datos 2d de 3 clases



► *Ejemplo (cont.):* Gaussianas condicionales ajustadas



► *Ejemplo (cont.):* fronteras cuadráticas



9.2.2. Fronteras de decisión lineales

► *Matriz de covarianzas común, ligada o compartida:* $\Sigma_c = \Sigma$

$$\log p(y = c \mid \mathbf{x}, \boldsymbol{\theta}) = \log \pi_c - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_c)^t \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) + \text{const} \quad (6)$$


$$= \underbrace{\log \pi_c - \frac{1}{2} \boldsymbol{\mu}_c^t \Sigma^{-1} \boldsymbol{\mu}_c}_{\gamma_c} + \mathbf{x}^t \underbrace{\Sigma^{-1} \boldsymbol{\mu}_c}_{\boldsymbol{\beta}_c} + \underbrace{\text{const} - \frac{1}{2} \mathbf{x}^t \Sigma^{-1} \mathbf{x}}_{\kappa} \quad (7)$$

$$= \gamma_c + \mathbf{x}^t \boldsymbol{\beta}_c + \kappa \quad (8)$$

donde el último término, κ , es independiente de c , por lo que puede ignorarse

► *Análisis discriminante lineal (LDA):* ya que la función discriminante es lineal

► *Ejemplo (cont.):* fronteras lineales



9.2.3. Conexión entre LDA y regresión logística

- ▶ LDA puede reescribirse como:

$$p(y = c \mid \mathbf{x}, \boldsymbol{\theta}) = \frac{\exp(\boldsymbol{\beta}_c^t \mathbf{x} + \gamma_c)}{\sum_{c'} \exp(\boldsymbol{\beta}_{c'}^t \mathbf{x} + \gamma_{c'})} = \frac{\exp(\mathbf{w}_c^t [1, \mathbf{x}])}{\sum_{c'} \exp(\mathbf{w}_{c'}^t [1, \mathbf{x}])} \quad (9)$$

con $\mathbf{w}_c = [\gamma_c, \boldsymbol{\beta}_c]$

- ▶ Así pues, LDA coincide con regresión logística (multinomial)
- ▶ Diferencia clave en entrenamiento:
 - ▷ LDA ajusta Gaussianas y priors mediante maximización de la verosimilitud conjunta $p(\mathbf{x}, y \mid \boldsymbol{\theta})$; luego deriva $\mathbf{w}$ a partir de $\boldsymbol{\theta}$
 - ▷ Regresión logística estima $\mathbf{w}$ directamente mediante maximización de la verosimilitud condicional $p(y \mid \mathbf{x}, \mathbf{w})$

► **Caso binario** $c = 0, 1$:

► La posterior es:

$$p(y = 1 \mid \mathbf{x}, \boldsymbol{\theta}) = \frac{\exp(\boldsymbol{\beta}_1^t \mathbf{x} + \gamma_1)}{\exp(\boldsymbol{\beta}_1^t \mathbf{x} + \gamma_1) + \exp(\boldsymbol{\beta}_0^t \mathbf{x} + \gamma_0)} \quad (10)$$

$$= \frac{1}{1 + \exp((\boldsymbol{\beta}_0 - \boldsymbol{\beta}_1)^t \mathbf{x} + (\gamma_0 - \gamma_1))} \quad (11)$$

$$= \sigma((\boldsymbol{\beta}_1 - \boldsymbol{\beta}_0)^t \mathbf{x} + (\gamma_1 - \gamma_0)) \quad (12)$$

donde $\sigma(\eta)$ es la sigmoide

► Tenemos que:

$$\gamma_1 - \gamma_0 = -\frac{1}{2} \boldsymbol{\mu}_1^t \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_1 + \frac{1}{2} \boldsymbol{\mu}_0^t \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_0 + \log(\pi_1/\pi_0) \quad (13)$$

$$= -\frac{1}{2} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_0) + \log(\pi_1/\pi_0) \quad (14)$$

▷ Así pues, si definimos

$$\mathbf{w} = \boldsymbol{\beta}_1 - \boldsymbol{\beta}_0 = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) \quad (15)$$

$$\mathbf{x}_0 = \frac{1}{2}(\boldsymbol{\mu}_1 + \boldsymbol{\mu}_0) - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) \frac{\log(\pi_1/\pi_0)}{(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)} \quad (16)$$

entonces

$$\mathbf{w}^t \mathbf{x}_0 = \frac{1}{2} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_0) - \log(\pi_1/\pi_0) \quad (17)$$

$$= -(\gamma_1 - \gamma_0) \quad (18)$$

y la posterior coincide con regresión logística binaria


$$p(y = 1 \mid \mathbf{x}, \boldsymbol{\theta}) = \sigma(\mathbf{w}^t(\mathbf{x} - \mathbf{x}_0)) \quad (19)$$

▷ Regla de decisión MAP:

$$\hat{y}(\mathbf{x}) = 1 \quad \text{sii} \quad \mathbf{w}^t \mathbf{x} > c \quad \text{con} \quad c = \mathbf{w}^t \mathbf{x}_0 \quad (20)$$

▷ Si $\pi_0 = \pi_1 = 0.5$, el umbral es $c = \frac{1}{2} \mathbf{w}^t (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_0)$

- ▷ Caso $\Sigma = \sigma^2 \mathbf{I}$: $w = \sigma^{-2}(\mu_1 - \mu_0)$, por lo que clasificamos proyectando en la línea que une los centroides y comparando con x_0 (a mitad de camino si las clases son equiprobables)



9.2.4. Ajuste del modelo

► *Función de verosimilitud (conjunta):*

$$p(\mathcal{D} \mid \theta) = \prod_{n=1}^N \text{Cat}(y_n \mid \boldsymbol{\pi}) \prod_{c=1}^C \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)^{\mathbb{1}(y_n=c)} \quad (21)$$

► *Log-verosimilitud:*

$$\begin{aligned} \log p(\mathcal{D} \mid \boldsymbol{\theta}) = & \left[\sum_{n=1}^N \sum_{c=1}^C \mathbb{1}(y_n = c) \log \pi_c \right] \\ & + \sum_{c=1}^C \left[\sum_{n:y_n=c} \log \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c) \right] \end{aligned} \quad (22)$$

por lo que $\boldsymbol{\pi}$ y $(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$ se optimizan separadamente

► **Estimador máximo-verosímil:** ver secciones 4.2.4 y 4.2.6

$$\hat{\pi}_c = \frac{N_c}{N} \quad (23)$$

$$\hat{\boldsymbol{\mu}}_c = \frac{1}{N_c} \sum_{n:y_n=c} \mathbf{x}_n \quad (24)$$

$$\hat{\boldsymbol{\Sigma}}_c = \frac{1}{N_c} \sum_{n:y_n=c} (\mathbf{x}_n - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_n - \hat{\boldsymbol{\mu}}_c)^t \quad (25)$$

► $\hat{\boldsymbol{\Sigma}}_c$ se sobre-ajusta si N_c es pequeño en comparación con D

9.2.4.1. Matriz de covarianzas común

- Con $\Sigma_c = \Sigma$ obtenemos un estimador más fiable:

$$\hat{\Sigma} = \frac{1}{N} \sum_{c=1}^C \sum_{n:y_n=c} (\mathbf{x}_n - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_n - \hat{\boldsymbol{\mu}}_c)^t \quad (26)$$

9.2.4.2. Matrices de covarianzas diagonales

- ▶ Con Σ_c diagonales, reducimos de $O(CD^2)$ a $O(CD)$ parámetros
- ▶ Perdemos la capacidad de capturar correlaciones entre variables
- ▶ Equivale a realizar la *asunción naive Bayes*
- ▶ *LDA diagonal*: matriz de covarianzas común y diagonal

9.2.4.3. Estimación MAP

- ▶ La asunción de matrices de covarianzas diagonales es muy fuerte
- ▶ Una alternativa más flexible consiste en aplicar estimación MAP, en lugar de MLE, de una matriz de covarianzas completa (común)
- ▶ *Análisis discriminante regularizado (RDA)*: aplica estimación MAP de Σ común

$$\hat{\Sigma}_{\text{map}} = \lambda \text{diag}(\hat{\Sigma}_{\text{mle}}) + (1 - \lambda) \hat{\Sigma}_{\text{mle}} \quad (27)$$

donde λ controla la fuerza de la regularización

9.2.5. Clasificador por el centroide más próximo

- *Clasificador por el centroide más próximo (NCM, nearest mean classifier):* asumiendo priors idénticos

$$\hat{y}(\mathbf{x}) = \arg \max_c \log p(y = c \mid \mathbf{x}, \boldsymbol{\theta}) \quad (28)$$

$$= \arg \min_c (\mathbf{x} - \boldsymbol{\mu}_c)^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) \quad (29)$$

$$= \arg \min_c d_{\text{Mah}}^2(\mathbf{x}, \boldsymbol{\mu}_c) \quad (30)$$

- Una generalización inmediata de NCM consiste en usar cualquier otra métrica $d(\cdot, \cdot)$ en lugar de Manhattan:

$$\hat{y}(\mathbf{x}) = \arg \min_c d^2(\mathbf{x}, \boldsymbol{\mu}_c) \quad (31)$$

► *Aprendizaje de la métrica:*

▷ Aproximación sencilla:

$$d^2(\mathbf{x}, \boldsymbol{\mu}_c) = \|\mathbf{x} - \boldsymbol{\mu}_c\|_{\mathbf{W}}^2 \quad (32)$$

$$= (\mathbf{x} - \boldsymbol{\mu}_c)^t (\mathbf{W}\mathbf{W}^t) (\mathbf{x} - \boldsymbol{\mu}_c) \quad (33)$$

$$= \|\mathbf{W}(\mathbf{x} - \boldsymbol{\mu}_c)\|^2 \quad (34)$$

▷ La posterior correspondiente es:

$$p(y = c \mid \mathbf{x}, \boldsymbol{\mu}, \mathbf{W}) = \frac{\exp(-\frac{1}{2}\|\mathbf{W}(\mathbf{x} - \boldsymbol{\mu}_c)\|_2^2)}{\sum_{c'=1}^C \exp(-\frac{1}{2}\|\mathbf{W}(\mathbf{x} - \boldsymbol{\mu}_{c'})\|_2^2)} \quad (35)$$

▷ $\mathbf{W}$ se aprende mediante descenso por gradiente; una vez aprendida, NCM permite el *aprendizaje en un paso (one-shot learning)* de nuevas clases (añadiendo un centroide por cada una)

9.3. Clasificadores naive Bayes

► *Asunción naive Bayes:*

- Suponemos que las características son condicionalmente independientes dada la clase
- Se llama “naive” porque es de ingenuos creer que se cumpla en la práctica, si bien suele resultar en buenos clasificadores
- La principal razón tras los buenos resultados prácticos es que conduce a modelos muy sencillos, con $O(CD)$ parámetros
- En concreto, asumimos que las condicionales son de la forma

$$p(\mathbf{x} \mid y = c, \boldsymbol{\theta}) = \prod_{d=1}^D p(x_d \mid y = c, \boldsymbol{\theta}_{dc}) \quad (36)$$

donde $\boldsymbol{\theta}_{dc}$ son los parámetros de la característica d en la clase c

- **Clasificador naive Bayes (NBC):** calcula las posteriors con base en la asunción naive Bayes,

$$p(y = c \mid \mathbf{x}, \boldsymbol{\theta}) = \frac{p(y = c \mid \boldsymbol{\pi}) \prod_{d=1}^D p(x_d \mid y = c, \boldsymbol{\theta}_{dc})}{\sum_{c'} p(y = c' \mid \boldsymbol{\pi}) \prod_{d=1}^D p(x_d \mid y = c', \boldsymbol{\theta}_{dc'})} \quad (37)$$

donde π_c es el prior de la clase c y $\boldsymbol{\theta} = (\boldsymbol{\pi}, \{\boldsymbol{\theta}_{dc}\})$

- Obviamente, NBC requiere especificar la forma de las condicionales por cada clase c y característica d

$$p(x_d \mid y = c, \boldsymbol{\theta}_{dc}) = \dots \quad (38)$$

cosa que dependerá del tipo de características: binarias, categóricas o reales.


9.3.1. Modelos ejemplo

- **Naive Bayes Bernoulli:** en el caso de características binarias, $x_d \in \{0, 1\}$, podemos emplear la Bernoulli

$$p(\mathbf{x} \mid y = c, \boldsymbol{\theta}) = \prod_{d=1}^D \text{Ber}(x_d \mid \theta_{dc}) \quad (39)$$

donde θ_{dc} es la probabilidad de que $x_d = 1$ en la clase c

- *Ejemplo:* prototipos y predicciones en MNIST (84 % acierto)



- **Naive Bayes categórico:** en el caso de características categóricas, $x_d \in \{1, \dots, K\}$, podemos emplear la categórica

$$p(\mathbf{x} \mid y = c, \boldsymbol{\theta}) = \prod_{d=1}^D \text{Cat}(x_d \mid \boldsymbol{\theta}_{dc}) \quad (40)$$

donde θ_{dck} es la probabilidad de que $x_d = k$ en la clase c

- **Naive Bayes Gaussiano:** en el caso de características reales, $x_d \in \mathbb{R}$, podemos emplear la Gaussiana (univariada)

$$p(\mathbf{x} \mid y = c, \boldsymbol{\theta}) = \prod_{d=1}^D \mathcal{N}(x_d \mid \mu_{dc}, \sigma_{dc}^2) \quad (41)$$

donde μ_{dc} y σ_{dc}^2 son la media y varianza de la característica d en c

- Este modelo coincide con LDA usando matrices de covarianzas diagonales

9.3.2. Ajuste del modelo

► *Función de verosimilitud (conjunta):*

$$p(\mathcal{D} \mid \theta) = \prod_{n=1}^N \text{Cat}(y_n \mid \boldsymbol{\pi}) \prod_{d=1}^D p(x_{nd} \mid y_n, \boldsymbol{\theta}_d) \quad (42)$$

$$= \prod_{n=1}^N \text{Cat}(y_n \mid \boldsymbol{\pi}) \prod_{d=1}^D \prod_{c=1}^C p(x_{nd} \mid \boldsymbol{\theta}_{dc})^{\mathbb{1}(y_n=c)} \quad (43)$$

► *Log-verosimilitud:*

$$\log p(\mathcal{D}|\boldsymbol{\theta}) = \log \left[\prod_{n=1}^N \text{Cat}(y_n | \boldsymbol{\pi}) \prod_{d=1}^D p(x_{nd} | y_n, \boldsymbol{\theta}_d) \right] \quad (44)$$

$$\begin{aligned} &= \left[\sum_{n=1}^N \sum_{c=1}^C \mathbb{1}(y_n = c) \log \pi_c \right] \\ &+ \sum_{c=1}^C \sum_{d=1}^D \left[\sum_{n:y_n=c} \log p(x_{nd} | \boldsymbol{\theta}_{dc}) \right] \end{aligned} \quad (45)$$

$$= \log p(\mathcal{D}_y | \boldsymbol{\pi}) + \sum_c \sum_d \log p(\mathcal{D}_{dc} | \boldsymbol{\theta}_{dc}) \quad (46)$$

donde $\mathcal{D}_y = \{y_n\}_{n=1}^N$ son las etiquetas y $\mathcal{D}_{dc} = \{x_{nd} : y_n = c\}_{n=1}^N$ son los valores de la característica d en la clase c

► $\boldsymbol{\pi}$ y cada $\boldsymbol{\theta}_{dc}$ se optimizan separadamente

► *Estimador máximo-verosímil:*

► Priors:

$$\hat{\pi}_c = \frac{N_c}{N} \quad (47)$$

► Naive Bayes Bernoulli: $x_d \in \{0, 1\}$

$$\hat{\theta}_{dc} = \frac{N_{dc}}{N_c} \quad (48)$$

► Naive Bayes categórico: $x_d \in \{1, \dots, K\}$

$$\hat{\theta}_{dck} = \frac{N_{cdk}}{\sum_{k'=1}^K N_{cdk'}} = \frac{N_{dck}}{N_c} \quad (49)$$

► Naive Bayes Gaussiano: $x_d \in \mathbb{R}$

$$\hat{\mu}_{dc} = \frac{1}{N_c} \sum_{n:y_n=c} x_{nd} \quad (50)$$

$$\hat{\sigma}_{dc}^2 = \frac{1}{N_c} \sum_{n:y_n=c} (x_{nd} - \hat{\mu}_{dc})^2 \quad (51)$$

9.3.3. Naive Bayes Bayesiano

- Consideramos naive Bayes categórico:

$$p(x_d \mid \boldsymbol{\theta}_{dc}) = \text{Cat}(x_d \mid \boldsymbol{\theta}_{dc}) \quad \text{con} \quad \theta_{cdk} = p(x_d = k \mid y = c) \quad (52)$$

- Prior conjugado para la categórica condicional de clase:

$$p(\boldsymbol{\theta}_{dc}) = \text{Dir}(\boldsymbol{\theta}_{dc} \mid \boldsymbol{\beta}_{dc}) \quad (53)$$

donde β_{cdk} puede interpretarse como una **pseudo-cuenta** que proviene de datos a priori y se corresponde con la cuenta N_{cdk}

- Densidad Dirichlet:

$$\text{Dir}(\boldsymbol{\theta}_{dc} \mid \boldsymbol{\beta}_{dc}) = \frac{1}{B(\boldsymbol{\beta}_{dc})} \prod_{k=1}^K \theta_{cdk}^{\beta_{cdk}-1} \quad (54)$$

donde $B(\boldsymbol{\beta}_{dc})$ es la función beta multivariada

- Prior conjugado para la categórica a priori:

$$p(\boldsymbol{\pi}) = \text{Dir}(\boldsymbol{\pi} \mid \boldsymbol{\alpha}) \quad (55)$$

$$= \frac{1}{B(\boldsymbol{\alpha})} \prod_{c=1}^C \pi_c^{\alpha_c - 1} \quad (56)$$

donde α_c puede interpretarse como una *pseudo-cuenta* que proviene de datos a priori y se corresponde con la cuenta N_c

- Posterior en forma cerrada:

$$p(\boldsymbol{\theta} \mid \mathcal{D}) = \text{Dir}(\boldsymbol{\pi} \mid \widehat{\boldsymbol{\alpha}}) \prod_{d=1}^D \prod_{c=1}^C \text{Dir}(\boldsymbol{\theta}_{dc} \mid \widehat{\boldsymbol{\beta}}_{dc}) \quad (57)$$

donde $\widehat{\alpha}_c = \widetilde{\alpha}_c + N_c$ y $\widehat{\beta}_{dck} = \widetilde{\beta}_{dck} + N_{dck}$

► Distribución predictiva a posteriori:

▷ Prior sobre las etiquetas de clase:

$$p(y \mid \mathcal{D}) = \text{Cat}(y \mid \bar{\pi}) \quad (58)$$

con

$$\bar{\pi} = \frac{\widehat{\alpha}_c}{\sum_{c'} \widehat{\alpha}_{c'}} \quad (59)$$

▷ Características:

$$p(x_d = k \mid y = c, \mathcal{D}) = \bar{\theta}_{dck} \quad (60)$$

con

$$\bar{\theta}_{dck} = \frac{\widehat{\beta}_{dck}}{\sum_{k'} \widehat{\beta}_{dck'}} = \frac{\widetilde{\beta}_{dck} + N_{dck}}{\sum_{k'} \widetilde{\beta}_{dck'} + N_{dck'}} \quad (61)$$

▷ ***Suavizado Laplace*** o ***add-one***:

→ Asume $\widetilde{\beta}_{cdk} = 1$, esto es, añade 1 a todas las cuentas empíricas antes de normalizar

→ *Ejemplo*: en el caso binario ($k = 0, 1$)

$$\bar{\theta}_{dc} = \frac{\widetilde{\beta}_{dc1} + N_{dc1}}{\widetilde{\beta}_{dc0} + N_{dc0} + \widetilde{\beta}_{dc1} + N_{dc1}} = \frac{1 + N_{dc1}}{2 + N_c} \quad (62)$$

▷ Distribución predictiva sobre las etiquetas de clase:

$$p(y = c \mid \mathbf{x}, \mathcal{D}) \propto p(y = c \mid \mathcal{D}) \prod_d p(x_d \mid y = c, \mathcal{D}) \quad (63)$$

$$= \bar{\pi}_c \prod_d \prod_k \bar{\theta}_{dck}^{1(x_d=k)} \quad (64)$$

9.3.4. Conexión de naive Bayes y regresión logística

► *El modelo NBC coincide con regresión logística multinomial:*

▷ Consideramos naive Bayes categórico:

$$p(\mathbf{x} \mid y = c, \boldsymbol{\theta}) = \prod_{d=1}^D \text{Cat}(x_d \mid y = c, \boldsymbol{\theta}) \quad (65)$$

$$= \prod_{d=1}^D \prod_{k=1}^K \theta_{dck}^{x_{dk}} \quad (66)$$

donde $x_{dk} = \mathbb{1}(x_d = k)$, esto es, $\mathbf{x}_d$ es una codificación one-hot de la característica d

▷ Posterior:

$$p(y = c \mid \mathbf{x}, \boldsymbol{\theta}) = \frac{\pi_c \prod_d \prod_k \theta_{dck}^{x_{dk}}}{\sum_{c'} \pi_{c'} \prod_d \prod_k \theta_{dc'k}^{x_{dk}}} \quad (67)$$

$$= \frac{\exp[\log \pi_c + \sum_d \sum_k x_{dk} \log \theta_{dck}]}{\sum_{c'} \exp[\log \pi_{c'} + \sum_d \sum_k x_{dk} \log \theta_{dc'k}]} \quad (68)$$

$$= \frac{\exp[\boldsymbol{\beta}_c^t \mathbf{x} + \gamma_c]}{\sum_{c'} \exp[\boldsymbol{\beta}_{c'}^t \mathbf{x} + \gamma_{c'}]} \quad (69)$$

escogiendo $\boldsymbol{\beta}_c$ y γ_c adecuadamente, por lo que el modelo NBC coincide con regresión logística (multinomial)

► *La diferencia se halla en el entrenamiento:*

- ▷ NB optimiza la verosimilitud conjunta, $\prod_n p(y_n, \mathbf{x}_n \mid \boldsymbol{\theta})$
- ▷ Regresión logística optimiza la condicional, $\prod_n p(y_n \mid \mathbf{x}_n, \boldsymbol{\theta})$


9.4. Clasificadores generativos vs discriminativos

► Clasificador generativo

$$p(\mathbf{x}, y) = p(y) p(\mathbf{x} | y)$$

Aprende priors y condicionales;
luego deriva posteriors

Puede *generar* muestras




► Clasificador discriminativo

$$p(y | \mathbf{x})$$

Aprende posteriors directamente

No puede generar muestras



9.4.1. Ventajas de los clasificadores discriminativos

- ▶ **Mejor precisión predictiva:** pues $p(y | x)$ suele ser más fácil de aprender y no deben “malgastar esfuerzos” modelando la distribución de los datos
- ▶ **Facilitan el preproceso de características:** por ejemplo, mediante expansión polinómica del vector de características, cosa complicada de hacer con generativos pues las nuevas características pueden exhibir correlaciones complejas difíciles de modelar
- ▶ **Probabilidades bien calibradas:** algunos generativos, por ejemplo naive Bayes, se basan en asunciones poco realistas que suelen conducir a posteriors extremas; sin embargo, los discriminativos, por ejemplo regresión logística, suelen estar mejor calibrados en términos de estimación de posteriors

9.4.2. Ventajas de los clasificadores generativos

- ▶ **Fáciles de ajustar:** usualmente mediante conteo y promediado; en contraste, regresión logística requiere resolver un problema de optimización convexo, y las redes neuronales uno no convexo, lo que se traduce en procesos computacionalmente muy costosos
- ▶ **Facilitan el tratamiento de datos perdidos:** gracias al modelado de condicionales, cosa que en los discriminativos no es posible
- ▶ **Pueden ajustar clases separadamente:** por lo general es así, lo que permite añadir nuevas clases sin reentrenar las demás
- ▶ **Pueden aprovechar datos de entrenamiento no etiquetados:** para aprendizaje semi-supervisado (difícil con discriminativos)
- ▶ **Pueden ser más robustos frente a características espúrias (degeneradas):** al capturar los mecanismos causales del proceso generativo subyacente

9.4.3. Tratamiento de datos perdidos

► Con generativos, marginalizamos los valores perdidos

► *Ejemplo:* perdemos el valor de x_1

▷ Posterior en función de condicional marginalizada:

$$p(y = c \mid \mathbf{x}_{2:D}, \boldsymbol{\theta}) \propto p(y = c \mid \boldsymbol{\pi}) p(\mathbf{x}_{2:D} \mid y = c, \boldsymbol{\theta}) \quad (70)$$

$$= p(y = c \mid \boldsymbol{\pi}) \sum_{x_1} p(x_1, \mathbf{x}_{2:D} \mid y = c, \boldsymbol{\theta}) \quad (71)$$

▷ Con naive Bayes, basta ignorar el término con x_1 :

$$\sum_{x_1} p(x_1, \mathbf{x}_{2:D} \mid y = c, \boldsymbol{\theta}) = \left[\sum_{x_1} p(x_1 \mid \boldsymbol{\theta}_{1c}) \right] \prod_{d=2}^D p(x_d \mid \boldsymbol{\theta}_{dc}) \quad (72)$$

$$= \prod_{d=2}^D p(x_d \mid \boldsymbol{\theta}_{dc}) \quad (73)$$