



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Regresión logística (actividades)

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

10.1	Introducción	1
10.2	Regresión logística binaria	2
10.2.1	Clasificadores lineales	3
10.2.2	Clasificadores no lineales	4
10.2.3	Estimación máximo-verosímil	5
10.2.4	Descenso por gradiente estocástico	6
10.2.5	Algoritmo Perceptrón	7
10.2.7	Estimación MAP	8
10.3	Regresión logística multinomial	13
10.3.1	Clasificadores lineales y no lineales	14
10.3.2	Estimación máximo-verosímil	15
10.3.3	Optimización basada en gradientes	17

10.1. Introducció

► Regresió logística es (indica la resposta correcta):

1. Un model de classificació lineal
2. Un model de classificació no lineal
3. Un model de regresió lineal
4. Un model de regresió no lineal

10.2. Regresión logística binaria

- Sea un problema de clasificación en dos clases, $y \in \{0, 1\}$, y sea $p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Ber}(y \mid \sigma(\mathbf{w}^t \mathbf{x} + b))$ un modelo de regresión logística binaria con $\mathbf{w} = (3, 3)^t$ y $b = 0$. Determina la probabilidad de que $\mathbf{x} = (0.5, 0.5)^t$ pertenezca a la clase 1 según el modelo dado.

10.2.1. Clasificadores lineales

- Sea un problema de clasificación en dos clases, $y \in \{0, 1\}$, y sea $p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Ber}(y \mid \sigma(\mathbf{w}^t \mathbf{x} + b))$ un modelo de regresión logística binaria con $\mathbf{w} = (3, 3)^t$ y $b = 0$. Determina la logit, $f(\mathbf{x}; \boldsymbol{\theta})$, así como la frontera y regiones de decisión que induce (con pérdida 0-1).

10.2.2. Clasificadores no lineales

► Sea $\mathcal{D} = \{(\mathbf{x}_n, y_n) : \mathbf{x}_n \in \mathbb{R}^D, y_n \in \{0, 1\}\}$, un conjunto de muestras no linealmente separables. Se quiere aprender un modelo de clasificación $p(y | \mathbf{x}; \boldsymbol{\theta})$ que las clasifique sin error (pérdida 0-1 nula). Indica la respuesta correcta:

1. Podemos usar regresión logística binaria convencional, esto es, con $p(y = 1 | \mathbf{x}) = \text{Ber}(y | \sigma(\mathbf{w}^t \mathbf{x} + b))$
- 2.** No podemos usar regresión logística binaria convencional, pero sí regresión logística binaria con una función de preproceso, $\phi(\mathbf{x})$, que linearice las muestras
3. No podemos usar regresión logística binaria, convencional o no, pues necesitamos un modelo de clasificación multi-clase
4. No podemos usar regresión logística binaria, convencional o no, pues es un modelo lineal y necesitamos uno no lineal

10.2.3. Estimación máximo-verosímil


- Demuestra que el gradiente de

$$\text{NLL}(\mathbf{w}) = -\frac{1}{N} \sum_n y_n \log \mu_n + (1 - y_n) \log(1 - \mu_n)$$

con $\mu_n = \sigma(a_n)$, es $\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = \frac{1}{N} \sum_n (\mu_n - y_n) \mathbf{x}_n$

10.2.4. Descenso por gradiente estocástico

- Reproduce el cuaderno de la [Figura 10.1](#)



10.2.5. Algoritmo Perceptrón

- Sea el algoritmo Perceptrón (en clasificación binaria) aplicado a una muestra $(\mathbf{x}_n, y_n)$ para actualizar el vector de parámetros actual, $\mathbf{w}_i$ (supón $x_{n0} = 1$ y $b = w_{i0}$) con factor de aprendizaje $\eta_i = 1$. Si $y_n = 0$ y $\hat{y}_n = \mathbb{1}(\mathbf{w}_i^t \mathbf{x} > 0) = 1$, entonces:

1. $\mathbf{w}_{i+1} = \mathbf{w}_i$

2. $\mathbf{w}_{i+1} = \mathbf{w}_i + \mathbf{x}_n$


3. $\mathbf{w}_{i+1} = \mathbf{w}_i - \mathbf{x}_n$

4. Ninguna de las anteriores


10.2.7. Estimación MAP

- ▶ Reproduce el cuaderno de las Figuras 10.4 y 10.6
 - ▷ Problema de regresión logística binaria 2d con expansión de características polinómicas
 - ▷ Primero se estudia el error en training y test en función del grado de la expansión de características polinómicas
 - ▷ Luego se repite el estudio con grado tres y regularización L2, en función de la varianza del prior (inversa del regularizador)


Degree1




Degree2




Degree3




Degree4







Degree3




Reg1-Degree3




Reg316-Degree3



Reg100000-Degree3







10.3. Regresión logística multinomial

- Sea un problema de clasificación en $C = 3$ clases, $y \in \{1, 2, 3\}$, y sea $p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Cat}(y \mid \mathcal{S}(\mathbf{W}\mathbf{x} + \mathbf{b}))$ un modelo de regresión logística multinomial con $\mathbf{W} = [1, 1; -1, 1; 0, 0]$ y $\mathbf{b} = \mathbf{0}$. Determina la probabilidad de que $\mathbf{x} = [0.5; 0.5]$ pertenezca a la clase 1.

10.3.1. Clasificadores lineales y no lineales

► Reproduce el cuaderno de la [Figura 10.7](#)



10.3.2. Estimación máximo-verosímil

► Sea $\mu_c = \mathcal{S}(\boldsymbol{\eta})_c$ con logits $\boldsymbol{\eta} \in \mathbb{R}^C$. Prueba que:

$$\frac{\partial \mu_c}{\partial \eta_j} = \mu_c(\delta_{cj} - \mu_j) \quad \text{donde} \quad \delta_{cj} = \mathbb{1}(c = j)$$

- Demuestra que el gradiente de

$$\text{NLL}(\boldsymbol{\theta}) = -\frac{1}{N} \sum_n \sum_c y_{nc} \log \mu_{nc}$$

con $\mu_{nc} = \mathcal{S}(f(\mathbf{x}_n; \boldsymbol{\theta}))_c$, es $\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = \frac{1}{N} \sum_n \mathbf{x}_n (\boldsymbol{\mu}_n - \mathbf{y}_n)^t$

10.3.3. Optimización basada en gradientes

- Completa el script para usar regresión logística multinomial en iris:

```
logreg10.3.3+.py
1 from sklearn.datasets import load_iris
2 from sklearn.model_selection import train_test_split
3 from sklearn.linear_model import LogisticRegression
4 from sklearn.metrics import accuracy_score, confusion_matrix
5
6 X, y = load_iris(return_X_y=True)
7 X_train, X_test, y_train, y_test = train_test_split(X, y,
8     ↪ random_state=0)
9
10 y_pred = clf.predict(X_test)
11 print(accuracy_score(y_test, y_pred))
12 print(confusion_matrix(y_test, y_pred))
```

```
logreg10.3.3+.out
1 0.9736842105263158
2 [[13  0  0]
3  [ 0 15  1]
4  [ 0  0  9]]
```