



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Regresión logística (actividades)

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

10.1	Introducción	1
10.2	Regresión logística binaria	2
10.2.1	Clasificadores lineales	3
10.2.2	Clasificadores no lineales	4
10.2.3	Estimación máximo-verosímil	5
10.2.4	Descenso por gradiente estocástico	6
10.2.5	Algoritmo Perceptrón	7
10.2.7	Estimación MAP	8
10.3	Regresión logística multinomial	13
10.3.1	Clasificadores lineales y no lineales	14
10.3.2	Estimación máximo-verosímil	15
10.3.3	Optimización basada en gradientes	17

10.1. Introducció

► Regresió logística es (indica la resposta correcta):

1. Un model de classificació lineal
2. Un model de classificació no lineal
3. Un model de regresió lineal
4. Un model de regresió no lineal

La 1.

10.2. Regresión logística binaria

- Sea un problema de clasificación en dos clases, $y \in \{0, 1\}$, y sea $p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Ber}(y \mid \sigma(\mathbf{w}^t \mathbf{x} + b))$ un modelo de regresión logística binaria con $\mathbf{w} = (3, 3)^t$ y $b = 0$. Determina la probabilidad de que $\mathbf{x} = (0.5, 0.5)^t$ pertenezca a la clase 1 según el modelo dado.

$$\begin{aligned} p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) &= \sigma(\mathbf{w}^t \mathbf{x} + b) \\ &= \sigma((3, 3)(0.5, 0.5)^t + 0) \\ &= \frac{1}{1 + e^{-3}} \\ &= 0.9526 \end{aligned}$$

10.2.1. Clasificadores lineales

- Sea un problema de clasificación en dos clases, $y \in \{0, 1\}$, y sea $p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Ber}(y \mid \sigma(\mathbf{w}^t \mathbf{x} + b))$ un modelo de regresión logística binaria con $\mathbf{w} = (3, 3)^t$ y $b = 0$. Determina la logit, $f(\mathbf{x}; \boldsymbol{\theta})$, así como la frontera y regiones de decisión que induce (con pérdida 0-1).

Logit: $f(\mathbf{x}; \boldsymbol{\theta}) = b + \mathbf{w}^t \mathbf{x} = 3x_1 + 3x_2$

Frontera: $3x_1 + 3x_2 = 0 \rightarrow x_2 = -x_1$

Regiones de decisión:

$$\begin{aligned}\mathcal{R}_1 &= \{\mathbf{x} : p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) > p(y = 0 \mid \mathbf{x}; \boldsymbol{\theta})\} \\ &= \left\{ \mathbf{x} : \frac{p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta})}{p(y = 0 \mid \mathbf{x}; \boldsymbol{\theta})} > 1 \right\} \\ &= \{\mathbf{x} : f(\mathbf{x}; \boldsymbol{\theta}) > 0\} \\ &= \{\mathbf{x} : 3x_1 + 3x_2 > 0\} \\ &= \{\mathbf{x} : x_2 > -x_1\} \\ \mathcal{R}_0 &= \{\mathbf{x} : x_2 < -x_1\}\end{aligned}$$

10.2.2. Clasificadores no lineales

► Sea $\mathcal{D} = \{(\mathbf{x}_n, y_n) : \mathbf{x}_n \in \mathbb{R}^D, y_n \in \{0, 1\}\}$, un conjunto de muestras no linealmente separables. Se quiere aprender un modelo de clasificación $p(y | \mathbf{x}; \boldsymbol{\theta})$ que las clasifique sin error (pérdida 0-1 nula). Indica la respuesta correcta:

1. Podemos usar regresión logística binaria convencional, esto es, con $p(y = 1 | \mathbf{x}) = \text{Ber}(y | \sigma(\mathbf{w}^t \mathbf{x} + b))$
2. No podemos usar regresión logística binaria convencional, pero sí regresión logística binaria con una función de preproceso, $\phi(\mathbf{x})$, que linearice las muestras
3. No podemos usar regresión logística binaria, convencional o no, pues necesitamos un modelo de clasificación multi-clase
4. No podemos usar regresión logística binaria, convencional o no, pues es un modelo lineal y necesitamos uno no lineal

La 2; la 4 es falsa porque puede haber una función de preproceso que linearice las muestras.

10.2.3. Estimación máximo-verosímil

► Demuestra que el gradiente de


$$\text{NLL}(\mathbf{w}) = -\frac{1}{N} \sum_n y_n \log \mu_n + (1 - y_n) \log(1 - \mu_n)$$

con $\mu_n = \sigma(a_n)$, es $\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = \frac{1}{N} \sum_n (\mu_n - y_n) \mathbf{x}_n$

$$\begin{aligned} \frac{\partial \text{NLL}}{\partial w_d} &= -\frac{1}{N} \sum_n y_n \frac{\partial}{\partial w_d} \log \mu_n + (1 - y_n) \frac{\partial}{\partial w_d} \log(1 - \mu_n) \\ &= -\frac{1}{N} \sum_n y_n \frac{1}{\mu_n} \frac{\partial}{\partial w_d} \mu_n - (1 - y_n) \frac{1}{1 - \mu_n} \frac{\partial}{\partial w_d} \mu_n \\ &= -\frac{1}{N} \sum_n \left[\frac{y_n}{\mu_n} - \frac{1 - y_n}{1 - \mu_n} \right] \frac{\partial}{\partial w_d} \mu_n \\ &= -\frac{1}{N} \sum_n \frac{y_n(1 - \mu_n) - (1 - y_n)\mu_n}{\mu_n(1 - \mu_n)} \frac{\partial}{\partial a_n} \sigma(a_n) \frac{\partial a_n}{\partial w_d} \\ &= -\frac{1}{N} \sum_n \frac{y_n - y_n\mu_n - \mu_n + y_n\mu_n}{\mu_n(1 - \mu_n)} \mu_n(1 - \mu_n) x_{nd} \\ &= -\frac{1}{N} \sum_n (y_n - \mu_n) x_{nd} \end{aligned}$$

10.2.4. Descenso por gradiente estocástico

- Reproduce el cuaderno de la [Figura 10.1](#)



10.2.5. Algoritmo Perceptrón

- Sea el algoritmo Perceptrón (en clasificación binaria) aplicado a una muestra $(\mathbf{x}_n, y_n)$ para actualizar el vector de parámetros actual, $\mathbf{w}_i$ (supón $x_{n0} = 1$ y $b = w_{i0}$) con factor de aprendizaje $\eta_i = 1$. Si $y_n = 0$ y $\hat{y}_n = \mathbb{1}(\mathbf{w}_i^t \mathbf{x} > 0) = 1$, entonces:

1. $\mathbf{w}_{i+1} = \mathbf{w}_i$

2. $\mathbf{w}_{i+1} = \mathbf{w}_i + \mathbf{x}_n$





3. $\mathbf{w}_{i+1} = \mathbf{w}_i - \mathbf{x}_n$


4. Ninguna de las anteriores





La 3.


10.2.7. Estimación MAP

- ▶ Reproduce el cuaderno de las Figuras 10.4 y 10.6
 - ▷ Problema de regresión logística binaria 2d con expansión de características polinómicas
 - ▷ Primero se estudia el error en training y test en función del grado de la expansión de características polinómicas
 - ▷ Luego se repite el estudio con grado tres y regularización L2, en función de la varianza del prior (inversa del regularizador)











10.3. Regresión logística multinomial

- Sea un problema de clasificación en $C = 3$ clases, $y \in \{1, 2, 3\}$, y sea $p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Cat}(y \mid \mathcal{S}(\mathbf{W}\mathbf{x} + \mathbf{b}))$ un modelo de regresión logística multinomial con $\mathbf{W} = [1, 1; -1, 1; 0, 0]$ y $\mathbf{b} = \mathbf{0}$. Determina la probabilidad de que $\mathbf{x} = [0.5; 0.5]$ pertenezca a la clase 1.

$$\begin{aligned} p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) &= \mathcal{S}([1, 1; -1, 1; 0, 0][0.5; 0.5])_1 \\ &= \mathcal{S}([1; 0; 0])_1 \\ &= \frac{e}{e + 2} \\ &= 0.5761 \end{aligned}$$

10.3.1. Clasificadores lineales y no lineales

► Reproduce el cuaderno de la [Figura 10.7](#)



10.3.2. Estimación máximo-verosímil

► Sea $\mu_c = \mathcal{S}(\boldsymbol{\eta})_c$ con logits $\boldsymbol{\eta} \in \mathbb{R}^C$. Prueba que:

$$\frac{\partial \mu_c}{\partial \eta_j} = \mu_c(\delta_{cj} - \mu_j) \quad \text{donde} \quad \delta_{cj} = \mathbb{1}(c = j)$$

Sea $S = \sum_i e^{\eta_i}$ el denominador de la softmax.

$$\begin{aligned} \frac{\partial \mu_c}{\partial \eta_j} &= \frac{\partial}{\partial \eta_j} [e^{\eta_c} S^{-1}] \\ &= \left[\frac{\partial}{\partial \eta_j} e^{\eta_c} \right] S^{-1} + e^{\eta_c} (-S^{-2}) \frac{\partial}{\partial \eta_j} S \\ &= (\delta_{cj} e^{\eta_c}) S^{-1} - e^{\eta_c} e^{\eta_j} S^{-2} \\ &= \frac{e^{\eta_c}}{S} \left(\delta_{cj} - \frac{e^{\eta_j}}{S} \right) \\ &= \mu_c(\delta_{cj} - \mu_j) \end{aligned}$$

► Demuestra que el gradiente de

$$\text{NLL}(\boldsymbol{\theta}) = -\frac{1}{N} \sum_n \sum_c y_{nc} \log \mu_{nc}$$

con $\mu_{nc} = \mathcal{S}(f(\mathbf{x}_n; \boldsymbol{\theta}))_c$, es $\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = \frac{1}{N} \sum_n \mathbf{x}_n (\boldsymbol{\mu}_n - \mathbf{y}_n)^t$

Sea $\mathbf{w}_j$ el vector de pesos asociados con la clase j

$$\begin{aligned} \frac{\partial \text{NLL}}{\partial \mathbf{w}_j} &= -\frac{1}{N} \sum_n \sum_c \frac{y_{nc}}{\mu_{nc}} \frac{\partial \mu_{nc}}{\partial \mathbf{w}_j} \\ &= -\frac{1}{N} \sum_n \sum_c \frac{y_{nc}}{\mu_{nc}} \frac{\partial \mu_{nc}}{\partial \eta_{nj}} \frac{\partial \eta_{nj}}{\partial \mathbf{w}_j} \\ &= -\frac{1}{N} \sum_n \sum_c \frac{y_{nc}}{\mu_{nc}} \mu_{nc} (\delta_{cj} - \mu_{nj}) \mathbf{x}_n \\ &= \frac{1}{N} \sum_n \sum_c y_{nc} (\mu_{nj} - \delta_{cj}) \mathbf{x}_n \\ &= \frac{1}{N} \sum_n \left(\left(\sum_c y_{nc} \right) \mu_{nj} \mathbf{x}_n - \sum_c \delta_{cj} y_{nc} \mathbf{x}_n \right) \\ &= \frac{1}{N} \sum_n (\mu_{nj} - y_{nj}) \mathbf{x}_n \end{aligned}$$

10.3.3. Optimización basada en gradientes

- Completa el script para usar regresión logística multinomial en iris:

```
logreg10.3.3+.py
1 from sklearn.datasets import load_iris
2 from sklearn.model_selection import train_test_split
3 from sklearn.linear_model import LogisticRegression
4 from sklearn.metrics import accuracy_score, confusion_matrix
5
6 X, y = load_iris(return_X_y=True)
7 X_train, X_test, y_train, y_test = train_test_split(X, y,
8     ↪ random_state=0)
9 clf = LogisticRegression(C=0.8).fit(X_train, y_train)
10 y_pred = clf.predict(X_test)
11 print(accuracy_score(y_test, y_pred))
12 print(confusion_matrix(y_test, y_pred))
```

```
logreg10.3.3+.out
1 0.9736842105263158
2 [[13  0  0]
3  [ 0 15  1]
4  [ 0  0  9]]
```