



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Aprendizaje Automático Probabilístico

Regresión logística

Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Índice

10.0 Resumen	1
10.1 Introducción	3
10.2 Regresión logística binaria	4
10.2.1 Clasificadores lineales	6
10.2.2 Clasificadores no lineales	9
10.2.3 Estimación máximo-verosímil	10
10.2.4 Descenso por gradiente estocástico	18
10.2.5 Algoritmo Perceptrón	19
10.2.7 Estimación MAP	21
10.2.8 Estandarización	26
10.3 Regresión logística multinomial	27
10.3.1 Clasificadores lineales y no lineales	29
10.3.2 Estimación máximo-verosímil	30
10.3.3 Optimización basada en gradientes	37
10.3.5 Estimación MAP	38

10.0. Resumen

► **Regresión logística binaria:** $y \in \{0, 1\}$

$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Ber}(y \mid \sigma(\mathbf{w}^t \mathbf{x} + b))$$

- **Clasificadores lineales:** frontera lineal con pérdida 0-1
- **Clasificadores no lineales:** linearizamos con preproceso
- **Estimación máximo-verosímil:** NLL, gradiente y Hessiana
- **SGD:** $\mathbf{w}_{t+1} = \mathbf{w}_t - \eta_t(\mu_n - y_n)\mathbf{x}_n$ con batch de una muestra
- **Algoritmo Perceptrón:** SGD con $\mu_n = p(y_n = 1 \mid \mathbf{x}_n) = \hat{y}_n$
- **Estimación MAP:** NLL con regularización L2
- **Estandarización:** conveniente con MAP
- ... IRLS (Newton)

► **Regresión logística multinomial:** $y \in \{1, \dots, C\}$

$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Cat}(y \mid \mathbf{S}(\mathbf{W}\mathbf{x} + \mathbf{b}))$$

- ▷ **Clasificadores lineales y no lineales:** lineales con preproceso
- ▷ **Estimación máximo-verosímil:** NLL, gradiente y Hessiana
- ▷ **Optimización basada en gradientes:** SGD, L-BFGS
- ▷ **Estimación MAP:** NLL con regularización L2
- ▷ ... optimización acotada, clasificadores máximo-entrópicos, clasificación jerárquica, número de clases grande

10.1. Introducción

- *Regresión logística:* modelo de clasificación

$$p(y \mid \mathbf{x}; \boldsymbol{\theta})$$

donde

- ▷ $\mathbf{x} \in \mathbb{R}^D$ es un vector de características de dimensión D
 - ▷ $y \in \{1, \dots, C\}$ es la etiqueta de clase
 - ▷ $\boldsymbol{\theta}$ es un vector de parámetros
-
- *Regresión logística binaria:* $C = 2$

 - *Regresión logística multinomial* o *multiclase:* $C > 2$

10.2. Regresión logística binaria

► *Regresión logística binaria:* con $y \in \{0, 1\}$, modelo

$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Ber}(y \mid \sigma(\mathbf{w}^t \mathbf{x} + b)) \quad (1)$$

donde σ es la función sigmoide, $\mathbf{w}$ son los pesos, b el sesgo y $\boldsymbol{\theta} = (\mathbf{w}, b)$ los parámetros; en otras palabras,

$$p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = \sigma(a) = \frac{1}{1 + e^{-a}} \quad (2)$$


donde $a = \mathbf{w}^t \mathbf{x} + b$ es la log-posibilidad, logit o pre-activación

$$a = \log \left(\frac{p}{1 - p} \right) \quad \text{con} \quad p = p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta})$$

► Con etiquetas $\tilde{y} \in \{-1, +1\}$, dado que $\sigma(-a) = 1 - \sigma(a)$,

$$p(\tilde{y} \mid \mathbf{x}, \boldsymbol{\theta}) = \sigma(\tilde{y}a) \quad (3)$$

$$p(y = 1 \mid x_1, x_2; \mathbf{w}) = \sigma(w_1x_1 + w_2x_2) \quad \text{para varios } \mathbf{w}$$



10.2.1. Clasificadores lineales

► *Regresión logística binaria con pérdida 0-1*: la regla de decisión óptima es

$$f(\mathbf{x}) = \mathbb{1}(p(y = 1 \mid \mathbf{x}) > p(y = 0 \mid \mathbf{x})) \quad (4)$$

$$= \mathbb{1} \left(\log \frac{p(y = 1 \mid \mathbf{x})}{p(y = 0 \mid \mathbf{x})} > 0 \right) \quad (5)$$


$$= \mathbb{1}(a > 0) \quad \text{con} \quad a = \mathbf{w}^t \mathbf{x} + b \quad (6)$$

por lo que la función predictora puede escribirse como

$$f(\mathbf{x}; \boldsymbol{\theta}) = b + \mathbf{w}^t \mathbf{x} = b + \sum_{d=1}^D w_d x_d \quad (7)$$


con frontera de hiperplano normal a $\mathbf{w}$ y ordenada en origen b

$$\mathbf{w}^t (\mathbf{x} - \mathbf{x}_0) = 0 \quad \Leftrightarrow \quad \mathbf{w}^t \mathbf{x} + b = 0 \quad \text{con} \quad b = -\mathbf{w}^t \mathbf{x}_0$$



► **Separabilidad lineal:** decimos que las muestras son linealmente separables si pueden separarse mediante un hiperplano


► La clases virginica y no-virginica de Iris no lo son:



10.2.2. Clasificadores no lineales

► *Linearización de un problema no lineal:* tratamos de linearizar el problema (las muestras) mediante preproceso

► *Ejemplo:* si $\phi(x_1, x_2) = [1, x_1^2, x_2^2]$ y $w = [-R^2, 1, 1]$, entonces $w^t \phi(x) = x_1^2 + x_2^2 - R^2$ y frontera igual a circunferencia de radio R



► Los parámetros de ϕ pueden aprenderse mediante redes

10.2.3. Estimación máximo-verosímil

10.2.3.0. Resumen

- Objetivo: $\mu_n = \sigma(a_n)$, $a_n = \mathbf{w}^t \mathbf{x}_n$, $\mathbb{H}(p, q)$ entropía cruzada binaria

$$\text{NLL}(\mathbf{w}) = -\frac{1}{N} \log \prod_n \text{Ber}(y_n \mid \mu_n) \quad (8)$$

$$= -\frac{1}{N} \sum_n [y_n \log \mu_n + (1 - y_n) \log(1 - \mu_n)] \quad (9)$$

$$= \frac{1}{N} \sum_n \mathbb{H}(y_n, \mu_n) \quad (10)$$

- Gradiente:

$$\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = \frac{1}{N} \sum_n (\mu_n - y_n) \mathbf{x}_n = \frac{1}{N} (\mathbf{1}_N^t (\text{diag}(\boldsymbol{\mu} - \mathbf{y}) \mathbf{X}))^t \quad (11)$$

- Hessiana:

$$\mathbf{H}(\mathbf{w}) = \frac{1}{N} \sum_n (\mu_n(1 - \mu_n) \mathbf{x}_n) \mathbf{x}_n^t = \frac{1}{N} \mathbf{X}^t \mathbf{S} \mathbf{X} \quad (12)$$

donde $\mathbf{S} \triangleq \text{diag}(\mu_1(1 - \mu_1), \dots, \mu_N(1 - \mu_N))$

10.2.3.1. Función objetivo

► **NLL:** escalada por $1/N$ y con sesgo absorbido por $\mathbf{w}$

$$\text{NLL}(\mathbf{w}) = -\frac{1}{N} \log p(\mathcal{D} \mid \mathbf{w}) \quad (13)$$

$$= -\frac{1}{N} \log \prod_n \text{Ber}(y_n \mid \mu_n) \quad (14)$$

$$= -\frac{1}{N} \sum_n \log[\mu_n^{y_n} (1 - \mu_n)^{1-y_n}] \quad (15)$$

$$= -\frac{1}{N} \sum_n [y_n \log \mu_n + (1 - y_n) \log(1 - \mu_n)] \quad (16)$$

$$= \frac{1}{N} \sum_n \mathbb{H}(y_n, \mu_n) \quad (17)$$

donde $\mu_n = \sigma(a_n)$ es la probabilidad de la clase 1, $a_n = \mathbf{w}^t \mathbf{x}$ es la logit y $\mathbb{H}(y_n, \mu_n)$ la entropía cruzada binaria,

$$\mathbb{H}(p, q) = -[p \log q + (1 - p) \log(1 - q)] \quad (18)$$

- Con $\tilde{y}_n \in \{-1, +1\}$ en lugar de $y_n \in \{0, 1\}$:


$$\text{NLL}(\mathbf{w}) = -\frac{1}{N} \sum_{n=1}^N [\mathbb{1}(\tilde{y}_n = 1) \log(\sigma(a_n)) + \mathbb{1}(\tilde{y}_n = -1) \log(\sigma(-a_n))] \quad (19)$$


$$= -\frac{1}{N} \sum_{n=1}^N \log(\sigma(\tilde{y}_n a_n)) \quad (20)$$

$$= \frac{1}{N} \sum_{n=1}^N \log(1 + \exp(-\tilde{y}_n a_n)) \quad (21)$$

- Preferimos la notación $y_n \in \{0, 1\}$ para generalizar a multiclase

► NLL en regresión logística binaria para iris con una característica





10.2.3.2. Optimización del objetivo

- Para hallar el MLE debemos resolver:

$$\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = \mathbf{g}(\mathbf{w}) = \mathbf{0} \quad (22)$$

10.2.3.3. Derivación del gradiente

- Dado que $\mu_n = \sigma(a_n)$ con $a_n = \mathbf{w}^t \mathbf{x}_n$:

$$\frac{d\mu_n}{da_n} = \sigma(a_n)(1 - \sigma(a_n)) \quad (23)$$

- Por la regla de la cadena (y las reglas de cálculo vectorial):

$$\frac{\partial}{\partial w_d} \mu_n = \frac{\partial}{\partial w_d} \sigma(\mathbf{w}^t \mathbf{x}_n) = \frac{\partial}{\partial a_n} \sigma(a_n) \frac{\partial a_n}{\partial w_d} = \mu_n(1 - \mu_n) x_{nd} \quad (24)$$

- El gradiente para b se deriva asumiendo $d = 0$, $w_0 = b$ y $x_{n0} = 1$

► Gradiente de $\log(\mu_n)$:

$$\nabla_{\mathbf{w}} \log(\mu_n) = \frac{1}{\mu_n} \nabla_{\mathbf{w}} \mu_n = (1 - \mu_n) \mathbf{x}_n \quad (25)$$

► Gradiente de $\log(1 - \mu_n)$:

$$\nabla_{\mathbf{w}} \log(1 - \mu_n) = \frac{-\mu_n(1 - \mu_n) \mathbf{x}_n}{1 - \mu_n} = -\mu_n \mathbf{x}_n \quad (26)$$

► Gradiente de $\text{NLL}(\mathbf{w})$:

$$\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = -\frac{1}{N} \sum_n [y_n(1 - \mu_n) \mathbf{x}_n - (1 - y_n) \mu_n \mathbf{x}_n] \quad (27)$$

$$= -\frac{1}{N} \sum_n [y_n \mathbf{x}_n - y_n \mathbf{x}_n \mu_n - \mathbf{x}_n \mu_n + y_n \mathbf{x}_n \mu_n] \quad (28)$$

$$= \frac{1}{N} \sum_n (\mu_n - y_n) \mathbf{x}_n \quad (29)$$

$$= \frac{1}{N} (\mathbf{1}_N^t (\text{diag}(\boldsymbol{\mu} - \mathbf{y}) \mathbf{X}))^t \quad (30)$$

Esto es, la suma de diferencias entre la etiqueta observada y_n y la predicción μ_n , ponderada por las entradas $\mathbf{x}_n$

10.2.3.4. Derivación de la Hessiana

► Hessiana:

$$\mathbf{H}(\mathbf{w}) = \nabla_{\mathbf{w}} \nabla_{\mathbf{w}}^t \text{NLL}(\mathbf{w}) = \frac{1}{N} \sum_n (\mu_n(1 - \mu_n) \mathbf{x}_n) \mathbf{x}_n^t = \frac{1}{N} \mathbf{X}^t \mathbf{S} \mathbf{X} \quad (31)$$

donde

$$\mathbf{S} \triangleq \text{diag}(\mu_1(1 - \mu_1), \dots, \mu_N(1 - \mu_N)) \quad (32)$$

► $\mathbf{H}$ es definida positiva ya que, para todo vector no nulo $\mathbf{v}$:

$$\mathbf{v}^t \mathbf{X}^t \mathbf{S} \mathbf{X} \mathbf{v} = (\mathbf{v}^t \mathbf{X}^t \mathbf{S}^{\frac{1}{2}}) (\mathbf{S}^{\frac{1}{2}} \mathbf{X} \mathbf{v}) = \|\mathbf{v}^t \mathbf{X}^t \mathbf{S}^{\frac{1}{2}}\|_2^2 > 0 \quad (33)$$

pues $\mu_n > 0$ para todo n por el uso de la sigmoide

► NLL es convexa, con un único mínimo global, ya que $\mathbf{H} \succ 0$

► La regularización es necesaria ya que valores de μ_n próximos a 0 o 1 pueden hacer que $\mathbf{H}$ sea quasi-singular

10.2.4. Descenso por gradiente estocástico

- Nuestro objetivo es resolver el problema de optimización:

$$\hat{\mathbf{w}} \triangleq \arg \min_{\mathbf{w}} \mathcal{L}(\mathbf{w}) \quad (34)$$

donde $\mathcal{L}$ es la pérdida, en este caso la log-verosimilitud negativa,

$$\text{NLL}(\mathbf{w}) = -\frac{1}{N} \sum_{n=1}^N [y_n \log \mu_n + (1 - y_n) \log(1 - \mu_n)] \quad (35)$$

con probabilidad de clase 1 $\mu_n = \sigma(a_n)$ y logit $a_n = \mathbf{w}^t \mathbf{x}_n$

- Descenso por gradiente estocástico con minibatch de talla 1:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta_t (\mu_n - y_n) \mathbf{x}_n \quad (36)$$

Converge al óptimo global ya que la pérdida es convexa

10.2.5. Algoritmo Perceptrón

- *Perceptrón*: es el modelo de regresión logística binaria con escalón Heaviside $H(a) \triangleq \mathbb{1}(a > 0)$ en lugar de sigmoide $\sigma(a)$

$$p(y = 1 \mid \mathbf{x}, \boldsymbol{\theta}) = H(f(\mathbf{x}; \boldsymbol{\theta})) \quad (37)$$

$$= \mathbb{1}(\mathbf{w}^t \mathbf{x} + b > 0) \quad (38)$$

- No usamos descenso por gradiente pues H no es diferenciable

- **Algoritmo (de aprendizaje) Perceptrón:** empieza con pesos aleatorios que se actualizan cada vez que el modelo falla como

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta_t(\hat{y}_n - y_n)\mathbf{x}_n = \begin{cases} \mathbf{w}_t & \text{si } y_n = \hat{y}_n \\ \mathbf{w}_t + \eta_t\mathbf{x}_n & \text{si } y_n = 1 \text{ y } \hat{y}_n = 0 \\ \mathbf{w}_t - \eta_t\mathbf{x}_n & \text{si } y_n = 0 \text{ y } \hat{y}_n = 1 \end{cases} \quad (39)$$

donde $(\mathbf{x}_n, y_n)$ y $\eta_t (=1)$ son la muestra y factor de aprendizaje en t

- Es SGD con $\mu_n = p(y_n = 1|\mathbf{x}_n) = \hat{y}_n$ sin cálculo de probabilidades y solo converge si los datos son linealmente separables

10.2.7. Estimación MAP

► Regularización ℓ_2 o penalización de pesos (*weight decay*)

▷ Asumimos un prior Gaussiano

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \mathbf{0}, \lambda^{-1}\mathbf{I}) \quad (40)$$

▷ Objetivo: log-verosimilitud negativa penalizada, PNLL


$$\text{PNLL}(\mathbf{w}) = \text{NLL}(\mathbf{w}) + \lambda \mathbf{w}^t \mathbf{w} \quad (41)$$

$$\nabla_{\mathbf{w}} \text{PNLL}(\mathbf{w}) = \mathbf{g}(\mathbf{w}) + 2\lambda \mathbf{w} \quad (42)$$


$$\nabla_{\mathbf{w}}^2 \text{PNLL}(\mathbf{w}) = \mathbf{H}(\mathbf{w}) + 2\lambda \mathbf{I} \quad (43)$$

donde $\mathbf{g}(\mathbf{w})$ es el gradiente y $\mathbf{H}(\mathbf{w})$ la Hessiana de la NLL


Degree1




Degree2








Degree3




Degree4









10.2.8. Estandarización

- ▶ Un prior isotrópico Gaussiano en estimación MAP asume que todos los pesos son de magnitud parecida, lo que a su vez supone asumir que todas las características son también de magnitud parecida, pero esto no se cumple en muchos conjuntos de datos
- ▶ **Estandarización:** preproceso separado de cada característica para que tenga media 0 y varianza 1

$$\text{standardize}(x_{nd}) = \frac{x_{nd} - \hat{\mu}_d}{\hat{\sigma}_d} \quad (44)$$

$$\hat{\mu}_d = \frac{1}{N} \sum_{n=1}^N x_{nd} \quad (45)$$

$$\hat{\sigma}_d^2 = \frac{1}{N} \sum_{n=1}^N (x_{nd} - \hat{\mu}_d)^2 \quad (46)$$

- ▶ **Escalado min-max:** re-escalado simple en $[0, 1]$

10.3. Regresión logística multinomial

► *Regresión logística multinomial:* modelo

$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \text{Cat}(y \mid S(\mathbf{W}\mathbf{x} + \mathbf{b})) \quad (47)$$

donde

▷ $\mathbf{x} \in \mathbb{R}^D$ es el vector (de características) de entrada

▷ $y \in \{1, \dots, C\}$ es la etiqueta de clase

▷ $S()$ es la función softmax

▷ $\mathbf{W} \in \mathbb{R}^{C \times D}$ es una matriz de pesos

↳ $\mathbf{W} \in \mathbb{R}^{(C-1) \times D}$ si fijamos $w_C = 0$ pues $\sum_c p(y=c \mid \mathbf{x}; \boldsymbol{\theta}) = 1$

▷ $\mathbf{b} \in \mathbb{R}^D$ es el término de sesgo

▷ $\boldsymbol{\theta} = (\mathbf{W}, \mathbf{b})$ son todos los parámetros

↳ $\boldsymbol{\theta} = \mathbf{W}$ ya que anteponemos un 1 a $\mathbf{x}$ y $\mathbf{b}$ (columna) a $\mathbf{W}$

► *Clasificación multiclase vs multi-etiqueta:*



- ▷ Multiclase es la estándar, con solo una etiqueta correcta
- ▷ Multi-etiqueta admite que haya cero, una o más correctas
 - ⇒ La salida es un vector de bits en $\mathcal{Y} = \{0, 1\}^C$ para indicar la presencia o ausencia de cada etiqueta
 - ⇒ Puede verse como extensión de regresión logística binaria:

$$p(\mathbf{y} \mid \mathbf{x}; \boldsymbol{\theta}) = \prod_{c=1}^C \text{Ber}(y_c \mid \sigma(\mathbf{w}_c^t \mathbf{x})) \quad (48)$$

10.3.1. Clasificadores lineales y no lineales

- ▶ Aunque regresión logística halla fronteras lineales, podemos transformar la entrada para crearlas no lineales

▷ *Ejemplo:* $C = 3$, $\mathbf{x} = (x_1, x_2)$, $\phi(\mathbf{x}) = [1, x_1, x_2, x_1^2, x_2^2, x_1x_2]$



10.3.2. Estimación máximo-verosímil

10.3.2.0. Resumen

► Objetivo:

$$\text{NLL}(\boldsymbol{\theta}) = -\log \prod_n \prod_c \mu_{nc}^{y_{nc}} = -\sum_n \sum_c y_{nc} \log \mu_{nc} = \sum_n \mathbb{H}(\mathbf{y}_n, \boldsymbol{\mu}_n) \quad (49)$$

donde

▷ $\mu_{nc} = p(y_{nc} = 1 \mid \mathbf{x}_n, \boldsymbol{\theta}) = S(f(\mathbf{x}_n; \boldsymbol{\theta}))_c$

▷ $\mathbf{y}_n$ es la codificación one-hot de la etiqueta; i.e., $y_{nc} = \mathbb{1}(y_n = c)$

▷ $\mathbb{H}(\mathbf{y}_n, \boldsymbol{\mu}_n)$ es la entropía cruzada:

$$\mathbb{H}(\mathbf{p}, \mathbf{q}) = -\sum_c p_c \log q_c \quad (50)$$

► Gradiente:

$$\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = \mathbf{g}(\mathbf{w}) = \sum_n \mathbf{x}_n (\boldsymbol{\mu}_n - \mathbf{y}_n)^t \quad (51)$$

► Hessiana: $\mathbf{A} \otimes \mathbf{B}$ denota el **producto de Kronecker**

$$\mathbf{H}(\mathbf{w}) = \sum_n (\text{diag}(\boldsymbol{\mu}_n) - \boldsymbol{\mu}_n \boldsymbol{\mu}_n^t) \otimes (\mathbf{x}_n \mathbf{x}_n^t) \quad (52)$$

10.3.2.1. Objetivo

$$\text{NLL}(\boldsymbol{\theta}) = -\log \prod_n \prod_c \mu_{nc}^{y_{nc}} \quad (53)$$

$$= -\sum_n \sum_c y_{nc} \log \mu_{nc} \quad (54)$$

$$= \sum_n \mathbb{H}(\mathbf{y}_n, \boldsymbol{\mu}_n) \quad (55)$$

donde

- ▶ $\mu_{nc} = p(y_{nc} = 1 \mid \mathbf{x}_n, \boldsymbol{\theta}) = S(f(\mathbf{x}_n; \boldsymbol{\theta}))_c$
- ▶ $\mathbf{y}_n$ es la codificación one-hot de la etiqueta; i.e., $y_{nc} = \mathbb{1}(y_n = c)$
- ▶ $\mathbb{H}(\mathbf{y}_n, \boldsymbol{\mu}_n)$ es la entropía cruzada:

$$\mathbb{H}(\mathbf{p}, \mathbf{q}) = -\sum_c p_c \log q_c \quad (56)$$

10.3.2.2. Optimización del objetivo

► Para hallar el MLE debemos resolver:

$$\nabla_{\boldsymbol{w}} \text{NLL}(\boldsymbol{w}) = \boldsymbol{g}(\boldsymbol{w}) = \mathbf{0} \quad (57)$$

10.3.2.3. Derivación del gradiente

► Jacobiana de la softmax:

$$\frac{\partial \mu_c}{\partial a_j} = \mu_c(\delta_{cj} - \mu_j) \quad (58)$$

► *Ejemplo:* para 3 clases

$$\left[\frac{\partial \mu_c}{\partial a_j} \right]_{cj} = \begin{bmatrix} \mu_1(1 - \mu_1) & -\mu_1\mu_2 & -\mu_1\mu_3 \\ -\mu_2\mu_1 & \mu_2(1 - \mu_2) & -\mu_2\mu_3 \\ -\mu_3\mu_1 & -\mu_3\mu_2 & \mu_3(1 - \mu_3) \end{bmatrix} \quad (59)$$

► En forma matricial:

$$\frac{\partial \mu}{\partial a} = (\mu \mathbf{1}^t) \odot (\mathbf{I} - \mathbf{1} \mu^t) \quad (60)$$

⇒ $\odot$ es el producto elemento a elemento

⇒ $\mu \mathbf{1}^t$ copia μ en cada columna

⇒ $\mathbf{1} \mu^t$ copia μ en cada fila

- Gradiente de la NLL para la muestra n :
- Aplanamos la matriz de pesos $C \times D$ en un vector w de talla CD (o $(C - 1)D$ si fijamos una de las clases a pesos nulos) por concatenación de filas y lo transponemos en vector columna
- Si w_j es el vector de pesos asociado a la clase j :

$$\nabla_{w_j} \text{NLL}_n = \sum_c \frac{\partial \text{NLL}}{\partial \mu_{nc}} \frac{\partial \mu_{nc}}{\partial a_{nj}} \frac{\partial a_{nj}}{\partial w_j} \quad (61)$$

$$= - \sum_c \frac{y_{nc}}{\mu_{nc}} \mu_{nc} (\delta_{jc} - \mu_{nj}) \mathbf{x}_n \quad (62)$$

$$= \sum_c y_{nc} (\mu_{nj} - \delta_{jc}) \quad (63)$$

$$= \left(\sum_c y_{nc} \right) \mu_{nj} \mathbf{x}_n - \sum_n y_{nj} \mathbf{x}_n \quad (64)$$

$$= (\mu_{nj} - y_{nj}) \mathbf{x}_n \quad (65)$$

- El gradiente (global) de la NLL es:

$$\mathbf{g}(\mathbf{w}) = \sum_{n=1}^N \mathbf{x}_n (\boldsymbol{\mu}_n - \mathbf{y}_n)^t \quad (66)$$

10.3.2.4. Derivación de la Hessiana

► Hessiana: $\mathbf{A} \otimes \mathbf{B}$ denota el producto de Kronecker

$$\mathbf{H}(\mathbf{w}) = \sum_n (\text{diag}(\boldsymbol{\mu}_n) - \boldsymbol{\mu}_n \boldsymbol{\mu}_n^t) \otimes (\mathbf{x}_n \mathbf{x}_n^t) \quad (67)$$

con submatriz c, c' :

$$\mathbf{H}_{c,c'}(\mathbf{w}) = \sum_n \mu_{nc} (\delta_{c,c'} - \mu_{n,c'}) \mathbf{x}_n \mathbf{x}_n^t \quad (68)$$

► *Ejemplo:* 3 características y 2 clases $\mathbf{X}_n = \mathbf{x}_n \mathbf{x}_n^t$

$$\mathbf{H}(\mathbf{w}) = \sum_n \begin{bmatrix} \mu_{n1} - \mu_{n1}^2 & -\mu_{n1}\mu_{n2} \\ -\mu_{n1}\mu_{n2} & \mu_{n2} - \mu_{n2}^2 \end{bmatrix} \otimes \begin{bmatrix} x_{n1}x_{n1} & x_{n1}x_{n2} & x_{n1}x_{n3} \\ x_{n2}x_{n1} & x_{n2}x_{n2} & x_{n2}x_{n3} \\ x_{n3}x_{n1} & x_{n3}x_{n2} & x_{n3}x_{n3} \end{bmatrix} \quad (69)$$

$$= \sum_n \begin{bmatrix} (\mu_{n1} - \mu_{n1}^2) \mathbf{X}_n & -\mu_{n1}\mu_{n2} \mathbf{X}_n \\ -\mu_{n1}\mu_{n2} \mathbf{X}_n & (\mu_{n2} - \mu_{n2}^2) \mathbf{X}_n \end{bmatrix} \quad (70)$$

► $\mathbf{H}$ es definida positiva, por lo que el objetivo es convexo

10.3.3. Optimización basada en gradientes

- ▶ El gradiente hallado puede usarse para derivar un algoritmo SGD
- ▶ Asimismo, la Hessiana hallada puede usarse para derivar un algoritmo de optimización de segundo orden
- ▶ Dado que el cálculo de la Hessiana suele ser muy costoso, se aproxima mediante métodos quasi-Newton como L-BFGS
- ▶ El cálculo de gradientes requiere el de probabilidades normalizadas a partir de un vector de logits $\mathbf{a} = \mathbf{W}\mathbf{x}$ y la lse:

$$p(y = c \mid \mathbf{x}) = \exp(a_c - \text{lse}(\mathbf{a})) \quad (71)$$

Por eficiencia, la entropía cruzada se suele modificar de forma que tome logits no normalizadas como entrada

10.3.5. Estimación MAP

- ▶ La regularización ℓ_2 para $C = 2$ se extiende fácilmente a $C > 2$
- ▶ **Identificabilidad:** decimos que los parámetros son identificables si existe un único valor que maximiza la log-verosimilitud o, equivalentemente, la NLL es estrictamente convexa
- ▶ Sin regularización, si no fijamos los parámetros de una clase, los parámetros óptimos no son identificables
- ▶ Con regularización, aunque no fijemos los parámetros de una clase, los parámetros óptimos sí son identificables
- ▶ Regresión logística multiclase sin fijación $\mathbf{w}_C = \mathbf{0}$:

$$p(y = c \mid \mathbf{x}, \mathbf{W}) = \frac{\exp(\mathbf{w}_c^t \mathbf{x})}{\sum_{c'} \exp(\mathbf{w}_{c'}^t \mathbf{x})} \quad (72)$$

- NLL ℓ_2 -regularizada:

$$\text{PNLL}(\mathbf{W}) = - \sum_n \log p(y_n \mid \mathbf{x}_n, \mathbf{W}) + \lambda \sum_c \|\mathbf{w}_c\|_2^2 \quad (73)$$

- En un óptimo:

$$\nabla \text{NLL}(\mathbf{w}) + 2\lambda \mathbf{w} = \mathbf{0} \quad \Rightarrow \quad \sum_n (\mathbf{y}_n - \boldsymbol{\mu}_n) \otimes \mathbf{x}_n = \lambda \mathbf{w} \quad (74)$$

por lo que, para toda característica j ,

$$\lambda \sum_c w_{cj} = \sum_n \sum_c (y_{nc} - \mu_{nc}) x_{nj} \quad (75)$$

$$= \sum_n \left(\sum_c y_{nc} - \sum_c \mu_{nc} \right) x_{nj} \quad (76)$$

$$= \sum_n (1 - 1) x_{nj} = 0 \quad (77)$$

- Si $\lambda > 0$ tenemos que $\sum_c w_{cj} = 0$, por lo que los pesos suman cero sobre las clases para toda característica j