



UNIVERSITAT  
POLITÈCNICA  
DE VALÈNCIA

Aprendizaje Automático Probabilístico

# Regresión lineal

Alfons Juan

*DSIC*

Departamento de Sistemas  
Informáticos y Computación

# Índice

|                                                     |           |
|-----------------------------------------------------|-----------|
| <b>11.0 Resumen</b>                                 | <b>1</b>  |
| <b>11.1 Introducción</b>                            | <b>5</b>  |
| <b>11.2 Regresión lineal por mínimos cuadrados</b>  | <b>6</b>  |
| 11.2.1 Terminología . . . . .                       | 6         |
| 11.2.2 Estimación por mínimos cuadrados . . . . .   | 10        |
| 11.2.2.1 Mínimos cuadrados ordinario . . . . .      | 12        |
| 11.2.2.2 Interpretación geométrica . . . . .        | 14        |
| 11.2.2.3 Aspectos algorítmicos . . . . .            | 17        |
| 11.2.2.4 Mínimos cuadrados ponderado . . . . .      | 19        |
| 11.2.4 Evaluación de la bondad del ajuste . . . . . | 20        |
| <b>11.3 Regresión de cresta</b>                     | <b>24</b> |
| <b>11.4 Regresión Lasso</b>                         | <b>28</b> |

# 11.0. Resumen

► *Introducción:*  $y \in \mathbb{R}$

▷ *Asunción principal:*  $\mathbb{E}[y \mid \mathbf{x}] = \mathbf{w}^t \mathbf{x}$

## ► Regresión lineal por mínimos cuadrados:

$$p(y \mid \mathbf{x}, \boldsymbol{\theta}) = \mathcal{N}(y \mid w_0 + \mathbf{w}^t \mathbf{x}, \sigma^2)$$

- **Terminología:** pesos, sesgo, simple/múltiple, uni/multi-variada, sin/con extractor de características (polinómico)
- **Estimación por mínimos cuadrados:** NLL coincide con **RSS** para  $\sigma^2$  dada, **OLS** obtiene un mínimo global

$$\begin{aligned}\hat{\mathbf{w}} &= \arg \min_{\mathbf{w}} \text{RSS}(\mathbf{w}) \\ &= \arg \min_{\mathbf{w}} \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 \\ &= \mathbf{X}^\dagger \mathbf{y} \quad \text{con} \quad \mathbf{X}^\dagger = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t\end{aligned}$$

... interpretación geométrica, cálculo robusto y mínimos cuadrados ponderado (con varianza dependiente de  $x$ )

- **Evaluación de la bondad del ajuste:** gráfica  $r_n = y_n - \hat{y}_n$  VS  $x_n$  ( $D = 1$ ) o  $\hat{y}_n$  VS  $y_n$  ( $D > 1$ ); coeficiente de determinación  $R^2$
- ... otras aproximaciones para calcular el MLE

- **Regresión de cresta:** estimación MAP con prior Gaussiano de media nula sobre los pesos,

$$\hat{\mathbf{w}}_{\text{ridge}} = \arg \min_{\mathbf{w}} \text{RSS}(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2$$

- ▷ **Cálculo del estimador MAP:** se usan métodos OLS con datos “aumentados” para hallar

$$\hat{\mathbf{w}}_{\text{ridge}} = (\mathbf{X}^t \mathbf{X} + \lambda \mathbf{I}_D)^{-1} \mathbf{X}^t \mathbf{y}$$

- ▷ **Elección de la fuerza del regularizador:** por validación cruzada, relajando gradualmente un modelo inicial restringido
- ▷ ... conexión entre regresión de cresta y PCA

- ▶ **Regresión Lasso:** estimación MAP con prior Laplace de media nula sobre los pesos,

$$\hat{\mathbf{w}}_{\text{lasso}} = \arg \min_{\mathbf{w}} \text{RSS}(\mathbf{w}) + \lambda \|\mathbf{w}\|_1$$

- ▷ **Lasso obtiene soluciones dispersas**
- ▷ **“Cálculo” del estimador:** OLS con
  - ↳ Umbralización débil (absolute shrinkage)
  - ↳ Umbralización fuerte (debiasing)
- ▷ **Camino de regularización:** pesos vs  $\lambda$
- ▷ **Comparación de mínimos cuadrados, lasso, cresta y selección de subconjunto**
- ▷ **Elastic net:** híbrido entre cresta y lasso

# 11.1. Introducción

- ▶ **Regresión lineal:** predicción de  $y \in \mathbb{R}$  a partir de  $x \in \mathbb{R}^D$ 
  - ▷ **Variable dependiente o respuesta:**  $y$
  - ▷ **Variables independientes, explicativas o regresoras:**  $x$
- ▶ **Asunción principal:** el valor esperado de la salida se asume que es función lineal de la entrada

$$\mathbb{E}[y \mid x] = w^t x \quad (1)$$

- ▷ Modelo fácil de ajustar e interpretar

# 11.2. Regresión lineal por mínimos cuadrados

## 11.2.1. Terminología

► **Regresión lineal:** modelo de la forma

$$p(y \mid \mathbf{x}, \boldsymbol{\theta}) = \mathcal{N}(y \mid w_0 + \mathbf{w}^t \mathbf{x}, \sigma^2) \quad (2)$$

donde  $\boldsymbol{\theta} = (w_0, \mathbf{w}, \sigma^2)$  son los parámetros del modelo

▷ **Pesos o coeficientes de regresión:**  $\mathbf{w}_{1:D}$

▷ **Desplazamiento o sesgo:**  $w_0$  (absorbido en  $\mathbf{w}$  con  $x_0 = 1$ )

▷ **Regresión lineal simple y múltiple:**  $\mathbf{x} \in \mathbb{R}^D$ ,  $D = 1$  o  $D > 1$



► **Regresión lineal multivariada:**  $\mathbf{y} \in \mathbb{R}^J$ ,  $J > 1$


$$p(\mathbf{y} \mid \mathbf{x}, \mathbf{W}) = \prod_{j=1}^J \mathcal{N}(y_j \mid \mathbf{w}_j^t \mathbf{x}, \sigma_j^2) \quad (3)$$

► **Extractor de características:**  $\phi$  (de parámetros fijos)


$$p(y \mid \mathbf{x}, \boldsymbol{\theta}) = \mathcal{N}(y \mid \mathbf{w}^t \phi(\mathbf{x}), \sigma^2) \quad (4)$$

▷ **Ejemplo 1D:** *regresión polinómica* con  $\phi = [1, x, x^2, \dots, x^d]$

▷ *Ejemplo 1D (cont.):* regresión lineal simple



▷ *Ejemplo 1D (cont.):* regresión polinómica de grado 2



## 11.2.2. Estimación por mínimos cuadrados

► NLL: función objetivo

$$\text{NLL}(\mathbf{w}, \sigma^2) = - \sum_n \log \left[ \left( \frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp \left( -\frac{1}{2\sigma^2} (y_n - \mathbf{w}^t \mathbf{x}_n)^2 \right) \right] \quad (5)$$

$$= \frac{1}{2\sigma^2} \sum_n (y_n - \hat{y}_n)^2 + \frac{N}{2} \log(2\pi\sigma^2) \quad (6)$$

donde la respuesta predicha se denota como  $\hat{y}_n \triangleq \mathbf{w}^t \mathbf{x}_n$

► El MLE debe satisfacer:

$$\nabla_{\mathbf{w}, \sigma} \text{NLL}(\mathbf{w}, \sigma^2) = \mathbf{0} \quad (7)$$

→ Primero optimizamos con respecto a  $\mathbf{w}$ ; luego  $\sigma$

- ***Residual sum of squares:*** la suma de cuadrados residual es una función objetivo equivalente a la NLL con respecto a  $\mathbf{w}$

$$\text{RSS}(\mathbf{w}) = \frac{1}{2} \sum_n (y_n - \mathbf{w}^t \mathbf{x}_n)^2 \quad (8)$$

$$= \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 \quad (9)$$

$$= \frac{1}{2} (\mathbf{X}\mathbf{w} - \mathbf{y})^t (\mathbf{X}\mathbf{w} - \mathbf{y}) \quad (10)$$

## 11.2.2.1. Mínimos cuadrados ordinario

### ► *Ordinary least squares (OLS):*

▷ Gradiente:

$$\nabla_{\mathbf{w}} \text{RSS}(\mathbf{w}) = \mathbf{X}^t \mathbf{X} \mathbf{w} - \mathbf{X}^t \mathbf{y} \quad (11)$$

▷ *Ecuaciones normales:* igualando a cero llegamos a

$$\mathbf{X}^t \mathbf{X} \mathbf{w} = \mathbf{X}^t \mathbf{y} \quad (12)$$

esto es,  $\mathbf{y} - \mathbf{X} \mathbf{w}$  debe ser normal al rango de  $\mathbf{X}$

▷ Solución:

$$\hat{\mathbf{w}} = \mathbf{X}^\dagger \mathbf{y} \quad (13)$$

donde  $\mathbf{X}^\dagger = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t$  es la pseudoinversa (izq.) de  $\mathbf{X}$

▷ Hessiana:


$$\mathbf{H}(\mathbf{w}) = \frac{\partial^2}{\partial \mathbf{x}^2} \text{RSS}(\mathbf{w}) = \mathbf{X}^t \mathbf{X} \quad (14)$$

▷ Si  $\mathbf{X}$  es de rango máximo (columnas linealmente independientes), entonces  $\mathbf{H}$  es definida positiva ya que, para todo  $\mathbf{v} > 0$ ,

$$\mathbf{v}^t (\mathbf{X}^t \mathbf{X}) \mathbf{v} = (\mathbf{X} \mathbf{v})^t (\mathbf{X} \mathbf{v}) = \|\mathbf{X} \mathbf{v}\|^2 > 0 \quad (15)$$

⇒ *OLS tiene un único mínimo global* (en este caso)

⇒ *Ejemplo 1D (cont.):* curvas de nivel de la RSS



## 11.2.2.2. Interpretación geométrica de mínimos cuadrados

- Suponemos más datos que incógnitas ( $N > D$ ) y buscamos el  $\hat{\mathbf{y}} \in \mathbb{R}^N$  más cercano a  $\mathbf{y}$  en el subespacio lineal generado por  $\mathbf{X}$ :

$$\hat{\mathbf{y}} = \arg \min_{\tilde{\mathbf{y}} \in \text{span}(\mathbf{X})} \|\mathbf{y} - \tilde{\mathbf{y}}\|_2 \quad (16)$$

- Dado que  $\hat{\mathbf{y}} \in \text{span}(\mathbf{X})$ , existe un  $\mathbf{w}$  tal que:

$$\hat{\mathbf{y}} = w_1 \mathbf{X}_{:,1} + \cdots + w_D \mathbf{X}_{:,D} = \mathbf{X} \mathbf{w} \quad (17)$$

- Para minimizar la norma del vector residuo,  $\|\mathbf{y} - \hat{\mathbf{y}}\|_2$ , el mismo debe ser ortogonal a cada columna de  $\mathbf{X}$

$$\mathbf{X}_{:,d}^t (\mathbf{y} - \hat{\mathbf{y}}) = 0 \quad (\text{para todo } d) \quad (18)$$

$$\Rightarrow \mathbf{X}^t (\mathbf{y} - \mathbf{X} \mathbf{w}) = \mathbf{0} \quad (19)$$

$$\Rightarrow \mathbf{w} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{y} \quad (20)$$



▷  $\hat{\mathbf{y}}$  es proyección ortogonal de  $\mathbf{y}$  en el espacio columna de  $\mathbf{X}$

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w} = \mathbf{X}(\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t\mathbf{y} \quad (21)$$

▷ *Matriz de proyección:*

$$\text{Proj}(\mathbf{X}) \triangleq \mathbf{X}(\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t \quad (22)$$


↳ En el caso particular de un único vector columna,  $\mathbf{X} = \mathbf{x}$ , la proyección ortogonal de  $\mathbf{y}$  en la línea  $\mathbf{x}$  es:

$$\hat{\mathbf{y}} = \text{Proj}(\mathbf{x})\mathbf{y} = \mathbf{x} \frac{\mathbf{x}^t\mathbf{y}}{\mathbf{x}^t\mathbf{x}} \quad (23)$$

↳ *Ejemplo:* sistema  $\mathbf{A}\mathbf{x} = \mathbf{b}$  con 3 ecuaciones y 2 incógnitas

$$[\mathbf{a}_1, \mathbf{a}_2] \mathbf{x} = \mathbf{b} \Rightarrow \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

→  $\hat{b}$  es la proyección ortogonal de  $b$  en el subespacio lineal sombreado; la línea de  $b$  a  $\hat{b}$  es el vector de errores residuales



### 11.2.2.3. Aspectos algorítmicos

► *Cálculo directo de la pseudoinversa:* la solución OLS es

$$\hat{\mathbf{w}} = \mathbf{X}^\dagger \mathbf{y} \quad (24)$$

donde la pseudoinversa izquierda de  $\mathbf{X}$

$$\mathbf{X}^\dagger = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \quad (25)$$

puede hallarse directamente invirtiendo  $\mathbf{X}^t \mathbf{X}$

► No es buena idea porque plantea problemas numéricos

## ► *Cálculo robusto de la pseudoinversa:*

- ▷ En general, se emplea la descomposición SVD
- ▷ Si  $N \gg D$ , la descomposición QR puede ser más eficiente
  - ↳ Hacemos  $X = QR$  con  $Q^t Q = I$
  - ↳ OLS equivale a resolver  $Xw = y$  minimizando  $\|Xw - y\|_2^2$

$$(QR)w = y \quad (26)$$

$$Q^t QRw = Q^t y \quad (27)$$

$$w = R^{-1}(Q^t y) \quad (28)$$

que es resoluble con sustituciones pues  $R$  es triangular

- ▷ También se emplean métodos iterativos no basados en descomposiciones matriciales como la SVD o la QR

► *Estandarización:* se suele hacer antes del ajuste del modelo

## 11.2.2.4. Mínimos cuadrados ponderado

► *Regresión heterocedástica:* con varianza dependiente de  $x$

$$p(y \mid \mathbf{x}; \boldsymbol{\theta}) = \mathcal{N}(y \mid \mathbf{w}^t \mathbf{x}, \sigma^2(\mathbf{x})) \quad (29)$$

$$= \frac{1}{\sqrt{2\pi\sigma^2(\mathbf{x})}} \exp \left( -\frac{1}{2\sigma^2(\mathbf{x})} (y - \mathbf{w}^t \mathbf{x})^2 \right) \quad (30)$$

► *Regresión lineal ponderada:* con  $\boldsymbol{\Lambda}^{-1} = \text{diag}(1/\sigma^2(\mathbf{x}_n))$





$$p(\mathbf{y} \mid \mathbf{x}; \boldsymbol{\theta}) = \mathcal{N}(\mathbf{y} \mid \mathbf{X}\mathbf{w}, \boldsymbol{\Lambda}^{-1}) \quad (31)$$

⇒ *Weighted least squares estimate:*





$$\hat{\mathbf{w}} = (\mathbf{X}^t \boldsymbol{\Lambda} \mathbf{X})^{-1} \mathbf{X}^t \boldsymbol{\Lambda} \mathbf{y} \quad (32)$$

## 11.2.4. Evaluación de la bondad del ajuste

►  $D = 1$ : *gráfica de residuos*  $r_n = y_n - \hat{y}_n \sim \mathcal{N}(0, \sigma^2)$  vs  $x_n$



►  $D > 1$ : gráfica  $\hat{y}_n$  vs  $y_n$ ; mejor cuanto más próxima a la diagonal



## ► *Precisión de la predicción y $R^2$*

### ▷ *Residual sum of squares (RSS):*

$$\text{RSS}(\mathbf{w}) = \sum_{n=1}^N (y_n - \mathbf{w}^t \mathbf{x}_n)^2 \quad (33)$$

### ▷ *Root mean squared error (RMSE):*

$$\text{RMSE}(\mathbf{w}) \triangleq \sqrt{\frac{1}{N} \text{RSS}(\mathbf{w})} \quad (34)$$





### ▷ *Total sum of squares:*

$$\text{TSS} = \sum_{n=1}^N (y_n - \bar{y})^2 \quad \text{con} \quad \bar{y} = \frac{1}{N} \sum_{n=1}^N y_n \quad (35)$$

### ▷ *Coeficiente de determinación:* $(\hat{y}_n = \bar{y}) \quad 0 \leq R^2 \leq 1 \quad (\hat{y}_n = y_n)$

$$R^2 \triangleq 1 - \frac{\sum_n (\hat{y}_n - y_n)^2}{\sum_n (\bar{y} - y_n)^2} = 1 - \frac{\text{RSS}}{\text{TSS}} \quad (36)$$





## 11.3. Regresión de cresta

- *Regresión de cresta, regularización  $\ell_2$  o weight decay*: estimación MAP con prior Gaussiano de media nula sobre los pesos,

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \mathbf{0}, \lambda^{-1}\mathbf{I}) \quad (37)$$





por lo que

$$\hat{\mathbf{w}}_{\text{map}} = \arg \min_{\mathbf{w}} \frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\mathbf{w})^t(\mathbf{y} - \mathbf{X}\mathbf{w}) + \frac{1}{2\tau^2}\mathbf{w}^t\mathbf{w} \quad (38)$$

$$= \arg \min_{\mathbf{w}} \text{RSS}(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2 \quad (39)$$

donde  $\lambda \triangleq \frac{\sigma^2}{\tau^2}$  es proporcional a la fuerza del prior

- El desplazamiento  $w_0$  no se penaliza pues solo afecta a la media global de la salida y no produce sobre-entrenamiento



## ► *Cálculo del estimador MAP*

► Objetivo:  $\lambda \triangleq \frac{\sigma^2}{\tau^2}$  es la fuerza del regularizador

$$J(\mathbf{w}) = (\mathbf{y} - \mathbf{X}\mathbf{w})^t(\mathbf{y} - \mathbf{X}\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2 \quad (40)$$

► Gradiente:

$$\nabla_{\mathbf{w}} J(\mathbf{w}) = 2(\mathbf{X}^t \mathbf{X} \mathbf{w} - \mathbf{X}^t \mathbf{y} + \lambda \mathbf{w}) \quad (41)$$

► Estimador MAP:

$$\hat{\mathbf{w}}_{\text{map}} = (\mathbf{X}^t \mathbf{X} + \lambda \mathbf{I}_D)^{-1} \mathbf{X}^t \mathbf{y} \quad (42)$$

$$= \left( \sum_n \mathbf{x}_n \mathbf{x}_n^t + \lambda \mathbf{I}_D \right)^{-1} \left( \sum_n y_n \mathbf{x}_n \right) \quad (43)$$

► Se usan métodos OLS aplicados a datos “aumentados”

## ► *Elección de la fuerza del regularizador*

- ▷ *Validación cruzada:* entre un número finito de valores posibles
  - ⇒ *Camino de regularización:* empezamos con un modelo restringido y lo relajamos gradualmente; esto es, tomamos  $\hat{w}(\lambda_k)$  como inicialización de  $\hat{w}(\lambda_{k+1})$ , con  $\lambda_{k+1} < \lambda_k$
- ▷ *Bayes empírico:* obtiene el mismo resultado que validación cruzada más eficientemente

$$\hat{\lambda} = \arg \max_{\lambda} \log p(\mathcal{D} \mid \lambda) \quad (44)$$

## 11.4. Regresión Lasso

- *Regresión Lasso (Least Absolute Shrinkage and Selection Operator) o regularización  $\ell_1$* : estimación MAP con prior Laplace de media nula y dispersión  $\lambda$  (escala  $b = 1/\lambda$ ),

$$p(\mathbf{w} \mid \lambda) = \prod_{d=1}^D \text{Lap}(w_d \mid 0, 1/\lambda) \propto \prod_{d=1}^D e^{-\lambda|w_d|} \quad (45)$$

por lo que la NLL penalizada es

$$\text{PNLL}(\mathbf{w}) = -\log p(\mathcal{D} \mid \mathbf{w}) - \log p(\mathbf{w} \mid \lambda) \quad (46)$$

$$= \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda\|\mathbf{w}\|_1 \quad (47)$$

con

$$\|\mathbf{w}\|_1 = \sum_{d=1}^D |w_d| \quad (48)$$


► *Lasso obtiene soluciones dispersas:*

► Lasso y regresión de cresta como optimización con restricción:

$$\min_{\mathbf{w}} \text{NLL}(\mathbf{w}) + \lambda \|\mathbf{w}\|_1 \rightarrow \min_{\mathbf{w}} \text{NLL}(\mathbf{w}) \text{ s.t. } \|\mathbf{w}\|_1 \leq B \quad (49)$$

$$\min_{\mathbf{w}} \text{NLL}(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2 \rightarrow \min_{\mathbf{w}} \text{NLL}(\mathbf{w}) \text{ s.t. } \|\mathbf{w}\|_2^2 \leq B \quad (50)$$

► A diferencia de la bola  $\ell_2$ , la  $\ell_1$  tiende a tocar el objetivo en una esquina correspondiente a una solución dispersa:




► “Cálculo” del estimador:


*Umbralización débil*

*absolute shrinkage*

respecto a  
mínimos cuadrados  
(línea de puntos)





*Umbralización fuerte*





► **Camino de regularización:** gráfica de  $\hat{w}_d$  en función de  $B = 1/\lambda$  (o  $\lambda$ ) para cada característica  $d$

► *Ejemplo (prostate):* caminos de regularización  $\ell_2$  y  $\ell_1$  (vs  $B$ )



► *Comparación de mínimos cuadrados, lasso, cresta y selección de subconjunto:*

- Si las características de  $\mathbf{X}$  son ortonormales ( $\mathbf{X}^t\mathbf{X} = \mathbf{I}$ ), la NLL puede expresarse como suma de términos, uno por cada  $d$ :

$$\text{NLL}(\mathbf{w}) = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 \quad (51)$$

$$= \mathbf{y}^t\mathbf{y} + \mathbf{w}^t\mathbf{X}^t\mathbf{X}\mathbf{w} - 2\mathbf{w}^t\mathbf{X}^t\mathbf{y} \quad (52)$$

$$= \text{const} + \sum_d w_d^2 - 2 \sum_d \sum_n w_d x_{nd} y_n \quad (53)$$

- Mínimos cuadrados:

$$\hat{w}_d^{\text{mle}} = \frac{c_d}{a_d} = \mathbf{X}_{:,d}^t \mathbf{y} \quad (54)$$

▷ Cresta:

$$\hat{w}_d^{\text{ridge}} = \frac{\hat{w}_d^{\text{mle}}}{1 + \lambda} \quad (55)$$

▷ Lasso: umbralización débil

$$\hat{w}_d^{\text{lasso}} = \text{sgn}(\hat{w}_d^{\text{mle}})(|\hat{w}_d^{\text{mle}}| - \lambda)_+ \quad (56)$$

▷ Selección de subconjunto:  $K$  características de mayor peso absoluto (umbralización fuerte)

$$\hat{w}_d^{\text{ss}} = \begin{cases} \hat{w}_d^{\text{mle}} & \text{si } |\hat{w}_d^{\text{mle}}| \text{ entre los } K \text{ mayores} \\ 0 & \text{si no} \end{cases} \quad (57)$$

► **Elastic net:** híbrido entre cresta y lasso

$$\mathcal{L}(\mathbf{w}, \lambda_1, \lambda_2) = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \lambda_2 \|\mathbf{w}\|_2^2 + \lambda_1 \|\mathbf{w}\|_1 \quad (58)$$

- La función de penalización es estrictamente convexa (si  $\lambda_2 > 0$ )
- En general, cualquier penalización estrictamente convexa produce un **efecto de agrupamiento**; esto es, los pesos de las variables altamente correladas tienden a ser iguales
- Si  $D > N$ , puede seleccionar más de  $N$  variables no nulas