

Entrenamiento y optimización de clasificadores lineales

Miguel García Bohigues

7 Noviembre 2022

Contents

1	Introducción	3
2	Selección de modelos	3
3	Evaluación	4
4	Conclusiones	6

1 Introducción

El reconocimiento automático del habla RAH, es una aplicación muy conocida del aprendizaje automático. Presenta un problema abierto y muy complejo en el que un sistema debe de ser capaz de, dada una entrada en formato de onda acústica, generar una cadena que se corresponda.

Un aspecto importante del RAH es conocer si la cadena gerada es correcta o no. Esto se puede hacer de manera manual por un humano, comprobando tanto la secuencia de voz como la cadena y comprobando si coinciden. Pero esto en la práctica es intratable. Para ello se utilizan modelos de clasificación que abordan este problema.

Dichos modelos de clasificación se encargan de discernir, a través de los parámetros de generación de la cadena y de un conjunto de muestras de entrenamiento, si la muestra está bien o no. Esto supone un clasificador en dos clases. Los datos a clasificar, en este caso, van a ser los resultados de RAH obtenidos sobre dos corpus de bastante renombre: *LibriSpeech* y *PoliMedia*.

El objetivo de este trabajo, por lo tanto, es desarrollar un clasificador lineal que consiga indicar, con la máxima precisión posible, cuándo una secuencia está mal generada.

Para el desarrollo de los diferentes clasificadores, vamos a utilizar el lenguaje de programación *Python 3.10*, junto con librerías de tratamiento de datos (tales como *numpy* o *pandas*) y librerías de aprendizaje automático como *sklearn*.

Una vez desarrollados los diferentes modelos, los compararemos utilizando métricas estándar, tales como la precisión acompañada de intervalos de confianza y el área bajo la curva ROC. Las curvas ROC comparan el ratio de positivos reales (veces en las que el sistema acierta al predecir que una secuencia es incorrecta) con el ratio de falsos positivos (aquellas situaciones en las que el sistema dice erróneamente que la secuencia es incorrecta)

2 Selección de modelos

Los corpus de datos que manejamos están compuestos por muestras de 20 características con sus respectivas etiquetas de clase: 0 correcta y 1 incorrecta.

De los diferentes modelos de clasificación lineal que existen y que tenemos disponibles en el paquete utilizado, hemos seleccionado los que a continuación se muestran. Se ha optado por ellos porque se encuentran dentro de nuestro dominio conceptual actual.

- Un clasificador basado en Descenso por Gradiente Estocástico (SGD)
- Un clasificador basado en Regresión Logística.
- Un Perceptrón Lineal
- Un clasificador basado en Regresión de Cresta(Rigde)

Además de ello, como los datos presentan una elevada dimensionalidad, realizaremos experimentos para ver cómo se comportan los clasificadores si realizamos procesos de redimensionamiento de los datos, tales como análisis de componentes principales (PCA) o análisis discriminante lineal (LDA).

Finalmente, comentar que todas las evaluaciones se han realizado utilizando validación cruzada del conjunto de entrenamiento. En concreto se ha utilizado 5 particiones para hacer esta validación cruzada.

3 Evaluación

Como punto de partida, hemos entrenado cada uno de los modelos lineales enunciados en el apartado anterior y hemos evaluado su rendimiento sobre el conjunto de desarrollo del corpus de *LibriSpeech*. Estos modelos se han entrenado sin ningún ajuste, utilizando la configuración por defecto que tienen en la librería. Los resultados se muestran en la tabla 3 y en ellos podemos apreciar cómo el que mejor rendimiento ha sacado en términos de CER es la Regresión Logística. Por otro lado, en términos de TP vs FP vemos como el clasificador *Ridge* es el que mejor resultado tiene.

Modelo	CER	IC	AUC
SGD	10.32%	0.267	86.1
Perceptron	10.84%	0.27	79.1
Ridge	9.92%	0.26	90.0
Reg. Logística	9.00%	0.25	86.8

Table 1: Evaluación preliminar de los modelos

Con las referencias base que hemos mostrado, vamos a ver si podemos, sin modificar el modelo, ajustar un poco más el resultado. Para ello, vamos a aplicar PCA a los datos de entrenamiento para reducir la dimensionalidad. En la imagen 1 podemos ver, sobre el modelo de regresión logística, cómo evoluciona la precisión del sistema a medida que reducimos la dimensionalidad. En concreto, los valores que hemos probado han sido: dimensión 20, que equivale a no aplicar PCA; y dimensiones 15, 9 y 2.

El CER, lejos de reducirse, va aumentando a medida que vamos reduciendo el número de características de las muestras. Esto significa que cada una de las características que presenta las muestras aporta información distinta y importante al modelo. Por ello descartamos que la aplicación de PCA pueda mejorar la salida.

Otro preproceso que podemos aplicar es la estandarización de los valores para cada una de las características de las muestras. En este caso, se ha observado cómo los modelos estandarizados presentaban un ligero empeoramiento en su valor del CER. No obstante, se ha observado cómo el modelo de Regresión Logística ha mejorado su tasa de TP. El resto de modelos, se ha mantenido en los mismos resultados. Deducimos entonces que no presenta tampoco mucho




Figure 1: Log. regression CER evolution over PCA

aporte realizar un proceso de estandarización a los datos.

Modelo	CER		AUC	
	No Stan.	Stan.	No Stan.	Stan.
SGD	10.32%	10.43%	86.1	86.7
Perceptron	10.84%	10.98%	79.1	77.1
Ridge	9.92%	9.94%	90.0	90.0
Reg. Logística	9.00%	10.26%	86.8	89.4

Table 2: Caption

Finalmente, vamos a ver el comportamiento si pasamos los datos por LDA antes de pasarlos a cualquier modelo. Este análisis va a reducir la dimensionalidad a 1 ($num_clases - 1$)

Modelo	CER	IC	AUC
SGD	9.062%	0.263	90.1
Perceptron	10.97%	0.271	90.1
Ridge	9.062%	0.263	90.1
Reg. Logística	9.062%	0.263	90.1

Table 3: Modelos pre-tratados con LDA

En este caso vemos como, menos para el perceptrón, todos los modelos han

obtenido el mismo resultado. Esto es comprensible, puesto que todos han partido del mismo análisis LDA. Además, vemos cómo los resultados son bastante mejores que los obtenidos sin dicho preproceso.


4 Conclusiones

Como hemos visto en la sección anterior, los mejores modelos han sido aquellos que realizaban previamente un proceso de LDA. Esto lo hemos observado tras realizar 180 experimentos con diferentes combinaciones de parámetros, preprocesos y modelos. Todos ellos con su validación cruzada en 5 segmentos.


Se han repetido los experimentos comentados en la sección anterior para el corpus de PoliMedia, obteniendo las mismas conclusiones. No se ha encontrado un modelo que, por sí mismo, sea capaz de mejorar el rendimiento de la combinación de LDA y el propio modelo. Además, una vez aplicado LDA, todos los modelos convergían a la misma solución.

Por todo esto, no hemos podido encontrar un único mejor modelo, sino que cualquier combinación de SGD, Regresión Logística y *Ridge* es válida para clasificar con máxima probabilidad las muestras.

No obstante, puesto que todos aportan el mismo resultado, vamos a realizar la selección basándonos en el tiempo de cómputo que toman estos modelos para entrenarse y validarse. En base a esto, vamos a seleccionar *Ridge*, puesto que es el que menor tiempo toma en entrenarse. A continuación se muestra la curva ROC obtenida con este sistema.



(a) Curva ROC en LibriSpeech



(b) Curva ROC en PoliMedia

Dónde el CER en PoliMedia es: 6.77%[6.50, 7.03] y para LibriSpeech es: 9.10%[8.85, 9.35]