

Ejercicio 2. Sentiment Analysis. Part 1

Objetivo: Construir un sistema de SA para el español

Recursos:

- *Sklearn* <http://scikit-learn.org/stable/>
- *NLTK* <https://www.nltk.org/>
- *Etc.*

Tarea:

T1: TASS2017 (Task 1: Sentiment Analysis at Tweet level) <http://www.sepln.org/workshops/tass/2017/>

Datos: disponibles en Poliformat

Tokenizer

`TweetTokenizer`

<http://www.nltk.org/api/nltk.tokenize.html>

Vectorizer

<code>feature_extraction.text.CountVectorizer(...)</code>	Convert a collection of text documents to a matrix of token counts
<code>feature_extraction.text.HashingVectorizer(...)</code>	Convert a collection of text documents to a matrix of token occurrences
<code>feature_extraction.text.TfidfTransformer(...)</code>	Transform a count matrix to a normalized tf or tf-idf representation
<code>feature_extraction.text.TfidfVectorizer(...)</code>	Convert a collection of raw documents to a matrix of TF-IDF features.

Classifiers

http://scikit-learn.org/stable/supervised_learning.html

<http://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html>

<http://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>

External Resources

Polarity Lexicons (ex: `ElhPolar_esV1.lex`). Disponible en poliformat

Metrics

`sklearn.metrics` -- `classification_report`, `accuracy_score`, `precision_recall_fscore_support`, etc.---

Trabajo a realizar.

1. Preproceso de datos.

- a. Train, Dev, Test en formato xml.
- b. Hacer un parser (sugerencia utilizar `minidom` de Python):
<https://docs.python.org/2/library/xml.dom.minidom.html>
- c. Utilizar un tokenizador

2. Vectorizar los datos (train,dev,test)

- a. Obtener una matriz de características (utilizando un vectorizer) a partir de los tweets (Hacer selección de características)
 - b. Incluir recursos externos. Añadir a la matriz la información de los diccionarios de polaridad a la matriz de características (Usando `scipy`, `numpy`,... de Python)
3. Probar con diferentes clasificadores. Entrenar con el conjunto de train y ajustar parámetros con el de development.
 4. Una vez elegido el mejor clasificador con los mejores parámetros, recursos, y preproceso, aplicarlo al test.
 5. La salida del test, la tenéis que enviar para que os la evalúe, en un fichero texto, el nombre del fichero que sea vuestro 'nombre' seguido del 'tipo de clasificador' (Ex. CarlosPerez_svm.txt) y el formato:
id_del_tweet \t etiqueta_polaridad (P,N,NEU,NONE)
 6. Deberéis hacer una pequeña memoria que describa los clasificadores utilizados y el proceso de ajuste realizado sobre el conjunto 'dev' incluyendo las tablas de los resultados en términos de P, R, F1 (clase), Accuracy y macroF1 (global). La medida para evaluar y hacer el ranking de los sistemas será la macroF1, por lo tanto enviad la salida del sistema que mayor macroF1 obtenga.
 7. Todo esto se entregará como una tarea de Poliformat.