



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Reconocimiento de Formas y Aprendizaje Computacional

Trabajo Académico 1

Entrenamiento y Optimización de Clasificadores Lineales

Albert Sanchis
Alfons Juan

DSIC

Departamento de Sistemas
Informáticos y Computación

Objetivos formativos

- ▶ Entrenar y optimizar clasificadores lineales
- ▶ Evaluar clasificadores lineales
- ▶ Entrenar clasificadores finales optimizados

Índice

1	Detección de errores en RAH	1
2	Trabajos relevantes relacionados	2
2.1	Tesis doctorales	2
2.2	Publicaciones científicas	3
3	Corpus LibriSpeech	4
4	Corpus Polimedia	5
5	Tipos de características	6
5.1	Calculadas durante el <i>decoding</i>	6
5.2	Calculadas sobre un grafo de palabras	7
6	Ficheros de datos	8
7	Preparación de los datos	9
8	Entrenamiento y optimización del clasificador	10
9	Entrenamiento del clasificador final	12
10	Curva ROC	13

1. Detección de errores en RAH

- ▶ La **detección de errores** en RAH es un problema de investigación abierto y de gran interés en el área.
- ▶ Se puede abordar como un **problema de clasificación binario** (clases: correcta/incorrecta).
- ▶ La salida del sistema de RAH (etiquetas de clase) se representa mediante **vectores de características** a nivel de palabra que se extraen de los modelos o del proceso mismo de clasificación (*decoding*).

2. Trabajos relevantes relacionados

2.1. Tesis doctorales

- ▶ 2002. F. Wessel. Word posterior probabilities for large vocabulary continuous speech recognition. Aachen University [1].
- ▶ 2004. A. Sanchis. Estimación y aplicación de medidas de confianza en reconocimiento automático del habla. UPV [2].
- ▶ 2013. M. Seigel. Confidence Estimation for Automatic Speech Recognition Hypotheses. Cambridge University [3].
- ▶ 2016. I. Sánchez. Confidence Measures for Automatic and Interactive Speech Recognition. UPV [4].
- ▶ 2019. M.A. del Agua. Contributions to Efficient Automatic Transcription of Video Lectures. UPV [5].

2.2. Publicaciones científicas

- ▶ 2001. F. Wessel et al. Confidence measures for large vocabulary continuous speech recognition [6].
- ▶ 2005. H. Jiang. Confidence measures for speech recognition: A survey [7].
- ▶ 2012. A. Sanchis et al. A Word-Based Naïve Bayes Classifier for Confidence Estimation in Speech Recognition [8].
- ▶ 2016. I. Sánchez et al. Speaker-adapted confidence measures for speech recognition of video lectures [9].
- ▶ 2018. M. del Agua et al. Speaker-Adapted Confidence Measures for ASR using Deep Bidirectional Recurrent Neural Networks [10].

3. Corpus LibriSpeech

- ▶ El corpus [LibriSpeech](#) es una tarea muy utilizada en el área del RAH [11].
- ▶ Se trata de una colección de aproximadamente 1.000 horas de [audiolibros](#) que provienen del [Proyecto Gutenberg](#) [12].
- ▶ Estadísticas:

Set	Duration (h)	Speakers	Words	Vocab	WER
train	961	1210	9.4M	89K	4.7
dev-other	5.3	33	51K	7.4K	12.5
test-other	5.1	33	52K	7.6K	13.5

4. Corpus Polimedia

- ▶ El corpus **PoliMedia** es una tarea desarrollada por el grupo de investigación **MLLP** durante el proyecto europeo **transLectures** [13].
- ▶ Se trata de una colección de más de 800 horas de **vídeos PoliMedia** transcritos manualmente.
- ▶ Estadísticas:

Set	Duration (h)	Videos	Speakers	Words	Vocab	WER
Train	813	9.5K	205	8.3M	36.6K	14.5
Dev	3.4	26	5	35K	2.6K	11.3
Test	3.2	23	5	30K	2.4K	12.5

5. Tipos de características

5.1. Calculadas durante el *decoding*

1. *Score* de la palabra estimado por modelo acústico y de lenguaje.
2. *Score* de la palabra estimado sólo por el modelo acústico.
3. Idem a 2. pero normalizado por la duración de la palabra.
4. Duración (en *ms.*) de la palabra.
5. Probabilidad de la palabra estimada por el modelo de lenguaje.
6. Longitud del n -grama en el que la palabra ha sido decodificada.
7. Número medio de hipótesis alternativas en el segmento que se decodificó la palabra.
8. Si la palabra aparece en las dos mejores hipótesis decodificadas o no (valor binario).

5.2. Calculadas sobre un grafo de palabras

- 9-11. Probabilidades *Forward*, *Backward* y *Forward-Backward*.
- 12-14. Tres variantes de probabilidades *Forward-Backward* calculadas *escalando* adecuadamente las probabilidades acústicas y del modelo de lenguaje y teniendo en cuenta *distintas segmentaciones* de la palabra solapadas en el tiempo.
- 15-17. Idem a 12-14. pero considerando sólo el *score acústico*.
- 18-20. Idem a 12-14. pero considerando sólo las probabilidades del *modelo de lenguaje*.

6. Ficheros de datos

- ▶ Se dispone de las muestras de *train* y *dev* de los corpus [LibriSpeech](#) y [Polimedia](#) utilizados en los experimentos reportados en [10]. [Descarga \(945Mb\)](#) (disponible hasta el 8 de noviembre).

- ▶ Estadísticas:



Corpus	# Palabras (K)		CER (%)	
	train	dev	train	dev
LibriSpeech	9438	50.9	4.2	11.0
PoliMedia	7419	34.6	11.9	8.8

- ▶ Cada fichero es una matriz con tantas filas como número de palabras (muestras) y 22 columnas (identificador de palabra, 20 características y etiqueta de clase: 0, correcta; 1, incorrecta). Por ejemplo:

```
1 2 -0.783303 -0.372636 ... 0.269034 -0.165769 1
2 3382 0.802786 -0.0754751 ... 0.269034 -0.165769 1
```

7. Preparación de los datos

nptxt2bin.py

```
1 import sys
2 import numpy as np
3
4 if len(sys.argv) != 3:
5     print('Usage: %s <trdata> <dvdata>' % sys.argv[0]);
6     sys.exit(1);
7
8 tr=np.loadtxt(sys.argv[1]);
9 dv=np.loadtxt(sys.argv[2]);
10
11 np.savez_compressed(sys.argv[1]+'.npz', tr=tr)
12 np.savez_compressed(sys.argv[2]+'.npz', dv=dv)
```

```
1 python3 nptxt2bin.py librispeech.tr.gz librispeech.dv.gz
2 python3 nptxt2bin.py polimedia.tr.gz polimedia.dv.gz
3 ls *.npz
4 librispeech.dv.gz.npz
5 librispeech.tr.gz.npz
6 polimedia.tr.gz.npz
7 polimedia.dv.gz.npz
```



8. Entrenamiento y optimización del clasificador

train.py

```
1 import math
2 import sys
3 import numpy as np
4 from sklearn import metrics
5 from sklearn.linear_model import LogisticRegression
6
7 if len(sys.argv) != 3:
8     print('Usage: %s <trdata> <devdata>' % sys.argv[0]);
9     sys.exit(1);
10
11 tr=np.load(sys.argv[1])['tr'];
12 dv=np.load(sys.argv[2])['dv'];
13 N,L=tr.shape; D=L-1;
14 Xtr=tr[:,2:D]; xltr=tr[:,-1];
15 Xdv=dv[:,2:D]; xldv=dv[:,-1];
16
17 clf = LogisticRegression().fit(Xtr, xltr);
18
19 probs = clf.predict_proba(Xdv)[:,1];
20 auc = metrics.roc_auc_score(xldv,probs);
21 print("Dev AUC: %.1f%%" % (auc*100));
22
23 estimated_xldv = clf.predict(Xdv);
24 err = (xldv != estimated_xldv).sum()/Xdv.shape[0];
25 r=1.96*math.sqrt(err*(1-err)/Xdv.shape[0]);
26 print("Dev CER: %.2f%% [%%.2f, %%.2f]" % (err*100, (err-r)*100, (err+r)*100));
```

```
1 python3 train.py librispeech.tr.gz librispeech.dv.gz
2 Dev AUC: 86.8%
3 Dev CER: 9.00% [8.75, 9.25]
4
5 python3 train.py polimedia.tr.gz polimedia.dv.gz
6 Dev AUC: 90.5%
7 Dev CER: 6.73% [6.47, 7.00]
```

9. Entrenamiento del clasificador final

save.py

```
1 import sys
2 import numpy as np
3 from sklearn.linear_model import LogisticRegression
4 import pickle
5
6 if len(sys.argv) != 3:
7     print('Usage: %s <trdata> <devdata>' % sys.argv[0]);
8     sys.exit(1);
9
10 tr=np.load(sys.argv[1])['tr'];
11 dv=np.load(sys.argv[2])['dv'];
12 N,L=tr.shape; D=L-1;
13
14 Xtr=tr[:,2:D]; xltr=tr[:,-1];
15 Xdv=dv[:,2:D]; xldv=dv[:,-1];
16 Xtr=np.concatenate((Xtr,Xdv));
17 xltr=np.concatenate((xltr,xldv));
18
19 clf = LogisticRegression().fit(Xtr, xltr)
20
21 filename = 'model.sav'
22 pickle.dump(clf, open(filename, 'wb'))
```

```
1 python3 save.py librispeech.tr.gz.npz librispeech.dv.gz.npz
2 ls *.sav
3 model.sav
```


10. Curva ROC

roc.py

```
1 import sys
2 import numpy as np
3 from sklearn import metrics
4 from sklearn.linear_model import LogisticRegression
5 import pickle
6 import matplotlib.pyplot as plt
7
8 if len(sys.argv) != 3:
9     print('Usage: %s <devdata> <model>' % sys.argv[0]);
10    sys.exit(1);
11
12 dv=np.load(sys.argv[1])['dv'];
13 N,L=dv.shape; D=L-1;
14 Xdv=dv[:,2:D]; xldv=dv[:,-1];
15
16 clf = pickle.load(open(sys.argv[2], 'rb'))
17
18 probs = clf.predict_proba(Xdv)[:,1];
19
20 fpr, tpr, _ = metrics.roc_curve(xldv,probs,pos_label=1);
21
22 plt.plot(fpr,tpr)
23 plt.ylabel('True Positive Rate')
24 plt.xlabel('False Positive Rate')
25 plt.show()
```



1

```
python3 roc.py librispeech.dv.gz librispeech.sav
```



1

```
python3 roc.py polimedia.dv.gz polimedia.sav
```



Desarrollo y entrega del trabajo

- ▶ Entrena y optimiza distintos tipos de clasificadores lineales (lo más precisos posible).
- ▶ Basándote en el script de la Sección 9, guarda el mejor modelo obtenido para cada corpus, en un fichero de nombres `libris-peech.sav` y `polimedia.sav`.
- ▶ Elabora una breve memoria (máximo 4 páginas) que describa los experimentos realizados. La memoria debe incluir una tabla de resultados para cada uno de los experimentos junto con una valoración de los mismos.
- ▶ **Empaqueta** en un fichero (p.e. .zip) la memoria, los mejores modelos y, para cada uno de ellos, un *script* que permita evaluarlo (AUC y CER) con un conjunto de datos independiente.
- ▶ Entrega el fichero mediante la actividad poliformaT Trabajo Académico 1. Fecha límite: 20 de noviembre.

Referencias

- [1] Frank Wessel. *Word posterior probabilities for large vocabulary continuous speech recognition*. PhD thesis, Aachen University, 2002.
- [2] Alberto Sanchis. *Estimación y aplicación de medidas de confianza en reconocimiento automático del habla*. PhD thesis, Universitat Politècnica de València, 2004. Advisors: Enrique Vidal Ruiz and Alfons Juan Ciscar (In Spanish).
- [3] Matthew Seigel. *Confidence Estimation for Automatic Speech Recognition Hypotheses*. PhD thesis, Cambridge University Engineering Department, 2013.
- [4] Isaías Sánchez-Cortina. *Confidence Measures for Automatic and Interactive Speech Recognition*. PhD thesis, Universitat Politècnica de València, 2016. Advisors: Alfons Juan Ciscar and Albert Sanchis Navarro.

- [5] Miguel Á. del Agua Teba. *Contributions to Efficient Automatic Transcription of Video Lectures*. PhD thesis, Universitat Politècnica de València, 2019. Advisers: Alfons Juan Ciscar and Albert Sanchis Navarro.
- [6] Frank Wessel, Ralf Schluter, Klaus Macherey, and Hermann Ney. Confidence measures for large vocabulary continuous speech recognition. *IEEE Transactions on speech and audio processing*, 9(3):288–298, 2001.
- [7] Hui Jiang. Confidence measures for speech recognition: A survey. *Speech communication*, 45(4):455–470, 2005.
- [8] Alberto Sanchis, Alfons Juan, and Enrique Vidal. A word-based naïve bayes classifier for confidence estimation in speech recognition. *IEEE Transactions on Audio, Speech, and Language Processing*, 20(2):565–574, 2012.
- [9] Isaias Sanchez-Cortina, Jesús Andrés-Ferrer, Alberto Sanchis, and Alfons Juan. Speaker-adapted confidence measures for

speech recognition of video lectures. *Computer Speech & Language*, 37:11–23, 2016.

- [10] Miguel Ángel Del-Agua, Adrià Giménez, Alberto Sanchis, Jorge Civera, and Alfons Juan. Speaker-adapted confidence measures for asr using deep bidirectional recurrent neural networks. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 26(7):1194–1202, 2018.
- [11] Vassil Panayotov, Guoguo Chen, Daniel Povey, and Sanjeev Khudanpur. Librispeech: an ASR corpus based on public domain audio books. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5206–5210, 2015.
- [12] Project Gutenberg. www.gutenberg.org.
- [13] Joan Albert Silvestre-Cerdà, Miguel Del Agua, Gonçal Garcés, Guillem Gascó, Adrià Giménez-Pastor, Adrià Martínez, Alejandro Pérez González de Martos, Isaías Sánchez, Nicolás Serrano Martínez-Santos, Rachel Spencer, Juan Daniel Va-

lor Miró, Jesús Andrés-Ferrer, Jorge Civera, Alberto Sanchís, and Alfons Juan. translectures. In *Proceedings (Online) of IberSPEECH 2012*, pages 345–351, Madrid (Spain), 2012.